Universidad Politécnica
de Madrid

**Escuela Técnica Superior de
Ingenieros Informáticos**

[Grado] en [Ingeniería Informática]

Trabajo Fin de [Grado]

[Modelos Predictivos Explicables de Analisis de Inversián Financiera]

Autor: [Rubén Sánchez Leal]
Tutor(a): [Juan Antonio Fernández del Pozo de Salamanca]

Madrid, [Febrero 2026]

Este Trabajo Fin de [Grado] se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de [Grado]
[Grado] en [Ingeniería Informática]

Título: [Modelos Predictivos Explicables de Analisis de Inversián Financiera]

[Febrero 2026]

Autor: [Rubén Sánchez Leal]
Tutor: [Juan Antonio Fernández del Pozo de Salamanca]
[Departamento de Inteligencia Artificial]
Escuela Técnica Superior de Ingenieros Informáticos
Universidad Politécnica de Madrid

Resumen

Aquí va el resumen del trabajo. Extensión máxima 2 páginas.

Abstract

Abstract of the Final Degree Project. Maximum length: 2 pages.

Tabla de contenidos

1. Introducción **1**
1.1. Motivación 1
1.2. Contexto 1
1.3. Objetivos del trabajo y alcance 2
1.4. Estructura de la memoria 3

2. Estado del arte **7**
2.1. Economía 7
2.1.1. Mercados financieros 7
2.1.2. Fondos de inversión y acciones 8
2.1.3. Variables macroeconómicas 9
2.1.4. Contextos económicos 10
2.2. Series temporales 10
2.2.1. Conceptos de series temporales 10
2.2.2. Técnicas de análisis de series temporales 12
2.3. Machine Learning 16
2.3.1. Random Forest 18
2.3.2. Gradient Boosting 19
2.4. Deep Learning 20
2.4.1. LSTM 21
2.5. Modelos explicativos 22
2.5.1. LIME 23
2.5.2. SHAP 23
2.6. Trabajos anteriores 23

3. Datos y preparación del dataset **25**
3.1. Datos a usar 25
3.2. Obtención e integración de los datos al dataset 25
3.3. Análisis exploratorio de datos (EDA) 27
3.3.1. Análisis univariante 28
3.3.2. Análisis multivariante 45
3.4. Selección de variables y dataset final 55
3.4.1. Criterios de selección 55
3.4.2. Proceso automatizado de selección 56
3.4.3. Resultados de la selección 56
3.4.4. Creación de datasets para Deep Learning y Machine Learning 57

4. Modelos predictivos **59**

5. Experimentos y resultados **61**

6. Conclusiones y trabajo futuro **63**

7. Análisis de impacto **65**

Bibliografía **67**

Anexos **75**

A. Primer anexo **75**

Capítulo 1

Introducción

1.1. Motivación

La motivación de este Trabajo de Fin de Grado nace tras la realización de mis prácticas, donde pude acercarme al funcionamiento del sector bancario y al uso del análisis de datos en el ámbito financiero. A partir de esta experiencia y tras conocer el potencial del Machine Learning aplicado a los mercados financieros, surgió el interés por desarrollar un modelo capaz de analizar y predecir la evolución de activos como acciones o fondos de inversión.

1.2. Contexto

En las últimas décadas, los mercados financieros han experimentado una notable transformación impulsada por dos fenómenos paralelos, la globalización económica y la revolución digital. La primera ha estrechado los vínculos entre los mercados mundiales, mientras que la segunda ha generado un aumento masivo en el volumen de información disponible, dando lugar al concepto de "Big Data financiero"[1]. Este escenario plantea un desafío crítico para analistas e inversores, ya que las metodologías tradicionales resultan insuficientes para procesar y extraer valor de la enorme cantidad de datos generados continuamente.

Ante esta situación, la Inteligencia Artificial (IA) y, específicamente, el Machine Learning (ML), han adquirido un gran protagonismo. Estas herramientas permiten abordar la complejidad de los mercados actuales, mejorando las capacidades predictivas en áreas como la evaluación de riesgos y la gestión de carteras [2]. Dentro de este ecosistema, modelos como Random Forest, Gradient Boosting y las redes neuronales LSTM se han consolidado como referentes para la predicción de series temporales. Su éxito radica en la capacidad para capturar relaciones no lineales y procesar grandes volúmenes de datos de forma automatizada, superando las limitaciones de los métodos estadísticos clásicos.

A pesar de estos avances, la aplicación de modelos complejos en finanzas presenta un reto fundamental: su naturaleza de çaja negra". La falta de interpretabilidad genera preocupaciones sobre la transparencia, la confianza y el cumpli-

miento normativo [3]. En respuesta a esta problemática, ha surgido la Inteligencia Artificial Explicable (XAI), que defiende la necesidad de desarrollar modelos que sean precisos y, al mismo tiempo, comprensibles para el ser humano. Técnicas de interpretabilidad post-hoc como SHAP y LIME permiten desglosar la contribución de cada variable a las predicciones, facilitando así la justificación de resultados ante organismos regulatorios [4].

Este Trabajo de Fin de Grado se sitúa precisamente en la intersección entre la potencia predictiva y la transparencia. El objetivo es desarrollar un sistema que aproveche el potencial de la IA en el análisis de inversiones sin renunciar a la comprensión de los factores que determinan cada predicción, un equilibrio esencial para su aplicación práctica en el mundo real [3].

1.3. Objetivos del trabajo y alcance

El presente Trabajo de Fin de Grado tiene como objetivo el **diseño e implementación** de un sistema informático orientado al análisis y la predicción del comportamiento de activos financieros, concretamente **fondos de inversión y acciones**. Para ello, se emplearán técnicas de análisis de datos, **Machine Learning y Deep Learning**, con el fin de desarrollar un modelo predictivo que permita predecir la evolución a diferentes horizontes temporales de estos activos y, a su vez, analizar los factores que influyen en su comportamiento.

A continuación, se enumeran las fases que componen el desarrollo del trabajo:

1. **Obtención y gestión de datos.** Se recopilarán datos históricos desde el año 2002 hasta el año 2025, correspondientes tanto a variables financieras como a variables macroeconómicas. Entre estas variables se incluirán precios históricos de activos financieros, así como distintos indicadores macroeconómicos importantes, como la inflación, los tipos de interés o las tasas de desempleo, entre otros. Todos estos datos serán almacenados e integrados en un **dataset global**, para así garantizar la consistencia, integridad y trazabilidad de la información utilizada durante el proyecto.

2. **Procesamiento y preparación del dataset.** Esta fase incluirá tareas de **limpieza, transformación e integración** de los datos, con el objetivo de homogeneizar los distintos formatos de información, tratar posibles valores faltantes y establecer una **frecuencia mensual** para todas las variables.

3. **Análisis exploratorio de datos (EDA).** Se realizará un estudio de las tendencias existentes en las series temporales, así como un análisis de la **volatilidad** de los activos y las **correlaciones** entre las diferentes variables del dataset. El objetivo es identificar posibles dependencias fuertes que puedan introducir ruido y, por lo tanto, afectar al rendimiento de los modelos.

4. **Generación de nuevas variables (Feature Engineering).** A partir de los datos procesados, se crearán nuevas variables mediante técnicas de **feature engineering**, como retornos financieros, medias móviles o medidas de volatilidad. El objetivo es dotar al dataset de variables relevantes que aporten valor a la hora de la predicción.

5. **Desarrollo de los modelos predictivos.** Para abordar el problema desde diferentes enfoques, se implementarán modelos de **Machine Learning** (Random Forest y Gradient Boosting), que ofrecen una mayor interpretabilidad y transparencia, y un modelo de **Deep Learning** basado en redes neuronales recurrentes del tipo **LSTM**, que aporta mayor precisión.

6. **Entrenamiento, validación y evaluación de los modelos.** Se realizará un proceso de **backtesting** para analizar el comportamiento de los modelos simulando su aplicación en distintos períodos históricos del mercado. La capacidad predictiva y de generalización se evaluará mediante métricas de error como **MAE** (Error Absoluto Medio) o **MSE** (Error Cuadrático Medio).

7. **Comparación con y sin variables macroeconómicas.** Se compararán modelos entrenados únicamente con variables propias del activo financiero y modelos que incorporen además **variables macroeconómicas**, para analizar si su inclusión mejora la capacidad predictiva del sistema.

8. **Generación de predicciones y simulación de escenarios.** Se generarán predicciones a distintos horizontes temporales (corto, medio y largo plazo). Además, el sistema permitirá realizar **simulaciones bajo diferentes escenarios**, modificando determinadas variables macroeconómicas para analizar el comportamiento de los modelos ante distintas condiciones económicas o de mercado.

9. **Interpretabilidad de los modelos (XAI).** Dado que uno de los objetivos del trabajo es entender los factores que influyen en las predicciones, se aplicarán técnicas de **Explainable Artificial Intelligence (XAI)**, concretamente los métodos **SHAP y LIME**, que permiten analizar la contribución de cada variable en las predicciones generadas.

10. **Presentación de resultados.** Los resultados obtenidos serán presentados mediante **gráficos y visualizaciones** que representen de forma clara el comportamiento de los modelos, la evolución de las predicciones y el impacto de las distintas variables en el rendimiento de los activos financieros.

Por último, el **alcance** del trabajo abarca todo el proceso necesario para la construcción de un sistema de predicción basado en datos, desde la obtención de la información hasta el análisis e interpretación de los resultados obtenidos.

1.4. Estructura de la memoria

La memoria se estructura en varios capítulos que abordan de forma progresiva y detallada los distintos aspectos relacionados con el desarrollo de un sistema de análisis y predicción de activos financieros mediante técnicas de análisis de datos, Machine Learning y Deep Learning:

1. **Capítulo 1: Introducción** Se presenta el contexto general del trabajo, así como la motivación que ha llevado al desarrollo del mismo. En este capítulo se describen los objetivos principales del trabajo, al igual que su alcance.

Asimismo, contiene un resumen de la estructura de la memoria con el fin de facilitar la comprensión del trabajo.

2. **Capítulo 2: Estado del arte** Este capítulo, busca explicar los fundamentos teóricos necesarios para la compresión del proyecto. En primer lugar, se explican los conceptos básicos sobre los mercados financieros, las acciones y los fondos de inversión, así como algunas de las variables macroeconómicas que influyen en su evolución. Posteriormente, se introducen las series temporales financieras, junto con sus conceptos. Continuando con el capítulo, se describen los fundamentos de Machine Learning y Deep Learning aplicados a problemas de predicción temporal, haciendo especial énfasis en los modelos que se utilizarán en el desarrollo del trabajo. Finalmente, se buscarán y mencionarán, trabajos anteriores en el ámbito de la predicción financiera con herramientas de IA.

3. **Capítulo 3: Datos y preparación del dataset** Aquí se describe el proceso de obtención, procesamiento y preparación de los datos usados a lo largo del proyecto. En primer lugar, se mencionarán las diferentes fuentes de datos utilizadas para la recopilación de variables financieras y macroeconómicas. Posteriormente, se explica el proceso de construcción del dataset, donde se incluye la selección de variables y la unificación de la frecuencia temporal de los datos. A continuación, se explican las etapas de procesamiento de los datos, como pueden ser la limpieza, la transformación y la normalización. Por último, se describen las técnicas de feature engineering utilizadas para generar nuevas variables a partir de las originales. A su vez, se realiza un análisis exploratorio de los datos con el objetivo de identificar tendencias, patrones y relaciones entre variables. Finalmente, se realizará a una selección de variables atendiendo al análisis mencionado y se obtendrá el dataset final que será usado en los modelos predictivos.

4. **Capítulo 4: Modelos predictivos** En este capítulo, se describen cada uno de los modelos de aprendizaje automático implementados para afrontar el problema de predicción de series temporales financieras. Primero de todo, se presentan los modelos de Machine Learning que serán usados en el proyecto, dichos modelos son Random Forest y Gradient Boosting. Más tarde, será introducido el modelo de Deep Learning basado en redes neuronales recurrentes del tipo LSTM, aquí, describiremos su arquitectura y su capacidad para identificar dependencias temporales en los datos. Finalmente, se explicará el proceso de entrenamiento de los modelos, donde dividiremos los datos en conjuntos de entrenamiento, validación y prueba.

5. **Capítulo 5: Experimentos y resultados** En este capítulo se presenta el proceso de evaluación de los modelos implementados. En primer lugar, se aplicará y describirá la evaluación de los modelos por backtesting, donde haremos simulaciones con datos históricos. A continuación, se introducirán las métricas de evaluación empleadas para medir la precisión de las predicciones. Del mismo modo, en este capítulo se realizará una comparación entre los distintos modelos implementados, donde se verá el comportamiento de cada uno de ellos veremos cual tiene mejor capacidad predic-

tiva. Además en este capítulo, se realizarán distintos experimentos donde se estudiará el impacto de la incorporación de variables macroeconómicas en los modelos, comparando resultados obtenidos con y sin estas variables, también realizaremos más experimentos como someter a los modelos a distintos escenarios como simulaciones con variables macroeconómicas dinámicas o estáticas o escenarios hipotéticos que permiten estudiar el comportamiento del sistema ante posibles cambios en las condiciones del mercado. Finalmente, se aplicarán técnicas de interpretabilidad, como SHAP y LIME, con el objetivo de analizar la importancia de las variables y comprender mejor las predicciones generadas por los modelos.

6. **Capítulo 6: Conclusiones** Aquí, se resumen los principales resultados obtenidos a lo largo del trabajo. En este capítulo se analizan las conclusiones que extraemos del estudio, mostrando qué modelos han mostrado un mejor rendimiento y en qué medida la incorporación de variables macroeconómicas ha contribuido a mejorar la capacidad predictiva del sistema. Asimismo, se discuten las principales limitaciones del trabajo y se proponen posibles líneas futuras de investigación que podrían ampliar o mejorar el sistema desarrollado.

7. **Análisis de impacto** En este capítulo se analizan las implicaciones del trabajo desde diferentes perspectivas, evaluando su posible impacto tecnológico, económico y social, así como su potencial aplicación en el ámbito del análisis financiero y la toma de decisiones basada en datos. Además, se alinea el trabajo con los Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030, ya que el uso de técnicas avanzadas de inteligencia artificial para la mejora del análisis financiero contribuye a una toma de decisiones más eficiente y transparente, lo que repercute positivamente en el crecimiento económico, la innovación tecnológica y la formación de calidad en el sector.

8. **Bibliografía** Recoge todas las referencias bibliográficas utilizadas durante el desarrollo del trabajo.

9. **Anexos** En esta sección se incluyen materiales adicionales que complementan la información presentada en los capítulos anteriores, como pueden ser códigos fuente, gráficos adicionales, tablas de resultados o cualquier otro recurso que se considere relevante para una mejor comprensión del trabajo realizado.

Capítulo 2

Estado del arte

2.1. Economía

Antes de comenzar con términos más técnicos o informáticos, es importante contextualizar este trabajo, para ello se ha realizado una breve introducción a conceptos básicos y necesarios para este trabajo.

2.1.1. Mercados financieros

Los mercados financieros son el lugar en el que oferentes y demandantes compran y venden activos financieros [5]. Son, por tanto, el lugar donde se encuentran quienes necesitan financiación y quienes disponen de dinero y desean obtener una rentabilidad. La función principal de estos mercados es dirigir el ahorro hacia la inversión productiva, facilitando así el crecimiento económico. A su vez, estos mercados siguen el principio de la oferta y la demanda.

Entre las características más relevantes de los mercados financieros, se encuentran la liquidez, que es la facilidad para comprar o vender un activo, luego está la transparencia, que es el acceso a la información para la toma de decisiones y por último, estos mercados financieros se caracterizan por la volatilidad, que se refiere a los constantes cambios en los precios de los activos, impulsados por eventos geopolíticos, el sentimiento colectivo del mercado o una serie de variables macroeconómicas que veremos más adelante. Tal y como señaló Eugene Fama en su formulación de la Hipótesis de los Mercados Eficientes, "los precios de los activos reflejan plenamente toda la información disponible"[6], lo que en teoría dificultaría su predicción. Sin embargo, la creciente evidencia de anomalías y la irrupción del Machine Learning han cuestionado esta visión tradicional, abriendo la puerta a enfoques predictivos como el que se plantea en este trabajo. Comprender esta volatilidad y predecir el comportamiento de los activos es el gran desafío del análisis financiero y el objetivo que motiva este trabajo.

2.1.2. Fondos de inversión y acciones

Este punto es clave, pues a través de él se pretende explicar cada uno de los elementos que el modelo va a predecir. A continuación, se definen y contextualizan los dos instrumentos financieros sobre los que recae el análisis predictivo de este trabajo, los fondos de inversión y las acciones.

- **Fondos de inversión** Respecto a los fondos de inversión, estos podrían definirse de acuerdo al banco Santander de la siguiente forma: Ün fondo de inversión, de inversión colectiva o inversión común es un instrumento que permite al ahorrador acceder al mercado financiero no de una manera directa, sino a través de inversiones diversificadas"[7]. Explicando un poco lo anterior, un fondo de inversión agrupa el dinero de varios ahorradores para invertirlo en una cesta de diferentes activos financieros, siendo todo ello gestionado por un equipo de profesionales que a su vez, se encargan de la toma de decisiones. Algunas de las principales ventajas que ofrecen los fondos de inversión, son la diversificación, al permitir acceder a múltiples mercados y clases de activos con un bajo coste, otra ventaja es la gestión profesional, ya que cuentan con especialistas que buscan maximizar la rentabilidad según el perfil de riesgo y por último, cabe mencionar también la transparencia, ya que estos fondos están supervisados por organismos como la Comisión Nacional del Mercado de Valores (CNMV). En cuanto a los tipos, podemos diferenciar tres: el fondo de renta variable, el de renta fija y el mixto. El presente trabajo se centra en el análisis y predicción del rendimiento de este tipo de instrumentos financieros, empleando para ello técnicas de Machine Learning y series temporales, todo ello con el objetivo de predecir su comportamiento futuro a distintos horizontes temporales.

- **Acciones** Al igual que con los fondos de inversión, a través del presente trabajo se pretende calcular la evolución temporal de las acciones de cualquier tipo de compañía. Pero antes de nada, ¿qué son las acciones? ¿En qué se basa su evolución? Una acción es un título que representa una parte del capital social de una empresa. Es por ello que todo aquel que posee acciones de una compañía es, por consiguiente, copropietario de dicha compañía en un porcentaje proporcionalmente relacionado al número de acciones que posea, y es que como bien señala el inversor Warren Buffett, üna acción es un instrumento que te permite poseer una pequeña parte de una gran empresa". En lo que respecta a ser accionista, esto supone un conjunto de derechos como el derecho a recibir parte de los beneficios mediante el reparto de dividendos, el derecho a asistir a las juntas de accionistas y ejercer el voto, el derecho a recibir información cada cierto tiempo sobre la evolución de la compañía y el derecho a recibir la parte proporcional del capital en caso de que la compañía desapareciese. Entrando en el tema de los precios, el valor de una acción no es fijo, sino que varía constantemente en función de la ley de la oferta y la demanda, que depende de varios factores como pueden ser la confianza de los inversores, los resultados de la empresa, las perspectivas de su sector y, de manera muy relevante para este trabajo, de la situación económica general y las variables macroeconómicas.

2.1.3. Variables macroeconómicas

Primero de todo, es importante entender que es la macroeconomía, se trata de la rama de la ciencia económica que estudia el funcionamiento de una economía en su conjunto, analizando fenómenos agregados como la producción, el empleo o la inflación [8]. En lo que respecta a las variables macroeconómicas, estas son indicadores que miden estos fenómenos, lo que permite entender el contexto en el que se desenvuelven los mercados financieros.

El contexto macroeconómico en el que se va situar este trabajo es en gran parte estadounidense, debido a que el mercado bursátil de Estados Unidos, representa una gran parte del mercado bursátil global, con valores cercanos al 50 %, ejerciendo una influencia dominante sobre el resto de los mercados internacionales, sin embargo, también se tendrán en cuenta variables europeas. Respecto a las variables seleccionadas para el dataset preanálisis, se encuentran las siguientes.

Variable	**Justificación**
S&P 500	Captura el movimiento agregado del mercado de renta variable estadounidense
VIX (Índice de volatilidad)	Refleja la incertidumbre y el riesgo percibido por los inversores
Petróleo	Materia prima clave, cuyo coste impacta directamente en los gastos de empresas e inflación
Oro	Considerado activo refugio, en épocas inflacionarias su precio sube
Tipos de Interés Fed	Principal referencia de política monetaria en EE.UU.
Tipos de Interés BCE	Principal referencia de política monetaria en la zona euro
IPC EE.UU.	Mide el aumento de precios y condiciona la política monetaria en EE.UU.
IPC Europa	Mide el aumento de precios y condiciona la política monetaria en la zona euro
Curva de tipos 10Y2Y	Sirve como predictor de recesiones
Desempleo en EE.UU.	Indica el estado del mercado laboral, influye fuertemente en la economía
Tipo de cambio Euro/Dólar	Divisas principales a nivel global

Cuadro 2.1: Variables macroeconómicas seleccionadas y su justificación

A parte de las variables mencionadas anteriormente, también se consideró añadir el PIB, sin embargo, pese a ser la variable macroeconómica más representativa del crecimiento económico de un país, el hecho de que se publique trimestralmente y con retraso, hace que no sea una variable útil para modelos predictivos a corto-medio plazo

2.1.4. Contextos económicos

A su vez, es importante introducir los diferentes contextos económicos que se pueden llegar a encontrar ya que los mercados financieros se pueden llegar a ver muy influenciados por dichos contextos y es que a lo largo de los últimos 22 años, la economía mundial ha atravesado diferentes contextos económicos, cada uno con unas características diferenciales y que tienen un gran impacto, ya sea positivo o negativo en los mercados y las variables macroeconómicas.

El primer contexto que se diferencia es el de **expansión económica**, caracterizado por un crecimiento sostenido de la actividad económica, bajada de la tasa de desempleo y VIX bajo y rentabilidades altas. El segundo contexto es totalmente lo opuesto, se trata de **crisis** que implican una dura bajada de la actividad económica, aumento del desempleo y fuertes caídas en los mercados financieros, un ejemplo cercano sería la crisis de 2008 o la del COVID-19. El tercer contexto es el de **alta inflación**, caracterizado por la fuerte subida en los precios, provocando con ello la subida de los tipos de interés. Todo lo contrario a la inflación, es la **deflación**, caracterizada por la bajada de tipos de interés, impulsando el consumo, la inversión, y los mercados. La identificación del contexto económico vigente en cada periodo resulta fundamental para los modelos predictivos, ya que el comportamiento de los fondos de inversión difiere significativamente entre épocas de expansión, crisis o inflación. Este análisis se retomará en el apartado de clustering del Análisis Exploratorio de Datos (EDA), donde se clasificarán los diferentes periodos temporales tratará más en detalle.

2.2. Series temporales

Este punto es uno de los más importantes, ya que se explica con detalle el concepto de serie temporal. Su relevancia radica en que el dataset final que se proporcionará al modelo será una serie temporal multivariante de frecuencia mensual. Por ello, resulta necesario explicar todos los conceptos relacionados, así como el análisis que se pretende seguir para la selección de variables.

2.2.1. Conceptos de series temporales

Una serie temporal se define como una colección de observaciones de una variable recogidas a lo largo del tiempo, normalmente en instantes equiespaciados. En estas series, las observaciones sucesivas no son independientes entre sí; existe una dependencia temporal intrínseca donde un valor está relacionado con su pasado. Como señalaron George Box y Gwilym Jenkins: “en una serie temporal, el orden de las observaciones es esencial, ya que los valores pasados contienen información sobre el futuro” [9]. Un ejemplo claro son los tipos de interés de la FED: un valor en un mes determinado está condicionado por el del mes anterior, ya que estas variables no suelen presentar cambios bruscos de forma aislada. Por ello, el análisis debe realizarse respetando estrictamente el orden cronológico.

En cuanto a su clasificación, las series pueden ser deterministas o estocásticas.

Las primeras son aquellas cuyos valores futuros pueden predecirse de forma exacta mediante una ley matemática. Por el contrario, en las estocásticas los valores futuros solo pueden conocerse a partir de una función de probabilidad. En el ámbito financiero, la mayoría de las series presentan un comportamiento principalmente estocástico, lo que justifica el uso de modelos de *Machine Learning* para su análisis, al no existir una fórmula determinista que permita conocer el valor futuro con certeza.

Continuando con su estructura, toda serie temporal puede descomponerse normalmente en cuatro componentes:

Tendencia: Cambio suave y a largo plazo en el nivel medio de la serie, que representa su dirección general (ascendente, descendente o lateral).

Estacionalidad: Variaciones periódicas y predecibles que se repiten en intervalos de tiempo fijos (anuales, trimestrales, etc.).

Componente cíclico: Variaciones de mayor duración que la estacionalidad, pero sin un periodo fijo, como los ciclos económicos de recesión.

Componente aleatoria: Variaciones impredecibles que permanecen una vez eliminados los efectos anteriores.

Es importante introducir aquí el concepto de **estacionariedad**, que no debe confundirse con la estacionalidad. Una serie es estacionaria cuando su media y su variabilidad permanecen constantes a lo largo del tiempo. Por el contrario, las series no estacionarias presentan propiedades estadísticas que cambian cronológicamente, lo que suele requerir transformaciones previas para su modelado.

En la Figura 2.1 se muestra un ejemplo de una serie no estacionaria y no cíclica, con una tendencia ascendente. La imagen detalla la evolución del índice IBEX35 en el periodo comprendido entre 2021 y 2026.

Figura 2.1: Evolución del índice IBEX35 (2021-2026). Fuente: BME Exchange

Finalmente, alineando esta explicación a este trabajo, el dataset final que se proporcionará a los modelos predictivos es una serie temporal multivariante de frecuencia mensual, que abarca desde diciembre de 2003 hasta septiembre de 2025. El hecho de que sea multivariante implica que, para cada mes, se dispone de múltiples variables como, por ejemplo, todas las variables macroeconómicas

mencionadas anteriormente. Este enfoque multivariante es especialmente relevante en el dominio financiero, donde las correlaciones entre diferentes variables son complejas. Por su parte, la frecuencia mensual ofrece un equilibrio adecuado entre la disponibilidad de datos históricos y la capacidad predictiva a horizontes de corto, medio y largo plazo, que son los tres escenarios contemplados en los objetivos de este trabajo.

2.2.2. Técnicas de análisis de series temporales

- **Análisis de series temporales** Una vez definidos los conceptos fundamentales, es necesario abordar las técnicas de análisis de las series temporales, el cual consta de diferentes etapas y cada una de las cuales aporta información importante sobre el comportamiento de los datos. Para este trabajo, el análisis que se va a llevar a cabo es un EDA, que incluye la recopilación, el preprocesamiento y la visualización de las series, pudiendo así entender mejor cada una de las variables. Tras el EDA, iría la selección del modelo, entrenamiento y evaluación, pero eso se verá más tarde.

  Antes de detallar las herramientas concretas, conviene distinguir entre dos enfoques posibles en el análisis de series temporales. Por un lado, el análisis univariante se centra en el estudio de una única variable a lo largo del tiempo, examinando sus propias características, su evolución, su memoria temporal y su capacidad de predicción a partir de sus propios valores pasados. Por otro lado, el análisis multivariante incorpora simultáneamente múltiples variables, lo que permite estudiar las interrelaciones entre ellas y aprovechar la información de unas variables para predecir el comportamiento de otras. Dado que el presente trabajo dispone de un dataset con once variables macroeconómicas además del activo financiero objetivo, el análisis que se llevará a cabo será fundamentalmente multivariante, si bien se complementará con análisis univariantes de cada variable para comprender su comportamiento individual.

  En cuanto a las herramientas más usadas en el análisis de series temporales, una de las principales es el análisis visual, esta herramienta permite comprender una serie temporal de forma mucho más clara que solo viendo datos. Algunos ejemplos de este análisis visual, son los gráficos, que permiten identificar múltiples características de los datos, como la frecuencia de las observaciones, la tendencia creciente o decreciente, la existencia de valores atípicos, la dispersión de los datos alrededor de su media, los cambios de pendiente, la existencia de patrones que se repiten a lo largo del tiempo, los diferentes cuartiles, la media y mediana o características como la curtosis y skewness, ambas son muy útiles a la hora de entender comportamientos de variables. Para acabar, algunos ejemplos de gráficos, podrían ser gráficos de barras, boxplots o de dispersión entre otros

  Otra de las herramientas a destacar, es la función de autocorrelación, la cual es muy útil en la exploración de series temporales ya que esta función analiza los datos de series temporales para buscar correlaciones en los valores de distintos puntos de una serie temporal, es decir, mide la co-

rrelación de un valor consigo mismo [10]. La representación gráfica de la función de autocorrelación, se denomina correlograma y resulta útil para identificar estacionalidad, tendencias y otros patrones en los datos, un claro ejemplo de correlograma es la Figura 2.2. La herramienta de autocorrelación, es fundamental para determinar la memoria temporal de cada variable y para ver si los valores pasados contienen información relevante acerca del valor futuro.

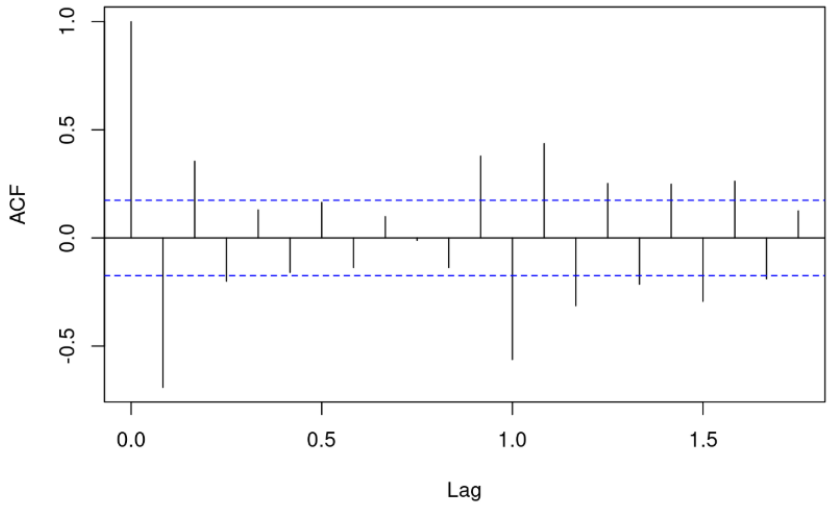

Figura 2.2: Ejemplo de un correlograma de una variable. Fuente: RPubs

Al igual que la autocorrelación, también existe la correlación de Pearson, la cual es muy útil en el análisis de series temporales multivariantes ya que esta función analiza la relación lineal entre dos variables diferentes, es decir, mide cómo se comporta una variable cuando la otra aumenta o disminuye. La representación gráfica de la correlación entre múltiples variables se denomina matriz de correlación y resulta útil para identificar relaciones directas (cuando una variable sube, la otra también sube), relaciones inversas (cuando una variable sube, la otra baja) o ausencia de relación lineal entre las variables. La herramienta de correlación es fundamental para entender cómo se relacionan las distintas variables macroeconómicas entre sí y, especialmente, cómo se relacionan con el activo financiero que se pretende predecir, lo que permite identificar qué variables pueden tener mayor poder explicativo sobre el comportamiento del target.

Por último, otra herramienta de gran utilidad es el clustering, que permite agrupar las observaciones en función de su similitud. Aplicado a series temporales, esta técnica permite segmentar el período de estudio en diferentes fases o regímenes económicos, identificando automáticamente momentos en los que el comportamiento de las variables presenta patrones similares, como períodos de expansión, crisis o recuperaciones.

En el contexto de este trabajo, y dado que el dataset final es una serie

temporal multivariante de frecuencia mensual que abarca desde diciembre de 2003 hasta septiembre de 2025, el análisis de series temporales se realizará combinando todas las técnicas mencionadas. En primer lugar, se realizará un análisis descriptivo de cada variable macroeconómica por separado, examinando su evolución temporal a lo largo del tiempo, su distribución estadística, sus valores extremos y su volatilidad en diferentes subperiodos. Adicionalmente, se estudiará la autocorrelación de cada variable mediante las funciones ACF, lo que permitirá determinar su memoria temporal y, por tanto, si resulta necesario incluir sus valores pasados como predictores en los modelos. Finalmente, dado el carácter multivariante del dataset, el análisis no se limitará al estudio individual de cada variable, sino que se extenderá a un análisis multivariante que explore las relaciones entre las distintas variables macroeconómicas y su interacción con el activo financiero objetivo. En este sentido, se calcularán las correlaciones entre todas las variables para identificar posibles relaciones lineales y ver si algunas son redundantes entre sí, a su vez, se aplicará un análisis de componentes principales (PCA) para reducir la dimensionalidad del sistema y comprender cuántas dimensiones explican la mayor parte de la varianza del conjunto de datos, y por último, se llevará a cabo un análisis de clustering con el objetivo de poder diferenciar los diferentes ciclos a lo largos del tiempo de estudio.

Todos estos análisis, que se presentan en detalle en el capítulo de Análisis Exploratorio de Datos (EDA), constituyen la base sobre la que se construirán los modelos predictivos en la fase posterior del trabajo.

- **Selección de variables** Una vez comprendida la naturaleza de las series temporales y las herramientas para su análisis, el siguiente paso clave es la selección de las variables más relevantes y que conformarán el dataset definitivo que le será entregado a los modelos predictivos. Como se ha visto anteriormente, en este trabajo se dispone de once variables macroeconómicas además de las variables propias del activo financiero. Sin embargo, no todas estas variables aportan la misma cantidad de información a la hora de realizar la predicción de un activo o fondo de inversión, ya que algunas pueden ser redundantes entre sí, otras pueden contener ruido y otras pueden tener una relación no lineal el target. Por esto mismo, la selección de variables es importante, ya que permite por un lado mejorar el potencial predictivo del dataset eliminando variables redundantes y que introducen ruido, y por otro lado, la selección de variables permite reducir la dimensión del dataset, consiguiendo así un menor coste computacional y una mayor interpretabilidad de los resultados. Es importante destacar que todo este proceso de selección se realiza antes que el entrenamiento de los modelos finales, asegurando que el dataset que se entregue a los modelos predictivos, sea ya el conjunto definitivo y optimizado.

  Entrando ahora a los diferentes métodos de selección de variables, existen diferentes formas de métodos de selección de variables, entre los que destacan los métodos de filtrado, los métodos envolventes y los métodos embebidos. Los métodos de filtrado evalúan la relevancia de cada variable

de forma independiente a cualquier modelo predictivo posterior, basándose únicamente en propiedades estadísticas de los datos. Estos métodos son computacionalmente eficientes y escalables, aunque no consideran las interacciones entre variables. Los métodos envolventes, por el contrario, evalúan subconjuntos de variables entrenando un modelo predictivo para cada subconjunto, lo que los hace más precisos pero también mucho más costosos computacionalmente. Por último, los métodos embebidos realizan la selección de variables durante el propio proceso de entrenamiento de un modelo. En este trabajo, se emplearán principalmente métodos de filtrado, junto con un análisis de correlación para detectar redundancias.

Entre los métodos de filtrado, destacan la entropía de datos y la información mutua. La entropía mide el grado de desorden asociado a una variable aleatoria. A la hora de seleccionar variables, si una variable presenta una entropía elevada, significa que dicha variable, presenta una gran variedad de valores y por consiguiente, contiene más información relevante. Sin embargo, si la entropía es baja, entonces significa que no aporta mucha información al dataset y entonces se podría eliminar del dataset. En el caso de este trabajo, se aplicará el estudio de la entropía a cada una de las variables del dataset y se seleccionarán aquellas que realmente aporten información, es decir, que tengan una entropía alta.

Por otro lado, la información mutua, mide la cantidad de información que una variable contiene sobre otra. Es importante no confundirlo con lo correlación de Pearson mencionada en las técnicas de análisis, ya que dicha correlación, sólo captura relaciones lineales, mientras que la información mutua es capaz de detectar cualquier tipo de dependencia estadística, ya sea lineal o no lineal. Dicha propiedad es muy útil a la hora de hacer este trabajo, ya que las relaciones entre variables macroeconómicas y del activo, no suelen ser lineales. Finalmente, en este trabajo, se calculará la información mutua entre cada variable predictora y la variable objetivo, lo que permitirá ordenar las variables por su capacidad predictiva individual y seleccionar para el dataset definitivo aquellas con mayor información mutua.

Además de estos métodos de filtrado, se empleará también un análisis de correlación entre las variables del dataset, con el objetivo de detectar posibles redundancias. En caso de que las correlaciones entre variables sean muy altas, entonces se consideraría la eliminación de una de ellas, con el objetivo de no introducir ruido.

En lo que respecta a este trabajo, el enfoque práctico que se seguirá para seleccionar las variables finales del dataset seguirá el siguiente proceso. En primer lugar, se analizarán las correlaciones entre las variables predictoras para detectar posibles redundancias. En segundo lugar, se aplicará un filtrado basado en entropía para eliminar aquellas variables con muy baja variabilidad y que no aportan información. En tercer lugar, se calculará la información mutua de cada variable restante con respecto al rendimiento del activo objetivo. Finalmente, con toda esta información, se montará el

dataset final, el cual contendrá las variables más relevantes de acuerdo a los filtros anteriores. Este dataset final será el que se entregue a los modelos de Random Forest, Gradient Boosting y LSTM para su entrenamiento y posteriores experimentos.

2.3. Machine Learning

Entrando ahora en la parte fundamental del trabajo, los modelos predictivos, los cuales serán los encargados de procesar la información del dataset y generar predicciones. Primero de todo el Machine Learning, el cual es el subconjunto de la Inteligencia Artificial centrado en algoritmos que pueden aprender los patrones de los datos de entrenamiento y, posteriormente, hacer inferencias sobre nuevos datos. Esta capacidad de reconocimiento de patrones permite a los modelos de machine learning tomar decisiones o realizar predicciones sin instrucciones explícitas y codificadas de forma rígida [11]. En resumen, un modelo de Machine Learning aprende a partir de ejemplos, identificando relaciones y estructuras que se encuentran en los datos. En un modelo de Machine Learning, cuantos más datos disponga sobre el tema, más precisas serán las predicciones que haga, ya que dispone de más información

Dentro del Machine Learning, se encuentran varias formas de aprendizaje, siendo el **aprendizaje supervisado** uno de los más relevantes para este trabajo. En el aprendizaje supervisado, el algoritmo se entrena a partir de un conjunto de datos que contiene tanto las variables de entrada como la variable objetivo que se quiere predecir. En esta forma de aprendizaje, el modelo aprende los patrones a partir de los cuales las entradas producen las salidas, y dichos patrones, los usa luego para predecir la variable objetivo a partir de nuevos datos de entrada, esto se puede ver en la Figura 2.3. Puesto que este trabajo es un problema de regresión donde se pretende predecir una variable continua, entonces el aprendizaje supervisado es la forma de aprendizaje adecuada. Por último, el aprendizaje supervisado se divide en problemas de clasificación, cuando la variable objetivo es categórica, y problemas de regresión, cuando es continua, siendo este último el caso de este trabajo.

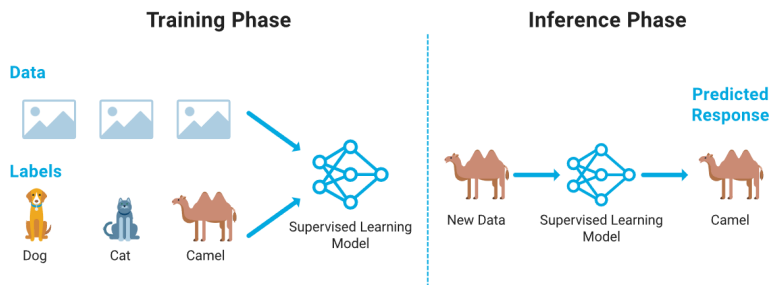

Figura 2.3: Esquema del funcionamiento del aprendizaje supervisado.

Continuando con el proceso de entrenamiento de un modelo de Machine Learning, este se basa en la optimización de una **función de pérdida**, la cúal calcula

la diferencia entre el valor de la predicción realizada y el valor real. En problemas de regresión, una de las funciones de pérdida más comunes es el error cuadrático medio (MSE), que calcula la media de los cuadrados de las diferencias entre predicciones y valores reales, otros ejemplos de funciones de pérdida, serían el error absoluto medio (MAE) o el error cuadratico medio raiz (RMSE). En Machine Learning, durante el entrenamiento, el objetivo es encontrar los parámetros del modelo que minimicen esta función de pérdida y para lograrlo, se hace uso de un algoritmo denominado **descenso de gradiente**, el cual calculando el gradiente de la función de pérdida con respecto a los parámetros del modelo, lo que indica la dirección en la que los parámetros deben ajustarse para reducir el error. En cada iteración, los parámetros se actualizan alejándose cada vez más del gradiente, este proceso se repite durante varias iteraciones hasta que el modelo alcanza un error muy bajo.

Otro concepto fundamental en la construcción de modelos predictivos es la reducción de la dimensionalidad. Cuando se trabaja con un conjunto de datos que contiene muchas variables, no todas ellas aportan información relevante para la predicción, algunas pueden ser redundantes entre sí, otras pueden contener principalmente ruido y algunas pueden tener una relación muy débil con el target. Es por ello, que incluir todas estas variables en el modelo, puede provocar sobreajuste o introducir ruido. Por esto mismo, es necesario aplicar técnicas de selección de variables y reducción de dimensionalidad sobre el dataset antes de entrenar los modelos. En este trabajo, esta tarea se ha abordado en profundidad durante la fase de Análisis Exploratorio de Datos (EDA) y se ha explicado en profundidad en el punto anterior, es por ello que aquí no se va a entrar en detalles.

Finalmente, en este trabajo, se trata de resolver un problema multivariante-multistep. Por un lado, es multivariante ya que se como se ha explicado anteriormente, se disponen varias variables para cada instante de tiempo y que actúan a la vez para predecir la variable objetivo. Esta característica exige que los modelos sean capaces de manejar entradas de alta dimensionalidad y de capturar las interacciones y dependencias entre las distintas variables. Por otro lado, es un problema multistep, ya que no se pretende predecir únicamente el valor del mes siguiente, sino que se busca generar predicciones a diferentes horizontes temporales, lo cual añade un punto de complejidad, ya que los errores tienden a acumularse, es por ello que el modelo debe de ser capaz de mantener la precisión.

Los modelos de Machine Learning que se van a usar, son Random Forest y Gradient Boosting. Ambos son modelos basados en árboles de decisión que pertenecen a la familia de **Ensemble Methods**. Estos métodos combinan múltiples modelos base para obtener un predictor final más robusto y preciso que cualquiera de los modelos individuales. La agregación de varias predicciones reduce la varianza y el error general del modelo, mejorando así su capacidad de generalización. Existen dos enfoques principales, el **bagging**, donde los modelos se entrenan de forma independiente y en paralelo, un ejemplo será Random Forest, y luego está **boosting**, en el que los modelos se entrenan de forma secuencial, corrigiendo los errores de los anteriores, un ejemplo de boosting, sería Gradient

Boosting.

2.3.1. Random Forest

Random Forest [12], es un algoritmo de aprendizaje automático que combina el resultado de múltiples árboles de decisión para llegar a un resultado único. Puede ser usado tanto en problemas de clasificación como de regresión debido a su flexibilidad. Random Forest es un modelo de árbol de decisión, eso significa que sigue un modelo muy similar al juego de quien el quien, donde a partir de preguntas, se van creando subconjuntos hasta llegar a la respuesta correcta, una definición más técnica sería que árbol de decisión divide recursivamente los datos en subconjuntos más homogéneos mediante nodos de decisión.

Como se ha comentado anteriormente, Random Forest, pertenece a la familia de Ensemble Methods. A su vez, es una extensión del método de bagging, que consiste en seleccionar muestras aleatorias del conjunto de entrenamiento con reemplazo, entrenar un árbol de decisión sobre cada subconjunto y agregar las predicciones promediando en el caso de regresión. Finalmente, este algoritmo de Machine Learning, añade una capa adicional llamada la aleatoriedad de características, que consiste en seleccionar un subconjunto aleatorio de características en cada división del árbol, lo que garantiza que los árboles del bosque no estén correlacionados entre sí, reduciendo la varianza y el riesgo de sobreajuste.

Entre las principales ventajas del Random Forest para este trabajo destacan las siguientes:

- **Menor riesgo de sobreajuste**: al combinar múltiples árboles entrenados sobre diferentes subconjuntos de datos y características, el promediado de sus predicciones reduce la varianza del modelo, evitando que se ajuste excesivamente al ruido de los datos de entrenamiento.
- **Flexibilidad para manejar regresiones sin preprocesamiento extensivo**: Random Forest no requiere normalización ni estandarización de las variables, y es robusto frente a valores atípicos y datos faltantes, lo que simplifica el preprocesamiento del dataset.
- **Capacidad para evaluar la importancia de las características**: el algoritmo puede medir la contribución de cada variable a la reducción de la impureza en los nodos de los árboles, permitiendo identificar qué variables macroeconómicas son más relevantes para la predicción.

Con respecto a las desventajas, este modelo presenta un entrenamiento más lento que otros modelos debido a que tiene que construir múltiples árboles de forma independiente, lo que puede ser costoso computacionalmente si se utiliza un número elevado de árboles o conjuntos de datos muy grandes. Además, su mayor complejidad interpretativa hace que sea más difícil explicar las predicciones individuales que con un único árbol de decisión, aunque las medidas de importancia de variables ayudan a solucionar este problema.

En cuanto a este trabajo, se implementará un *RandomForestRegressor* con scikit-learn [13], ajustando sus hiperparámetros principales como el número de árbo-

les, la profundidad máxima y el número de características por división.

2.3.2. Gradient Boosting

Por otro lado, Gradient Boosting [14] es otro Ensemble Method basado en árboles de decisión, pero a diferencia del Random Forest que entrena los árboles de forma independiente y en paralelo, Gradient Boosting los construye de forma secuencial y acumulativa. Pertenece a la familia de métodos de boosting, cuyo objetivo es combinar múltiples modelos débiles para crear un modelo fuerte, donde cada nuevo modelo se centra en corregir los errores cometidos por los anteriores.

Su funcionamiento es el siguiente. Primero, se inicializa el modelo con una predicción base (generalmente la media de la variable objetivo). En cada iteración, se calculan los errores (residuos) del modelo actual y se entrena un nuevo árbol de decisión para predecir esos errores. Este nuevo árbol se añade al modelo multiplicado por un factor *learning rate*, que controla la contribución de cada árbol y evita el sobreajuste. El proceso se repite durante un número determinado de iteraciones o hasta que el error sea suficientemente pequeño.

En cuanto a los hiperparámetros, el *learning rate* es el más importante, ya que un valor bajo hace que el modelo aprenda más lentamente pero de forma más generalizable, debido a que se requieren más árboles para aproximar la función objetivo. Otros hiperparámetros relevantes son la profundidad máxima de cada árbol y la fracción de muestras utilizada en cada iteración.

Entre las principales ventajas del Gradient Boosting para este trabajo destacan las siguientes:

- **Rendimiento predictivo superior**: al construir los árboles de forma secuencial corrigiendo los errores de los anteriores, el modelo puede capturar patrones más complejos y sutiles que otros algoritmos, lo que suele traducirse en una mayor precisión predictiva.
- **Capacidad para evaluar la importancia de las características**: al igual que Random Forest, Gradient Boosting puede medir la contribución de cada variable a la reducción del error durante el proceso de entrenamiento, lo que permite identificar qué variables macroeconómicas son más relevantes para la predicción.

Con respecto a las desventajas, su entrenamiento es más lento que el de Random Forest debido a su naturaleza secuencial. Además, es más sensible a los hiperparámetros, especialmente al *learning rate* y al número de árboles. Un ajuste inadecuado puede provocar sobreajuste si el aprendizaje es demasiado rápido o infraprendizaje si es demasiado lento. Por ello, el ajuste de hiperparámetros debe realizarse con especial cuidado, utilizando técnicas como validación cruzada para encontrar la configuración óptima.

Finalmente, en este trabajo se implementará un *GradientBoostingRegressor* con scikit-learn [14], ajustando sus hiperparámetros principales mediante validación cruzada.

2.4. Deep Learning

El Deep Learning es un subconjunto del Machine Learning impulsado por redes neuronales cuyo diseño se inspira en la estructura del cerebro humano y que implica el entrenamiento de modelos de al menos 4 capas. A diferencia de los modelos de Machine Learning, que siguen una lógica matemática, las redes neuronales de los modelos de Deep Learning comprenden muchas capas interconectadas de neuronas, que realizan cada una una operación matemática. En estos modelos de Deep Learning, se puede ajustar los pesos y sesgos variables del modelo para así optimizar la red y obtener salidas más precisas.

Continuando ahora con las redes neuronales, estas son un modelo de aprendizaje automático que apila neuronas simples en capas y aprende a reconocer patrones a partir de datos para así asignar entradas a salidas. Los componentes básicos de una red neuronal son una capa de entrada, que contiene las características sin procesar; una o varias capas ocultas, que transforman las entradas en nuevas representaciones mediante funciones de activación no lineales; y una capa de salida, que genera la predicción final. En la Figura 2.4 se pueden ver dichas capas. Se ha mencionado que en las capas ocultas las entradas se transforman con funciones de activación. Algunos ejemplos de estas funciones son la tangente hiperbólica, la unidad lineal rectificada (ReLU) o la función sigmoide. Todas ellas introducen no linealidad en el modelo, permitiendo a la red capturar patrones complejos y relaciones no lineales en los datos.

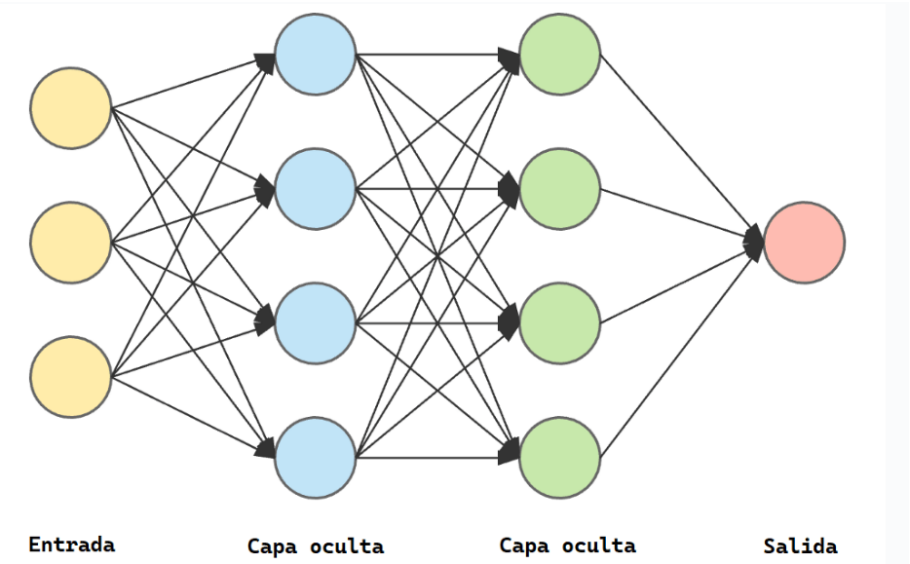

Figura 2.4: Estructura de una red neuronal con capas de entrada, ocultas y salida. Fuente: OpenWebinars

El entrenamiento de una red neuronal se basa en dos algoritmos fundamentales: la retropropagación [15] y el descenso de gradiente [16], que se explicó anteriormente en el apartado de Machine Learning. Profundizando ahora en la retropropagación, esta es un método muy útil para calcular cómo afectan los

cambios en cualquier peso o sesgo individual de una red neuronal a la precisión de las predicciones del modelo. Para ello, durante el entrenamiento, se compara la predicción de la red con el valor real mediante una función de pérdida y, a continuación, la retropropagación propaga este error hacia atrás a través de la red desde la capa de salida hasta la capa de entrada, calculando mediante la regla de la cadena del cálculo el gradiente de la función de pérdida con respecto a cada parámetro del modelo. Este gradiente indica en qué dirección deben ajustarse los pesos y sesgos para reducir el error. Posteriormente, un algoritmo de descenso de gradiente utiliza este gradiente para actualizar los parámetros del modelo. Finalmente, este proceso se repite en bucle hasta que el modelo encuentra un conjunto de parámetros que producen predicciones suficientemente precisas.

Sin embargo, es importante señalar que el descenso de gradiente no garantiza la convergencia al mínimo global de la función de pérdida. En la práctica, la función de pérdida de una red neuronal es no convexa y presenta una gran cantidad de mínimos locales y puntos de silla. Es por ello que el algoritmo puede quedar atrapado en un mínimo local, que no necesariamente es la solución óptima, o por el contrario, puede oscilar sin converger si la tasa de aprendizaje no es la adecuada. No existe una única solución, ya que diferentes inicializaciones aleatorias de los pesos pueden llevar a distintos conjuntos de parámetros finales que producen un rendimiento muy parecido. Además, la robustez del proceso depende fuertemente de la elección de la tasa de aprendizaje y de la calidad de los datos. Una tasa de aprendizaje demasiado alta puede provocar divergencia u oscilaciones, mientras que una demasiado baja puede ralentizar excesivamente la convergencia.

Antes de concluir con el Deep Learning es importante mencionar el equilibrio entre sesgo y varianza, que busca reducir el error. El sesgo mide lo lejos que están las predicciones de un modelo de los valores reales, mientras que la varianza captura cuánto varían las predicciones en función de los diferentes datos de entrenamiento. Un modelo con alto sesgo es propenso a un ajuste insuficiente, es decir, no logra capturar los patrones importantes de los datos y da lugar a un modelo demasiado simple. Por el contrario, un modelo con alta varianza es propenso al sobreajuste, lo que significa que se ajusta excesivamente a los datos de entrenamiento, aprendiendo el ruido como si fuera señal y perdiendo capacidad de generalización a nuevos datos. Con el entrenamiento, se busca encontrar el punto óptimo entre ambos errores, minimizando el error de predicción. Algunas técnicas para mantener este equilibrio son la regularización, que añade una penalización a la función de pérdida para desalentar modelos demasiado complejos, también está el *dropout*, que apaga aleatoriamente neuronas durante el entrenamiento para reducir el sobreajuste y por último, la detención temprana, que detiene el entrenamiento cuando la pérdida en validación deja de mejorar.

2.4.1. LSTM

Las redes neuronales recurrentes (RNN) son un tipo de red neuronal diseñada específicamente para trabajar con datos secuenciales, como series temporales. A

diferencia de las redes neuronales convencionales, las RNN cuentan con bucles de retroalimentación que permiten que la información se mantenga a lo largo de los pasos temporales, creando una memoria de entradas pasadas. Sin embargo, las RNN convencionales presentan una limitación importante, el problema de la desaparición del gradiente, el cual impide que la red aprenda dependencias a largo plazo.

Para superar este problema, surge la arquitectura Long Short-Term Memory (LSTM), diseñada para capturar dependencias temporales a largo plazo de manera efectiva y es que tal y como mencionan Sepp Hochreiter y Jürgen Schmidhuber "las redes LSTM pueden aprender a puentear intervalos de tiempo de más de 1000 pasos sin perder información relevante"[17]. Esto lo consigue gracias a su estructura interna, que cuenta con tres puertas que regulan el flujo de información, una de las puertas es la **puerta de olvido**, que decide qué información del pasado debe descartarse, luego está la **puerta de entrada**, que determina qué nueva información debe almacenarse, y por último, la **puerta de salida** controla qué información se utiliza para generar la predicción. Gracias a estas puertas, LSTM, es capaz de sobreponerse a la limitación planteada anteriormente y además, permite a la red olvidar información que no es relevante.

En el contexto de este trabajo, la LSTM presenta ventajas bastante interesantes. Una de las ventajas, como se ha mencionado antes, es la gran capacidad de LSTM para capturar dependencias temporales prolongadas. En segundo lugar, LSTM es capaz de manejar el carácter multivariante del problema, pudiendo procesar a la vez todas las variables macroeconómicas y del activo como una secuencia de entrada. Por último, LSTM es capaz de abordar el problema multistep, generando predicciones a diferentes horizontes temporales y manteniendo la coherencia temporal de las predicciones. En cuanto a las desventajas, LSTM requiere una mayor cantidad de datos para entrenarse adecuadamente, es más costosa computacionalmente y la interpretabilidad de las predicciones es más costosa que en modelos de Machine Learning.

En este trabajo se implementará una red LSTM utilizando TensorFlow [18], configurándola para el problema multivariante-multistep, y se comparará su rendimiento con el de Random Forest y Gradient Boosting, evaluando si su capacidad de memoria a largo plazo ofrece ventajas significativas sobre los métodos basados en árboles para la predicción de rendimientos financieros.

2.5. Modelos explicativos

En este trabajo no solo se pretende realizar predicciones, sino que también se busca entender el porqué de las salidas del modelo, es por ello que se emplearán modelos explicativos para así poder comprender la influencia de cada una de las variables en las predicciones y entender mejor el comportamiento del modelo. Para conseguir esta transparencia, se emplearán dos técnicas de Explainable Artificial Intelligence (XAI) [19], LIME y SHAP, las cuales permitirán interpretar las predicciones del modelo y analizar la influencia de cada variable macroeconómica en los resultados obtenidos.

2.5.1. LIME

LIME [20] es una técnica explicativa que genera explicaciones locales para predicciones individuales. Su funcionamiento consiste en aproximar el comportamiento del modelo complejo en la vecindad de una instancia específica mediante un modelo más simple e interpretable, como una regresión lineal. De esta forma, para una predicción concreta del rendimiento de un fondo en un mes determinado, LIME permite identificar qué variables macroeconómicas han influido más en esa decisión concreta, ofreciendo una explicación comprensible y localizada. Su principal ventaja es que puede aplicarse tanto a Random Forest, como a Gradient Boosting o a LSTM sin necesidad de modificaciones.

2.5.2. SHAP

Por otro lado, SHAP [21] es una técnica explicativa que se basa en la teoría de juegos cooperativos [22]. SHAP asigna a cada variable un valor de importancia conocido como Shapley value, que representa su contribución a la predicción. A diferencia de LIME, que se centra en explicaciones locales para predicciones individuales, SHAP permite tanto el análisis local de predicciones concretas como la visión global de la importancia de las variables en todo el conjunto de datos, ofreciendo propiedades deseables como consistencia, precisión local y aditividad. En el contexto de este trabajo, la combinación de SHAP y LIME permitirá identificar qué variables macroeconómicas, como los tipos de interés, la inflación, el diferencial de la curva de tipos o el precio del petróleo, son más influyentes en las predicciones del rendimiento de los fondos de inversión, proporcionando así una comprensión completa y robusta del comportamiento del modelo.

2.6. Trabajos anteriores

Por último, para concluir con el marco teórico, se verán trabajos relacionados con este TFG, con el objetivo de contextualizar la investigación actual dentro del panorama más amplio de la aplicación de Inteligencia Artificial en finanzas. Y es que, en los últimos años, el uso de técnicas de Machine Learning y Deep Learning en el ámbito financiero ha crecido muy significativamente, debido a la gran cantidad de datos y el fácil acceso a los mismos, a su vez, los avances computacionales, también han impulsado este crecimiento. Tal y como se menciona en la revisión sistemática de El Alami y colaboradores [2], los modelos más utilizados en el ámbito financiero son Random Forest, XGBoost, Support Vector Machines, y redes neuronales como LSTM, Bidirectional LSTM y CNN, del mismo modo, se hace uso de modelos híbridos que combinan métodos estadísticos con inteligencia artificial.

En cuanto al rendimiento de estos modelos, tal y como señalan Nabipour Mojtaba y colaboradores [23], las arquitecturas basadas en LSTM superan consistentemente a los métodos tradicionales como ARIMA o GARCH en la predicción de series financieras, esto es gracias a su capacidad para capturar dependencias temporales largas. No obstante, los propios autores advierten que las LSTM pueden ser propensas al sobreajuste y requieren un ajuste cuidadoso de sus

hiperparámetros, algo que se tendrá en cuenta en la fase de modelado de este trabajo.

En lo que respecta al uso de variables macroeconómicas, tal y como explica Abdou Housein en su artículo "The impact of oil and global markets on Saudi stock market predictability: A machine learning approach" [24], el hecho de introducir variables como los precios del petróleo, los tipos de interés y los índices de volatilidad mejora significativamente la predictibilidad de los mercados bursátiles cuando se incorporan dentro de marcos de Machine Learning. Este artículo, da aún más fuerza a la decisión adoptada en este TFG de incluir un importante número de variables macroeconómicas como predictores del rendimiento de los fondos de inversión o activos financieros.

En el aspecto de la interpretabilidad de los modelos, es un tema que ha ganado mucha popularidad en los últimos años, esto queda reflejado en el artículo de Mohsin y Nasim "Explaining the Unexplainable: A Systematic Review of Explainable AI in Finance." [25], donde se explica que la falta de interpretabilidad de los modelos complejos limita su adopción en entornos regulados como el financiero, donde la transparencia es clave. Para solucionar este problema, Ye y Chen [4], proponen técnicas como SHAP y LIME, que permiten explicar las predicciones de modelos de caja negra, demostrando que es posible realizar modelos complejos manteniendo la transparencia necesaria.

Por último, tal y como se señala en la revisión sistemática sobre forecasting financiero [1], actualmente, muchos estudios evalúan sus modelos solo con métricas estadísticas sin integrar las predicciones en estrategias de inversión reales, a su vez pocos, modelos son validados en diferentes ciclos económicos como pueden ser crisis financieras o períodos de alta inflación. Estas limitaciones refuerzan el enfoque adoptado en este TFG, que combina la predicción multivariante-multistep con un análisis exhaustivo de interpretabilidad mediante SHAP y LIME, y una evaluación en diferentes contextos económicos identificados mediante clustering.

Capítulo 3

Datos y preparación del dataset

En este capítulo, se describirá el proceso de obtención, limpieza e integración de los datos macroeconómicos y financieros utilizados en este trabajo. Además, se realizará un análisis exploratorio de datos **(EDA)** tanto univariante como multivariante, esto se hará para comprender mejor el comportamiento de las variables seleccionadas y su relación con el activo financiero objetivo, que en este caso es Apple Inc. Este análisis permitirá identificar patrones, tendencias y posibles relaciones entre las variables, lo que será fundamental para la fase de modelización predictiva.

3.1. Datos a usar

Tras realizar un estudio de las variables macroeconómicas y financieras más relevantes en los mercados, se ha decidido trabajar con un conjunto de variables representativas que permitan capturar tanto el comportamiento del mercado como el contexto económico global. En concreto, tal y como se mencionó en la introducción, se incluyen los tipos de interés de la Federal Reserve y del European Central Bank, la inflación de Estados Unidos y de la eurozona, la tasa de desempleo en Estados Unidos, el tipo de cambio euro/dólar, la curva de tipos 10Y-2Y de Estados Unidos, así como los retornos del oro, del petróleo y del índice S&P 500. A su vez, se añade el índice de volatilidad VIX.

Con el objetivo de enriquecer el conjunto de datos, se aplican técnicas de **feature engineering** sobre algunas de estas variables, construyendo así un dataset lo más completo posible. Asimismo, se incluyen variables propias del activo que se esté estudiando, en este caso Apple Inc, sobre dichas variables, también se aplican transformaciones adicionales para mejorar la capacidad predictiva del modelo.

3.2. Obtención e integración de los datos al dataset

En cuanto al proceso de obtención, limpieza e integración de los datos, este se ha llevado a cabo de forma estructurada. En primer lugar, se han importado las

librerías fredapi [26] e yfinance [27] en Python [28], con el objetivo de acceder a fuentes externas de datos financieros y macroeconómicos y así no cargar el proyecto con muchos archivos CSV. Posteriormente, se ha definido el período de estudio, comprendido entre el 1 de diciembre de 2001 y el 1 de marzo de 2026, y se ha inicializado un dataset global donde se han ido integrando las distintas variables.

Para la obtención de datos macroeconómicos procedentes de la base de datos de la Federal Reserve Economic Data (FRED), se ha utilizado una **API key**, que en este caso es `af59516007957e0c89174b4d426736ca`.

El proceso comienza con la descarga de los datos. En primer lugar, se descargan los datos del S&P 500 [29] mediante yfinance, obteniendo el precio de cierre. Posteriormente, se transforma la serie a frecuencia mensual, seleccionando el último valor de cada mes. A continuación, se comprueba la existencia de valores nulos y luego se calcula el retorno mediante la función `pct_change()`. Esta transformación resulta especialmente útil, ya que los modelos de Machine Learning suelen trabajar mejor con retornos que con precios absolutos. Finalmente, se comprueba de nuevo la existencia de valores nulos y se integra la variable en el dataset global. Este mismo procedimiento se aplica a otras variables como el tipo de cambio euro/dólar o el índice VIX [30], con la diferencia de que en estos casos no se calcula el retorno. Las variables se integran en el dataset final a partir de un `inner join` en la columna `Date`.

En el caso del oro y el petróleo, el proceso presenta una particularidad adicional: tras la obtención de los datos y su conversión a frecuencia mensual, se encuentran valores nulos debido a días en los que no hay actividad en los mercados. Para resolver este problema, se ha implementado una función denominada `imputar_valores_faltantes`, que combina tres métodos de imputación: interpolación lineal (50 %), media móvil (30 %) y último valor observado (20 %). Esta combinación permite obtener una serie mucho más completa. Una vez rellenados los valores nulos, se calcula el retorno y se incorpora al dataset final.

El resto de variables macroeconómicas, como los tipos de interés, la curva de tipos o el desempleo, se obtienen directamente desde FRED siguiendo un proceso similar: se descargan, se ajustan a frecuencia mensual y se integran los datos en el dataset. En el caso del desempleo, al presentar valores nulos, ha sido necesario aplicar la función `imputar_valores_faltantes` antes de integrar los datos en el dataset final.

Por otro lado, la inflación es una variable importante para el modelo, sin embargo, no se obtiene directamente, sino que se calcula a partir del Índice de Precios al Consumo (IPC) [31] mediante la variación interanual. Para ello, se utiliza la función `pct_change(12)`. De este modo, se obtiene una medida más representativa de la evolución de los precios en cada región.

Finalmente, en el dataset final se incorporan las variables propias del activo analizado, obtenidas a través de yfinance. A partir de los precios de cierre, se aplican técnicas de feature engineering para generar nuevas variables como el retorno, medias móviles, volatilidad, momentum y lags, que resultan fundamen-

tales para capturar la dinámica temporal del activo. Todas estas variables se integran en el dataset global mediante un inner join a partir de la columna Date.

Para concluir, se realiza una validación final del dataset, verificando que todas las variables se encuentran en frecuencia mensual, que no existen valores nulos y que los tipos de datos son correctos. Asimismo, se renombran las columnas para facilitar su interpretación y, finalmente, el dataset se exporta en formato CSV, lo que permite su posterior utilización en herramientas como R [32] o Google Sheets [33]. Todo el proceso anterior se puede ver en la Figura 3.1.

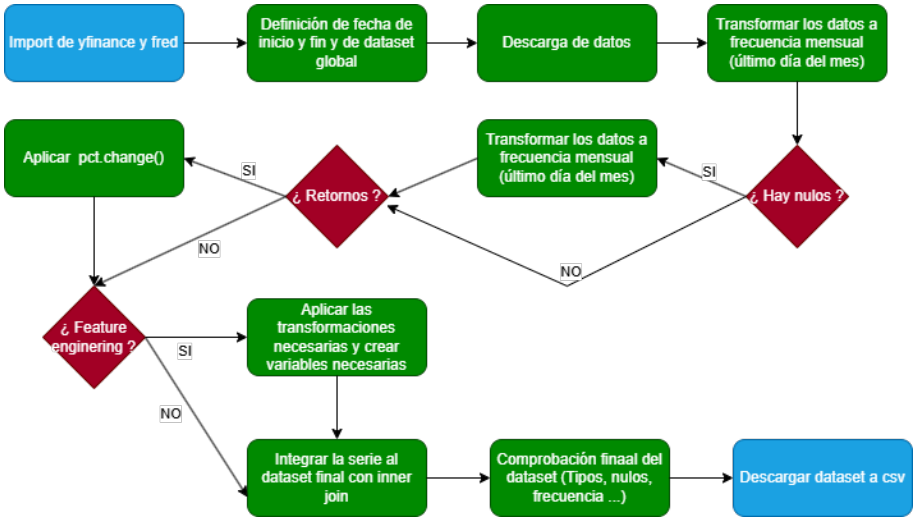

Figura 3.1: Diagrama del proceso de obtención, limpieza e integración de datos. Fuente: elaboración propia.

3.3. Análisis exploratorio de datos (EDA)

Una vez obtenidos todos los datos e integrados en el dataset, se procede a la realización del análisis exploratorio de datos (EDA). Dicho análisis se ha estructurado en dos grandes bloques, primero un análisis univariante, donde se examina cada variable macroeconómica de forma individual, y luego, un análisis multivariante, donde se estudian las relaciones entre las distintas variables y su interacción con el activo financiero objetivo. También se realizará clustering, con el objetivo de identificar diferentes contextos económicos a lo largo del período de estudio. Dicho dataset cuenta con 265 filas y sin valores nulos, por lo que no habrá valores que entorpezcan el análisis.

El análisis exploratorio de datos realizado en este trabajo se ha centrado en las variables macroeconómicas, ya que estas constituyen el único conjunto de variables que permanece constante independientemente del activo o fondo de inversión analizado. Dado que el objetivo del TFG es desarrollar una metodología general para el análisis predictivo de fondos de inversión, resulta fundamental comprender en profundidad el comportamiento de estas variables, su evolución temporal, sus distribuciones, sus correlaciones y su memoria, ya que son los elementos que aportarán el contexto económico a cualquier modelo predictivo.

En cuanto a las variables específicas del activo, en este caso se ha elegido Apple Inc [34] como caso de estudio, y se ha aplicado feature engineering sobre los precios del activo como medias móviles a 3, 6 y 12 meses para capturar tendencias; volatilidades móviles para medir el riesgo; momentum para reflejar la inercia del precio; y lags del rendimiento en los horizontes 1, 2, 3, 6 y 12 meses para capturar la posible dependencia temporal del propio activo.

Estas variables específicas no han sido objeto de un análisis exploratorio detallado por dos razones. En primer lugar, porque su comportamiento es particular del activo concreto que se esté analizando, por lo que un análisis profundo de las mismas no aportaría valor generalizable a la metodología propuesta. En segundo lugar, porque su construcción sigue criterios estándar en el análisis técnico y en la modelización de series temporales financieras, siendo suficiente con incluirlas directamente en los modelos predictivos.

En una aplicación real de esta metodología a otro fondo de inversión o activo financiero, bastaría con sustituir los datos específicos de Apple por los del nuevo activo, manteniendo la misma estructura de variables técnicas y conservando intacto el análisis del entorno macroeconómico.

3.3.1. Análisis univariante

En el análisis univariante, se examina cada variable de forma individual, con el objetivo de caracterizar su comportamiento estadístico, identificar la presencia de eventos extremos y evaluar su distribución de probabilidad. Para ello, se calcularán medidas de medias y medianas, volatilidad, *skewness* y curtosis, así como los valores mínimos y máximos históricos. Se complementará el análisis con representaciones gráficas como *boxplots*, para detectar `outliers`. Este análisis univariante es fundamental para comprender el perfil de riesgo individual de cada variable.

Distribución de las variables macroeconómicas

A partir de este análisis, se pretende ver las medias, medianas y volatilidades de cada una de las variables macroeconómicas, así como la presencia de eventos extremos. Este análisis es fundamental para entender el comportamiento individual de cada variable y su impacto potencial en los modelos predictivos.

Antes de comenzar, es necesario explicar la curtosis [35] y la *skewness* [36], que son dos medidas estadísticas que permiten caracterizar la forma de la distribución de una variable. La curtosis mide la presencia de colas pesadas en la distribución, es decir, la frecuencia con la que ocurren eventos extremos. Una curtosis mayor que 3 indica colas pesadas, lo que significa que los eventos extremos son más frecuentes de lo normal. Por otro lado, la *skewness* mide la asimetría de la distribución. Una *skewness* positiva indica una asimetría hacia la derecha, lo que significa que hay una mayor propensión a ganancias extremas, mientras que una skewness negativa indica una asimetría hacia la izquierda, lo que sugiere una mayor propensión a pérdidas extremas. En la Figura 3.2 se

muestra una rápida explicación visual de como se ven la curtosis y la *skewness* en gráficas.

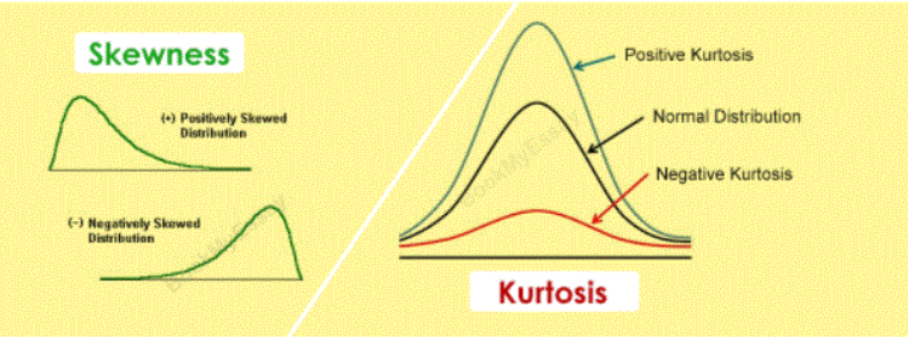

Figura 3.2: Imagen explicativa de skewness y curtosis. Fuente: Media2u.com.

- **Distribución de retornos del S&P 500:** En primer lugar, se analiza el S&P 500, que presenta un rendimiento medio mensual del 0,80 % con una volatilidad del 4,20 %. A su vez, presenta un *skewness* de -0,618, lo que indica una mayor propensión a pérdidas extremas. Por otro lado, la curtosis de 4,39 confirma la presencia de colas pesadas. Los valores de la *skewness* y la curtosis indican que el S&P 500 es más propenso a tener pérdidas grandes que ganancias grandes debido a la asimetría negativa. Además, el valor de la curtosis, mayor que 3, indica que los eventos extremos ocurren con mayor frecuencia. En resumen, los eventos extremos son más habituales de lo normal y son más propensos a generar pérdidas. En lo que respecta al rendimiento, el valor mínimo del S&P 500 se registró en octubre de 2008, con un valor de -16,9 % en plena crisis financiera, mientras que el máximo del 12,7 % data de abril de 2020, tras el desplome inicial por la pandemia. Todo lo mencionado es visible en la Figura 3.3.

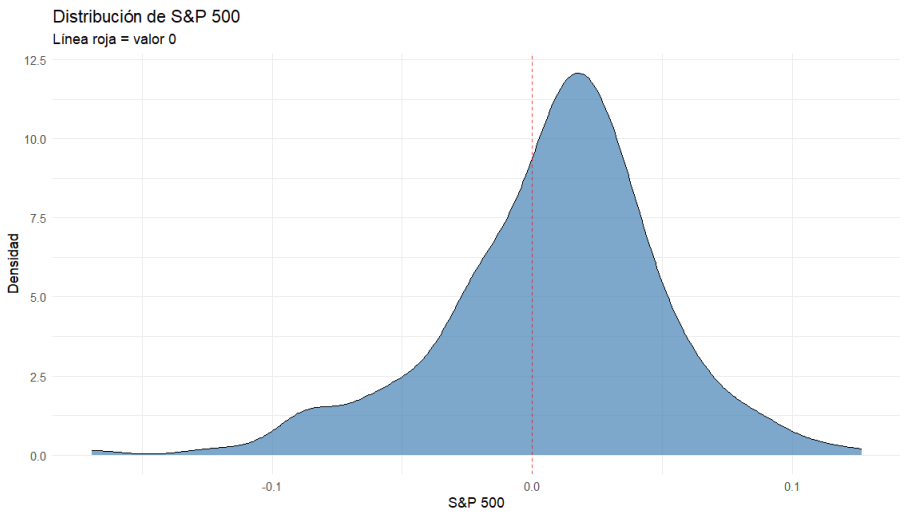

Figura 3.3: Gráfica de distribución de los retornos del S&P 500. Fuente: elaboración propia.

- **Distribución del VIX:** En lo que respecta al VIX, que se muestra en la Figura 3.4, este presenta una media de 19,05 puntos, aunque su mediana de 16,63 es significativamente inferior, lo que refleja la naturaleza episódica de la volatilidad. Esta volatilidad tiene un valor del 7,93 %. Su *skewness* de 2,09 indica una fuerte asimetría positiva, lo que significa que hay muchos valores bajos pero algunos extremadamente altos, mientras que la curtosis de 8,69 confirma la presencia de colas muy pesadas. Esto indica que los picos de pánico en el mercado son eventos extremos que ocurren con mayor frecuencia de lo normal y, cuando ocurren, lo hacen de forma muy intensa. El valor máximo de 59,89 se alcanzó en octubre de 2008, durante la crisis financiera. Por el contrario, el mínimo de 9,51 se registró en julio de 2017, un período de calma y baja volatilidad.

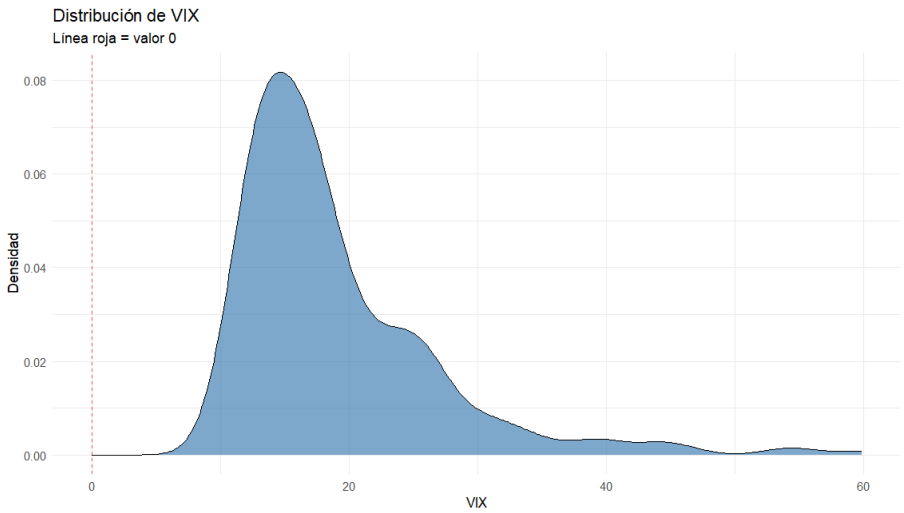

Figura 3.4: Gráfica de la distribución del índice de volatilidad VIX. Fuente: elaboración propia.

- **Distribución de retornos del petróleo:** En cuanto al petróleo, que se muestra en la Figura 3.5, este destaca como el activo más volátil del dataset, con una desviación típica mensual (volatilidad) del 10,4 %, más del doble que la del S&P 500. Su *skewness* de 1,78 indica asimetría positiva, mientras que su curtosis de 22,5 es exageradamente elevada. Estos dos valores muestran que el petróleo sufre movimientos extremos con una frecuencia enorme y que estos extremos tienden a ser en forma de crecimiento. En cuanto toca a los valores extremos, destaca la caída del retorno en un -40,8 % en marzo de 2020, cuando la demanda colapsó por los confinamientos globales provocados por el COVID-19 [37]. Por otro lado, en mayo de 2020, subió un 88,4 %.

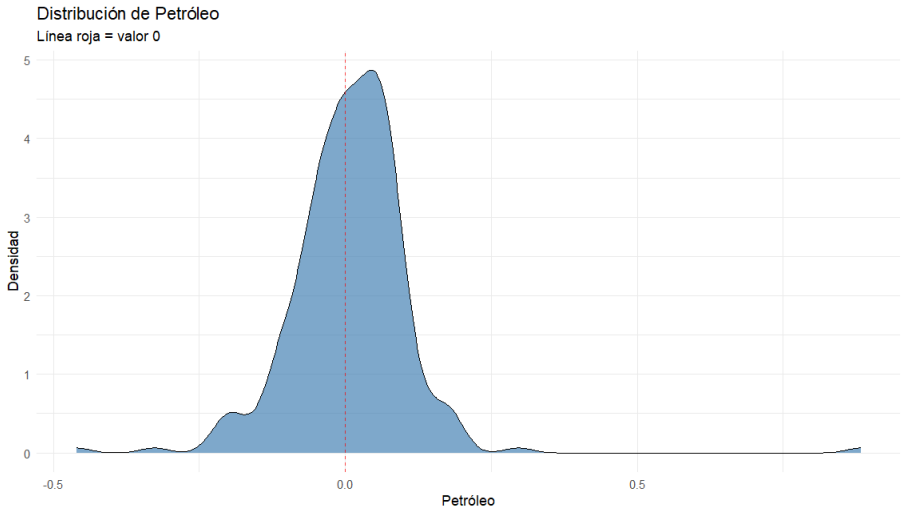

Figura 3.5: Gráfica de la distribución de los retornos del petróleo. Fuente: elaboración propia.

- **Distribución de retornos del oro:** El oro, que es considerado activo refugio, presenta una volatilidad mensual del 4,4 %, similar a la del S&P 500. Su retorno mínimo de -18 % en marzo de 2020 se dio al inicio de la pandemia, mientras que el máximo del 13,9 % en abril de 2020 confirma su recuperación como activo refugio. Su curtosis de 4,34 confirma la presencia de colas pesadas, aunque menos extremas que en el petróleo. En lo que respecta a su *skewness*, este es de -0,241, lo que indica una ligera asimetría negativa. Todo lo mencionado es visible en la Figura 3.6.

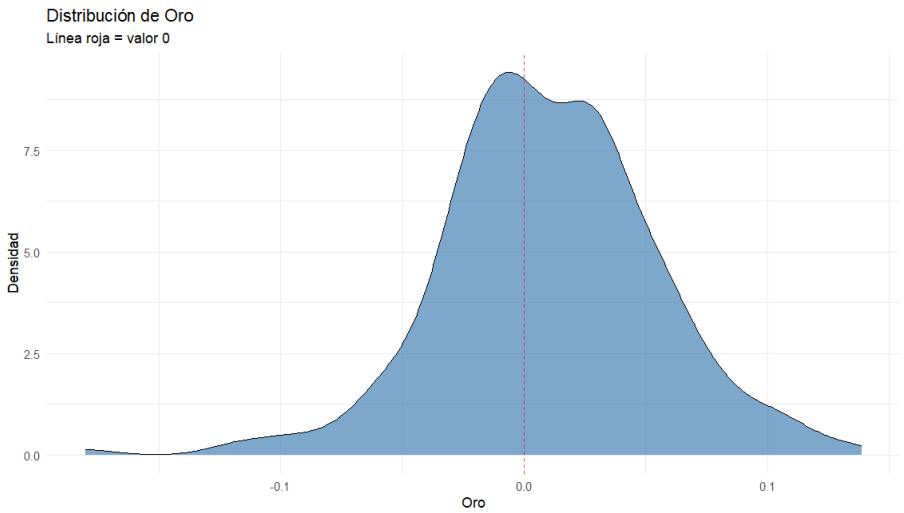

Figura 3.6: Gráfica de la distribución de los retornos del oro. Fuente: elaboración propia.

- **Distribución de los tipos de interes FED:** Pasando ahora a los tipos de

interés de la Reserva Federal, que se muestran en la Figura 3.7, estos presentan una media del 1,78 %, aunque la mediana del 1,00 % revela largos períodos de tipos cercanos a cero. Su volatilidad mensual es del 1,93 %, reflejando cambios graduales. Su *skewness* de 0,750 indica asimetría positiva, mientras que la curtosis de 1,98, inferior a 3, indica que la distribución es más plana que la normal, es decir, los tipos no cuentan con muchos eventos extremos. En cuanto al máximo, este se da en agosto de 2023, siendo los tipos de un 5,33 %, mientras que el mínimo del 0,05 % se alcanzó en abril de 2020.

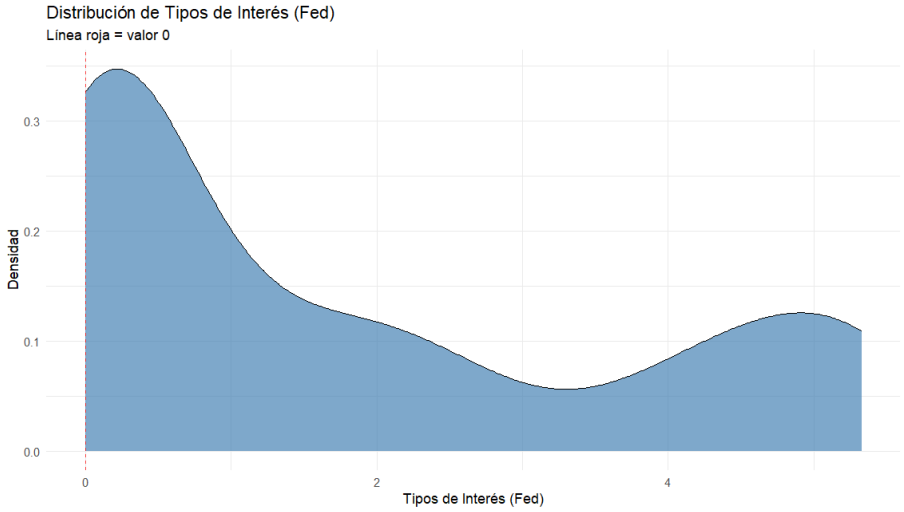

Figura 3.7: Gráfica de la distribución de los tipos de interés de la Reserva Federal. Fuente: elaboración propia.

- **Distribución de los tipos de interes BCE:** Por su parte, el Banco Central Europeo mantuvo una política aún más expansiva, con una media del 0,79 % y una volatilidad mensual del 1,38 %. Su mínimo histórico de -0,50 % se mantuvo durante gran parte del período 2014-2022. Por otro lado, el máximo del 4,00 % se registró en septiembre de 2023. Todo lo mencionado es visible en la Figura 3.8.

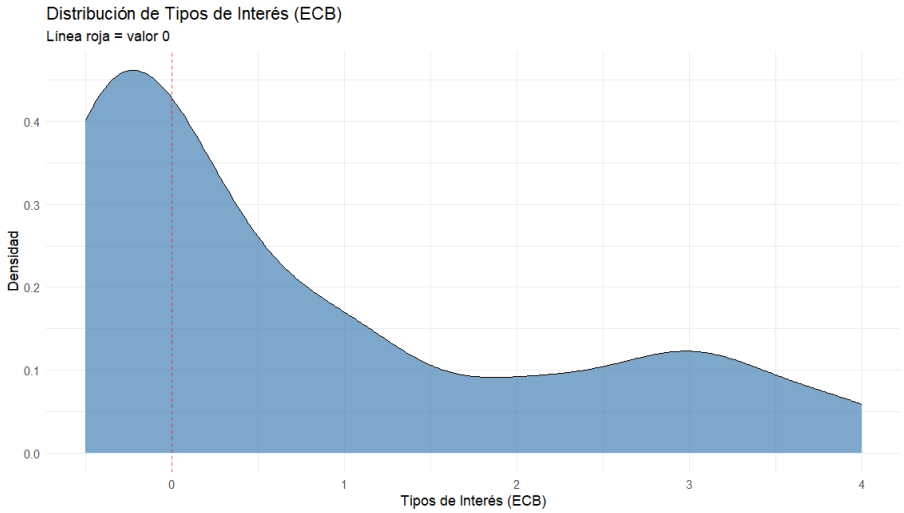

Figura 3.8: Gráfica de la distribución de los tipos de interés del Banco Central Europeo. Fuente: elaboración propia.

- **Distribución de la inflación USA:** Otro factor importante es la inflación estadounidense, la cual presenta una media del 2,59 %, un poco por encima del objetivo de la FED, y una volatilidad mensual del 1,85 %. El mínimo de -1,96 % se da en julio de 2009, después de la crisis, mientras que el máximo del 8,98 % en junio de 2022 corresponde al período post-COVID. La curtosis de 5,07 y el *skewness* de 1,05 indican que los eventos extremos son más frecuentes de lo normal y tienden a ser al alza. Todo lo mencionado es visible en la Figura 3.9.

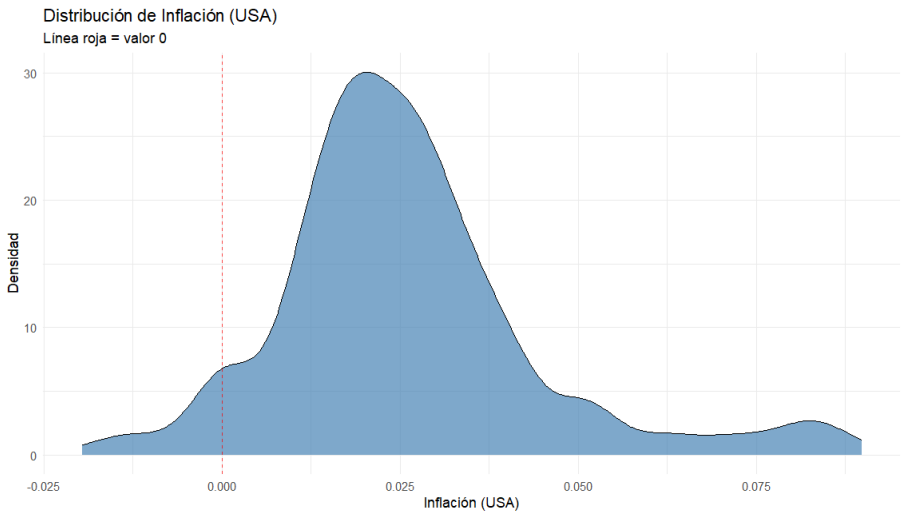

Figura 3.9: Gráfica de la distribución de la inflación en Estados Unidos. Fuente: elaboración propia.

- **Distribución de la inflación Europa:** En Europa, la dinámica es similar

pero algo más intensa, con un pico del 10,62 % en octubre de 2022, impulsado por el COVID y los conflictos bélicos. Por otro lado, el mínimo se da en enero de 2015, con un valor de -0,62 %. La elevada curtosis de 8,31 confirma que se trató de un evento extremo. La volatilidad mensual es del 1,94 %. Todo lo mencionado es visible en la Figura 3.10.

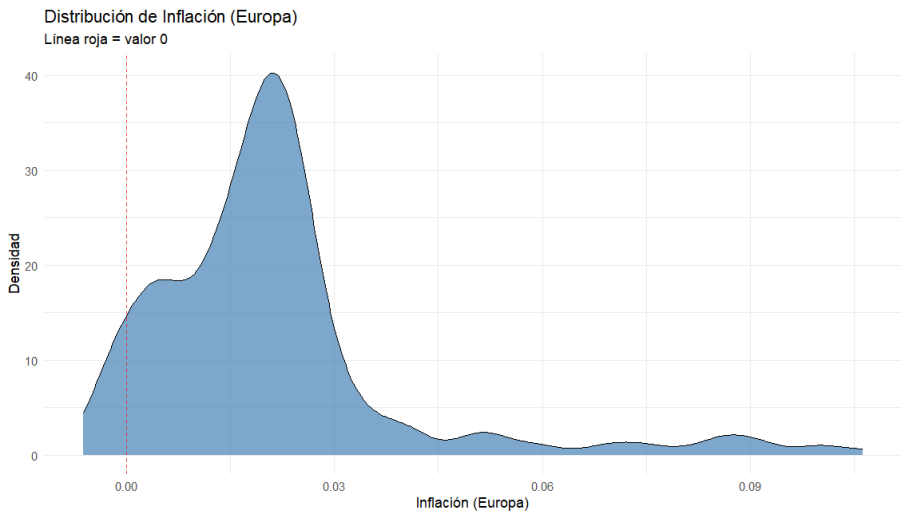

Figura 3.10: Gráfica de la distribución de la inflación en Europa. Fuente: elaboración propia.

- **Distribución de la tasa de desempleo USA:** La tasa de desempleo, representada en la Figura 3.11, cuenta con una media del 5,73 % y una volatilidad mensual del 2,06 %, alcanzó su mínimo histórico del 3,4 % en diciembre de 2019, reflejando un mercado laboral bastante boyante antes de la pandemia. Sin embargo, el máximo del 14,8 % en abril de 2020, tras dicha pandemia, constituye un evento extremo reflejado en su curtosis de 4,01. Todo lo mencionado es visible en la Figura 3.11.

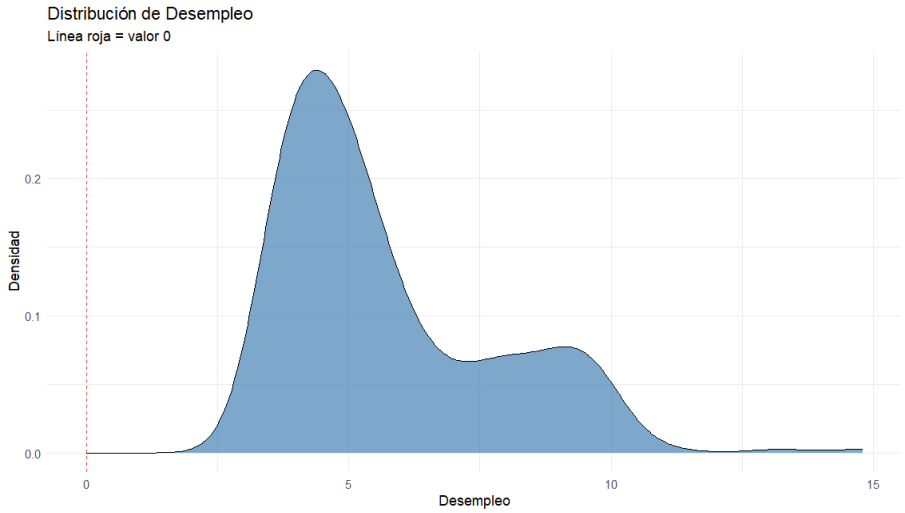

Figura 3.11: Gráfica de la distribución de la tasa de desempleo en Estados Unidos. Fuente: elaboración propia.

- **Distribución del bono 10Y-2Y USA:** En la Figura 3.12 se muestra el diferencial entre el bono a 10 años y a 2 años, que presenta una media positiva del 1,01 % y una volatilidad mensual del 0,95 %, indicando una pendiente ligeramente creciente. El mínimo de -1,06 % se presenta en julio de 2022. También se registraron inversiones importantes en 2006-2007 y en 2019. El hecho de que la *skewness* sea 0,122 y la curtosis esté cercana a la normal indica una distribución simétrica. .

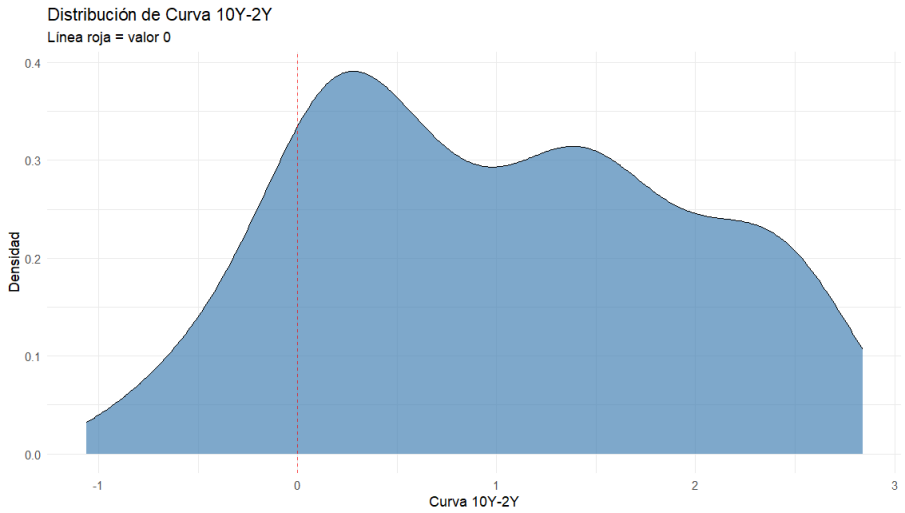

Figura 3.12: Distribución del diferencial de la curva de tipos 10Y-2Y.

- **Distribución del tipo de cambio euro/dólar:** Por último, el tipo de cambio euro-dólar, que se muestra en la Figura 3.13, presenta una media de 1,227 dólares por euro, reflejando un euro generalmente más fuerte que el dólar

durante el período analizado. El valor máximo es de 1,576 y se alcanzó en abril de 2008. Por el contrario, el mínimo de 0,983 se registró en septiembre de 2022, momento en el cual el euro se equiparó con el dólar en cuanto a valor. La desviación típica de 0,129 refleja una volatilidad moderada, y la curtosis de 2,51 indica una distribución cercana a la normalidad.

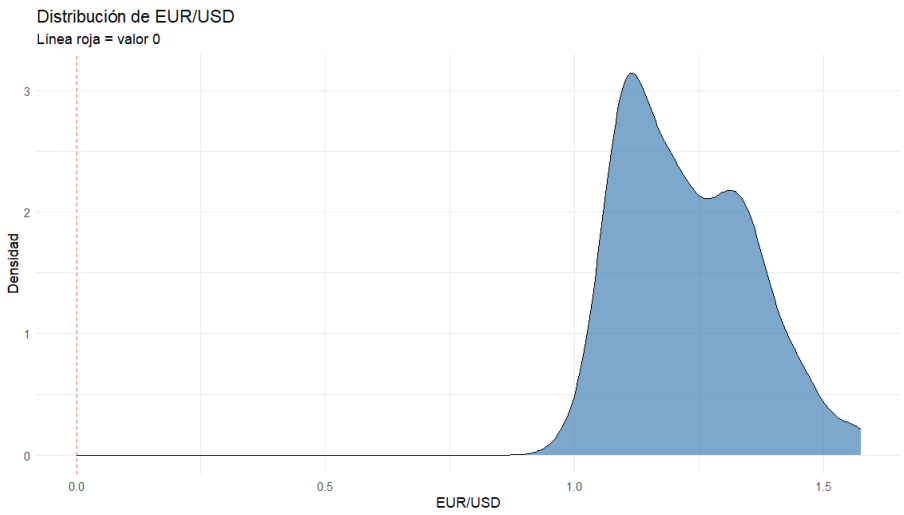

Figura 3.13: Distribución del tipo de cambio euro-dólar.

- **Resumen de la distribución de las variables macroeconómicas:** El análisis de las distribuciones revela que las variables macroeconómicas presentan, en su mayoría, distribuciones con colas pesadas (curtosis >3), lo que confirma la presencia de eventos extremos en los mercados financieros. Destaca especialmente el petróleo (curtosis 22,5) y el VIX (curtosis 8,69) como las variables con mayor concentración de episodios extremos. La asimetría negativa del S&P 500 (-0,618) sugiere que las caídas abruptas son más probables que las subidas extraordinarias, un patrón común en renta variable. Estos hallazgos justifican la necesidad de utilizar modelos robustos que capturen adecuadamente estos eventos extremos en la fase de predicción.

  En lo que respecta a la volatilidad, esta no es constante en el tiempo, sino que presenta picos que coinciden con períodos de crisis o eventos extraordinarios. Como se puede observar en la Figura 3.14, estos picos se concentran especialmente en 2008 (crisis financiera global), 2020 (pandemia de COVID-19) y 2022 (guerra de Ucrania e inflación descontrolada), momentos en los que la incertidumbre en los mercados se disparó. Conocer la volatilidad de las variables resulta importante, ya que aquellas variables con una mayor volatilidad (petróleo o VIX) implican que la variable presenta fluctuaciones más bruscas y eventos extremos con mayor frecuencia, lo que obliga a los modelos predictivos a ser robustos y capaces de capturar estos picos. Por el contrario, una menor volatilidad indica comportamientos más estables y predecibles.

Todos los períodos que se han mencionado a lo largo de este análisis se verán más adelante, en la parte de clustering, de forma más detallada y completa.

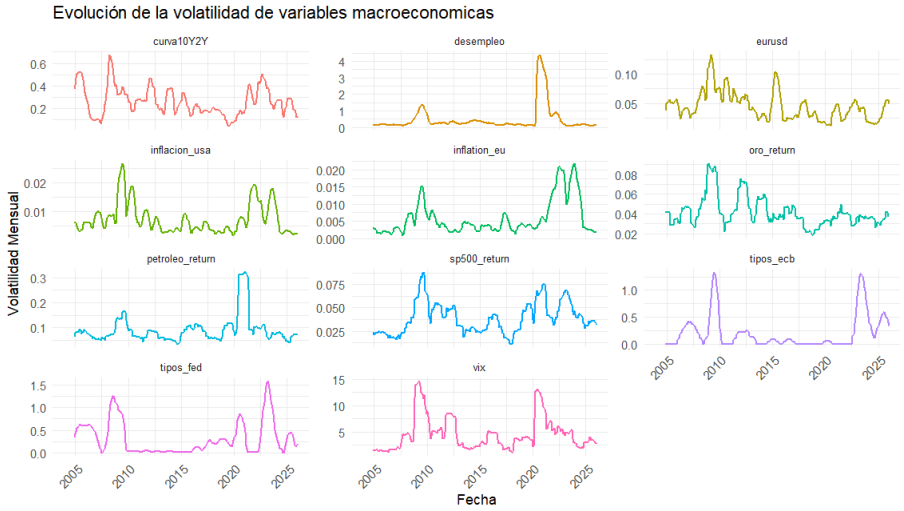

Figura 3.14: Evolución de la volatilidad de las variables macroeconómicas (2003-2025).

Evolución temporal de las variables

Este análisis, permitirá conocer cómo han avanzado las variables macroeconómicas a lo largo del tiempo y comprobar la presencia de tendencias y de los eventos extremos mencionados anteriormente.

- **Tipos de interés:** En la Figura 3.15 se puede ver la evolución de los tipos de interés de la Reserva Federal (Fed) [38] y del Banco Central Europeo (BCE) [39] desde diciembre de 2003 hasta diciembre de 2025.

  Antes de la crisis de 2008, ambos bancos mantuvieron los tipos en niveles altos para combatir la inflación. Sin embargo, con el estallido de la crisis financiera en 2008, ambos los bajaron drásticamente, situándose cerca del 0 %.

  Desde 2008 hasta 2015, la FED mantuvo los tipos en mínimos, y no fue hasta diciembre de 2015 cuando comenzó a subirlos de nuevo, alcanzando el 2,4 % en julio de 2019. Sin embargo, la llegada del COVID en 2020 volvió a llevarlos a valores cercanos al 0 % en abril de ese mismo año. Esta situación se prolongó durante dos años, hasta que en enero de 2022 la FED inició una nueva subida, alcanzando un máximo del 5,33 % en octubre de 2023. En los últimos meses, debido a ciertos conflictos bélicos y a la desaceleración económica, los tipos han experimentado una pequeña bajada.

  Por el lado del BCE, la recuperación fue mucho más lenta. Tras la crisis de 2008, este banco no empezó a subir tipos hasta junio de 2022. De he-

cho, entre 2008 y 2022, los tipos europeos sufrieron una bajada continua, llegando a alcanzar un mínimo histórico del -0,50 % en octubre de 2019 (tipos negativos). Sin embargo, al igual que la FED, a partir de 2022 los tipos subieron con fuerza, alcanzando un máximo del 4

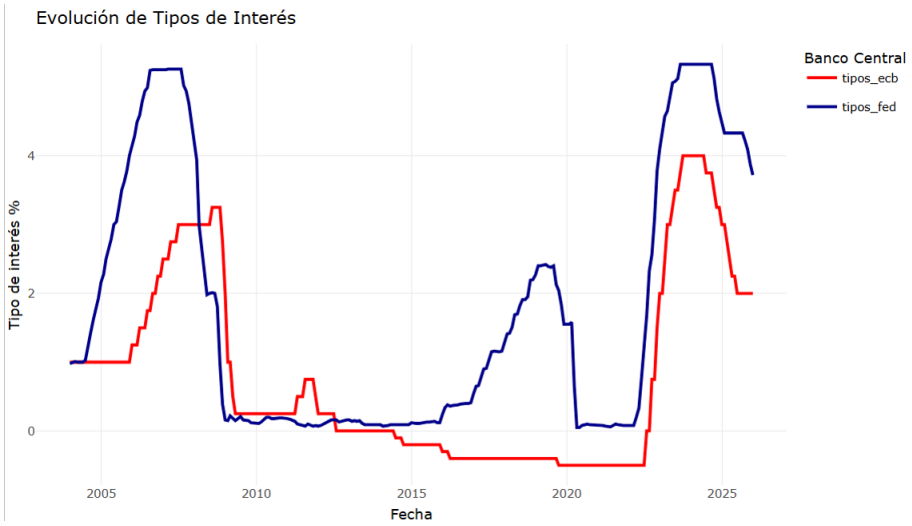

Figura 3.15: Evolución de los tipos de interés de la Reserva Federal y del Banco Central Europeo (2003-2025). Fuente: elaboración propia.

- **Inflación:** En la Figura 3.16 se puede ver la evolución de la inflación en Estados Unidos y en Europa desde diciembre de 2003 hasta diciembre de 2025.

  Se puede observar que antes de la crisis de 2008, la inflación se mantuvo controlada en torno al 2-3 % en ambas regiones. Sin embargo, con la crisis financiera de 2008, la inflación se desplomó. Estados Unidos llegó a tener deflación (inflación negativa) en 2009, mientras que Europa también sufrió esa deflación, pero en menor medida, quedando cerca del 0 %.

  A finales de 2009, ambas regiones empezaron a recuperarse y hasta 2015 mantuvieron una inflación en torno al 2 %. Sin embargo, a inicios de 2015, tanto Europa como Estados Unidos sufrieron una nueva deflación debido a la caída del precio del petróleo.

  Entre 2015 y 2017, la inflación volvió a subir, llegando de nuevo cerca del 2 %. Estos valores se mantuvieron durante dos años, hasta que en 2019, con el COVID, volvió a bajar, situándose de nuevo en valores negativos en 2020.

  Sin embargo, todo cambió en 2021. Después del COVID, la inflación se disparó como no se había visto en décadas. Estados Unidos alcanzó su máximo del 9 % en junio de 2022, mientras que Europa llegó al 10,6 % en octubre de ese mismo año, superando a Estados Unidos por primera vez en todo el período.

Desde 2023 en adelante, la inflación ha ido bajando gradualmente, alcanzando de nuevo valores cercanos al 2 % en 2024, unos valores que se han mantenido hasta 2025.

En esta gráfica se puede ver lo mencionado anteriormente: los eventos extremos son frecuentes y tienden a ser al alza.

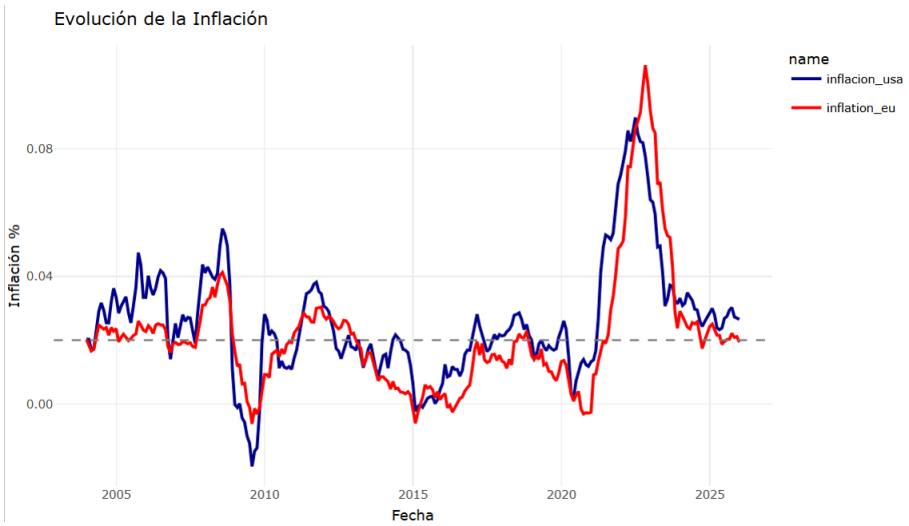

Figura 3.16: Evolución de la inflación en Estados Unidos y Europa (2003-2025). Fuente: elaboración propia.

- **S&P 500 vs VIX:** En la Figura 3.17 se compara la evolución del S&P 500 con el VIX.

  Lo primero que llama la atención es la relación inversa entre ambos, es decir, cuando el VIX se dispara, el S&P 500 suele caer, y viceversa.

  El mayor pico del VIX se vivió en 2008, con la crisis financiera, alcanzando casi los 60 puntos en octubre, siendo este su máximo histórico. Por otro lado, el S&P 500 llegó a caer más de un 40 % desde sus máximos en 2008-2009.

  Entre 2009 y 2019 se vivió una larga etapa de tranquilidad. El VIX se mantuvo en niveles bajos (entre 15 y 20), exceptuando algunos picos en 2010, 2011 y 2015. Por otro lado, el S&P 500 no paró de subir durante una década, multiplicándose por cuatro su valor desde los mínimos de 2009.

  En 2020, con el COVID, el VIX volvió a dispararse hasta los 53,4 puntos. Esto conllevó la caída del S&P 500; sin embargo, no fue muy drástica y apenas perdió un 5 %.

  Entre 2021 y 2023, el VIX se quedó en niveles medios-altos (20-25), reflejando la incertidumbre por la inflación, la guerra y la subida de tipos. El S&P 500 se estancó, sin una tendencia clara, bajando y subiendo constantemente.

Finalmente, en 2024 y 2025, el VIX recuperó niveles bajos y el S&P 500 recuperó una tendencia al alza, subiendo de nuevo su valor.

En la gráfica se puede apreciar el alto valor de la curtosis de ambas variables.

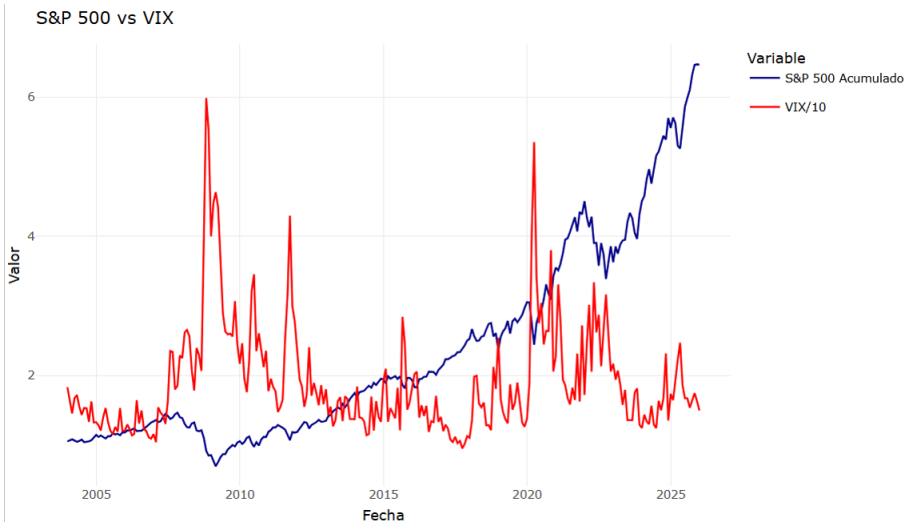

Figura 3.17: Evolución del S&P 500 y del VIX (2003-2025). Fuente: elaboración propia.

- **Oro vs Petróleo:** En la Figura 3.18 se puede ver cómo han evolucionado los retornos del petróleo y del oro desde diciembre de 2003 hasta diciembre de 2025. Esto permite comparar su comportamiento a largo plazo.

  El principal evento a destacar es la crisis de 2008, cuando ambos cayeron, aunque el petróleo sufrió un desplome mucho más fuerte, cayendo hasta un 60 %, mientras que el oro resistió mucho mejor, cayendo solo un 20 % debido a su cualidad de activo refugio.

  Entre 2009 y 2011, el oro siguió subiendo de forma continua. Por otro lado, el petróleo también se recuperó, pero sin llegar a los niveles de 2008.

  Entre 2012 y 2019, el oro se tomó un respiro y bajó. El petróleo, en cambio, sufrió dos caídas adicionales: una en 2014-2015 y otra en 2018.

  En 2020 llegó el COVID y, con ello, el precio del petróleo cayó drásticamente. El oro, por el contrario, creció bastante, haciendo así que la diferencia entre ambos fuese enorme.

  Entre 2021 y 2025, se puede observar cómo los retornos del oro han ido creciendo de forma continua, mientras que los del petróleo han sido un poco más estacionarios.

  En la gráfica se puede apreciar la alta volatilidad y curtosis del petróleo, así como la alta curtosis del oro, aunque no tan alta como la del petróleo.

Figura 3.18: Evolución de los retornos del oro y del petróleo (2003-2025). Fuente: elaboración propia.

- **Desempleo vs Curva de tipos 10Y-2Y:** En la Figura 3.19 se muestra la comparación entre la Curva de Tipos 10Y-2Y y el desempleo.

  Se puede observar cómo, en la gráfica, la curva se encontraba en valores negativos (curva invertida) durante gran parte de los años 2006 y 2007 y, tal y como se ha visto anteriormente, en 2008 se produjo una gran crisis financiera. Este suceso coincide con el aumento de la tasa de paro, que durante dicha crisis alcanzó valores muy altos, llegando hasta el 10 %.

  Después de la crisis, entre 2008 y 2009, la curva tomó valores positivos debido a la recuperación del mercado.

  Entre 2010 y 2018, la curva se mantuvo positiva todo el tiempo, hasta que en 2019 volvió a invertirse brevemente, anticipando así la recesión que se produciría por el COVID. Del mismo modo, entre 2010 y 2018, la tasa de desempleo estuvo en constante bajada; sin embargo, al igual que la curva de tipos, en 2019 con el COVID, la tasa de desempleo sufrió un fuerte aumento, alcanzando máximos históricos cercanos al 15 %. Después del COVID, entre 2020 y 2021, la curva se puso muy positiva, pero en 2022 volvió a valores negativos, esta vez de forma profunda y duradera. La curva se mantuvo en terreno negativo durante todo 2023, con un mínimo de -1,06 % en julio de 2022. Sin embargo, a diferencia de situaciones anteriores, pese a encontrarse la curva en valores negativos, la tasa de desempleo no siguió creciendo; de hecho, bajó exponencialmente hasta valores cercanos al 5 %.

  Finalmente, en 2024 y 2025, la curva volvió a terreno positivo y la tasa de desempleo se estabilizó, con valores muy constantes durante estos años.

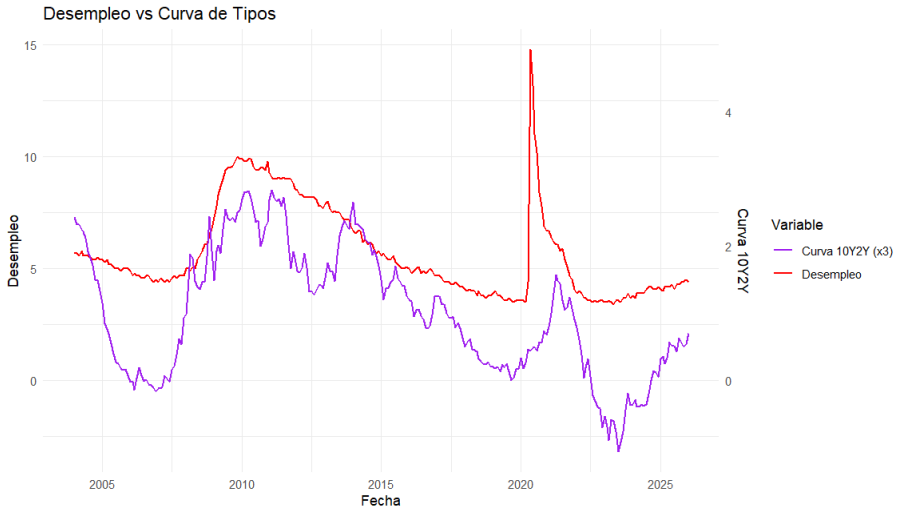

Figura 3.19: Evolución de la curva de tipos 10Y-2Y y la tasa de desempleo en Estados Unidos (2003-2025). Fuente: elaboración propia.

Detección de datos atípicos

A continuación, en la Figura 3.20 se visualizan los diagramas de *boxplots*. En ellos se detectan algunos outliers. Estos outliers no se eliminan, ya que en el ámbito financiero representan información valiosa sobre crisis y eventos extraordinarios que el modelo debe aprender a manejar.

El S&P 500 presenta 6 outliers inferiores que representan las caídas en 2008 y 2020, y 3 outliers superiores, como el de abril de 2020. El VIX destaca con 12 outliers superiores, reflejando picos de pánico en 2008, 2020 y 2022-2023. El petróleo muestra 6 outliers inferiores, donde cabe destacar la caída del -40,8 % en marzo de 2020, y 2 superiores, como el rebote del 88,4 % en mayo de 2020. El oro presenta 4 outliers inferiores y 3 superiores.

La inflación es la variable con más outliers. En el caso de Estados Unidos, presenta 17 outliers superiores, siendo el más destacado el pico del 9 % en 2022. Por otro lado, Europa cuenta con 22 outliers superiores, destacando el pico del 10,6 % en octubre de 2022. En cuanto al desempleo, este tiene 3 outliers superiores debidos a la pandemia. Los tipos de interés de la FED y del BCE, la curva 10Y2Y y el tipo de cambio no presentan outliers.

En resumen, tal y como era de esperar, los outliers se concentran en la crisis financiera, la pandemia y el episodio inflacionario, afectando principalmente a la inflación, el VIX y el petróleo. Estos valores extremos se mantienen en el dataset para que los modelos de Machine Learning aprendan a manejar situaciones extremas.

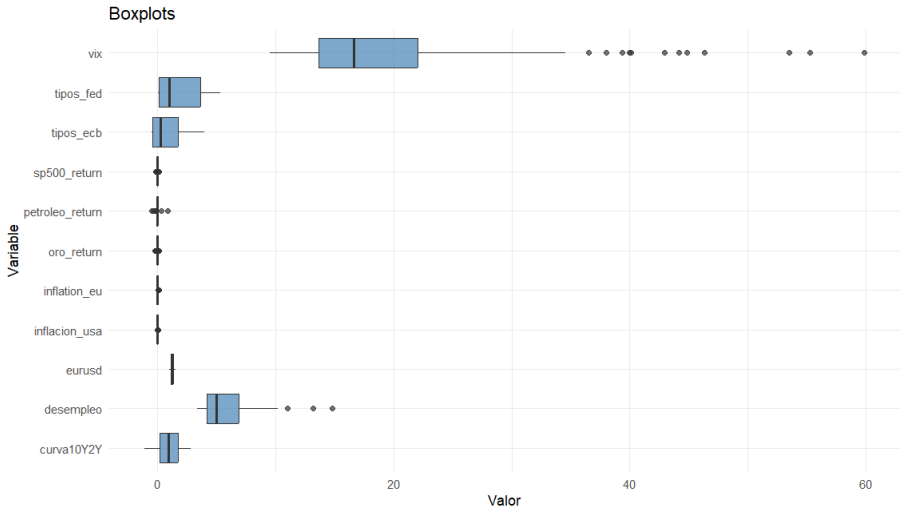

Figura 3.20: Boxplots de las variables macroeconómicas. Fuente: elaboración propia.

Análisis de autocorrelación

Para finalizar con el análisis univariante, se realiza un análisis de autocorrelación. Este permite entender la memoria temporal de cada variable, es decir, cómo influyen sus valores pasados en los presentes. Este paso resulta muy importante para la fase de modelado, ya que indica qué variables pueden requerir la inclusión de sus retardos como predictores y cuáles son buenas candidatas para modelos con memoria larga, como las redes LSTM.

En las Figuras 3.21, 3.22 y 3.23 se muestran las funciones de autocorrelación para las variables macroeconómicas y para el rendimiento de Apple. En estas figuras se aprecia cómo, tanto en los retornos del S&P 500 como en los del petróleo y del oro, solo el primer lag supera las bandas de significancia (líneas azules), mientras que el resto de los lags se mantienen dentro del intervalo de confianza. Esto indica que los retornos pasados tienen muy poca influencia sobre los retornos actuales. Para el modelo, esto sugiere que con incluir el valor actual de las variables será suficiente.

El VIX, por el contrario, muestra varios lags que superan el intervalo de confianza. Esto sugiere que incluir varios de sus valores pasados (lags 1, 2 y 3) puede ayudar a capturar mejor la dinámica del riesgo en el mercado.

Por otro lado, los tipos de interés de la Reserva Federal y del Banco Central Europeo presentan una correlación muy alta y persistente, con múltiples lags significativos y una caída extremadamente lenta de los coeficientes. Es por ello que los tipos de interés son candidatos ideales para modelos como las redes **LSTM**.

En lo que respecta a la inflación, tanto en Estados Unidos como en Europa, muestra un comportamiento similar al de los tipos de interés, con alta persistencia y numerosos lags significativos. Al igual que los tipos, la inflación es una

variable con memoria larga que se beneficiará de modelos capaces de capturar sus efectos retardados.

Tanto el desempleo como la Curva de Tipos 10Y-2Y y el tipo de cambio euro-dólar presentan una autocorrelación muy alta y persistente.

Finalmente, el rendimiento de Apple presenta baja autocorrelación, lo que indica que los valores pasados no influyen significativamente en el rendimiento futuro. No obstante, en modelos no lineales como Random Forest o LSTM, estos lags pueden seguir siendo útiles al interactuar con otras variables.

En resumen, el análisis de autocorrelación permite clasificar las variables según su memoria temporal. Los retornos financieros presentan baja memoria, por lo que bastará con sus valores actuales. El VIX tiene memoria media, por lo que podría ser de utilidad añadir varios lags recientes. Lo mismo sucede con los tipos de interés, la inflación, el desempleo y la curva de tipos. Toda esta clasificación será utilizada en la fase de modelado para seleccionar los retardos adecuados para cada variable predictora, justificar el uso de LSTM para las variables con alta persistencia y optimizar la dimensionalidad del modelo, evitando lags innecesarios en variables con baja memoria.

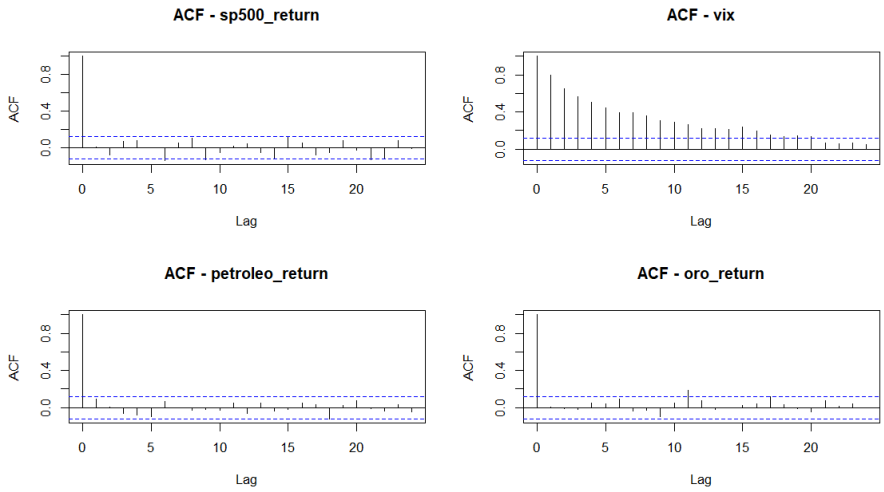

Figura 3.21: Gráficas de autocorrelación del VIX y los retornos del S&P 500, oro y petróleo. Fuente: elaboración propia.

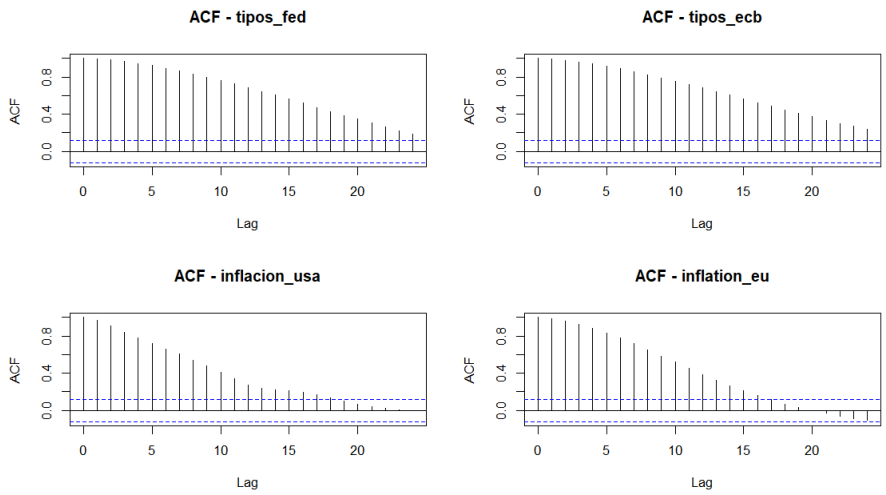

Figura 3.22: Gráficas de autocorrelación para tipos de interés e inflación. Fuente: elaboración propia.

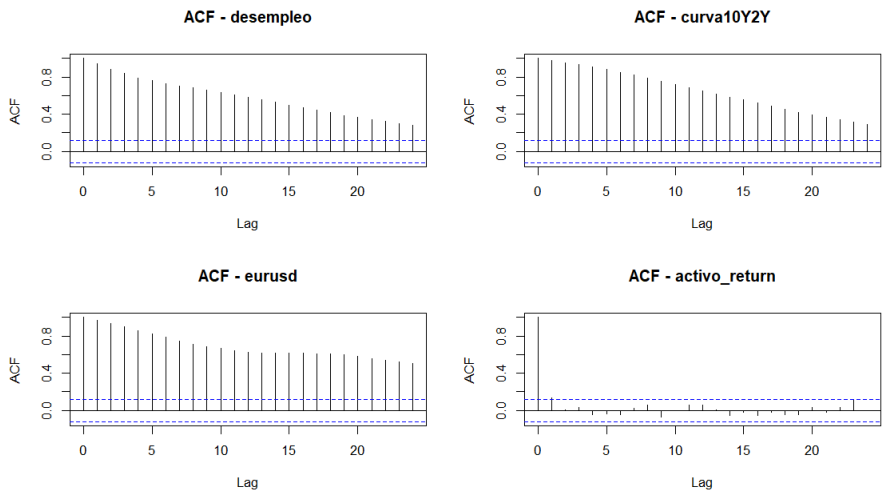

Figura 3.23: Gráficas de autocorrelación para desempleo, curva de tipos y rendimiento de Apple. Fuente: elaboración propia.

3.3.2. Análisis multivariante

En esta sección, se realiza un análisis multivariante de las variables seleccionadas. Este análisis tiene como objetivo entender las relaciones entre las variables, identificar posibles redundancias y reducir la dimensionalidad del dataset para mejorar la eficiencia de los modelos predictivos. Para ello, se aplicarán técnicas como el análisis de correlación, el análisis de componentes principales **(PCA)** y el análisis de **clusters**.

Correlación entre variables

Comenzando con la correlación, en la Figura 3.24 se puede ver la matriz de correlación entre las variables. Se distinguen dos tonalidades: un azul oscuro que indica una correlación de +1 (las variables se comportan igual) y un rojo oscuro que indica una correlación inversa de -1 (se comportan de forma opuesta: si una sube, la otra baja). Los valores más cercanos al blanco indican que las variables tienen correlaciones cercanas a 0, por lo que podría decirse que no están correlacionadas.

En dicha matriz se puede observar que las correlaciones más fuertes son entre la inflación de Estados Unidos y la de Europa, con un valor de 0,86, y entre los tipos de la FED y los del BCE, con un valor de 0,81. Esto se puede apreciar en las gráficas presentadas en la evolución temporal de cada una de las variables, donde se puede ver esta correlación positiva. Por otro lado, destaca la correlación inversa entre el desempleo y la curva 10Y2Y (-0,74), esto se puede comprobar también, fijándose en la gráfica de la evolución temporal entre la curva y el desempleo, cuando una sube la otra baja.

Realizar este análisis de correlaciones resulta muy importante, ya que en caso de haber obtenido valores muy altos (>0,9), se habría planteado eliminar ciertas variables para no introducir ruido al entrenar los modelos predictivos. Más adelante, en la sección de selección de variables, se determinará si estas variables se mantienen o se eliminan. En el caso de que se mantengan todas las variables, sería por dos razones, en primer lugar, los modelos de Machine Learning que se emplearán (Random Forest, Gradient Boosting y LSTM) son robustos a la multicolinealidad, a diferencia de los modelos lineales tradicionales. En segundo lugar, mantener ambas variables permite capturar posibles asimetrías entre regiones, como el hecho de que en 2022 la inflación europea superara a la americana, algo que no recogería una variable única.

No obstante, se tendrá en cuenta esta alta correlación en la fase de interpretación de los modelos, especialmente al analizar la importancia de las variables.

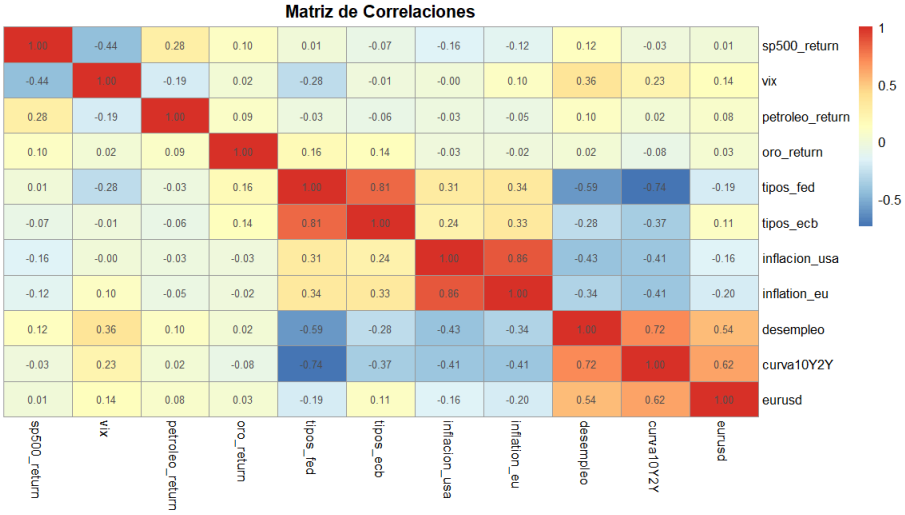

Figura 3.24: Matriz de correlación entre las variables macroeconómicas. Fuente: elaboración propia.

Correlación con el target

Para justificar el uso de los modelos elegidos, se ha llevado a cabo un analisis de correlación entre las variables macroeconómicas y el target.

En la Figura 3.25 se pueden ver las correlaciones entre las variables macroeconómicas y el rendimiento del activo utilizado para las pruebas, que en este caso es Apple. Lo primero que llama la atención es que ninguna correlación supera 0,12 en valor absoluto, lo que indica que la relación entre estas variables y Apple no es lineal, lo cual no es negativo. Más adelante en esta sección se verá el motivo.

La variable con mayor correlación positiva es el petróleo, con un valor de 0,12, seguida del S&P 500, con 0,10. En el lado negativo, la inflación europea, con un valor de -0,08, y la inflación estadounidense, con -0,06, son las que presentan correlaciones más negativas. Por último, destaca la correlación casi nula del VIX (-0,02) con Apple, lo que se debe a que los picos de volatilidad son episódicos y no lineales.

El hecho de obtener correlaciones tan bajas indica que un modelo lineal simple no será suficiente para capturar la relación entre las variables macroeconómicas y Apple. Será necesario recurrir a modelos no lineales como Random Forest, Gradient Boosting o LSTM, que puedan capturar relaciones más complejas y efectos retardados.

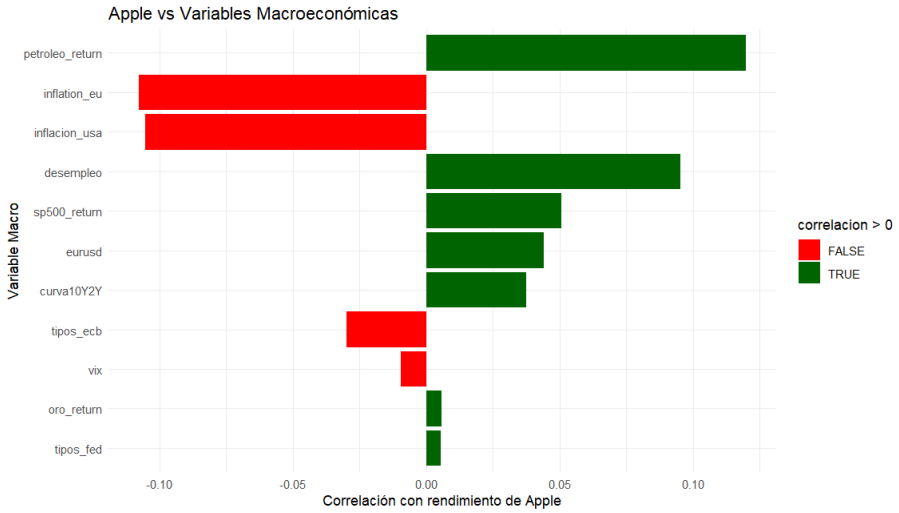

Figura 3.25: Correlaciones entre las variables macroeconómicas y el rendimiento de Apple. Fuente: elaboración propia.

Análisis de componentes principales (PCA)

A continuación, se realiza un análisis de componentes principales (PCA) con el objetivo de reducir la dimensionalidad del conjunto de datos, identificando un conjunto de variables no correlacionadas que capturen la mayor parte de la variabilidad del sistema. Los componentes principales se ordenan de mayor a menor según la cantidad de varianza que explican. El primer componente principal (PC1) es la combinación lineal de las variables originales que representa la máxima varianza posible. El PC2, que no está correlacionado con el PC1, captura la máxima varianza restante, y así sucesivamente. De esta forma, es posible determinar cuántas dimensiones son necesarias para resumir la información contenida en las variables originales.

En la Figura 3.26 se muestra la varianza explicada por cada componente principal. Los primeros cuatro componentes explican el 73,8 % de la varianza total: PC1 representa un 33,4 %, PC2 un 16,4 %, PC3 un 13,1 % y PC4 un 10,9 %. Esto indica que la información contenida en las once variables macroeconómicas originales puede resumirse en un número reducido de dimensiones. A partir del quinto componente, la varianza explicada por cada uno es inferior al 9 %, lo que confirma que los cuatro primeros componentes capturan la mayor parte de la estructura del sistema.

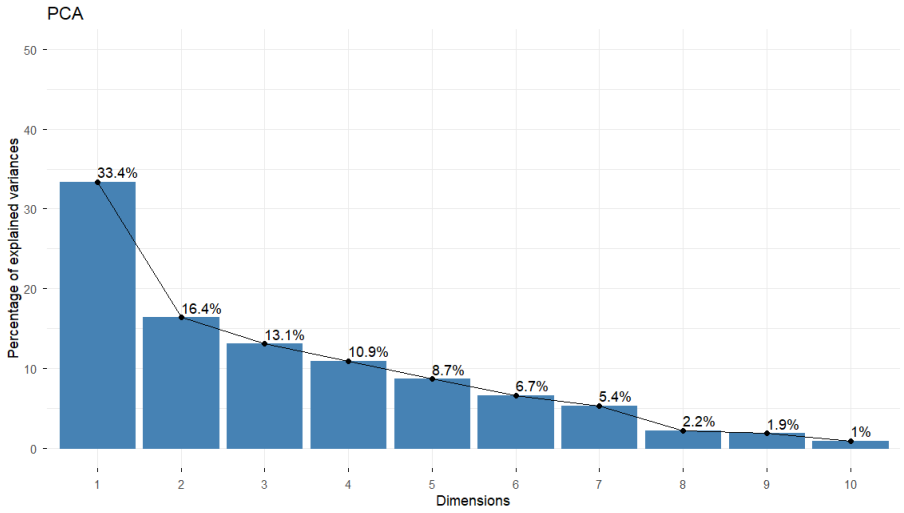

Figura 3.26: Varianza explicada por cada componente principal. Fuente: elaboración propia.

Las Figuras 3.27, 3.28, 3.29 y 3.30 muestran la contribución de cada variable a los cuatro primeros componentes principales, lo que permite interpretar su significado económico.

- **PC1:** Comenzando con el PC1, este está definido por la curva de tipos (21 %), los tipos de la FED (18,5 %) y el desempleo (17,8 %). En este componente, los valores altos indican un entorno de tipos elevados, curva normal y desempleo controlado, mientras que los valores bajos indican tipos bajos o recesiones cercanas.El primer componente principal (PC1) está fuertemente influenciado por la inflación (tanto en Estados Unidos como en Europa), los tipos de interés (FED y BCE) y el desempleo. Esto sugiere que PC1 representa un factor macroeconómico general que captura la dinámica de la política monetaria y las condiciones económicas. Un aumento en PC1 podría interpretarse como un entorno de alta inflación, tipos de interés elevados y mayor desempleo, lo que suele ser negativo para los activos financieros.

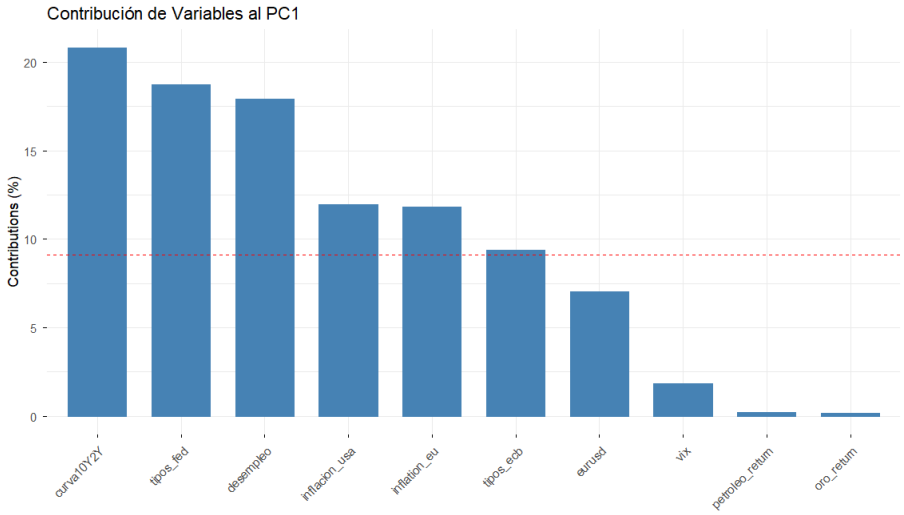

Figura 3.27: Contribución de las variables al primer componente principal (PC1). Fuente: elaboración propia.

- **PC2:** En cuanto al PC2, este se encuentra dominado por el VIX (32 %) y el S&P 500 (29,5 %), que juntos aportan más del 60 % del total. Este componente captura la alternancia entre períodos de expansión (S&P 500 alto, VIX bajo) y crisis (S&P 500 bajo, VIX alto). Cuando el PC1 es positivo, el mercado se encuentra en alza y con baja volatilidad, mientras que cuando es negativo, se está en épocas de recesión.

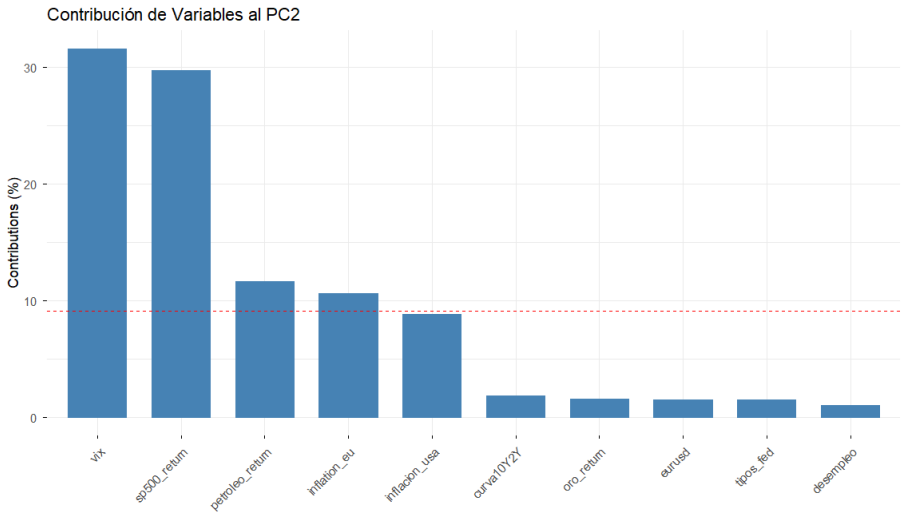

Figura 3.28: Contribución de las variables al segundo componente principal (PC2). Fuente: elaboración propia.

- **PC3:** En el PC3 dominan los tipos del BCE (33 %), la curva de tipos (30,5 %) y el oro (15,5 %). Este componente refleja la política monetaria europea y los activos refugio. Cuando este PC se encuentra alto, puede suponer una

crisis cercana.

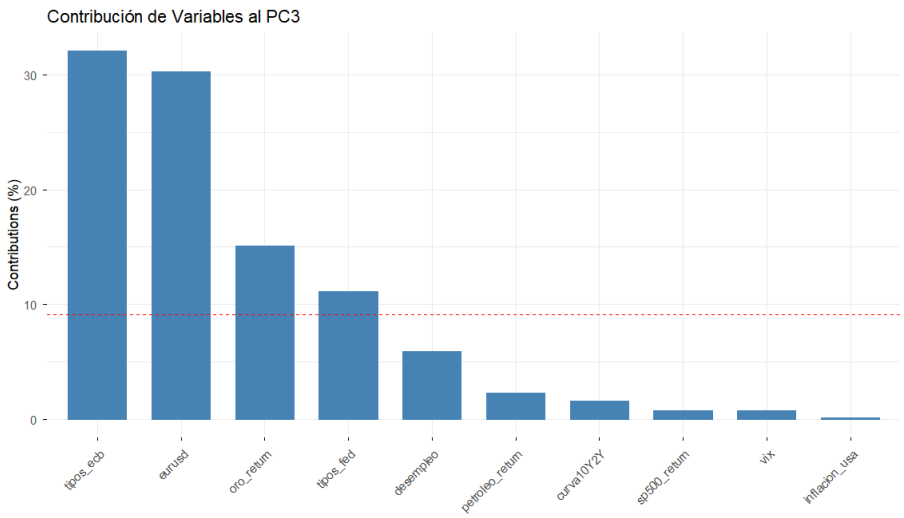

Figura 3.29: Contribución de las variables al tercer componente principal (PC3). Fuente: elaboración propia.

- **PC4:** Finalmente, el PC4 está formado por la inflación de Estados Unidos (28 %), el petróleo (27,5 %) y la inflación europea (25 %). Este componente define básicamente períodos inflacionarios, en los que los precios se disparan. Un ejemplo cercano podría ser el año 2022.

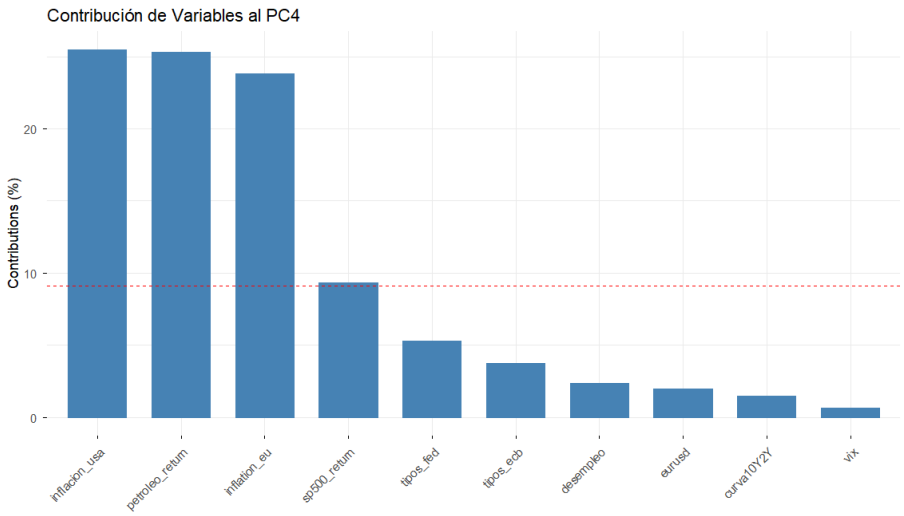

Figura 3.30: Contribución de las variables al cuarto componente principal (PC4). Fuente: elaboración propia.

Tras este análisis de PCA, se confirma que el sistema macroeconómico no está definido por una sola variable, sino que responde a varias dimensiones independientes como las vistas anteriormente. En la fase de modelado se mantendrán

las variables originales en lugar de los componentes principales. Sin embargo, el análisis realizado será de gran utilidad a la hora de seleccionar variables y de interpretar los modelos.

Análisis de clusters

Para finalizar el análisis multivariante, se realiza un análisis de clusters con el objetivo de identificar grupos de períodos temporales que compartan características macroeconómicas similares. Este análisis permite segmentar el dataset en diferentes ciclos económicos, lo que resulta útil para entender mejor la dinámica del sistema y para evaluar el comportamiento de los modelos predictivos en distintos contextos.

En la Figura 3.31 se muestra la segmentación temporal de los seis ciclos económicos identificados entre 2003 y 2025, así como la evolución del activo Apple a lo largo de los mismos. Cada color representa un ciclo diferente, permitiendo observar cuándo comienza y termina cada ciclo, así como su duración.

El primer ciclo, que abarca desde 2003 hasta 2007, corresponde al período de precrisis, caracterizado por un fuerte crecimiento económico. El siguiente ciclo es la crisis financiera de 2008, que abarca desde 2008 hasta 2009 y está marcado por la recesión global y la destrucción masiva de empleo. A continuación, se identifica el período de recuperación de la crisis, un ciclo largo que va desde 2010 hasta 2013 y que refleja las consecuencias de la crisis financiera experimentada anteriormente.

A partir de 2014, la economía comienza a recuperarse y se inicia un periodo de crecimiento económico que representa la fase expansiva más prolongada, con tasas de crecimiento muy altas, tipos de interés en mínimos históricos y una racha alcista prolongada en los mercados. Sin embargo, se pueden encontrar picos en variables como el VIX, provocados por la incertidumbre aún existente. Pese a este crecimiento, en 2019 surge el COVID-19, provocando un parón y una mini crisis que perduró hasta 2021. Este ciclo captura el impacto de la pandemia en la economía.

Finalmente, el período de recuperación y estabilización, que abarca desde 2022 hasta 2025, se caracteriza por la recuperación post-pandemia, con una fuerte inflación y, en consecuencia, una subida muy pronunciada de los tipos de interés durante los primeros años. No obstante, con el paso del tiempo, la situación se estabilizó.

Cabe destacar que, a pesar de la crisis sanitaria y económica provocada por la pandemia, Apple alcanzó máximos históricos en su cotización durante el período 2020-2021. Este comportamiento puede explicarse por varios factores: la percepción de las grandes tecnológicas como activos refugio en momentos de incertidumbre, los tipos de interés en mínimos históricos que favorecieron la valoración de empresas de crecimiento, los estímulos fiscales masivos que incrementaron la liquidez en los mercados, el cambio en los hábitos de consumo hacia la tecnología (provocado por el teletrabajo y la educación online) y los sólidos resultados financieros de la compañía durante la pandemia.

Por último, esta segmentación en seis ciclos será utilizada en la fase de modelado para evaluar el comportamiento de los modelos predictivos en diferentes contextos económicos, permitiendo analizar su robustez tanto en períodos de expansión como en situaciones de crisis.

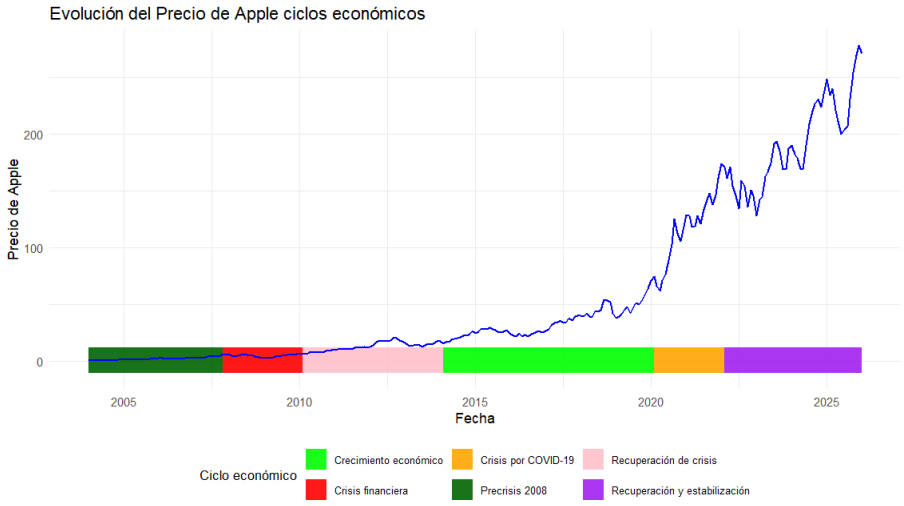

Figura 3.31: Segmentación temporal de los seis ciclos económicos (2003-2025) y evolución de Apple durante cada ciclo. Fuente: elaboración propia.

Para concluir con el clustering, se muestra la importancia de cada variable en cada uno de los ciclos. En las Figuras 3.32 y 3.33 se pueden ver los valores medios de las principales variables macroeconómicas para cada uno de los seis ciclos mencionados anteriormente. Este análisis permite identificar patrones claros que caracterizan cada fase del ciclo económico.

Se puede observar cómo en períodos de expansión y auge, como los de 2003-2007 y 2014-2019, el crecimiento del S&P 500 es elevado, la volatilidad es baja, la inflación está controlada, los tipos de interés se encuentran en niveles normales o bajos y el desempleo está en descenso. Estas variables reflejan una economía sana y próspera.

Por otro lado, el período de la crisis de 2008-2009 se caracteriza por un VIX muy alto, alcanzando valores por encima de 40. A su vez, el S&P 500 cae con fuerza, la inflación se desploma, los tipos de interés se reducen a cero y el desempleo comienza a aumentar. A diferencia del período anterior, este muestra una economía debilitada y cercana al colapso.

Entre 2010 y 2013, en el período de recuperación de la crisis, el VIX se mantuvo elevado, el S&P 500 se recuperó gradualmente y la inflación se mantuvo en valores muy bajos. Por otro lado, los tipos se mantenían en mínimos; sin embargo, el desempleo alcanzó su punto máximo en 2010. Estos datos reflejan un escenario con una economía aún bastante débil, pero con signos de mejoría.

Durante el ciclo de la crisis por el COVID-19, se pueden encontrar similitudes con la crisis de 2008, ya que ambos períodos se caracterizan por una volatili-

dad muy alta. No obstante, durante el COVID la recuperación fue bastante más rápida: los tipos volvieron a cero y el S&P 500 se recuperó significativamente, alcanzando nuevos máximos en menos de un año.

Por último, en el período de recuperación y estabilización, se presenta un patrón único: la inflación alcanza máximos históricos, provocando que los tipos de interés también alcancen máximos. Debido a esto, la curva de tipos se invierte profundamente, anticipando una posible recesión. A pesar de ello, el S&P 500 muestra resistencia, creciendo pese a las dificultades económicas iniciales.

Tras este análisis, se confirma que cada ciclo está marcado por una serie de características. Los períodos de expansión se asocian con baja volatilidad y crecimiento sostenido; las crisis presentan picos de volatilidad y bajadas de los tipos de interés; y los períodos de alta inflación suelen conllevar subidas de tipos. Estos datos serán de gran utilidad en la fase de modelado a la hora de realizar la simulación de escenarios.

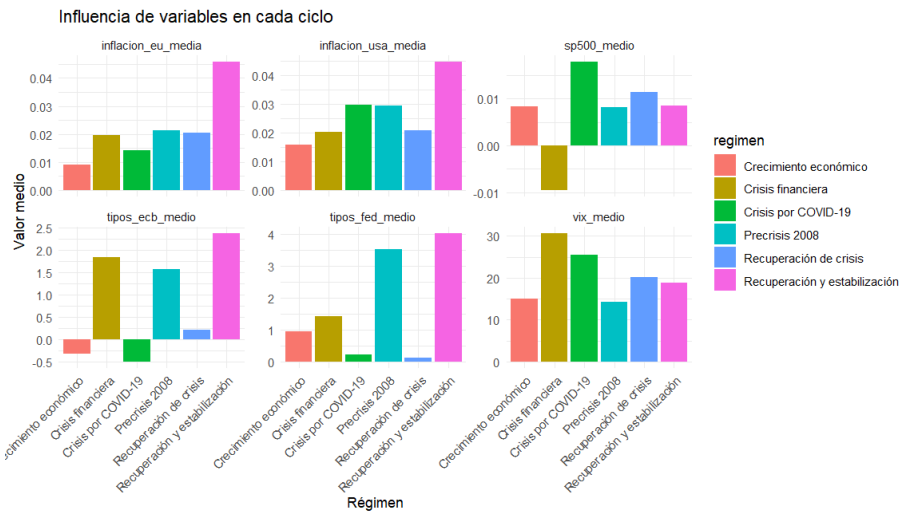

Figura 3.32: Valores medios de las variables macroeconómicas por ciclo económico (parte 1). Fuente: elaboración propia.

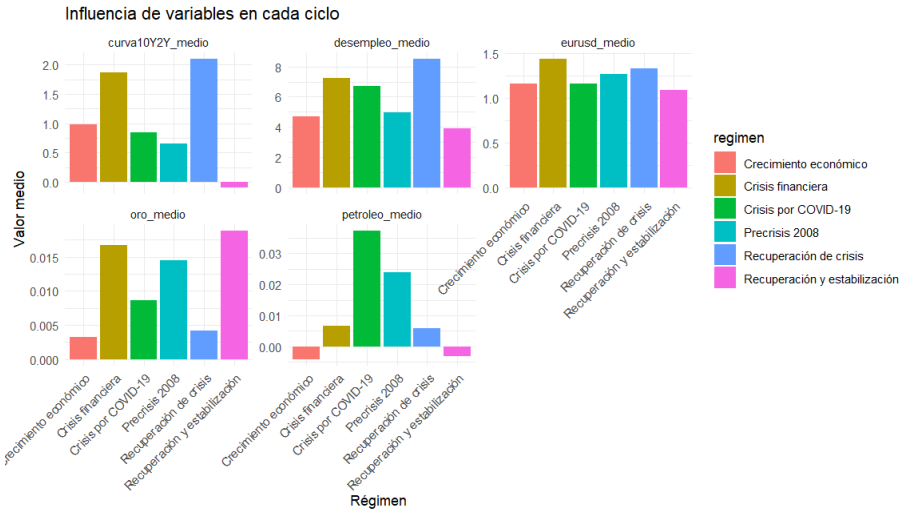

Figura 3.33: Valores medios de las variables macroeconómicas por ciclo económico (parte 2). Fuente: elaboración propia.

3.4. Selección de variables y dataset final

Una vez completado el análisis exploratorio de datos, el siguiente paso fundamental es la selección de las variables que conformarán el dataset definitivo para el entrenamiento de los modelos predictivos. El objetivo es maximizar la información relevante, eliminar redundancias y reducir la dimensionalidad del problema, mejorando así la eficiencia computacional y la capacidad de generalización de los modelos.

Cabe destacar que este proceso de selección se ha ejemplificado utilizando Apple como activo de estudio. En una aplicación real de esta metodología a otro fondo de inversión o activo financiero, los resultados podrían variar, ya que la relación entre las variables macroeconómicas y el target depende del activo concreto analizado. Por esta razón, se ha implementado un proceso automatizado en Python que permite replicar la selección de variables de forma sistemática para cualquier activo o fondo de inversión, garantizando así la reproducibilidad y escalabilidad del método.

3.4.1. Criterios de selección

La estrategia de selección de variables se ha basado en dos criterios complementarios:

1. **Información mutua (Mutual Information - MI)** [40]: Mide la dependencia estadística entre cada variable predictora y el rendimiento del target. Para calcularla se ha utilizado el método de discretización uniforme en 10 bins, simulando el enfoque habitual en el software R, lo que permite capturar relaciones no lineales. Las variables se ordenan de mayor a menor MI.

2. **Correlación entre predictores** [41]: Una vez ordenadas las variables por

MI, se recorre la lista y se eliminan aquellas que presentan una correlación de Pearson superior a 0,80 con alguna variable ya seleccionada, quedándose así con la de mayor MI dentro de cada grupo redundante. Este proceso elimina la redundancia informativa.

Adicionalmente, se ha definido un conjunto de variables macroeconómicas que se mantienen independientemente de su valor de MI por su relevancia conceptual en la literatura financiera. Dichas variables son: el rendimiento del S&P 500 , el índice de volatilidad VIX, los tipos de interés de la Reserva Federal, la curva de tipos 10Y-2Y, la inflación de Estados Unidos y el rendimiento del activo.

3.4.2. Proceso automatizado de selección

Para garantizar la reproducibilidad y objetividad del proceso, se ha implementado una función en Python denominada `seleccion_variables`. El algoritmo sigue los siguientes pasos:

1. **Cálculo de la información mutua**: Se discretizan todas las variables predictoras en 10 bins de anchura uniforme y se calcula la MI con respecto al target utilizando la función `mutual_info_regression` de scikit-learn [13].

2. **Eliminación de redundancia por correlación**: Las variables se ordenan de mayor a menor MI. A continuación, se recorre la lista y se selecciona una variable solo si su correlación con cualquiera de las ya seleccionadas es inferior a 0,80. En caso contrario, se descarta.

3. **Selección por percentil**: Una vez obtenido el conjunto de variables no redundantes, se calcula el percentil 50 de sus valores de MI y se conservan únicamente las que superan dicho umbral. Esto equivale a quedarse con el 50 % de las variables con mayor MI.

4. **Mantenimiento de variables forzadas**: Finalmente, se añaden las variables macroeconómicas forzadas, asegurando así su presencia en el dataset final.

3.4.3. Resultados de la selección

Tras aplicar el proceso de selección sobre el conjunto de datos completo, las variables seleccionadas se muestran en la Tabla 3.1.

Cuadro 3.1: Variables del dataset final

Variable	**Descripción**
media_movil_6m	Media móvil a 6 meses del rendimiento de Apple
lag_3	Retraso de 3 meses del rendimiento de Apple
vix	Índice de volatilidad VIX (forzada)
oro_return	Retorno mensual del oro
eurusd	Tipo de cambio euro/dólar
lag_12	Retraso de 12 meses del rendimiento de Apple
lag_6	Retraso de 6 meses del rendimiento de Apple
volatilidad_3m	Volatilidad móvil a 3 meses del rendimiento de Apple
inflacion_usa	Inflación de Estados Unidos (forzada)
sp500_return	Retorno mensual del S&P 500 (forzada)
tipos_fed	Tipos de interés de la Reserva Federal (forzada)
curva10Y2Y	Diferencial bono 10 años - 2 años (forzada)
activo_return	Rendimiento pasado del activo (forzada)

3.4.4. Creación de datasets para Deep Learning y Machine Learning

Debido a que los modelos de Machine Learning carecen de memoria temporal, mientras que las redes LSTM están diseñadas específicamente para capturar dependencias secuenciales, se han construido dos versiones del dataset:

- **Dataset para Deep Learning (LSTM)**: Contiene únicamente las variables seleccionadas en su valor contemporáneo, sin incluir retardos. La LSTM es capaz de aprender directamente la estructura temporal de la serie.
- **Dataset para Machine Learning**: Parte del mismo conjunto de variables seleccionadas, pero se han añadido retardos (*lags*) de variables económicas, dichas variables son los tipos de interés, la inflación, el VIX, el desempleo y la curva de tipos. De esta forma se proporciona a los modelos de ML información sobre el pasado, y solucionando asi su falta de memoria temporal. Los retrdos que se han incorporado son de 1, 3 y 6 meses para los tipos y la inflación, y de 1, 2 y 3 meses para el VIX, el desempleo y la curva de tipos.

Ambos datasets se han alineado temporalmente eliminando las filas iniciales con valores faltantes debidos a los retardos, garantizando así la comparabilidad de los resultados.

Este dataset final, que consta de 13 variables predictoras y la variable target, será el utilizado para el entrenamiento y evaluación de los modelos Random Forest, Gradient Boosting y LSTM en los capítulos siguientes.

Capítulo 4

Modelos predictivos

Por hacer

Capítulo 5

Experimentos y resultados

Por hacer

Capítulo 6

Conclusiones y trabajo futuro

Resumen de resultados obtenidos en el trabajo, conclusiones sobre los mismos y potencial trabajo futuro si existiera.

Capítulo 7

Análisis de impacto

En este capítulo se realizará un análisis del impacto potencial de los resultados obtenidos durante la realización del trabajo, en los diferentes contextos para los que se aplique:[1]

- Personal
- Empresarial
- Social
- Económico
- Medioambiental
- Cultural

En dicho análisis se destacarán los beneficios esperados, así como también los posibles **efectos adversos**. Además, se harán notar aquellas decisiones tomadas a lo largo del trabajo que tienen como base la consideración del impacto.

Se recomienda analizar también el potencial impacto respecto a los Objetivos de Desarrollo Sostenible (ODS), de la Agenda 2030, que sean relevantes para el trabajo realizado (ver enlace)

[1] Téngase en cuenta que no se espera que un trabajo tenga impacto en todos los contextos

Bibliografía

[1] L. Vancsura et al., «Navigating AI-Driven Financial Forecasting: A Systematic Review of Current Status and Critical Research Gaps», *MDPI*, vol. 7, n.º 3, pág. 36, 2025. dirección: https://www.mdpi.com/2571-9394/7/3/36

[2] S. El Alami, A. Mouiha, A. Hafid y A. E. H. Alaoui, «Machine Learning and Deep Learning in Computational Finance: A Systematic Review», *arXiv preprint arXiv:2511.21588*, 2025. dirección: https://arxiv.org/pdf/2511.21588

[3] MDPI, «From Black Box to Glass Box: A Practical Review of Explainable Artificial Intelligence (XAI)», *MDPI*, 2025. dirección: https://www.researchgate.net/publication/397220182_From_Black_Box_to_Glass_Box_A_Practical_Review_of_Explainable_Artificial_Intelligence_XAI

[4] R. Ye y J. Chen, «Unlocking the Black Box: A Five-Dimensional Framework for Evaluating Explainable AI in Credit Risk», *arXiv preprint arXiv:2511.04980*, 2025. dirección: https://arxiv.org/pdf/2511.04980

[5] Raisin. «Mercados financieros: definición, características y volatilidad», visitado 15 de abr. de 2025. dirección: https://www.raisin.com/es-es/educacion-financiera/mercados-financieros-definicion-caracteristicas-y-volatilidad/

[6] E. F. Fama, «Efficient Capital Markets: A Review of Theory and Empirical Work», *The Journal of Finance*, vol. 25, n.º 2, págs. 383-417, 1970. dirección: http://efinance.org.cn/cn/fm/Efficient%20Capital%20Markets%20A%20Review%20of%20Theory%20and%20Empirical%20Work.pdf

[7] Banco Santander. «¿Qué es un fondo de inversión?», visitado 15 de abr. de 2025. dirección: https://www.bancosantander.es/faqs/particulares/ahorro-inversion/que-es-fondo-inversion

[8] UNIR. «¿Qué son las variables macroeconómicas (VME)?», visitado 15 de abr. de 2025. dirección: https://www.unir.net/revista/empresa/variables-macroeconomicas/

[9] G. E. P. Box y G. M. Jenkins, *Time Series Analysis: Forecasting and Control*. Holden-Day, 1970. dirección: https://repo.darmajaya.ac.id/4781/1/Time%20Series%20Analysis_%20Forecasting%20and%20Control%20%28%20PDFDrive%20%29.pdf

[10] IBM. «¿Qué es la autocorrelación?», visitado 15 de abr. de 2025. dirección: https://www.ibm.com/mx-es/think/topics/autocorrelation

[11] IBM. «¿Qué es el machine learning?», visitado 15 de abr. de 2025. dirección: https://www.ibm.com/es-es/think/topics/machine-learning

[12] scikit-learn developers, *RandomForestRegressor*, scikit-learn, 2025. visitado 17 de abr. de 2025. dirección: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html

[13] F. Pedregosa et al., *scikit-learn: Machine Learning in Python*, 2011. visitado 15 de abr. de 2025. dirección: https://scikit-learn.org/

[14] scikit-learn developers, *GradientBoostingRegressor*, scikit-learn, 2025. visitado 17 de abr. de 2025. dirección: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.GradientBoostingRegressor.html

[15] IBM. «¿Qué es la retropropagación?», visitado 17 de abr. de 2025. dirección: https://www.ibm.com/es-es/think/topics/backpropagation

[16] IBM. «¿Qué es el descenso de gradiente?», visitado 17 de abr. de 2025. dirección: https://www.ibm.com/es-es/think/topics/gradient-descent

[17] S. Hochreiter y J. Schmidhuber, «Long Short-Term Memory», *Neural Computation*, vol. 9, n.º 8, págs. 1735-1780, 1997. dirección: https://ieeexplore.ieee.org/abstract/document/6795963

[18] Google Brain Team, *TensorFlow: An end-to-end platform for machine learning*, 2025. visitado 15 de abr. de 2025. dirección: https://www.tensorflow.org/

[19] IBM. «¿Qué es explainable AI?», visitado 17 de abr. de 2025. dirección: https://www.ibm.com/think/topics/explainable-ai

[20] Geeks Forgeeks developers. «XAI Using Lime», Geeks Forgeeks, visitado 17 de abr. de 2025. dirección: https://www.geeksforgeeks.org/artificial-intelligence/introduction-to-explainable-aixai-using-lime/

[21] Geeks Forgeeks developers. «XAI Using SHAP», Geeks Forgeeks, visitado 17 de abr. de 2025. dirección: https://www.geeksforgeeks.org/machine-learning/shap-a-comprehensive-guide-to-shapley-additive-explanations/

[22] Economipedia developers. «Teoría de juegos cooperativos», Economipedia, visitado 17 de abr. de 2025. dirección: https://economipedia.com/definiciones/juegos-cooperativos.html

[23] M. Nabipour et al., «Predicting Stock Market Trends Using Machine Learning and Deep Learning Algorithms», *The Journal of Supercomputing*, 2020. dirección: https://scispace.com/pdf/predicting-stock-market-trends-using-machine-learning-and-50ru6rl37h.pdf

[24] H. Abdou, «The Impact of Oil and Global Markets on Saudi Stock Market Predictability: A Machine Learning Approach», *Energy Economics*, 2024. dirección: https://www.sciencedirect.com/science/article/pii/S0140988324001245

[25] M. T. Mohsin y N. B. Nasim, «Explaining the Unexplainable: A Systematic Review of Explainable AI in Finance», *arXiv preprint arXiv:2503.05966*, 2025. dirección: https://arxiv.org/pdf/2503.05966

[26] W. Morten, *fredapi: Python API for Federal Reserve Economic Data (FRED)*, 2025. visitado 15 de abr. de 2025. dirección: https://github.com/mortada/fredapi

[27] R. Aroussi, *yfinance: Yahoo Finance market data downloader*, 2025. visitado 15 de abr. de 2025. dirección: https://github.com/ranaroussi/yfinance

[28] Python Software Foundation, *The Python Tutorial*, 2025. visitado 15 de abr. de 2025. dirección: https://docs.python.org/3/tutorial/

[29] ING developers. «Explicación del SP500», ING, visitado 18 de abr. de 2025. dirección: https://www.ing.es/ennaranja/invertir-dinero/como-invertir/sp-500-y-su-importancia

[30] Forex.com developers. «¿Qué es el índice VIX?», Forex.com, visitado 18 de abr. de 2025. dirección: https://www.forex.com/es/news-and-analysis/what-is-the-vix/

[31] Banc Santander developers. «Índice de Precios al Consumo (IPC)», Banco Santander, visitado 18 de abr. de 2025. dirección: https://www.bancosantander.es/glosario/ipc-indice-precios-consumo

[32] R Core Team, *R: A Language and Environment for Statistical Computing*, 2025. visitado 15 de abr. de 2025. dirección: https://cran.r-project.org/doc/manuals/r-release/R-intro.html

[33] Docentes de la Universidad Nacional de Cajamarca, *Manual de Google Sheets*, 2025. visitado 15 de abr. de 2025. dirección: https://siteplus.unc.edu.pe/wp-content/uploads/2021/04/MANUAL-GOOGLE-SHEETS.pdf

[34] Wikipedia developers. «Apple Inc.», Wikipedia, visitado 18 de abr. de 2025. dirección: https://www.apple.com/financial-info/

[35] Economipedia developers. «Que es la curtosis», Economipedia, visitado 18 de abr. de 2025. dirección: https://economipedia.com/definiciones/curtosis.html

[36] Rakia developers. «Que es la skewness», Rakia, visitado 18 de abr. de 2025. dirección: https://www.rankia.com/diccionario/fondos-inversion/skewness

[37] World Health Organization. «COVID-19 Pandemic», WHO, visitado 18 de abr. de 2025. dirección: https://www.who.int/emergencies/diseases/novel-coronavirus-2019

[38] Reserva Federal de los Estados Unidos. «Historical Data on Interest Rates», Federal Reserve, visitado 18 de abr. de 2025. dirección: https://www.federalreserve.gov/

[39] Banco Central Europeo. «Historical Data on Interest Rates», European Central Bank, visitado 18 de abr. de 2025. dirección: https://www.ecb.europa.eu/

[40] Mario Beraha, Alberto Maria Metelli, and others. «Feature Selection with Mutual Information», arXiv, visitado 19 de abr. de 2025. dirección: https://arxiv.org/pdf/1907.07384

[41] QuestionPro developers. «Que es la correlación de Pearson», QuestionPro, visitado 19 de abr. de 2025. dirección: https://www.questionpro.com/blog/es/coeficiente-de-correlacion-de-pearson/

[42] IBM. «¿Qué es random forest?», visitado 17 de abr. de 2025. dirección: https://www.ibm.com/mx-es/think/topics/random-forest

[43] The pandas development team, *pandas: Python Data Analysis Library*, 2025. visitado 15 de abr. de 2025. dirección: https://pandas.pydata.org/

[44] NumPy developers, *NumPy: The fundamental package for scientific computing with Python*, 2025. visitado 15 de abr. de 2025. dirección: https://numpy.org/

[45] Matplotlib development team, *Matplotlib: Visualization with Python*, 2025. visitado 15 de abr. de 2025. dirección: https://matplotlib.org/

[46] Banco de España. «Estadísticas y Publicaciones», visitado 15 de abr. de 2025. dirección: https://www.bde.es/

[47] Google. «Google Finance», visitado 15 de abr. de 2025. dirección: https://www.google.com/finance/

[48] Q2BStudio. «Entropía de Shannon: qué es, cómo se calcula y para qué sirve», visitado 15 de abr. de 2025. dirección: https://www.q2bstudio.com/nuestro-blog/447316/descubre-que-es-la-entropia-de-shannon-como-se-calcula-y-sus-multiples-aplicaciones-en-diferentes-areas-una-herramienta-fundamental-en-el-analisis-de-informacion-y-comunicacion

[49] M. T. Ribeiro, S. Singh y C. Guestrin, «"Why Should I Trust You?": Explaining the Predictions of Any Classifier», en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, págs. 1135-1144. dirección: https://dl.acm.org/doi/10.1145/2939672.2939778

[50] S. M. Lundberg y S.-I. Lee, «A Unified Approach to Interpreting Model Predictions», *arXiv preprint arXiv:1705.07874*, 2017. dirección: https://arxiv.org/pdf/1705.07874

[51] Banco Santander. «¿Qué son las acciones y cómo se clasifican?», visitado 15 de abr. de 2025. dirección: https://www.bancosantander.es/glosario/acciones

[52] ETSIINF. «Recomendaciones sobre el contenido de la Memoria Final», visitado 1 de jun. de 2023. dirección: http://www.fi.upm.es/?pagina=1475

[53] A. Feder. «BibTeX.org», visitado 1 de jun. de 2023. dirección: http://www.bibtex.org

[54] W. Stallings, *Computer Organization and Architecture*. Prentice Hall, 2006.

Anexos

Apéndice A

Primer anexo

Este capítulo (anexo) es opcional, y se escribirá de acuerdo con las indicaciones del Tutor.