



Universidad Politécnica
de Madrid

**Escuela Técnica Superior de
Ingenieros Informáticos**



Grado en Ingeniería Informática

Trabajo Fin de Grado

Modelos Predictivos Explicables de Análisis de Inversión Financiera

Autor: Rubén Sánchez Leal

Tutor(a): Juan Antonio Fernández del Pozo de Salamanca

Madrid, Febrero 2026

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado
Grado en Ingeniería Informática

Título: Modelos Predictivos Explicables de Analisis de Inversión Financiera

Febrero 2026

Autor: Rubén Sánchez Leal

Tutor: Juan Antonio Fernández del Pozo de Salamanca
Departamento de Inteligencia Artificial
Escuela Técnica Superior de Ingenieros Informáticos
Universidad Politécnica de Madrid

Resumen

Este Trabajo de Fin de Grado aborda la predicción del rendimiento mensual de Apple (AAPL) mediante técnicas de Machine Learning y Deep Learning, para dicha predicción, se han incorporado un amplio número de variables tanto macroeconómicas como financieras. En cuanto a los objetivos del trabajo, se pretende determinar hasta qué punto es posible anticipar el comportamiento de un activo financiero utilizando información macroeconómica y algoritmos de aprendizaje automático, identificar qué variables resultan más influyentes en dichas predicciones y establecer para qué contexto o situación resulta más adecuado cada modelo.

Para ello, se ha diseñado e implementado un pipeline completo de procesamiento de datos que incluye la obtención de datos históricos de variables macroeconómicas y financieras desde Yahoo Finance y de fuentes macroeconómicas oficiales como la Reserva Federal, más adelante se aplicó feature engineering sobre ciertas variables, con el objetivo de generar nuevas variables que aportasen información. Una vez obtenidos todos los datos, se realizó un análisis exploratorio con R sobre todas las variables, con el objetivo de entenderlas mejor y a su vez, poder definir periodos en función del comportamiento de estas variables. Una vez finalizado el análisis, se llevó a cabo una selección de variables de acuerdo a los resultados obtenidos anteriormente. De dicha selección de variables, surgen los dos datasets diferenciados, uno para Machine Learning con retardos de las variables macroeconómicas, y otro para Deep Learning sin retardos, aprovechando la memoria temporal de las redes LSTM.

En cuanto a los modelos predictivos, se implementaron Random Forest, Gradient Boosting, LightGBM y una red LSTM. Cada modelo fue optimizado mediante búsqueda de hiperparámetros con validación cruzada temporal, respetando el orden cronológico de los datos. La evaluación se realizó sobre un conjunto de prueba independiente y mediante backtesting con ventana deslizante, lo que permitió analizar la robustez temporal de cada modelo. En el caso de LSTM, también ha sido necesario aplicar técnicas de regularización como data augmentation y Gaussian noise para evitar el sobreajuste, dada la limitación del tamaño del dataset.

Una vez finalizado el entrenamiento, los resultados obtenidos mostraron que LightGBM alcanza el mejor rendimiento predictivo, con un R^2 de 0,2688 y una directional accuracy del 77,78 %, posicionándose como la mejor opción cuando se busca maximizar la precisión de las predicciones. Por su parte, Gradient

Boosting logra un R^2 de 0,1574 y una directional accuracy del 62,96 %, ofreciendo un buen equilibrio entre precisión y estabilidad temporal, lo que lo hace especialmente adecuado para contextos donde puedan producirse cambios de régimen. En cuanto a Random Forest, con un R^2 prácticamente nulo (-0,0001) y una directional accuracy del 59,26 %, se muestra como el modelo más conservador y robusto. En lo que respecta a la LSTM, aunque se vio limitada por el reducido tamaño del dataset, logró alcanzar un R^2 positivo del 3,96 % y una directional accuracy del 61,11 % gracias a las técnicas de regularización aplicadas.

Tras el entrenamiento, se realizó un análisis de interpretabilidad mediante SHAP y LIME sobre los modelos de Machine Learning. Este análisis reveló que el precio del activo es la variable más influyente en todos los modelos, con un impacto sistemáticamente negativo sobre el rendimiento previsto. A su vez, algunas de las variables más importantes son los tipos de interés del BCE, la inflación estadounidense (con retardos de 3 y 6 meses) y la volatilidad del mercado (VIX). Estos resultados validan la decisión de incluir variables macroeconómicas en el análisis, así como la importancia de los retardos temporales.

Una vez finalizado el análisis de interpretabilidad, se ha llevado a cabo una serie de experimentos, con el fin de discutir el modelo y justificar decisiones. A partir de dichos experimentos adicionales se vio que las decisiones de diseño tomadas a lo largo del trabajo (inclusión de variables macroeconómicas, selección de variables ...), fueron realmente importantes y mejoraron notablemente los resultados sobre la predicción del activo. Asimismo, se comprobó que el pipeline desarrollado no generaliza automáticamente a otros activos tecnológicos, lo que sugiere la necesidad de recalibración específica para cada activo.

Finalmente, a pesar de los buenos resultados obtenidos, el trabajo presenta limitaciones como el reducido tamaño del dataset, la alta variabilidad en backtesting y la baja interpretabilidad de la LSTM. Debido a estas limitaciones, al final del trabajo se proponen unas líneas de trabajo futuro, con el fin de mejorar el rendimiento de los modelos y su aplicabilidad a otros activos financieros. Del mismo modo, al final del proyecto, se analiza el impacto de este trabajo y se alinea dicho impacto con los Objetivos de Desarrollo Sostenible (ODS) de la ONU de la agenda 2030.

Abstract

This Final Degree Project addresses the prediction of Apple's (AAPL) monthly return using Machine Learning and Deep Learning techniques, incorporating a wide range of both macroeconomic and financial variables. Regarding the objectives of the work, it aims to determine to what extent it is possible to anticipate the behavior of a financial asset using macroeconomic information and machine learning algorithms, to identify which variables are most influential in these predictions, and to establish for which context or situation each model is most suitable.

To achieve this, a complete data processing pipeline has been designed and implemented, including the collection of historical data from Yahoo Finance and official macroeconomic sources such as the Federal Reserve. Subsequently, feature engineering was applied to certain variables in order to generate new variables that could provide additional information. Once all the data was obtained, an exploratory analysis was carried out using R to better understand the variables and to define periods based on their behavior. After this analysis, a variable selection process was carried out according to the previously obtained results. From this selection, two differentiated datasets emerged: one for Machine Learning with lags of the macroeconomic variables, and another for Deep Learning without lags, taking advantage of the temporal memory of LSTM networks.

Regarding the predictive models, Random Forest, Gradient Boosting, LightGBM and an LSTM network were implemented. Each model was optimized through hyperparameter search with temporal cross-validation, respecting the chronological order of the data. The evaluation was performed on an independent test set and through sliding window backtesting, which allowed analyzing the temporal robustness of each model. In the case of the LSTM, it was also necessary to apply regularization techniques such as data augmentation and Gaussian noise to avoid overfitting, given the limited dataset size.

Once the training was completed, the results showed that LightGBM achieves the best predictive performance, with an R^2 of 0.2688 and a directional accuracy of 77.78%, positioning itself as the best option when seeking to maximize prediction accuracy. Gradient Boosting achieves an R^2 of 0.1574 and a directional accuracy of 62.96%, offering a good balance between accuracy and temporal stability, making it especially suitable for contexts where regime changes may occur. Regarding Random Forest, with an almost null R^2 (-0.0001) and a direc-

tional accuracy of 59.26%, it stands out as the most conservative and robust model. Regarding the LSTM, although it was limited by the small dataset size, it managed to achieve a positive R^2 of 3.96% and a directional accuracy of 61.11% thanks to the applied regularization techniques.

After training, an interpretability analysis was carried out using SHAP and LIME on the Machine Learning models. This analysis revealed that the asset price is the most influential variable in all models, with a systematically negative impact on the predicted return. Other important variables include ECB interest rates, US inflation (with 3 and 6 month lags) and market volatility (VIX). These results validate the decision to include macroeconomic variables in the analysis, as well as the importance of temporal lags.

Once the interpretability analysis was completed, a series of experiments were carried out in order to discuss the model and justify design decisions. These additional experiments showed that the design decisions made throughout the work (inclusion of macroeconomic variables, variable selection, etc.) were really important and significantly improved the results on asset prediction. Likewise, it was found that the developed pipeline does not automatically generalize to other technological assets, suggesting the need for specific recalibration for each asset.

Finally, despite the good results obtained, the work presents limitations such as the small dataset size, the high variability in backtesting and the low interpretability of the LSTM. Due to these limitations, future work lines are proposed at the end of the work, in order to improve the performance of the models and their applicability to other financial assets. Likewise, at the end of the project, the impact of this work is analyzed and aligned with the United Nations Sustainable Development Goals (SDGs) of the 2030 Agenda.

Tabla de contenidos

Introducción	vi
0.1. Motivación	vi
0.2. Contexto	vi
0.3. Objetivos del trabajo y alcance	vii
0.4. Estructura de la memoria	viii
Estado del arte	xi
0.5. Economía	xi
0.5.1. Mercados financieros	xi
0.5.2. Fondos de inversión y acciones	xi
0.5.3. Variables macroeconómicas	xii
0.5.4. Contextos económicos	xiii
0.6. Series temporales	xiv
0.6.1. Conceptos de series temporales	xiv
0.6.2. Técnicas de análisis de series temporales	xvi
0.7. Machine Learning	xx
0.7.1. Random Forest	xxii
0.7.2. Gradient Boosting	xxiii
0.7.3. LightGBM	xxiv
0.8. Deep Learning	xxv
0.8.1. LSTM	xxvii
0.9. Modelos explicativos	xxviii
0.9.1. LIME	xxviii
0.9.2. SHAP	xxviii
0.10. Trabajos anteriores	xxix
Datos y preparación del dataset	xxxi
0.11. Datos a usar	xxxi
0.12. Obtención e integración de los datos al dataset	xxxi
0.13. Análisis exploratorio de datos (EDA)	xxxv
0.13.1. Análisis univariante	xxxvi
0.13.2. Análisis multivariante	liii
0.14. Selección de variables y dataset final	lxiii
0.14.1. Criterios de selección	lxiii
0.14.2. Proceso automatizado de selección	lxiv
0.14.3. Resultados de la selección	lxvi

TABLA DE CONTENIDOS

0.14.4 Creación de datasets para Deep Learning y Machine Learning	lxvi
Entrenamiento y validación de los modelos predictivos	lxviii
0.15 División de los datos en entrenamiento, validación y prueba	lxviii
0.15.1 Criterios de división	lxviii
0.15.2 Aplicación a los datasets de ML y DL	lxix
0.15.3 Funcionalidad de cada conjunto	lxix
0.16 Métricas de evaluación	lxx
0.17 Entrenamiento de modelos de Machine Learning	lxx
0.17.1 Random Forest	lxx
0.17.2 Gradient Boosting	lxxiii
0.17.3 LGBM	lxxiv
0.18 Modelo de Deep Learning: LSTM	lxxv
0.18.1 Preprocesamiento específico para LSTM	lxxvi
0.18.2 Técnicas de regularización para datos limitados	lxxvii
0.18.3 Arquitectura de la red	lxxviii
0.18.4 Compilación y entrenamiento	lxxviii
0.19 Evaluación de los modelos	lxxx
0.19.1 Estrategia de backtesting	lxxx
0.19.2 Resultados de Random Forest	lxxx
0.19.3 Resultados de Gradient Boosting	lxxxiii
0.19.4 Resultados de LGBM	lxxxv
0.19.5 Resultados de LSTM	lxxxviii
0.19.6 Comparativa global	xc
0.20 Conclusiones del capítulo	xciii
Discusión e interpretabilidad de los modelos	xcv
0.21 Aplicación de técnicas de interpretabilidad	xcv
0.21.1 Análisis con SHAP	xcv
0.21.2 Análisis con LIME	cx
0.22 Discusión del modelo	cxii
0.23 Conclusiones del trabajo	cxix
0.23.1 Limitaciones del estudio	cxx
Conclusiones y análisis de impacto	cxxi
0.24 Cumplimiento de los objetivos del trabajo	cxxi
0.24.1 Objetivos cumplidos	cxxi
0.24.2 Líneas de trabajo futuro	cxxii
0.25 Evaluación del proceso de elaboración del TFG	cxxiii
0.26 Análisis de impacto	cxxiv
0.26.1 Impacto económico	cxxiv
0.26.2 Impacto tecnológico	cxxv
0.26.3 Impacto social	cxxv
0.26.4 Alineación con los Objetivos de Desarrollo Sostenible (ODS) .	cxxv
Bibliografía	cxxvi

Anexos	cxxxiv
---------------	---------------

Primer anexo	cxxxiv
---------------------	---------------

Capítulo 1

Introducción

1.1. Motivación

La motivación de este Trabajo de Fin de Grado nace tras la realización de mis prácticas, donde pude acercarme al funcionamiento del sector bancario y al uso del análisis de datos en el ámbito financiero. A partir de esta experiencia y tras conocer el potencial del Machine Learning aplicado a los mercados financieros, surgió el interés por desarrollar un modelo capaz de analizar y predecir la evolución de activos como acciones o fondos de inversión.

1.2. Contexto

En las últimas décadas, los mercados financieros han experimentado una notable transformación impulsada por dos fenómenos paralelos, la globalización económica y la revolución digital. La primera ha estrechado los vínculos entre los mercados mundiales, mientras que la segunda ha generado un aumento masivo en el volumen de información disponible, dando lugar al concepto de "Big Data financiero"[1]. Este escenario plantea un desafío crítico para analistas e inversores, ya que las metodologías tradicionales resultan insuficientes para procesar y extraer valor de la enorme cantidad de datos generados continuamente.

Ante esta situación, la Inteligencia Artificial (IA) y, específicamente, el Machine Learning (ML), han adquirido un gran protagonismo. Estas herramientas permiten abordar la complejidad de los mercados actuales, mejorando las capacidades predictivas en áreas como la evaluación de riesgos y la gestión de carteras [2]. Dentro de este ecosistema, modelos como Random Forest, Gradient Boosting y las redes neuronales LSTM se han consolidado como referentes para la predicción de series temporales. Su éxito radica en la capacidad para capturar relaciones no lineales y procesar grandes volúmenes de datos de forma automatizada, superando las limitaciones de los métodos estadísticos clásicos.

A pesar de estos avances, la aplicación de modelos complejos en finanzas presenta un reto fundamental: su naturaleza de "caja negra". La falta de interpretabilidad genera preocupaciones sobre la transparencia, la confianza y el cumpli-

miento normativo [3]. En respuesta a esta problemática, ha surgido la Inteligencia Artificial Explicable (XAI), que defiende la necesidad de desarrollar modelos que sean precisos y, al mismo tiempo, comprensibles para el ser humano. Técnicas de interpretabilidad post-hoc como SHAP y LIME permiten desglosar la contribución de cada variable a las predicciones, facilitando así la justificación de resultados ante organismos regulatorios [4].

Este Trabajo de Fin de Grado se sitúa precisamente en la intersección entre la potencia predictiva y la transparencia. El objetivo es desarrollar un sistema que aproveche el potencial de la IA en el análisis de inversiones sin renunciar a la comprensión de los factores que determinan cada predicción, un equilibrio esencial para su aplicación práctica en el mundo real [3].

1.3. Objetivos del trabajo y alcance

El presente Trabajo de Fin de Grado tiene como objetivo el **diseño e implementación** de un sistema informático orientado al análisis y la predicción del comportamiento de activos financieros, concretamente **fondos de inversión y acciones**. Para ello, se emplearán técnicas de análisis de datos, **Machine Learning y Deep Learning**, con el fin de desarrollar un modelo predictivo que permita predecir la evolución a diferentes horizontes temporales de estos activos y, a su vez, analizar los factores que influyen en su comportamiento.

A continuación, se enumeran las fases que componen el desarrollo del trabajo:

1. **Obtención y gestión de datos.** Se recopilarán datos históricos desde el año 2002 hasta el año 2025, correspondientes tanto a variables financieras como a variables macroeconómicas. Entre estas variables se incluirán precios históricos de activos financieros, así como distintos indicadores macroeconómicos importantes, como la inflación, los tipos de interés o las tasas de desempleo, entre otros. Todos estos datos serán almacenados e integrados en un **dataset global**, para así garantizar la consistencia, integridad y trazabilidad de la información utilizada durante el proyecto.
2. **Procesamiento y preparación del dataset.** Esta fase incluirá tareas de **limpieza, transformación e integración** de los datos, con el objetivo de homogeneizar los distintos formatos de información, tratar posibles valores faltantes y establecer una **frecuencia mensual** para todas las variables.
3. **Análisis exploratorio de datos (EDA).** Se realizará un estudio de las tendencias existentes en las series temporales, así como un análisis de la **volatilidad** de los activos y las **correlaciones** entre las diferentes variables del dataset. El objetivo es identificar posibles dependencias fuertes que puedan introducir ruido y, por lo tanto, afectar al rendimiento de los modelos.
4. **Generación de nuevas variables (Feature Engineering).** A partir de los datos procesados, se crearán nuevas variables mediante técnicas de **feature engineering**, como retornos financieros, medias móviles o medidas de volatilidad. El objetivo es dotar al dataset de variables relevantes que aporten valor a la hora de la predicción.

5. **Desarrollo de los modelos predictivos.** Para abordar el problema desde diferentes enfoques, se implementarán modelos de **Machine Learning** (Random Forest y Gradient Boosting), que ofrecen una mayor interpretabilidad y transparencia, y un modelo de **Deep Learning** basado en redes neuronales recurrentes del tipo **LSTM**, que aporta mayor precisión.
6. **Entrenamiento, validación y evaluación de los modelos.** Se realizará un proceso de **backtesting** para analizar el comportamiento de los modelos simulando su aplicación en distintos períodos históricos del mercado. La capacidad predictiva y de generalización se evaluará mediante métricas de error como **MAE** (Error Absoluto Medio) o **MSE** (Error Cuadrático Medio).
7. **Comparación con y sin variables macroeconómicas.** Se compararán modelos entrenados únicamente con variables propias del activo financiero y modelos que incorporen además **variables macroeconómicas**, para analizar si su inclusión mejora la capacidad predictiva del sistema.
8. **Generación de predicciones y simulación de escenarios.** Se generarán predicciones a distintos horizontes temporales (corto, medio y largo plazo). Además, el sistema permitirá realizar **simulaciones bajo diferentes escenarios**, modificando determinadas variables macroeconómicas para analizar el comportamiento de los modelos ante distintas condiciones (Sin selección de variables, sin ciertas variables ...).
9. **Interpretabilidad de los modelos (XAI).** Dado que uno de los objetivos del trabajo es entender los factores que influyen en las predicciones, se aplicarán técnicas de **Explainable Artificial Intelligence (XAI)**, concretamente los métodos **SHAP y LIME**, que permiten analizar la contribución de cada variable en las predicciones generadas.
10. **Presentación de resultados.** Los resultados obtenidos serán presentados mediante **gráficos y visualizaciones** que representen de forma clara el comportamiento de los modelos, la evolución de las predicciones y el impacto de las distintas variables en el rendimiento de los activos financieros.

Por último, el **alcance** del trabajo abarca todo el proceso necesario para la construcción de un sistema de predicción basado en datos, desde la obtención de la información hasta el análisis e interpretación de los resultados obtenidos.

1.4. Estructura de la memoria

La memoria se estructura en varios capítulos que abordan de forma progresiva y detallada los distintos aspectos relacionados con el desarrollo de un sistema de análisis y predicción de activos financieros mediante técnicas de análisis de datos, Machine Learning y Deep Learning:

1. **Capítulo 1: Introducción** Se presenta el contexto general del trabajo, así como la motivación que ha llevado al desarrollo del mismo. En este capítulo se describen los objetivos principales del trabajo, al igual que su alcance.

Asimismo, contiene un resumen de la estructura de la memoria con el fin de facilitar la comprensión del trabajo.

2. **Capítulo 2: Estado del arte** Este capítulo, busca explicar los fundamentos teóricos necesarios para la comprensión del proyecto. En primer lugar, se explican los conceptos básicos sobre los mercados financieros, las acciones y los fondos de inversión, así como algunas de las variables macroeconómicas que influyen en su evolución. Posteriormente, se introducen las series temporales financieras, junto con sus conceptos. Continuando con el capítulo, se describen los fundamentos de Machine Learning y Deep Learning aplicados a problemas de predicción temporal, haciendo especial énfasis en los modelos que se utilizarán en el desarrollo del trabajo. Finalmente, se buscarán y mencionarán, trabajos anteriores en el ámbito de la predicción financiera con herramientas de IA.
3. **Capítulo 3: Datos y preparación del dataset** Aquí se describe el proceso de obtención, procesamiento y preparación de los datos usados a lo largo del proyecto. En primer lugar, se mencionarán las diferentes fuentes de datos utilizadas para la recopilación de variables financieras y macroeconómicas. Posteriormente, se explica el proceso de construcción del dataset, donde se incluye la selección de variables y la unificación de la frecuencia temporal de los datos. A continuación, se explican las etapas de procesamiento de los datos, como pueden ser la limpieza, la transformación y la normalización. Por último, se describen las técnicas de feature engineering utilizadas para generar nuevas variables a partir de las originales. A su vez, se realiza un análisis exploratorio de los datos con el objetivo de identificar tendencias, patrones y relaciones entre variables, del mismo modo, se buscará diferenciar los diferentes periodos y entender el comportamiento de las variables en dichos periodos. Finalmente, se realizará a una selección de variables atendiendo al análisis mencionado y se obtendrá el dataset final que será usado en los modelos predictivos.
4. **Capítulo 4: Entrenamiento y validación de los modelos predictivos** En este capítulo se describe la implementación, el entrenamiento y la validación de los modelos predictivos seleccionados (Random Forest, Gradient Boosting, LightGBM y LSTM) sobre los datasets optimizados obtenidos en el capítulo anterior. Para ello, se detalla la partición temporal de los datos en entrenamiento, validación y prueba, la configuración de hiperparámetros mediante búsqueda en rejilla, y el entrenamiento de cada modelo. Finalmente, se presentan los resultados obtenidos en el conjunto de prueba, se evalúa la robustez temporal mediante backtesting y se realiza una comparativa global para analizar las fortalezas de cada enfoque.
5. **Capítulo 5: Discusión e interpretabilidad de los modelos** En este capítulo se aborda un análisis más profundo de los resultados obtenidos en el capítulo anterior, centrándose en la interpretabilidad de los modelos y en la discusión de su comportamiento bajo diferentes condiciones. Para ello, se aplican técnicas de interpretabilidad como SHAP y LIME, que permiten descomponer las predicciones y comprender la influencia de cada variable.

A continuación, se somete el modelo a diferentes escenarios, con el fin de justificar ciertas decisiones de diseño tomadas anteriormente. Finalmente, se evalúa la capacidad de generalización de los modelos a otros activos y se presentan las conclusiones extraídas del análisis.

6. **Capítulo 6: Conclusiones y análisis de impacto** En este capítulo se evalúa el grado de cumplimiento de los objetivos iniciales planteados al inicio del trabajo, analizando qué se ha conseguido y qué aspectos han quedado pendientes. A continuación, se proponen líneas de trabajo futuro orientadas a superar las limitaciones identificadas y a ampliar el alcance del sistema desarrollado. Posteriormente, se presenta una reflexión personal sobre el proceso de elaboración del TFG, incluyendo las herramientas utilizadas, las dificultades encontradas y el aprendizaje adquirido. Finalmente, se analiza el impacto del trabajo en diferentes ámbitos (económico, tecnológico, social) y su alineación con los Objetivos de Desarrollo Sostenible de la Agenda 2030.
7. **Bibliografía** Recoge todas las referencias bibliográficas utilizadas durante el desarrollo del trabajo.
8. **Anexos** En esta sección se incluyen materiales adicionales que complementan la información presentada en los capítulos anteriores, como pueden ser códigos fuente, gráficos adicionales, tablas de resultados o cualquier otro recurso que se considere relevante para una mejor comprensión del trabajo realizado.

Capítulo 2

Estado del arte

2.1. Economía

Antes de comenzar con términos más técnicos o informáticos, es importante contextualizar este trabajo, para ello se ha realizado una breve introducción a conceptos básicos y necesarios para este trabajo.

2.1.1. Mercados financieros

Los mercados financieros son el lugar en el que oferentes y demandantes compran y venden activos financieros [5]. Son, por tanto, el lugar donde se encuentran quienes necesitan financiación y quienes disponen de dinero y desean obtener una rentabilidad. La función principal de estos mercados es dirigir el ahorro hacia la inversión productiva, facilitando así el crecimiento económico. A su vez, estos mercados siguen el principio de la oferta y la demanda.

Entre las características más relevantes de los mercados financieros, se encuentran la liquidez, que es la facilidad para comprar o vender un activo, luego está la transparencia, que es el acceso a la información para la toma de decisiones y por último, estos mercados financieros se caracterizan por la volatilidad, que se refiere a los constantes cambios en los precios de los activos, impulsados por eventos geopolíticos, el sentimiento colectivo del mercado o una serie de variables macroeconómicas que veremos más adelante. Tal y como señaló Eugene Fama en su formulación de la Hipótesis de los Mercados Eficientes, "los precios de los activos reflejan plenamente toda la información disponible"[6], lo que en teoría dificultaría su predicción. Sin embargo, la creciente evidencia de anomalías y la irrupción del Machine Learning han cuestionado esta visión tradicional, abriendo la puerta a enfoques predictivos como el que se plantea en este trabajo. Comprender esta volatilidad y predecir el comportamiento de los activos es el gran desafío del análisis financiero y el objetivo que motiva este trabajo.

2.1.2. Fondos de inversión y acciones

Este punto es clave, pues a través de él se pretende explicar cada uno de los elementos que el modelo va a predecir. A continuación, se definen y contextualizan los dos instrumentos financieros sobre los que recae el análisis predictivo de este trabajo, los fondos de inversión y las acciones.

- **Fondos de inversión** Respecto a los fondos de inversión, estos podrían definirse de acuerdo al banco Santander de la siguiente forma: "Un fondo de inversión, de inversión colectiva o inversión común es un instrumento que permite al ahorrador acceder al mercado financiero no de una manera directa, sino a través de inversiones diversificadas"[7]. Explicando un poco lo anterior, un fondo de inversión agrupa el dinero de varios ahorradores para invertirlo en una cesta de diferentes activos financieros, siendo todo ello gestionado por un equipo de profesionales que a su vez, se encargan de la toma de decisiones. Algunas de las principales ventajas que ofrecen los fondos de inversión, son la diversificación, al permitir acceder a múltiples mercados y clases de activos con un bajo coste, otra ventaja es la gestión profesional, ya que cuentan con especialistas que buscan maximizar la rentabilidad según el perfil de riesgo y por último, cabe mencionar también la transparencia, ya que estos fondos están supervisados por organismos como la Comisión Nacional del Mercado de Valores (CNMV). En cuanto a los tipos, podemos diferenciar tres: el fondo de renta variable, el de renta fija y el mixto. El presente trabajo se centra en el análisis y predicción del rendimiento de este tipo de instrumentos financieros, empleando para ello técnicas de Machine Learning y series temporales, todo ello con el objetivo de predecir su comportamiento futuro a distintos horizontes temporales.
- **Acciones** Al igual que con los fondos de inversión, a través del presente trabajo se pretende calcular la evolución temporal de las acciones de cualquier tipo de compañía. Pero antes de nada, ¿qué son las acciones? ¿En qué se basa su evolución? Una acción es un título que representa una parte del capital social de una empresa. Es por ello que todo aquel que posee acciones de una compañía es, por consiguiente, copropietario de dicha compañía en un porcentaje proporcionalmente relacionado al número de acciones que posea, y es que como bien señala el inversor Warren Buffett, "una acción es un instrumento que te permite poseer una pequeña parte de una gran empresa". En lo que respecta a ser accionista, esto supone un conjunto de derechos como el derecho a recibir parte de los beneficios mediante el reparto de dividendos, el derecho a asistir a las juntas de accionistas y ejercer el voto, el derecho a recibir información cada cierto tiempo sobre la evolución de la compañía y el derecho a recibir la parte proporcional del capital en caso de que la compañía desapareciese. Entrando en el tema de los precios, el valor de una acción no es fijo, sino que varía constantemente en función de la ley de la oferta y la demanda, que depende de varios factores como pueden ser la confianza de los inversores, los resultados de la empresa, las perspectivas de su sector y, de manera muy relevante para este trabajo, de la situación económica general y las variables macroeconómicas.

Capítulo 2. Estado del arte

2.1.3. Variables macroeconómicas

Primero de todo, es importante entender que es la macroeconomía, se trata de la rama de la ciencia económica que estudia el funcionamiento de una economía en su conjunto, analizando fenómenos agregados como la producción, el empleo o la inflación [8]. En lo que respecta a las variables macroeconómicas, estas son indicadores que miden estos fenómenos, lo que permite entender el contexto en el que se desenvuelven los mercados financieros.

El contexto macroeconómico en el que se va situar este trabajo es en gran parte estadounidense, debido a que el mercado bursátil de Estados Unidos, representa una gran parte del mercado bursátil global, con valores cercanos al 50%, ejerciendo una influencia dominante sobre el resto de los mercados internacionales, sin embargo, también se tendrán en cuenta variables europeas. Respecto a las variables seleccionadas para el dataset preanálisis, se encuentran las siguientes.

Variable	Justificación
S&P 500	Captura el movimiento agregado del mercado de renta variable estadounidense
VIX (Índice de volatilidad)	Refleja la incertidumbre y el riesgo percibido por los inversores
Petróleo	Materia prima clave, cuyo coste impacta directamente en los gastos de empresas e inflación
Oro	Considerado activo refugio, en épocas inflacionarias su precio sube
Tipos de Interés Fed	Principal referencia de política monetaria en EE.UU.
Tipos de Interés BCE	Principal referencia de política monetaria en la zona euro
IPC EE.UU.	Mide el aumento de precios y condiciona la política monetaria en EE.UU.
IPC Europa	Mide el aumento de precios y condiciona la política monetaria en la zona euro
Curva de tipos 10Y2Y	Sirve como predictor de recesiones
Desempleo en EE.UU.	Indica el estado del mercado laboral, influye fuertemente en la economía
Tipo de cambio Euro/Dólar	Divisas principales a nivel global

Cuadro 2.1: Variables macroeconómicas seleccionadas y su justificación. Fuente: elaboración propia.

A parte de las variables mencionadas anteriormente, también se consideró añadir el PIB, sin embargo, pese a ser la variable macroeconómica más representativa del crecimiento económico de un país, el hecho de que se publique trimestralmente y con retraso, hace que no sea una variable útil para modelos predictivos a corto-medio plazo

2.1.4. Contextos económicos

A su vez, es importante introducir los diferentes contextos económicos que se pueden llegar a encontrar ya que los mercados financieros se pueden llegar a ver muy influenciados por dichos contextos y es que a lo largo de los últimos 22 años, la economía mundial ha atravesado diferentes contextos económicos, cada uno con unas características diferenciales y que tienen un gran impacto, ya sea positivo o negativo en los mercados y las variables macroeconómicas.

El primer contexto que se diferencia es el de **expansión económica**, caracterizado por un crecimiento sostenido de la actividad económica, bajada de la tasa de desempleo y VIX bajo y rentabilidades altas. El segundo contexto es totalmente lo opuesto, se trata de **crisis** que implican una dura bajada de la actividad económica, aumento del desempleo y fuertes caídas en los mercados financieros, un ejemplo cercano sería la crisis de 2008 o la del COVID-19. El tercer contexto es el de **alta inflación**, caracterizado por la fuerte subida en los precios, provocando con ello la subida de los tipos de interés. Todo lo contrario a la inflación, es la **deflación**, caracterizada por la bajada de tipos de interés, impulsando el consumo, la inversión, y los mercados. La identificación del contexto económico vigente en cada periodo resulta fundamental para los modelos predictivos, ya que el comportamiento de los fondos de inversión difiere significativamente entre épocas de expansión, crisis o inflación. Este análisis se retomará en el apartado de clustering del Análisis Exploratorio de Datos (EDA), donde se clasificarán los diferentes periodos temporales tratará más en detalle.

2.2. Series temporales

Este punto es uno de los más importantes, ya que se explica con detalle el concepto de serie temporal. Su relevancia radica en que el dataset final que se proporcionará al modelo será una serie temporal multivariante de frecuencia mensual. Por ello, resulta necesario explicar todos los conceptos relacionados, así como el análisis que se pretende seguir para la selección de variables.

2.2.1. Conceptos de series temporales

Una serie temporal se define como una colección de observaciones de una variable recogidas a lo largo del tiempo, normalmente en instantes equiespaciados. En estas series, las observaciones sucesivas no son independientes entre sí; existe una dependencia temporal intrínseca donde un valor está relacionado con su pasado. Como señalaron George Box y Gwilym Jenkins: “en una serie temporal, el orden de las observaciones es esencial, ya que los valores pasados contienen información sobre el futuro” [9]. Un ejemplo claro son los tipos de interés de la FED: un valor en un mes determinado está condicionado por el del mes anterior, ya que estas variables no suelen presentar cambios bruscos de forma aislada. Por ello, el análisis debe realizarse respetando estrictamente el orden cronológico.

En cuanto a su clasificación, las series pueden ser deterministas o estocásticas.

Capítulo 2. Estado del arte

Las primeras son aquellas cuyos valores futuros pueden predecirse de forma exacta mediante una ley matemática. Por el contrario, en las estocásticas los valores futuros solo pueden conocerse a partir de una función de probabilidad. En el ámbito financiero, la mayoría de las series presentan un comportamiento principalmente estocástico, lo que justifica el uso de modelos de *Machine Learning* para su análisis, al no existir una fórmula determinista que permita conocer el valor futuro con certeza.

Continuando con su estructura, toda serie temporal puede descomponerse normalmente en cuatro componentes:

Tendencia: Cambio suave y a largo plazo en el nivel medio de la serie, que representa su dirección general (ascendente, descendente o lateral).

Estacionalidad: Variaciones periódicas y predecibles que se repiten en intervalos de tiempo fijos (anuales, trimestrales, etc.).

Componente cíclico: Variaciones de mayor duración que la estacionalidad, pero sin un periodo fijo, como los ciclos económicos de recesión.

Componente aleatoria: Variaciones impredecibles que permanecen una vez eliminados los efectos anteriores.

Es importante introducir aquí el concepto de **estacionariedad**, que no debe confundirse con la estacionalidad. Una serie es estacionaria cuando su media y su variabilidad permanecen constantes a lo largo del tiempo. Por el contrario, las series no estacionarias presentan propiedades estadísticas que cambian cronológicamente, lo que suele requerir transformaciones previas para su modelado.

En la Figura 1 se muestra un ejemplo de una serie no estacionaria y no cíclica, con una tendencia ascendente. La imagen detalla la evolución del índice IBEX35 en el periodo comprendido entre 2021 y 2026.



Figura 2.1: Evolución del índice IBEX35 (2021-2026). Fuente: BME Exchange

Finalmente, alineando esta explicación a este trabajo, el dataset final que se proporcionará a los modelos predictivos es una serie temporal multivariante de frecuencia mensual, que abarca desde diciembre de 2003 hasta septiembre de 2025. El hecho de que sea multivariante implica que, para cada mes, se dispone de múltiples variables como, por ejemplo, todas las variables macroeconómicas

mencionadas anteriormente. Este enfoque multivariante es especialmente relevante en el dominio financiero, donde las correlaciones entre diferentes variables son complejas. Por su parte, la frecuencia mensual ofrece un equilibrio adecuado entre la disponibilidad de datos históricos y la capacidad predictiva a horizontes de corto, medio y largo plazo, que son los tres escenarios contemplados en los objetivos de este trabajo.

2.2.2. Técnicas de análisis de series temporales

- **Análisis de series temporales** Una vez definidos los conceptos fundamentales, es necesario abordar las técnicas de análisis de las series temporales, el cual consta de diferentes etapas y cada una de las cuales aporta información importante sobre el comportamiento de los datos. Para este trabajo, el análisis que se va a llevar a cabo es un EDA, que incluye la recopilación, el preprocesamiento y la visualización de las series, pudiendo así entender mejor cada una de las variables. Tras el EDA, iría la selección del modelo, entrenamiento y evaluación, pero eso se verá más tarde.

Antes de detallar las herramientas concretas, conviene distinguir entre dos enfoques posibles en el análisis de series temporales. Por un lado, el análisis univariante se centra en el estudio de una única variable a lo largo del tiempo, examinando sus propias características, su evolución, su memoria temporal y su capacidad de predicción a partir de sus propios valores pasados. Por otro lado, el análisis multivariante incorpora simultáneamente múltiples variables, lo que permite estudiar las interrelaciones entre ellas y aprovechar la información de unas variables para predecir el comportamiento de otras. Dado que el presente trabajo dispone de un dataset con once variables macroeconómicas además del activo financiero objetivo, el análisis que se llevará a cabo será fundamentalmente multivariante, si bien se complementará con análisis univariantes de cada variable para comprender su comportamiento individual.

En cuanto a las herramientas más usadas en el análisis de series temporales, una de las principales es el análisis visual, esta herramienta permite comprender una serie temporal de forma mucho más clara que solo viendo datos. Algunos ejemplos de este análisis visual, son los gráficos, que permiten identificar múltiples características de los datos, como la frecuencia de las observaciones, la tendencia creciente o decreciente, la existencia de valores atípicos, la dispersión de los datos alrededor de su media, los cambios de pendiente, la existencia de patrones que se repiten a lo largo del tiempo, los diferentes cuartiles, la media y mediana o características como la curtosis y skewness, ambas son muy útiles a la hora de entender comportamientos de variables. Para acabar, algunos ejemplos de gráficos, podrían ser gráficos de barras, boxplots o de dispersión entre otros

Otra de las herramientas a destacar, es la función de autocorrelación, la cual es muy útil en la exploración de series temporales ya que esta función analiza los datos de series temporales para buscar correlaciones en los valores de distintos puntos de una serie temporal, es decir, mide la co-

relación de un valor consigo mismo [10]. La representación gráfica de la función de autocorrelación, se denomina correlograma y resulta útil para identificar estacionalidad, tendencias y otros patrones en los datos, un claro ejemplo de correlograma es la Figura 2. La herramienta de autocorrelación, es fundamental para determinar la memoria temporal de cada variable y para ver si los valores pasados contienen información relevante acerca del valor futuro.




Figura 2.2: Ejemplo de un correlograma de una variable. Fuente: RPubS

Al igual que la autocorrelación, también existe la correlación de Pearson, la cual es muy útil en el análisis de series temporales multivariantes ya que esta función analiza la relación lineal entre dos variables diferentes, es decir, mide cómo se comporta una variable cuando la otra aumenta o disminuye. La representación gráfica de la correlación entre múltiples variables se denomina matriz de correlación y resulta útil para identificar relaciones directas (cuando una variable sube, la otra también sube), relaciones inversas (cuando una variable sube, la otra baja) o ausencia de relación lineal entre las variables. La herramienta de correlación es fundamental para entender cómo se relacionan las distintas variables macroeconómicas entre sí y, especialmente, cómo se relacionan con el activo financiero que se pretende predecir, lo que permite identificar qué variables pueden tener mayor poder explicativo sobre el comportamiento del target.

Por último, otra herramienta de gran utilidad es el clustering, que permite agrupar las observaciones en función de su similitud. Aplicado a series temporales, esta técnica permite segmentar el período de estudio en diferentes fases o regímenes económicos, identificando automáticamente momentos en los que el comportamiento de las variables presenta patrones similares, como períodos de expansión, crisis o recuperaciones.

En el contexto de este trabajo, y dado que el dataset final es una serie

temporal multivariante de frecuencia mensual que abarca desde diciembre de 2003 hasta septiembre de 2025, el análisis de series temporales se realizará combinando todas las técnicas mencionadas. En primer lugar, se realizará un análisis descriptivo de cada variable macroeconómica por separado, examinando su evolución temporal a lo largo del tiempo, su distribución estadística, sus valores extremos y su volatilidad en diferentes subperiodos. Adicionalmente, se estudiará la autocorrelación de cada variable mediante las funciones ACF, lo que permitirá determinar su memoria temporal y, por tanto, si resulta necesario incluir sus valores pasados como predictores en los modelos. Finalmente, dado el carácter multivariante del dataset, el análisis no se limitará al estudio individual de cada variable, sino que se extenderá a un análisis multivariante que explore las relaciones entre las distintas variables macroeconómicas y su interacción con el activo financiero objetivo. En este sentido, se calcularán las correlaciones entre todas las variables para identificar posibles relaciones lineales y ver si algunas son redundantes entre sí, a su vez, se aplicará un análisis de componentes principales (PCA) para reducir la dimensionalidad del sistema y comprender cuántas dimensiones explican la mayor parte de la varianza del conjunto de datos, y por último, se llevará a cabo un análisis de clustering con el objetivo de poder diferenciar los diferentes ciclos a lo largos del tiempo de estudio.

Todos estos análisis, que se presentan en detalle en el capítulo de Análisis Exploratorio de Datos (EDA), constituyen la base sobre la que se construirán los modelos predictivos en la fase posterior del trabajo.

- **Selección de variables** Una vez comprendida la naturaleza de las series temporales y las herramientas para su análisis, el siguiente paso clave es la selección de las variables más relevantes y que conformarán el dataset definitivo que le será entregado a los modelos predictivos. Como se ha visto anteriormente, en este trabajo se dispone de once variables macroeconómicas además de las variables propias del activo financiero. Sin embargo, no todas estas variables aportan la misma cantidad de información a la hora de realizar la predicción de un activo o fondo de inversión, ya que algunas pueden ser redundantes entre sí, otras pueden contener ruido y otras pueden tener una relación no lineal el target. Por esto mismo, la selección de variables es importante, ya que permite por un lado mejorar el potencial predictivo del dataset eliminando variables redundantes y que introducen ruido, y por otro lado, la selección de variables permite reducir la dimensión del dataset, consiguiendo así un menor coste computacional y una mayor interpretabilidad de los resultados. Es importante destacar que todo este proceso de selección se realiza antes que el entrenamiento de los modelos finales, asegurando que el dataset que se entregue a los modelos predictivos, sea ya el conjunto definitivo y optimizado.

Entrando ahora a los diferentes métodos de selección de variables, existen diferentes formas de métodos de selección de variables, entre los que destacan los métodos de filtrado, los métodos envolventes y los métodos embebidos. Los métodos de filtrado evalúan la relevancia de cada variable

de forma independiente a cualquier modelo predictivo posterior, basándose únicamente en propiedades estadísticas de los datos. Estos métodos son computacionalmente eficientes y escalables, aunque no consideran las interacciones entre variables. Los métodos envolventes, por el contrario, evalúan subconjuntos de variables entrenando un modelo predictivo para cada subconjunto, lo que los hace más precisos pero también mucho más costosos computacionalmente. Por último, los métodos embebidos realizan la selección de variables durante el propio proceso de entrenamiento de un modelo. En este trabajo, se emplearán principalmente métodos de filtrado, junto con un análisis de correlación para detectar redundancias.

Entre los métodos de filtrado, destacan la entropía de datos y la información mutua. La entropía mide el grado de desorden asociado a una variable aleatoria. A la hora de seleccionar variables, si una variable presenta una entropía elevada, significa que dicha variable, presenta una gran variedad de valores y por consiguiente, contiene más información relevante. Sin embargo, si la entropía es baja, entonces significa que no aporta mucha información al dataset y entonces se podría eliminar del dataset. En el caso de este trabajo, se aplicará el estudio de la entropía a cada una de las variables del dataset y se seleccionarán aquellas que realmente aporten información, es decir, que tengan una entropía alta.

Por otro lado, la información mutua, mide la cantidad de información que una variable contiene sobre otra. Es importante no confundirlo con la correlación de Pearson mencionada en las técnicas de análisis, ya que dicha correlación, sólo captura relaciones lineales, mientras que la información mutua es capaz de detectar cualquier tipo de dependencia estadística, ya sea lineal o no lineal. Dicha propiedad es muy útil a la hora de hacer este trabajo, ya que las relaciones entre variables macroeconómicas y del activo, no suelen ser lineales. Finalmente, en este trabajo, se calculará la información mutua entre cada variable predictora y la variable objetivo, lo que permitirá ordenar las variables por su capacidad predictiva individual y seleccionar para el dataset definitivo aquellas con mayor información mutua.

Además de estos métodos de filtrado, se empleará también un análisis de correlación entre las variables del dataset, con el objetivo de detectar posibles redundancias. En caso de que las correlaciones entre variables sean muy altas, entonces se consideraría la eliminación de una de ellas, con el objetivo de no introducir ruido.

En lo que respecta a este trabajo, el enfoque práctico que se seguirá para seleccionar las variables finales del dataset seguirá el siguiente proceso. En primer lugar, se analizarán las correlaciones entre las variables predictoras para detectar posibles redundancias. En segundo lugar, se aplicará un filtrado basado en entropía para eliminar aquellas variables con muy baja variabilidad y que no aportan información. En tercer lugar, se calculará la información mutua de cada variable restante con respecto al rendimiento del activo objetivo. Finalmente, con toda esta información, se montará el

dataset final, el cual contendrá las variables más relevantes de acuerdo a los filtros anteriores. Este dataset final será el que se entregue a los modelos de Random Forest, Gradient Boosting y LSTM para su entrenamiento y posteriores experimentos.

2.3. Machine Learning

Entrando ahora en la parte fundamental del trabajo, los modelos predictivos, los cuales serán los encargados de procesar la información del dataset y generar predicciones. Primero de todo el Machine Learning, el cual es el subconjunto de la Inteligencia Artificial centrado en algoritmos que pueden aprender los patrones de los datos de entrenamiento y, posteriormente, hacer inferencias sobre nuevos datos. Esta capacidad de reconocimiento de patrones permite a los modelos de machine learning tomar decisiones o realizar predicciones sin instrucciones explícitas y codificadas de forma rígida [11]. En resumen, un modelo de Machine Learning aprende a partir de ejemplos, identificando relaciones y estructuras que se encuentran en los datos. En un modelo de Machine Learning, cuantos más datos disponga sobre el tema, más precisas serán las predicciones que haga, ya que dispone de más información

Dentro del Machine Learning, se encuentran varias formas de aprendizaje, siendo el **aprendizaje supervisado** uno de los más relevantes para este trabajo. En el aprendizaje supervisado, el algoritmo se entrena a partir de un conjunto de datos que contiene tanto las variables de entrada como la variable objetivo que se quiere predecir. En esta forma de aprendizaje, el modelo aprende los patrones a partir de los cuales las entradas producen las salidas, y dichos patrones, los usa luego para predecir la variable objetivo a partir de nuevos datos de entrada, esto se puede ver en la Figura 3. Puesto que este trabajo es un problema de regresión donde se pretende predecir una variable continua, entonces el aprendizaje supervisado es la forma de aprendizaje adecuada. Por último, el aprendizaje supervisado se divide en problemas de clasificación, cuando la variable objetivo es categórica, y problemas de regresión, cuando es continua, siendo este último el caso de este trabajo.




Figura 2.3: Esquema del funcionamiento del aprendizaje supervisado.

Continuando con el proceso de entrenamiento de un modelo de Machine Learning, este se basa en la optimización de una **función de pérdida**, la cual calcula

la diferencia entre el valor de la predicción realizada y el valor real. En problemas de regresión, una de las funciones de pérdida más comunes es el error cuadrático medio (MSE), que calcula la media de los cuadrados de las diferencias entre predicciones y valores reales, otros ejemplos de funciones de pérdida, serían el error absoluto medio (MAE) o el error cuadrático medio raíz (RMSE). En Machine Learning, durante el entrenamiento, el objetivo es encontrar los parámetros del modelo que minimicen esta función de pérdida y para lograrlo, se hace uso de un algoritmo denominado **descenso de gradiente**, el cual calculando el gradiente de la función de pérdida con respecto a los parámetros del modelo, lo que indica la dirección en la que los parámetros deben ajustarse para reducir el error. En cada iteración, los parámetros se actualizan alejándose cada vez más del gradiente, este proceso se repite durante varias iteraciones hasta que el modelo alcanza un error muy bajo.

Otro concepto fundamental en la construcción de modelos predictivos es la reducción de la dimensionalidad. Cuando se trabaja con un conjunto de datos que contiene muchas variables, no todas ellas aportan información relevante para la predicción, algunas pueden ser redundantes entre sí, otras pueden contener principalmente ruido y algunas pueden tener una relación muy débil con el target. Es por ello, que incluir todas estas variables en el modelo, puede provocar sobreajuste o introducir ruido. Por esto mismo, es necesario aplicar técnicas de selección de variables y reducción de dimensionalidad sobre el dataset antes de entrenar los modelos. En este trabajo, esta tarea se ha abordado en profundidad durante la fase de Análisis Exploratorio de Datos (EDA) y se ha explicado en profundidad en el punto anterior, es por ello que aquí no se va a entrar en detalles.

Finalmente, en este trabajo, se trata de resolver un problema multivariante-multistep. Por un lado, es multivariante ya que se como se ha explicado anteriormente, se disponen varias variables para cada instante de tiempo y que actúan a la vez para predecir la variable objetivo. Esta característica exige que los modelos sean capaces de manejar entradas de alta dimensionalidad y de capturar las interacciones y dependencias entre las distintas variables. Por otro lado, es un problema multistep, ya que no se pretende predecir únicamente el valor del mes siguiente, sino que se busca generar predicciones a diferentes horizontes temporales, lo cual añade un punto de complejidad, ya que los errores tienden a acumularse, es por ello que el modelo debe de ser capaz de mantener la precisión.

Los modelos de Machine Learning que se van a usar, son Random Forest y Gradient Boosting. Ambos son modelos basados en árboles de decisión que pertenecen a la familia de **Ensemble Methods**. Estos métodos combinan múltiples modelos base para obtener un predictor final más robusto y preciso que cualquiera de los modelos individuales. La agregación de varias predicciones reduce la varianza y el error general del modelo, mejorando así su capacidad de generalización. Existen dos enfoques principales, el **bagging**, donde los modelos se entrenan de forma independiente y en paralelo, un ejemplo será Random Forest, y luego está **boosting**, en el que los modelos se entrenan de forma secuencial, corrigiendo los errores de los anteriores, un ejemplo de boosting, sería Gradient

Boosting.

Antes de pasar a la explicación de cada uno de los modelos, quería mencionar que durante la fase de entrenamiento que se verá más tarde en el capítulo 4, se encontró un modelo de Machine Learning que daba mejores resultados que los mencionados anteriormente, se trata de LightGBM, que sigue el enfoque de boosting y también se va a explicar con detalle en esta sección.

2.3.1. Random Forest

Random Forest [12], es un algoritmo de aprendizaje automático que combina el resultado de múltiples árboles de decisión para llegar a un resultado único. Puede ser usado tanto en problemas de clasificación como de regresión debido a su flexibilidad. Random Forest es un modelo de árbol de decisión, eso significa que sigue un modelo muy similar al juego de quien el quien, donde a partir de preguntas, se van creando subconjuntos hasta llegar a la respuesta correcta, una definición más técnica sería que árbol de decisión divide recursivamente los datos en subconjuntos más homogéneos mediante nodos de decisión.

Como se ha comentado anteriormente, Random Forest, pertenece a la familia de Ensemble Methods. A su vez, es una extensión del método de bagging, que consiste en seleccionar muestras aleatorias del conjunto de entrenamiento con reemplazo, entrenar un árbol de decisión sobre cada subconjunto y agregar las predicciones promediando en el caso de regresión. Finalmente, este algoritmo de Machine Learning, añade una capa adicional llamada la aleatoriedad de características, que consiste en seleccionar un subconjunto aleatorio de características en cada división del árbol, lo que garantiza que los árboles del bosque no estén correlacionados entre sí, reduciendo la varianza y el riesgo de sobreajuste.

Entre las principales ventajas del Random Forest para este trabajo destacan las siguientes:

- **Menor riesgo de sobreajuste:** al combinar múltiples árboles entrenados sobre diferentes subconjuntos de datos y características, el promediado de sus predicciones reduce la varianza del modelo, evitando que se ajuste excesivamente al ruido de los datos de entrenamiento.
- **Flexibilidad para manejar regresiones sin preprocesamiento extensivo:** Random Forest no requiere normalización ni estandarización de las variables, y es robusto frente a valores atípicos y datos faltantes, lo que simplifica el preprocesamiento del dataset.
- **Capacidad para evaluar la importancia de las características:** el algoritmo puede medir la contribución de cada variable a la reducción de la impureza en los nodos de los árboles, permitiendo identificar qué variables macroeconómicas son más relevantes para la predicción.

Con respecto a las desventajas, este modelo presenta un entrenamiento más lento que otros modelos debido a que tiene que construir múltiples árboles de forma independiente, lo que puede ser costoso computacionalmente si se utiliza un número elevado de árboles o conjuntos de datos muy grandes. Además, su

mayor complejidad interpretativa hace que sea más difícil explicar las predicciones individuales que con un único árbol de decisión, aunque las medidas de importancia de variables ayudan a solucionar este problema.

En cuanto a este trabajo, se implementará un *RandomForestRegressor* con scikit-learn [13], ajustando sus hiperparámetros principales como el número de árboles, la profundidad máxima y el número de características por división.

2.3.2. Gradient Boosting

Por otro lado, Gradient Boosting [14] es otro Ensemble Method basado en árboles de decisión, pero a diferencia del Random Forest que entrena los árboles de forma independiente y en paralelo, Gradient Boosting los construye de forma secuencial y acumulativa. Pertenecce a la familia de métodos de boosting, cuyo objetivo es combinar múltiples modelos débiles para crear un modelo fuerte, donde cada nuevo modelo se centra en corregir los errores cometidos por los anteriores.

Su funcionamiento es el siguiente. Primero, se inicializa el modelo con una predicción base (generalmente la media de la variable objetivo). En cada iteración, se calculan los errores (residuos) del modelo actual y se entrena un nuevo árbol de decisión para predecir esos errores. Este nuevo árbol se añade al modelo multiplicado por un factor *learning rate*, que controla la contribución de cada árbol y evita el sobreajuste. El proceso se repite durante un número determinado de iteraciones o hasta que el error sea suficientemente pequeño.

En cuanto a los hiperparámetros, el *learning rate* es el más importante, ya que un valor bajo hace que el modelo aprenda más lentamente pero de forma más generalizable, debido a que se requieren más árboles para aproximar la función objetivo. Otros hiperparámetros relevantes son la profundidad máxima de cada árbol y la fracción de muestras utilizada en cada iteración.

Entre las principales ventajas del Gradient Boosting para este trabajo destacan las siguientes:

- **Rendimiento predictivo superior:** al construir los árboles de forma secuencial corrigiendo los errores de los anteriores, el modelo puede capturar patrones más complejos y sutiles que otros algoritmos, lo que suele traducirse en una mayor precisión predictiva.
- **Capacidad para evaluar la importancia de las características:** al igual que Random Forest, Gradient Boosting puede medir la contribución de cada variable a la reducción del error durante el proceso de entrenamiento, lo que permite identificar qué variables macroeconómicas son más relevantes para la predicción.

Con respecto a las desventajas, su entrenamiento es más lento que el de Random Forest debido a su naturaleza secuencial. Además, es más sensible a los hiperparámetros, especialmente al *learning rate* y al número de árboles. Un ajuste inadecuado puede provocar sobreajuste si el aprendizaje es demasiado rápido o

infraprendizaje si es demasiado lento. Por ello, el ajuste de hiperparámetros debe realizarse con especial cuidado, utilizando técnicas como validación cruzada para encontrar la configuración óptima.

Finalmente, en este trabajo se implementará un *GradientBoostingRegressor* con scikit-learn [14], ajustando sus hiperparámetros principales mediante validación cruzada.

2.3.3. LightGBM

Por último, LightGBM (LGBM) [15] es otro Ensemble Method basado en árboles de decisión, perteneciente también a la familia de métodos de boosting. Sin embargo, a diferencia del Gradient Boosting tradicional, LightGBM introduce innovaciones significativas en cuanto a eficiencia computacional y velocidad de entrenamiento, lo que lo hace especialmente adecuado para conjuntos de datos grandes o con muchas características. Su nombre proviene de *Light Gradient Boosting Machine* y ha sido ampliamente adoptado en competiciones de machine learning y aplicaciones industriales por su excelente relación entre rendimiento predictivo y coste computacional.

Su funcionamiento se basa en dos innovaciones fundamentales. Primero, utiliza la técnica *Gradient-based One-Side Sampling* (GOSS), que consiste en preservar las muestras con gradientes más grandes (aquellas que contribuyen más al error) y muestrear aleatoriamente las de gradiente pequeño, manteniendo la distribución de los datos sin perder información relevante. Segundo, emplea *Exclusive Feature Bundling* (EFB), que agrupa características mutuamente exclusivas (es decir, que raramente toman valores distintos de cero simultáneamente) para reducir la dimensionalidad del problema. Gracias a estas dos técnicas, LightGBM puede entrenar modelos mucho más rápidamente que el Gradient Boosting convencional, especialmente cuando el número de características es elevado.

Otra diferencia clave respecto al Gradient Boosting tradicional es que LightGBM construye los árboles de decisión de forma *leaf-wise* (hoja a hoja) en lugar de *level-wise* (nivel a nivel). Mientras que el enfoque tradicional crece el árbol expandiendo todas las hojas de un mismo nivel de forma equilibrada, LightGBM selecciona en cada iteración la hoja con mayor pérdida para expandirla, lo que permite alcanzar una mayor profundidad y una convergencia más rápida. No obstante, esta estrategia puede provocar sobreajuste si no se controla adecuadamente mediante el hiperparámetro `max_depth` o `num_leaves`.

En cuanto a los hiperparámetros principales, destacan los siguientes. El hiperparámetro `num_leaves` controla el número máximo de hojas por árbol y es el principal regulador de la complejidad del modelo. Un valor elevado permite capturar patrones más complejos pero aumenta el riesgo de sobreajuste. El *learning rate* cumple la misma función que en Gradient Boosting, controlando la contribución de cada árbol al modelo final. El hiperparámetro `max_depth` limita la profundidad máxima del árbol, actuando como una regularización adicional. Por último, `min_child_samples` establece el número mínimo de muestras requerido

para crear una nueva hoja, evitando divisiones que generalicen pobremente.

Entre las principales ventajas de LightGBM para este trabajo destacan las siguientes:

- **Eficiencia computacional:** gracias a las técnicas GOSS y EFB, LightGBM es significativamente más rápido que Gradient Boosting, especialmente cuando se trabaja con muchas características o conjuntos de datos extensos. Esto permite explorar un espacio de hiperparámetros más amplio mediante validación cruzada en menos tiempo.
- **Rendimiento predictivo competitivo:** a pesar de su mayor velocidad, LightGBM no sacrifica precisión predictiva. De hecho, en numerosos estudios y competiciones ha demostrado igualar o superar a otros algoritmos de boosting como XGBoost o Gradient Boosting tradicional.
- **Capacidad para manejar características categóricas:** LightGBM puede procesar directamente variables categóricas sin necesidad de codificarlas previamente mediante one-hot encoding, lo que simplifica el preprocesamiento y reduce la dimensionalidad del problema.
- **Evaluación de importancia de características:** al igual que otros métodos basados en árboles, LightGBM proporciona medidas de importancia de cada variable, lo que facilita la interpretación del modelo y la identificación de los principales determinantes macroeconómicos del precio del oro.

En cuanto a sus desventajas, la principal es que la estrategia de crecimiento *leaf-wise* puede provocar sobreajuste si no se ajustan correctamente los hiperparámetros de regularización, especialmente en conjuntos de datos pequeños. Además, aunque LightGBM es generalmente más rápido que Gradient Boosting, su configuración óptima requiere un ajuste más cuidadoso de hiperparámetros como `num_leaves` y `min_child_samples`, ya que un valor inadecuado puede llevar a modelos demasiado complejos o, por el contrario, demasiado simples.

Finalmente, en este trabajo se implementará un `LGBMRegressor` de la librería `lightgbm` [15], ajustando sus hiperparámetros principales mediante validación cruzada con búsqueda de cuadrícula o búsqueda aleatoria, prestando especial atención a `num_leaves`, `learning_rate` y `max_depth` para evitar el sobreajuste dado el tamaño reducido del conjunto de datos.

2.4. Deep Learning

El Deep Learning es un subconjunto del Machine Learning impulsado por redes neuronales cuyo diseño se inspira en la estructura del cerebro humano y que implica el entrenamiento de modelos de al menos 4 capas. A diferencia de los modelos de Machine Learning, que siguen una lógica matemática, las redes neuronales de los modelos de Deep Learning comprenden muchas capas interconectadas de neuronas, que realizan cada una una operación matemática. En estos modelos de Deep Learning, se puede ajustar los pesos y sesgos variables del modelo para así optimizar la red y obtener salidas más precisas.

Continuando ahora con las redes neuronales, estas son un modelo de aprendizaje automático que apila neuronas simples en capas y aprende a reconocer patrones a partir de datos para así asignar entradas a salidas. Los componentes básicos de una red neuronal son una capa de entrada, que contiene las características sin procesar; una o varias capas ocultas, que transforman las entradas en nuevas representaciones mediante funciones de activación no lineales; y una capa de salida, que genera la predicción final. En la Figura 4 se pueden ver dichas capas. Se ha mencionado que en las capas ocultas las entradas se transforman con funciones de activación. Algunos ejemplos de estas funciones son la tangente hiperbólica, la unidad lineal rectificada (ReLU) o la función sigmoide. Todas ellas introducen no linealidad en el modelo, permitiendo a la red capturar patrones complejos y relaciones no lineales en los datos.




Figura 2.4: Estructura de una red neuronal con capas de entrada, ocultas y salida. Fuente: OpenWebinars

El entrenamiento de una red neuronal se basa en dos algoritmos fundamentales: la retropropagación [16] y el descenso de gradiente [17], que se explicó anteriormente en el apartado de Machine Learning. Profundizando ahora en la retropropagación, esta es un método muy útil para calcular cómo afectan los cambios en cualquier peso o sesgo individual de una red neuronal a la precisión de las predicciones del modelo. Para ello, durante el entrenamiento, se compara la predicción de la red con el valor real mediante una función de pérdida y, a continuación, la retropropagación propaga este error hacia atrás a través de la red desde la capa de salida hasta la capa de entrada, calculando mediante la regla de la cadena del cálculo el gradiente de la función de pérdida con respecto a cada parámetro del modelo. Este gradiente indica en qué dirección deben ajustarse los pesos y sesgos para reducir el error. Posteriormente, un algoritmo de descenso de gradiente utiliza este gradiente para actualizar los parámetros del modelo. Finalmente, este proceso se repite en bucle hasta que el modelo en-

cuentra un conjunto de parámetros que producen predicciones suficientemente precisas.

Sin embargo, es importante señalar que el descenso de gradiente no garantiza la convergencia al mínimo global de la función de pérdida. En la práctica, la función de pérdida de una red neuronal es no convexa y presenta una gran cantidad de mínimos locales y puntos de silla. Es por ello que el algoritmo puede quedar atrapado en un mínimo local, que no necesariamente es la solución óptima, o por el contrario, puede oscilar sin converger si la tasa de aprendizaje no es la adecuada. No existe una única solución, ya que diferentes inicializaciones aleatorias de los pesos pueden llevar a distintos conjuntos de parámetros finales que producen un rendimiento muy parecido. Además, la robustez del proceso depende fuertemente de la elección de la tasa de aprendizaje y de la calidad de los datos. Una tasa de aprendizaje demasiado alta puede provocar divergencia u oscilaciones, mientras que una demasiado baja puede ralentizar excesivamente la convergencia.

Antes de concluir con el Deep Learning es importante mencionar el equilibrio entre sesgo y varianza, que busca reducir el error. El sesgo mide lo lejos que están las predicciones de un modelo de los valores reales, mientras que la varianza captura cuánto varían las predicciones en función de los diferentes datos de entrenamiento. Un modelo con alto sesgo es propenso a un ajuste insuficiente, es decir, no logra capturar los patrones importantes de los datos y da lugar a un modelo demasiado simple. Por el contrario, un modelo con alta varianza es propenso al sobreajuste, lo que significa que se ajusta excesivamente a los datos de entrenamiento, aprendiendo el ruido como si fuera señal y perdiendo capacidad de generalización a nuevos datos. Con el entrenamiento, se busca encontrar el punto óptimo entre ambos errores, minimizando el error de predicción. Algunas técnicas para mantener este equilibrio son la regularización, que añade una penalización a la función de pérdida para desalentar modelos demasiado complejos, también está el *dropout*, que apaga aleatoriamente neuronas durante el entrenamiento para reducir el sobreajuste y por último, la detención temprana, que detiene el entrenamiento cuando la pérdida en validación deja de mejorar.

2.4.1. LSTM

Las redes neuronales recurrentes (RNN) son un tipo de red neuronal diseñada específicamente para trabajar con datos secuenciales, como series temporales. A diferencia de las redes neuronales convencionales, las RNN cuentan con bucles de retroalimentación que permiten que la información se mantenga a lo largo de los pasos temporales, creando una memoria de entradas pasadas. Sin embargo, las RNN convencionales presentan una limitación importante, el problema de la desaparición del gradiente, el cual impide que la red aprenda dependencias a largo plazo.

Para superar este problema, surge la arquitectura Long Short-Term Memory (LSTM), diseñada para capturar dependencias temporales a largo plazo de manera efectiva y es que tal y como mencionan Sepp Hochreiter y Jürgen Schmidhuber "las redes LSTM pueden aprender a puentear intervalos de tiempo de

más de 1000 pasos sin perder información relevante"[18]. Esto lo consigue gracias a su estructura interna, que cuenta con tres puertas que regulan el flujo de información, una de las puertas es la **puerta de olvido**, que decide qué información del pasado debe descartarse, luego está la **puerta de entrada**, que determina qué nueva información debe almacenarse, y por último, la **puerta de salida** controla qué información se utiliza para generar la predicción. Gracias a estas puertas, LSTM, es capaz de sobreponerse a la limitación planteada anteriormente y además, permite a la red olvidar información que no es relevante.

En el contexto de este trabajo, la LSTM presenta ventajas bastante interesantes. Una de las ventajas, como se ha mencionado antes, es la gran capacidad de LSTM para capturar dependencias temporales prolongadas. En segundo lugar, LSTM es capaz de manejar el carácter multivariante del problema, pudiendo procesar a la vez todas las variables macroeconómicas y del activo como una secuencia de entrada. Por último, LSTM es capaz de abordar el problema multi-step, generando predicciones a diferentes horizontes temporales y manteniendo la coherencia temporal de las predicciones. En cuanto a las desventajas, LSTM requiere una mayor cantidad de datos para entrenarse adecuadamente, es más costosa computacionalmente y la interpretabilidad de las predicciones es más costosa que en modelos de Machine Learning.

En este trabajo se implementará una red LSTM utilizando TensorFlow [19], configurándola para el problema multivariante-multistep, y se comparará su rendimiento con el de los modelos de Machine Learning, evaluando si su capacidad de memoria a largo plazo ofrece ventajas significativas sobre los métodos basados en árboles para la predicción de rendimientos financieros.

2.5. Modelos explicativos

En este trabajo no solo se pretende realizar predicciones, sino que también se busca entender el porqué de las salidas del modelo, es por ello que se emplearán modelos explicativos para así poder comprender la influencia de cada una de las variables en las predicciones y entender mejor el comportamiento del modelo. Para conseguir esta transparencia, se emplearán dos técnicas de Explainable Artificial Intelligence (XAI) [20], LIME y SHAP, las cuales permitirán interpretar las predicciones del modelo y analizar la influencia de cada variable macroeconómica en los resultados obtenidos.

2.5.1. LIME

LIME [21] es una técnica explicativa que genera explicaciones locales para predicciones individuales. Su funcionamiento consiste en aproximar el comportamiento del modelo complejo en la vecindad de una instancia específica mediante un modelo más simple e interpretable, como una regresión lineal. De esta forma, para una predicción concreta del rendimiento de un fondo en un mes determinado, LIME permite identificar qué variables macroeconómicas han influido más en esa decisión concreta, ofreciendo una explicación comprensible y localizada.

Su principal ventaja es que puede aplicarse tanto a Random Forest, como a Gradient Boosting, LGBM o a LSTM sin necesidad de modificaciones.

2.5.2. SHAP

Por otro lado, SHAP [22] es una técnica explicativa que se basa en la teoría de juegos cooperativos [23]. SHAP asigna a cada variable un valor de importancia conocido como Shapley value, que representa su contribución a la predicción. A diferencia de LIME, que se centra en explicaciones locales para predicciones individuales, SHAP permite tanto el análisis local de predicciones concretas como la visión global de la importancia de las variables en todo el conjunto de datos, ofreciendo propiedades deseables como consistencia, precisión local y aditividad. En el contexto de este trabajo, la combinación de SHAP y LIME permitirá identificar qué variables macroeconómicas, como los tipos de interés, la inflación, el diferencial de la curva de tipos o el precio del petróleo, son más influyentes en las predicciones del rendimiento de los fondos de inversión, proporcionando así una comprensión completa y robusta del comportamiento del modelo.

2.6. Trabajos anteriores

Por último, para concluir con el marco teórico, se verán trabajos relacionados con este TFG, con el objetivo de contextualizar la investigación actual dentro del panorama más amplio de la aplicación de Inteligencia Artificial en finanzas. Y es que, en los últimos años, el uso de técnicas de Machine Learning y Deep Learning en el ámbito financiero ha crecido muy significativamente, debido a la gran cantidad de datos y el fácil acceso a los mismos, a su vez, los avances computacionales, también han impulsado este crecimiento. Tal y como se menciona en la revisión sistemática de El Alami y colaboradores [2], los modelos más utilizados en el ámbito financiero son Random Forest, XGBoost, Support Vector Machines, y redes neuronales como LSTM, Bidirectional LSTM y CNN, del mismo modo, se hace uso de modelos híbridos que combinan métodos estadísticos con inteligencia artificial.

En cuanto al rendimiento de estos modelos, tal y como señalan Nabipour Mojtaba y colaboradores [24], las arquitecturas basadas en LSTM superan consistentemente a los métodos tradicionales como ARIMA o GARCH en la predicción de series financieras, esto es gracias a su capacidad para capturar dependencias temporales largas. No obstante, los propios autores advierten que las LSTM pueden ser propensas al sobreajuste y requieren un ajuste cuidadoso de sus hiperparámetros, algo que se tendrá en cuenta en la fase de modelado de este trabajo.

En lo que respecta al uso de variables macroeconómicas, tal y como explica Abdou Housein en su artículo “The impact of oil and global markets on Saudi stock market predictability: A machine learning approach” [25], el hecho de introducir variables como los precios del petróleo, los tipos de interés y los índices de volatilidad mejora significativamente la predictibilidad de los mercados bursátiles cuando se incorporan dentro de marcos de Machine Learning. Este artículo, da

aún más fuerza a la decisión adoptada en este TFG de incluir un importante número de variables macroeconómicas como predictores del rendimiento de los fondos de inversión o activos financieros.

En el aspecto de la interpretabilidad de los modelos, es un tema que ha ganado mucha popularidad en los últimos años, esto queda reflejado en el artículo de Mohsin y Nasim “Explaining the Unexplainable: A Systematic Review of Explainable AI in Finance.” [26], donde se explica que la falta de interpretabilidad de los modelos complejos limita su adopción en entornos regulados como el financiero, donde la transparencia es clave. Para solucionar este problema, Ye y Chen [4], proponen técnicas como SHAP y LIME, que permiten explicar las predicciones de modelos de caja negra, demostrando que es posible realizar modelos complejos manteniendo la transparencia necesaria.

Por último, tal y como se señala en la revisión sistemática sobre forecasting financiero [1], actualmente, muchos estudios evalúan sus modelos solo con métricas estadísticas sin integrar las predicciones en estrategias de inversión reales, a su vez pocos, modelos son validados en diferentes ciclos económicos como pueden ser crisis financieras o períodos de alta inflación. Estas limitaciones refuerzan el enfoque adoptado en este TFG, que combina la predicción multivariante-multistep con un análisis exhaustivo de interpretabilidad mediante SHAP y LIME, y una evaluación en diferentes contextos económicos identificados mediante clustering.

Capítulo 3

Datos y preparación del dataset

En este capítulo, se describirá el proceso de obtención, limpieza e integración de los datos macroeconómicos y financieros utilizados en este trabajo. Además, se realizará un análisis exploratorio de datos (**EDA**) tanto univariante como multivariante, esto se hará para comprender mejor el comportamiento de las variables seleccionadas y su relación con el activo financiero objetivo, que en este caso es Apple Inc. Este análisis permitirá identificar patrones, tendencias y posibles relaciones entre las variables, lo que será fundamental para la fase de modelización predictiva.

3.1. Datos a usar

Tras realizar un estudio de las variables macroeconómicas y financieras más relevantes en los mercados, se ha decidido trabajar con un conjunto de variables representativas que permitan capturar tanto el comportamiento del mercado como el contexto económico global. En concreto, tal y como se mencionó en la introducción, se incluyen los tipos de interés de la Federal Reserve y del European Central Bank, la inflación de Estados Unidos y de la eurozona, la tasa de desempleo en Estados Unidos, el tipo de cambio euro/dólar, la curva de tipos 10Y-2Y de Estados Unidos, así como los retornos del oro, del petróleo y del índice S&P 500. A su vez, se añade el índice de volatilidad VIX.

Con el objetivo de enriquecer el conjunto de datos, se aplican técnicas de **feature engineering** sobre algunas de estas variables, construyendo así un dataset lo más completo posible. Asimismo, se incluyen variables propias del activo que se esté estudiando, en este caso Apple Inc, sobre dichas variables, también se aplican transformaciones adicionales para mejorar la capacidad predictiva del modelo.

3.2. Obtención e integración de los datos al dataset

En cuanto al proceso de obtención, limpieza e integración de los datos, este se ha llevado a cabo de forma estructurada. En primer lugar, se han importado las

3.2. Obtención e integración de los datos al dataset

librerías `fredapi` [27] e `yfinance` [28] en Python [29], con el objetivo de acceder a fuentes externas de datos financieros y macroeconómicos y así no cargar el proyecto con muchos archivos CSV. Posteriormente, se ha definido el período de estudio, comprendido entre el 1 de diciembre de 2001 y el 1 de marzo de 2026, y se ha inicializado un dataset global donde se han ido integrando las distintas variables.

Para la obtención de datos macroeconómicos procedentes de la base de datos de la Federal Reserve Economic Data (FRED), se ha utilizado una **API key**, que en este caso es `af59516007957e0c89174b4d426736ca`.

El proceso comienza con la descarga de los datos. En primer lugar, se descargan los datos del S&P 500 [30] mediante `yfinance`, obteniendo el precio de cierre. Posteriormente, se transforma la serie a frecuencia mensual, seleccionando el último valor de cada mes. A continuación, se comprueba la existencia de valores nulos y luego se calcula el retorno mediante la función `pct_change()`. Esta transformación resulta especialmente útil, ya que los modelos de Machine Learning suelen trabajar mejor con retornos que con precios absolutos. Finalmente, se comprueba de nuevo la existencia de valores nulos y se integra la variable en el dataset global. Este mismo procedimiento se aplica a otras variables como el tipo de cambio euro/dólar o el índice VIX [31], con la diferencia de que en estos casos no se calcula el retorno. Las variables se integran en el dataset final a partir de un `inner join` en la columna `Date`.

En el caso del oro y el petróleo, el proceso presenta una particularidad adicional, tras la obtención de los datos y su conversión a frecuencia mensual, se encuentran valores nulos debido a días en los que no hay actividad en los mercados. Para resolver este problema, se ha implementado una función denominada `imputar_valores_faltantes`, que combina tres métodos de imputación: interpolación lineal (50%), media móvil (30%) y último valor observado (20%). Esta combinación permite obtener una serie mucho más completa. Una vez rellenados los valores nulos, se calcula el retorno y se incorpora al dataset final.

Listing 3.1: Función para imputar valores faltantes

```
def imputar_valores_faltantes(dataframe, nombre_columna=None):

    if isinstance(dataframe, pd.Series):
        serie_imputada = dataframe.copy()
    elif isinstance(dataframe, pd.DataFrame):
        if nombre_columna is not None: #
            serie_imputada = dataframe[nombre_columna].copy()
        elif dataframe.shape[1] == 1:
            serie_imputada = dataframe.iloc[:, 0].copy()
        else:
            raise ValueError("Debes especificar 'nombre_columna'")
    else:
        raise TypeError("Input debe ser DataFrame o Series")
```

Capítulo 3. Datos y preparación del dataset

```
serie_imputada = pd.to_numeric(serie_imputada, errors='coerce')

valores_cero = (serie_imputada == 0)
valores_nan = serie_imputada.isna()
total_a_imputar = valores_cero.sum() + valores_nan.sum()

serie_imputada[valores_cero] = np.nan

if total_a_imputar == 0:
    return serie_imputada

#Método 1: Interpolación lineal
metodo1 = serie_imputada.interpolate(method='linear', limit_direction='both')

#Método 2: Medias móviles ponderadas
media_3m = serie_imputada.rolling(window=3,
                                   center=True, min_periods=1).mean()
media_6m = serie_imputada.rolling(window=6,
                                   center=True, min_periods=1).mean()
metodo2 = media_3m * 0.7 + media_6m * 0.3

#Método 3: Forward/backward fill
ffill = serie_imputada.ffill()
bfill = serie_imputada.bfill()
metodo3 = ffill.fillna(bfill)

mask = serie_imputada.isna()
valores_nulos = np.where(mask)[0]

for valor in valores_nulos:
    valores = []
    pesos = []

    if valor < len(metodo1) and not pd.isna(metodo1.iloc[valor]):
        valores.append(metodo1.iloc[valor])
        pesos.append(0.50)

    if valor < len(metodo2) and not pd.isna(metodo2.iloc[valor]):
        valores.append(metodo2.iloc[valor])
        pesos.append(0.30)

    if valor < len(metodo3) and not pd.isna(metodo3.iloc[valor]):
        valores.append(metodo3.iloc[valor])
        pesos.append(0.20)

    if valores:
        pesos_normalizados = np.array(pesos) / np.sum(pesos)
```

3.2. Obtención e integración de los datos al dataset

```
valor_imputado = np.average(valores,
                             weights=pesos_normalizados)
serie_imputada.iloc[valor] = valor_imputado

if serie_imputada.isna().any():
    serie_imputada = serie_imputada.interpolate(method='linear',
                                                limit_direction='both')

if serie_imputada.isna().any():
    serie_imputada = serie_imputada.ffill()
    serie_imputada = serie_imputada.bfill()

return serie_imputada

#Llamada a la función:
petroleo = yf.download('CL=F', start=inicio, end=fin, interval='1mo')
petroleo.info()
petroleo.columns = petroleo.columns.get_level_values(0)
petroleo = petroleo.resample("ME").last()
petroleo = petroleo[['Close']].copy()
petroleo['Close'] = imputar_valores_faltantes(petroleo, 'Close')
petroleo["petroleo_return"] = petroleo["Close"].pct_change()
petroleo = petroleo[["petroleo_return"]]
petroleo = petroleo.reset_index()

dataset = pd.merge(dataset, petroleo, on="Date", how="inner")
```

El resto de variables macroeconómicas, como los tipos de interés, la curva de tipos o el desempleo, se obtienen directamente desde FRED siguiendo un proceso similar: se descargan, se ajustan a frecuencia mensual y se integran los datos en el dataset. En el caso del desempleo, al presentar valores nulos, ha sido necesario aplicar la función `imputar_valores_faltantes` antes de integrar los datos en el dataset final.

Por otro lado, la inflación es una variable importante para el modelo, sin embargo, no se obtiene directamente, sino que se calcula a partir del Índice de Precios al Consumo (IPC) [32] mediante la variación interanual. Para ello, se utiliza la función `pct_change(12)`. De este modo, se obtiene una medida más representativa de la evolución de los precios en cada región.

Finalmente, en el dataset final se incorporan las variables propias del activo analizado, obtenidas a través de yfinance. A partir de los precios de cierre, se aplican técnicas de feature engineering para generar nuevas variables como el retorno, medias móviles, volatilidad, momentum y lags, que resultan fundamentales para capturar la dinámica temporal del activo. Todas estas variables se integran en el dataset global mediante un inner join a partir de la columna Date.

Para concluir, se realiza una validación final del dataset, verificando que todas las variables se encuentran en frecuencia mensual, que no existen valores nulos

Capítulo 3. Datos y preparación del dataset

y que los tipos de datos son correctos. Asimismo, se renombran las columnas para facilitar su interpretación y, finalmente, el dataset se exporta en formato CSV, lo que permite su posterior utilización en herramientas como R [33] o Google Sheets [34]. Todo el proceso anterior se puede ver en la Figura 5.




Figura 3.1: Diagrama del proceso de obtención, limpieza e integración de datos. Fuente: elaboración propia.

3.3. Análisis exploratorio de datos (EDA)

Una vez obtenidos todos los datos e integrados en el dataset, se procede a la realización del análisis exploratorio de datos (EDA) en R. Dicho análisis se ha estructurado en dos grandes bloques, primero un análisis univariante, donde se examina cada variable macroeconómica de forma individual, y luego, un análisis multivariante, donde se estudian las relaciones entre las distintas variables y su interacción con el activo financiero objetivo. También se realizará clustering, con el objetivo de identificar diferentes contextos económicos a lo largo del período de estudio. Dicho dataset cuenta con 265 filas y sin valores nulos, por lo que no habrá valores que entorpezcan el análisis.

El análisis exploratorio de datos realizado en este trabajo se ha centrado en las variables macroeconómicas, ya que estas constituyen el único conjunto de variables que permanece constante independientemente del activo o fondo de inversión analizado. Dado que el objetivo del TFG es desarrollar una metodología general para el análisis predictivo de fondos de inversión, resulta fundamental comprender en profundidad el comportamiento de estas variables, su evolución temporal, sus distribuciones, sus correlaciones y su memoria, ya que son los elementos que aportarán el contexto económico a cualquier modelo predictivo.

En cuanto a las variables específicas del activo, en este caso se ha elegido Apple Inc [35] como caso de estudio, y se ha aplicado feature engineering sobre los precios del activo como medias móviles a 3, 6 y 12 meses para capturar tendencias; volatilidades móviles para medir el riesgo; momentum para reflejar la

inercia del precio; y lags del rendimiento en los horizontes 1, 2, 3, 6 y 12 meses para capturar la posible dependencia temporal del propio activo.

Estas variables específicas no han sido objeto de un análisis exploratorio detallado por dos razones. En primer lugar, porque su comportamiento es particular del activo concreto que se esté analizando, por lo que un análisis profundo de las mismas no aportaría valor generalizable a la metodología propuesta. En segundo lugar, porque su construcción sigue criterios estándar en el análisis técnico y en la modelización de series temporales financieras, siendo suficiente con incluirlas directamente en los modelos predictivos.

En una aplicación real de esta metodología a otro fondo de inversión o activo financiero, bastaría con sustituir los datos específicos de Apple por los del nuevo activo, manteniendo la misma estructura de variables técnicas y conservando intacto el análisis del entorno macroeconómico.

3.3.1. Análisis univariante

En el análisis univariante, se examina cada variable de forma individual, con el objetivo de caracterizar su comportamiento estadístico, identificar la presencia de eventos extremos y evaluar su distribución de probabilidad. Para ello, se calcularán medidas de medias y medianas, volatilidad, *skewness* y curtosis, así como los valores mínimos y máximos históricos. Se complementará el análisis con representaciones gráficas como *boxplots*, para detectar *outliers*. Este análisis univariante es fundamental para comprender el perfil de riesgo individual de cada variable.

Distribución de las variables macroeconómicas

A partir de este análisis, se pretende ver las medias, medianas y volatilidades de cada una de las variables macroeconómicas, así como la presencia de eventos extremos. Este análisis es fundamental para entender el comportamiento individual de cada variable y su impacto potencial en los modelos predictivos.

Antes de comenzar, es necesario explicar la curtosis [36] y la *skewness* [37], que son dos medidas estadísticas que permiten caracterizar la forma de la distribución de una variable. La curtosis mide la presencia de colas pesadas en la distribución, es decir, la frecuencia con la que ocurren eventos extremos. Una curtosis mayor que 3 indica colas pesadas, lo que significa que los eventos extremos son más frecuentes de lo normal. Por otro lado, la *skewness* mide la asimetría de la distribución. Una *skewness* positiva indica una asimetría hacia la derecha, lo que significa que hay una mayor propensión a ganancias extremas, mientras que una *skewness* negativa indica una asimetría hacia la izquierda, lo que sugiere una mayor propensión a pérdidas extremas. En la Figura 6 se muestra una rápida explicación visual de como se ven la curtosis y la *skewness* en gráficas.




Figura 3.2: Imagen explicativa de skewness y kurtosis. Fuente: Media2u.com.

- **Distribución de retornos del S&P 500:** En primer lugar, se analiza el S&P 500, que presenta un rendimiento medio mensual del 0,80% con una volatilidad del 4,20%. A su vez, presenta un *skewness* de -0,618, lo que indica una mayor propensión a pérdidas extremas. Por otro lado, la kurtosis de 4,39 confirma la presencia de colas pesadas. Los valores de la *skewness* y la kurtosis indican que el S&P 500 es más propenso a tener pérdidas grandes que ganancias grandes debido a la asimetría negativa. Además, el valor de la kurtosis, mayor que 3, indica que los eventos extremos ocurren con mayor frecuencia. En resumen, los eventos extremos son más habituales de lo normal y son más propensos a generar pérdidas. En lo que respecta al rendimiento, el valor mínimo del S&P 500 se registró en octubre de 2008, con un valor de -16,9% en plena crisis financiera, mientras que el máximo del 12,7% data de abril de 2020, tras el desplome inicial por la pandemia. Todo lo mencionado es visible en la Figura 7.




Figura 3.3: Gráfica de distribución de los retornos del S&P 500. Fuente: elaboración propia.

- **Distribución del VIX:** En lo que respecta al VIX, que se muestra en la

3.3. Análisis exploratorio de datos (EDA)

Figura 8, este presenta una media de 19,05 puntos, aunque su mediana de 16,63 es significativamente inferior, lo que refleja la naturaleza episódica de la volatilidad. Esta volatilidad tiene un valor del 7,93 %. Su *skewness* de 2,09 indica una fuerte asimetría positiva, lo que significa que hay muchos valores bajos pero algunos extremadamente altos, mientras que la curtosis de 8,69 confirma la presencia de colas muy pesadas. Esto indica que los picos de pánico en el mercado son eventos extremos que ocurren con mayor frecuencia de lo normal y, cuando ocurren, lo hacen de forma muy intensa. El valor máximo de 59,89 se alcanzó en octubre de 2008, durante la crisis financiera. Por el contrario, el mínimo de 9,51 se registró en julio de 2017, un período de calma y baja volatilidad.




Figura 3.4: Gráfica de la distribución del índice de volatilidad VIX. Fuente: elaboración propia.

- **Distribución de retornos del petróleo:** En cuanto al petróleo, que se muestra en la Figura 9, este destaca como el activo más volátil del dataset, con una desviación típica mensual (volatilidad) del 10,4%, más del doble que la del S&P 500. Su *skewness* de 1,78 indica asimetría positiva, mientras que su curtosis de 22,5 es exageradamente elevada. Estos dos valores muestran que el petróleo sufre movimientos extremos con una frecuencia enorme y que estos extremos tienden a ser en forma de crecimiento. En cuanto toca a los valores extremos, destaca la caída del retorno en un -40,8% en marzo de 2020, cuando la demanda colapsó por los confinamientos globales provocados por el COVID-19 [38]. Por otro lado, en mayo de 2020, subió un 88,4%.

Capítulo 3. Datos y preparación del dataset




Figura 3.5: Gráfica de la distribución de los retornos del petróleo. Fuente: elaboración propia.

- **Distribución de retornos del oro:** El oro, que es considerado activo refugio, presenta una volatilidad mensual del 4,4 %, similar a la del S&P 500. Su retorno mínimo de -18 % en marzo de 2020 se dio al inicio de la pandemia, mientras que el máximo del 13,9 % en abril de 2020 confirma su recuperación como activo refugio. Su curtosis de 4,34 confirma la presencia de colas pesadas, aunque menos extremas que en el petróleo. En lo que respecta a su *skewness*, este es de -0,241, lo que indica una ligera asimetría negativa. Todo lo mencionado es visible en la Figura 10.




Figura 3.6: Gráfica de la distribución de los retornos del oro. Fuente: elaboración propia.

- **Distribución de los tipos de interes FED:** Pasando ahora a los tipos de

3.3. Análisis exploratorio de datos (EDA)

interés de la Reserva Federal, que se muestran en la Figura 11, estos presentan una media del 1,78 %, aunque la mediana del 1,00 % revela largos períodos de tipos cercanos a cero. Su volatilidad mensual es del 1,93 %, reflejando cambios graduales. Su *skewness* de 0,750 indica asimetría positiva, mientras que la *kurtosis* de 1,98, inferior a 3, indica que la distribución es más plana que la normal, es decir, los tipos no cuentan con muchos eventos extremos. En cuanto al máximo, este se da en agosto de 2023, siendo los tipos de un 5,33 %, mientras que el mínimo del 0,05 % se alcanzó en abril de 2020.




Figura 3.7: Gráfica de la distribución de los tipos de interés de la Reserva Federal. Fuente: elaboración propia.

- **Distribución de los tipos de interés BCE:** Por su parte, el Banco Central Europeo mantuvo una política aún más expansiva, con una media del 0,79 % y una volatilidad mensual del 1,38 %. Su mínimo histórico de -0,50 % se mantuvo durante gran parte del período 2014-2022. Por otro lado, el máximo del 4,00 % se registró en septiembre de 2023. Todo lo mencionado es visible en la Figura 12.

Capítulo 3. Datos y preparación del dataset




Figura 3.8: Gráfica de la distribución de los tipos de interés del Banco Central Europeo. Fuente: elaboración propia.

- **Distribución de la inflación USA:** Otro factor importante es la inflación estadounidense, la cual presenta una media del 2,59%, un poco por encima del objetivo de la FED, y una volatilidad mensual del 1,85%. El mínimo de -1,96% se da en julio de 2009, después de la crisis, mientras que el máximo del 8,98% en junio de 2022 corresponde al período post-COVID. La curtosis de 5,07 y el *skewness* de 1,05 indican que los eventos extremos son más frecuentes de lo normal y tienden a ser al alza. Todo lo mencionado es visible en la Figura 13.




Figura 3.9: Gráfica de la distribución de la inflación en Estados Unidos. Fuente: elaboración propia.

- **Distribución de la inflación Europa:** En Europa, la dinámica es similar

3.3. Análisis exploratorio de datos (EDA)

pero algo más intensa, con un pico del 10,62% en octubre de 2022, impulsado por el COVID y los conflictos bélicos. Por otro lado, el mínimo se da en enero de 2015, con un valor de -0,62%. La elevada curtosis de 8,31 confirma que se trató de un evento extremo. La volatilidad mensual es del 1,94%. Todo lo mencionado es visible en la Figura 14.




Figura 3.10: Gráfica de la distribución de la inflación en Europa. Fuente: elaboración propia.

- **Distribución de la tasa de desempleo USA:** La tasa de desempleo, representada en la Figura 15, cuenta con una media del 5,73% y una volatilidad mensual del 2,06%, alcanzó su mínimo histórico del 3,4% en diciembre de 2019, reflejando un mercado laboral bastante boyante antes de la pandemia. Sin embargo, el máximo del 14,8% en abril de 2020, tras dicha pandemia, constituye un evento extremo reflejado en su curtosis de 4,01. Todo lo mencionado es visible en la Figura 15.

Capítulo 3. Datos y preparación del dataset




Figura 3.11: Gráfica de la distribución de la tasa de desempleo en Estados Unidos. Fuente: elaboración propia.

- **Distribución del bono 10Y-2Y USA:** En la Figura 16 se muestra el diferencial entre el bono a 10 años y a 2 años, que presenta una media positiva del 1,01 % y una volatilidad mensual del 0,95 %, indicando una pendiente ligeramente creciente. El mínimo de -1,06 % se presenta en julio de 2022. También se registraron inversiones importantes en 2006-2007 y en 2019. El hecho de que la *skewness* sea 0,122 y la *kurtosis* esté cercana a la normal indica una distribución simétrica. .




Figura 3.12: Distribución del diferencial de la curva de tipos 10Y-2Y. Fuente: elaboración propia.

- **Distribución del tipo de cambio euro/dólar:** Por último, el tipo de cambio euro-dólar, que se muestra en la Figura 17, presenta una media de 1,227

3.3. Análisis exploratorio de datos (EDA)

dólares por euro, reflejando un euro generalmente más fuerte que el dólar durante el periodo analizado. El valor máximo es de 1,576 y se alcanzó en abril de 2008. Por el contrario, el mínimo de 0,983 se registró en septiembre de 2022, momento en el cual el euro se equiparó con el dólar en cuanto a valor. La desviación típica de 0,129 refleja una volatilidad moderada, y la curtosis de 2,51 indica una distribución cercana a la normalidad.




Figura 3.13: Distribución del tipo de cambio euro-dólar. Fuente: elaboración propia.

- **Resumen de la distribución de las variables macroeconómicas:** El análisis de las distribuciones revela que las variables macroeconómicas presentan, en su mayoría, distribuciones con colas pesadas (curtosis >3), lo que confirma la presencia de eventos extremos en los mercados financieros. Destaca especialmente el petróleo (curtosis 22,5) y el VIX (curtosis 8,69) como las variables con mayor concentración de episodios extremos. La asimetría negativa del S&P 500 (-0,618) sugiere que las caídas abruptas son más probables que las subidas extraordinarias, un patrón común en renta variable. Estos hallazgos justifican la necesidad de utilizar modelos robustos que capturen adecuadamente estos eventos extremos en la fase de predicción.

En lo que respecta a la volatilidad, esta no es constante en el tiempo, sino que presenta picos que coinciden con períodos de crisis o eventos extraordinarios. Como se puede observar en la Figura 18, estos picos se concentran especialmente en 2008 (crisis financiera global), 2020 (pandemia de COVID-19) y 2022 (guerra de Ucrania e inflación descontrolada), momentos en los que la incertidumbre en los mercados se disparó. Conocer la volatilidad de las variables resulta importante, ya que aquellas variables con una mayor volatilidad (petróleo o VIX) implican que la variable presenta fluctuaciones más bruscas y eventos extremos con mayor frecuencia, lo que obliga a los modelos predictivos a ser robustos y capaces de capturar

Capítulo 3. Datos y preparación del dataset

estos picos. Por el contrario, una menor volatilidad indica comportamientos más estables y predecibles.

Todos los períodos que se han mencionado a lo largo de este análisis se verán más adelante, en la parte de clustering, de forma más detallada y completa.




Figura 3.14: Evolución de la volatilidad de las variables macroeconómicas (2003-2025). Fuente: elaboración propia.

Evolución temporal de las variables

Este análisis, permitirá conocer cómo han avanzado las variables macroeconómicas a lo largo del tiempo y comprobar la presencia de tendencias y de los eventos extremos mencionados anteriormente.

- **Tipos de interés:** En la Figura 19 se puede ver la evolución de los tipos de interés de la Reserva Federal (Fed) [39] y del Banco Central Europeo (BCE) [40] desde diciembre de 2003 hasta diciembre de 2025.

Antes de la crisis de 2008, ambos bancos mantuvieron los tipos en niveles altos para combatir la inflación. Sin embargo, con el estallido de la crisis financiera en 2008, ambos los bajaron drásticamente, situándose cerca del 0%.

Desde 2008 hasta 2015, la FED mantuvo los tipos en mínimos, y no fue hasta diciembre de 2015 cuando comenzó a subirlos de nuevo, alcanzando el 2,4% en julio de 2019. Sin embargo, la llegada del COVID en 2020 volvió a llevarlos a valores cercanos al 0% en abril de ese mismo año. Esta situación se prolongó durante dos años, hasta que en enero de 2022 la FED inició una nueva subida, alcanzando un máximo del 5,33% en octubre de 2023. En los últimos meses, debido a ciertos conflictos bélicos y a la desaceleración económica, los tipos han experimentado una pequeña bajada.

3.3. Análisis exploratorio de datos (EDA)

Por el lado del BCE, la recuperación fue mucho más lenta. Tras la crisis de 2008, este banco no empezó a subir tipos hasta junio de 2022. De hecho, entre 2008 y 2022, los tipos europeos sufrieron una bajada continua, llegando a alcanzar un mínimo histórico del -0,50 % en octubre de 2019 (tipos negativos). Sin embargo, al igual que la FED, a partir de 2022 los tipos subieron con fuerza, alcanzando un máximo del 4 % en septiembre de 2023. Desde entonces se han mantenido bastante estables, aunque en los últimos meses también han registrado una ligera bajada por los mismos motivos que en Estados Unidos.




Figura 3.15: Evolución de los tipos de interés de la Reserva Federal y del Banco Central Europeo (2003-2025). Fuente: elaboración propia.

- **Inflación:** En la Figura 20 se puede ver la evolución de la inflación en Estados Unidos y en Europa desde diciembre de 2003 hasta diciembre de 2025.

Se puede observar que antes de la crisis de 2008, la inflación se mantuvo controlada en torno al 2-3 % en ambas regiones. Sin embargo, con la crisis financiera de 2008, la inflación se desplomó. Estados Unidos llegó a tener deflación (inflación negativa) en 2009, mientras que Europa también sufrió esa deflación, pero en menor medida, quedando cerca del 0 %.

A finales de 2009, ambas regiones empezaron a recuperarse y hasta 2015 mantuvieron una inflación en torno al 2 %. Sin embargo, a inicios de 2015, tanto Europa como Estados Unidos sufrieron una nueva deflación debido a la caída del precio del petróleo.

Entre 2015 y 2017, la inflación volvió a subir, llegando de nuevo cerca del 2 %. Estos valores se mantuvieron durante dos años, hasta que en 2019, con el COVID, volvió a bajar, situándose de nuevo en valores negativos en 2020.

Sin embargo, todo cambió en 2021. Después del COVID, la inflación se

Capítulo 3. Datos y preparación del dataset

disparó como no se había visto en décadas. Estados Unidos alcanzó su máximo del 9% en junio de 2022, mientras que Europa llegó al 10,6% en octubre de ese mismo año, superando a Estados Unidos por primera vez en todo el período.

Desde 2023 en adelante, la inflación ha ido bajando gradualmente, alcanzando de nuevo valores cercanos al 2% en 2024, unos valores que se han mantenido hasta 2025.

En esta gráfica se puede ver lo mencionado anteriormente: los eventos extremos son frecuentes y tienden a ser al alza.




Figura 3.16: Evolución de la inflación en Estados Unidos y Europa (2003-2025). Fuente: elaboración propia.

- **S&P 500 vs VIX:** En la Figura 21 se compara la evolución del S&P 500 con el VIX.

Lo primero que llama la atención es la relación inversa entre ambos, es decir, cuando el VIX se dispara, el S&P 500 suele caer, y viceversa.

El mayor pico del VIX se vivió en 2008, con la crisis financiera, alcanzando casi los 60 puntos en octubre, siendo este su máximo histórico. Por otro lado, el S&P 500 llegó a caer más de un 40% desde sus máximos en 2008-2009.

Entre 2009 y 2019 se vivió una larga etapa de tranquilidad. El VIX se mantuvo en niveles bajos (entre 15 y 20), exceptuando algunos picos en 2010, 2011 y 2015. Por otro lado, el S&P 500 no paró de subir durante una década, multiplicándose por cuatro su valor desde los mínimos de 2009.

En 2020, con el COVID, el VIX volvió a dispararse hasta los 53,4 puntos. Esto conllevó la caída del S&P 500; sin embargo, no fue muy drástica y apenas perdió un 5%.

3.3. Análisis exploratorio de datos (EDA)

Entre 2021 y 2023, el VIX se quedó en niveles medios-altos (20-25), reflejando la incertidumbre por la inflación, la guerra y la subida de tipos. El S&P 500 se estancó, sin una tendencia clara, bajando y subiendo constantemente.

Finalmente, en 2024 y 2025, el VIX recuperó niveles bajos y el S&P 500 recuperó una tendencia al alza, subiendo de nuevo su valor.

En la gráfica se puede apreciar el alto valor de la curtosis de ambas variables.




Figura 3.17: Evolución del S&P 500 y del VIX (2003-2025). Fuente: elaboración propia.

- **Oro vs Petróleo:** En la Figura 22 se puede ver cómo han evolucionado los retornos del petróleo y del oro desde diciembre de 2003 hasta diciembre de 2025. Esto permite comparar su comportamiento a largo plazo.

El principal evento a destacar es la crisis de 2008, cuando ambos cayeron, aunque el petróleo sufrió un desplome mucho más fuerte, cayendo hasta un 60 %, mientras que el oro resistió mucho mejor, cayendo solo un 20 % debido a su cualidad de activo refugio.

Entre 2009 y 2011, el oro siguió subiendo de forma continua. Por otro lado, el petróleo también se recuperó, pero sin llegar a los niveles de 2008.

Entre 2012 y 2019, el oro se tomó un respiro y bajó. El petróleo, en cambio, sufrió dos caídas adicionales: una en 2014-2015 y otra en 2018.

En 2020 llegó el COVID y, con ello, el precio del petróleo cayó drásticamente. El oro, por el contrario, creció bastante, haciendo así que la diferencia entre ambos fuese enorme.

Entre 2021 y 2025, se puede observar cómo los retornos del oro han ido creciendo de forma continua, mientras que los del petróleo han sido un

poco más estacionarios.

En la gráfica se puede apreciar la alta volatilidad y curtosis del petróleo, así como la alta curtosis del oro, aunque no tan alta como la del petróleo.




Figura 3.18: Evolución de los retornos del oro y del petróleo (2003-2025). Fuente: elaboración propia.

- **Desempleo vs Curva de tipos 10Y-2Y:** En la Figura 23 se muestra la comparación entre la Curva de Tipos 10Y-2Y y el desempleo.

Se puede observar cómo, en la gráfica, la curva se encontraba en valores negativos (curva invertida) durante gran parte de los años 2006 y 2007 y, tal y como se ha visto anteriormente, en 2008 se produjo una gran crisis financiera. Este suceso coincide con el aumento de la tasa de paro, que durante dicha crisis alcanzó valores muy altos, llegando hasta el 10%.

Después de la crisis, entre 2008 y 2009, la curva tomó valores positivos debido a la recuperación del mercado.

Entre 2010 y 2018, la curva se mantuvo positiva todo el tiempo, hasta que en 2019 volvió a invertirse brevemente, anticipando así la recesión que se produciría por el COVID. Del mismo modo, entre 2010 y 2018, la tasa de desempleo estuvo en constante bajada; sin embargo, al igual que la curva de tipos, en 2019 con el COVID, la tasa de desempleo sufrió un fuerte aumento, alcanzando máximos históricos cercanos al 15%. Después del COVID, entre 2020 y 2021, la curva se puso muy positiva, pero en 2022 volvió a valores negativos, esta vez de forma profunda y duradera. La curva se mantuvo en terreno negativo durante todo 2023, con un mínimo de -1,06% en julio de 2022. Sin embargo, a diferencia de situaciones anteriores, pese a encontrarse la curva en valores negativos, la tasa de desempleo no siguió creciendo; de hecho, bajó exponencialmente hasta valores cercanos al 5%.

3.3. Análisis exploratorio de datos (EDA)

Finalmente, en 2024 y 2025, la curva volvió a terreno positivo y la tasa de desempleo se estabilizó, con valores muy constantes durante estos años.




Figura 3.19: Evolución de la curva de tipos 10Y-2Y y la tasa de desempleo en Estados Unidos (2003-2025). Fuente: elaboración propia.

Detección de datos atípicos

A continuación, en la Figura 24 se visualizan los diagramas de *boxplots*. En ellos se detectan algunos outliers. Estos outliers no se eliminan, ya que en el ámbito financiero representan información valiosa sobre crisis y eventos extraordinarios que el modelo debe aprender a manejar.

El S&P 500 presenta 6 outliers inferiores que representan las caídas en 2008 y 2020, y 3 outliers superiores, como el de abril de 2020. El VIX destaca con 12 outliers superiores, reflejando picos de pánico en 2008, 2020 y 2022-2023. El petróleo muestra 6 outliers inferiores, donde cabe destacar la caída del -40,8 % en marzo de 2020, y 2 superiores, como el rebote del 88,4 % en mayo de 2020. El oro presenta 4 outliers inferiores y 3 superiores.

La inflación es la variable con más outliers. En el caso de Estados Unidos, presenta 17 outliers superiores, siendo el más destacado el pico del 9 % en 2022. Por otro lado, Europa cuenta con 22 outliers superiores, destacando el pico del 10,6 % en octubre de 2022. En cuanto al desempleo, este tiene 3 outliers superiores debidos a la pandemia. Los tipos de interés de la FED y del BCE, la curva 10Y2Y y el tipo de cambio no presentan outliers.

En resumen, tal y como era de esperar, los outliers se concentran en la crisis financiera, la pandemia y el episodio inflacionario, afectando principalmente a la inflación, el VIX y el petróleo. Estos valores extremos se mantienen en el dataset para que los modelos de Machine Learning aprendan a manejar situaciones extremas.

Capítulo 3. Datos y preparación del dataset




Figura 3.20: Boxplots de las variables macroeconómicas. Fuente: elaboración propia.

Análisis de autocorrelación

Para finalizar con el análisis univariante, se realiza un análisis de autocorrelación. Este permite entender la memoria temporal de cada variable, es decir, cómo influyen sus valores pasados en los presentes. Este paso resulta muy importante para la fase de modelado, ya que indica qué variables pueden requerir la inclusión de sus retardos como predictores y cuáles son buenas candidatas para modelos con memoria larga, como las redes LSTM.

En las Figuras 25, 26 y 27 se muestran las funciones de autocorrelación para las variables macroeconómicas y para el rendimiento de Apple. En estas figuras se aprecia cómo, tanto en los retornos del S&P 500 como en los del petróleo y del oro, solo el primer lag supera las bandas de significancia (líneas azules), mientras que el resto de los lags se mantienen dentro del intervalo de confianza. Esto indica que los retornos pasados tienen muy poca influencia sobre los retornos actuales. Para el modelo, esto sugiere que con incluir el valor actual de las variables será suficiente.

El VIX, por el contrario, muestra varios lags que superan el intervalo de confianza. Esto sugiere que incluir varios de sus valores pasados (lags 1, 2 y 3) puede ayudar a capturar mejor la dinámica del riesgo en el mercado.

Por otro lado, los tipos de interés de la Reserva Federal y del Banco Central Europeo presentan una correlación muy alta y persistente, con múltiples lags significativos y una caída extremadamente lenta de los coeficientes. Es por ello que los tipos de interés son candidatos ideales para modelos como las redes **LSTM**.

En lo que respecta a la inflación, tanto en Estados Unidos como en Europa, muestra un comportamiento similar al de los tipos de interés, con alta persistencia y numerosos lags significativos. Al igual que los tipos, la inflación es una

3.3. Análisis exploratorio de datos (EDA)

variable con memoria larga que se beneficiará de modelos capaces de capturar sus efectos retardados.

Tanto el desempleo como la Curva de Tipos 10Y-2Y y el tipo de cambio euro-dólar presentan una autocorrelación muy alta y persistente.

Finalmente, el rendimiento de Apple presenta baja autocorrelación, lo que indica que los valores pasados no influyen significativamente en el rendimiento futuro. No obstante, en modelos no lineales como Random Forest o LSTM, estos lags pueden seguir siendo útiles al interactuar con otras variables.

En resumen, el análisis de autocorrelación permite clasificar las variables según su memoria temporal. Los retornos financieros presentan baja memoria, por lo que bastará con sus valores actuales. El VIX tiene memoria media, por lo que podría ser de utilidad añadir varios lags recientes. Lo mismo sucede con los tipos de interés, la inflación, el desempleo y la curva de tipos. Toda esta clasificación será utilizada en la fase de modelado para seleccionar los retardos adecuados para cada variable predictora, justificar el uso de LSTM para las variables con alta persistencia y optimizar la dimensionalidad del modelo, evitando lags innecesarios en variables con baja memoria.




Figura 3.21: Gráficas de autocorrelación del VIX y los retornos del S&P 500, oro y petróleo. Fuente: elaboración propia.

Capítulo 3. Datos y preparación del dataset




Figura 3.22: Gráficas de autocorrelación para tipos de interés e inflación. Fuente: elaboración propia.




Figura 3.23: Gráficas de autocorrelación para desempleo, curva de tipos y rendimiento de Apple. Fuente: elaboración propia.

3.3.2. Análisis multivariante

En esta sección, se realiza un análisis multivariante de las variables seleccionadas. Este análisis tiene como objetivo entender las relaciones entre las variables, identificar posibles redundancias y reducir la dimensionalidad del dataset para mejorar la eficiencia de los modelos predictivos. Para ello, se aplicarán técnicas como el análisis de correlación, el análisis de componentes principales (**PCA**) y el análisis de **clusters**.

Correlación entre variables

Comenzando con la correlación, en la Figura 28 se puede ver la matriz de correlación entre las variables. Se distinguen dos tonalidades: un azul oscuro que indica una correlación de +1 (las variables se comportan igual) y un rojo oscuro que indica una correlación inversa de -1 (se comportan de forma opuesta: si una sube, la otra baja). Los valores más cercanos al blanco indican que las variables tienen correlaciones cercanas a 0, por lo que podría decirse que no están correlacionadas.

En dicha matriz se puede observar que las correlaciones más fuertes son entre la inflación de Estados Unidos y la de Europa, con un valor de 0,86, y entre los tipos de la FED y los del BCE, con un valor de 0,81. Esto se puede apreciar en las gráficas presentadas en la evolución temporal de cada una de las variables, donde se puede ver esta correlación positiva. Por otro lado, destaca la correlación inversa entre el desempleo y la curva 10Y2Y (-0,74), esto se puede comprobar también, fijándose en la gráfica de la evolución temporal entre la curva y el desempleo, cuando una sube la otra baja.

Realizar este análisis de correlaciones resulta muy importante, ya que en caso de haber obtenido valores muy altos ($>0,9$), se habría planteado eliminar ciertas variables para no introducir ruido al entrenar los modelos predictivos. Más adelante, en la sección de selección de variables, se determinará si estas variables se mantienen o se eliminan. En el caso de que se mantengan todas las variables, sería por dos razones, en primer lugar, los modelos de Machine Learning que se emplearán (Random Forest, Gradient Boosting y LSTM) son robustos a la multicolinealidad, a diferencia de los modelos lineales tradicionales. En segundo lugar, mantener ambas variables permite capturar posibles asimetrías entre regiones, como el hecho de que en 2022 la inflación europea superara a la americana, algo que no recogería una variable única.

No obstante, se tendrá en cuenta esta alta correlación en la fase de interpretación de los modelos, especialmente al analizar la importancia de las variables.

Capítulo 3. Datos y preparación del dataset




Figura 3.24: Matriz de correlación entre las variables macroeconómicas. Fuente: elaboración propia.

Correlación con el target

Para justificar el uso de los modelos elegidos, se ha llevado a cabo un análisis de correlación entre las variables macroeconómicas y el target.

En la Figura 29 se pueden ver las correlaciones entre las variables macroeconómicas y el rendimiento del activo utilizado para las pruebas, que en este caso es Apple. Lo primero que llama la atención es que ninguna correlación supera 0,12 en valor absoluto, lo que indica que la relación entre estas variables y Apple no es lineal, lo cual no es negativo. Más adelante en esta sección se verá el motivo.

La variable con mayor correlación positiva es el petróleo, con un valor de 0,12, seguida del S&P 500, con 0,10. En el lado negativo, la inflación europea, con un valor de -0,08, y la inflación estadounidense, con -0,06, son las que presentan correlaciones más negativas. Por último, destaca la correlación casi nula del VIX (-0,02) con Apple, lo que se debe a que los picos de volatilidad son episódicos y no lineales.

El hecho de obtener correlaciones tan bajas indica que un modelo lineal simple no será suficiente para capturar la relación entre las variables macroeconómicas y Apple. Será necesario recurrir a modelos no lineales como Random Forest, Gradient Boosting o LSTM, que puedan capturar relaciones más complejas y efectos retardados.

3.3. Análisis exploratorio de datos (EDA)




Figura 3.25: Correlaciones entre las variables macroeconómicas y el rendimiento de Apple. Fuente: elaboración propia.

Análisis de componentes principales (PCA)

A continuación, se realiza un análisis de componentes principales (PCA) con el objetivo de reducir la dimensionalidad del conjunto de datos, identificando un conjunto de variables no correlacionadas que capturen la mayor parte de la variabilidad del sistema. Los componentes principales se ordenan de mayor a menor según la cantidad de varianza que explican. El primer componente principal (PC1) es la combinación lineal de las variables originales que representa la máxima varianza posible. El PC2, que no está correlacionado con el PC1, captura la máxima varianza restante, y así sucesivamente. De esta forma, es posible determinar cuántas dimensiones son necesarias para resumir la información contenida en las variables originales.

En la Figura 30 se muestra la varianza explicada por cada componente principal. Los primeros cuatro componentes explican el 73,8% de la varianza total: PC1 representa un 33,4%, PC2 un 16,4%, PC3 un 13,1% y PC4 un 10,9%. Esto indica que la información contenida en las once variables macroeconómicas originales puede resumirse en un número reducido de dimensiones. A partir del quinto componente, la varianza explicada por cada uno es inferior al 9%, lo que confirma que los cuatro primeros componentes capturan la mayor parte de la estructura del sistema.

Capítulo 3. Datos y preparación del dataset




Figura 3.26: Varianza explicada por cada componente principal. Fuente: elaboración propia.

Las Figuras 31, 32, 33 y 34 muestran la contribución de cada variable a los cuatro primeros componentes principales, lo que permite interpretar su significado económico.

- **PC1:** Comenzando con el PC1, este está definido por la curva de tipos (21%), los tipos de la FED (18,5%) y el desempleo (17,8%). En este componente, los valores altos indican un entorno de tipos elevados, curva normal y desempleo controlado, mientras que los valores bajos indican tipos bajos o recesiones cercanas. El primer componente principal (PC1) está fuertemente influenciado por la inflación (tanto en Estados Unidos como en Europa), los tipos de interés (FED y BCE) y el desempleo. Esto sugiere que PC1 representa un factor macroeconómico general que captura la dinámica de la política monetaria y las condiciones económicas. Un aumento en PC1 podría interpretarse como un entorno de alta inflación, tipos de interés elevados y mayor desempleo, lo que suele ser negativo para los activos financieros.

3.3. Análisis exploratorio de datos (EDA)




Figura 3.27: Contribución de las variables al primer componente principal (PC1). Fuente: elaboración propia.

- **PC2:** En cuanto al PC2, este se encuentra dominado por el VIX (32%) y el S&P 500 (29,5%), que juntos aportan más del 60% del total. Este componente captura la alternancia entre períodos de expansión (S&P 500 alto, VIX bajo) y crisis (S&P 500 bajo, VIX alto). Cuando el PC1 es positivo, el mercado se encuentra en alza y con baja volatilidad, mientras que cuando es negativo, se está en épocas de recesión.




Figura 3.28: Contribución de las variables al segundo componente principal (PC2). Fuente: elaboración propia.

- **PC3:** En el PC3 dominan los tipos del BCE (33%), la curva de tipos (30,5%) y el oro (15,5%). Este componente refleja la política monetaria europea y los activos refugio. Cuando este PC se encuentra alto, puede suponer una

Capítulo 3. Datos y preparación del dataset

crisis cercana.




Figura 3.29: Contribución de las variables al tercer componente principal (PC3).
Fuente: elaboración propia.

- **PC4:** Finalmente, el PC4 está formado por la inflación de Estados Unidos (28%), el petróleo (27,5%) y la inflación europea (25%). Este componente define básicamente periodos inflacionarios, en los que los precios se disparan. Un ejemplo cercano podría ser el año 2022.




Figura 3.30: Contribución de las variables al cuarto componente principal (PC4).
Fuente: elaboración propia.

Tras este análisis de PCA, se confirma que el sistema macroeconómico no está definido por una sola variable, sino que responde a varias dimensiones independientes como las vistas anteriormente. En la fase de modelado se mantendrán

3.3. Análisis exploratorio de datos (EDA)

las variables originales en lugar de los componentes principales. Sin embargo, el análisis realizado será de gran utilidad a la hora de seleccionar variables y de interpretar los modelos.

Análisis de clusters

Para finalizar el análisis multivariante, se realiza un análisis de clusters con el objetivo de identificar grupos de períodos temporales que compartan características macroeconómicas similares. Este análisis permite segmentar el dataset en diferentes ciclos económicos, lo que resulta útil para entender mejor la dinámica del sistema y para evaluar el comportamiento de los modelos predictivos en distintos contextos.

En la Figura 35 se muestra la segmentación temporal de los seis ciclos económicos identificados entre 2003 y 2025, así como la evolución del activo Apple a lo largo de los mismos. Cada color representa un ciclo diferente, permitiendo observar cuándo comienza y termina cada ciclo, así como su duración.

El primer ciclo, que abarca desde 2003 hasta 2007, corresponde al período de precrisis, caracterizado por un fuerte crecimiento económico. El siguiente ciclo es la crisis financiera de 2008, que abarca desde 2008 hasta 2009 y está marcado por la recesión global y la destrucción masiva de empleo. A continuación, se identifica el período de recuperación de la crisis, un ciclo largo que va desde 2010 hasta 2013 y que refleja las consecuencias de la crisis financiera experimentada anteriormente.

A partir de 2014, la economía comienza a recuperarse y se inicia un período de crecimiento económico que representa la fase expansiva más prolongada, con tasas de crecimiento muy altas, tipos de interés en mínimos históricos y una racha alcista prolongada en los mercados. Sin embargo, se pueden encontrar picos en variables como el VIX, provocados por la incertidumbre aún existente. Pese a este crecimiento, en 2019 surge el COVID-19, provocando un parón y una mini crisis que perduró hasta 2021. Este ciclo captura el impacto de la pandemia en la economía.

Finalmente, el período de recuperación y estabilización, que abarca desde 2022 hasta 2025, se caracteriza por la recuperación post-pandemia, con una fuerte inflación y, en consecuencia, una subida muy pronunciada de los tipos de interés durante los primeros años. No obstante, con el paso del tiempo, la situación se estabilizó.

Cabe destacar que, a pesar de la crisis sanitaria y económica provocada por la pandemia, Apple alcanzó máximos históricos en su cotización durante el período 2020-2021. Este comportamiento puede explicarse por varios factores: la percepción de las grandes tecnológicas como activos refugio en momentos de incertidumbre, los tipos de interés en mínimos históricos que favorecieron la valoración de empresas de crecimiento, los estímulos fiscales masivos que incrementaron la liquidez en los mercados, el cambio en los hábitos de consumo hacia la tecnología (provocado por el teletrabajo y la educación online) y los sólidos resultados financieros de la compañía durante la pandemia.

Capítulo 3. Datos y preparación del dataset

Por último, esta segmentación en seis ciclos será utilizada en la fase de modelado para evaluar el comportamiento de los modelos predictivos en diferentes contextos económicos, permitiendo analizar su robustez tanto en períodos de expansión como en situaciones de crisis.




Figura 3.31: Segmentación temporal de los seis ciclos económicos (2003-2025) y evolución de Apple durante cada ciclo. Fuente: elaboración propia.

Para concluir con el clustering, se muestra la importancia de cada variable en cada uno de los ciclos. En las Figuras 36 y 37 se pueden ver los valores medios de las principales variables macroeconómicas para cada uno de los seis ciclos mencionados anteriormente. Este análisis permite identificar patrones claros que caracterizan cada fase del ciclo económico.

Se puede observar cómo en períodos de expansión y auge, como los de 2003-2007 y 2014-2019, el crecimiento del S&P 500 es elevado, la volatilidad es baja, la inflación está controlada, los tipos de interés se encuentran en niveles normales o bajos y el desempleo está en descenso. Estas variables reflejan una economía sana y próspera.

Por otro lado, el período de la crisis de 2008-2009 se caracteriza por un VIX muy alto, alcanzando valores por encima de 40. A su vez, el S&P 500 cae con fuerza, la inflación se desploma, los tipos de interés se reducen a cero y el desempleo comienza a aumentar. A diferencia del período anterior, este muestra una economía debilitada y cercana al colapso.

Entre 2010 y 2013, en el período de recuperación de la crisis, el VIX se mantuvo elevado, el S&P 500 se recuperó gradualmente y la inflación se mantuvo en valores muy bajos. Por otro lado, los tipos se mantenían en mínimos; sin embargo, el desempleo alcanzó su punto máximo en 2010. Estos datos reflejan un escenario con una economía aún bastante débil, pero con signos de mejoría.

Durante el ciclo de la crisis por el COVID-19, se pueden encontrar similitudes con la crisis de 2008, ya que ambos períodos se caracterizan por una volatili-

3.3. Análisis exploratorio de datos (EDA)

dad muy alta. No obstante, durante el COVID la recuperación fue bastante más rápida: los tipos volvieron a cero y el S&P 500 se recuperó significativamente, alcanzando nuevos máximos en menos de un año.

Por último, en el período de recuperación y estabilización, se presenta un patrón único: la inflación alcanza máximos históricos, provocando que los tipos de interés también alcancen máximos. Debido a esto, la curva de tipos se invierte profundamente, anticipando una posible recesión. A pesar de ello, el S&P 500 muestra resistencia, creciendo pese a las dificultades económicas iniciales.

Tras este análisis, se confirma que cada ciclo está marcado por una serie de características. Los períodos de expansión se asocian con baja volatilidad y crecimiento sostenido; las crisis presentan picos de volatilidad y bajadas de los tipos de interés; y los períodos de alta inflación suelen conllevar subidas de tipos. Estos datos serán de gran utilidad en la fase de modelado a la hora de realizar la simulación de escenarios.




Figura 3.32: Valores medios de las variables macroeconómicas por ciclo económico (parte 1). Fuente: elaboración propia.




Figura 3.33: Valores medios de las variables macroeconómicas por ciclo económico (parte 2). Fuente: elaboración propia.

3.4. Selección de variables y dataset final

Una vez completado el análisis exploratorio de datos, el siguiente paso fundamental es la selección de las variables que conformarán el dataset definitivo para el entrenamiento de los modelos predictivos. El objetivo es maximizar la información relevante, eliminar redundancias y reducir la dimensionalidad del problema, mejorando así la eficiencia computacional y la capacidad de generalización de los modelos.

Cabe destacar que este proceso de selección se ha ejemplificado utilizando Apple como activo de estudio. En una aplicación real de esta metodología a otro fondo de inversión o activo financiero, los resultados podrían variar, ya que la relación entre las variables macroeconómicas y el target depende del activo concreto analizado. Por esta razón, se ha implementado un proceso automatizado en Python que permite replicar la selección de variables de forma sistemática para cualquier activo o fondo de inversión, garantizando así la reproducibilidad y escalabilidad del método.

3.4.1. Criterios de selección

La estrategia de selección de variables se ha basado en dos criterios complementarios:

1. **Información mutua (Mutual Information - MI)** [41]: Mide la dependencia estadística entre cada variable predictora y el rendimiento del target. Para calcularla se ha utilizado el método de discretización uniforme en 10 bins, simulando el enfoque habitual en el software R, lo que permite capturar relaciones no lineales. Las variables se ordenan de mayor a menor MI.
2. **Correlación entre predictores** [42]: Una vez ordenadas las variables por

3.4. Selección de variables y dataset final

MI, se recorre la lista y se eliminan aquellas que presentan una correlación de Pearson superior a 0,80 con alguna variable ya seleccionada, quedándose así con la de mayor MI dentro de cada grupo redundante. Este proceso elimina la redundancia informativa.

Adicionalmente, se ha definido un conjunto de variables macroeconómicas que se mantienen independientemente de su valor de MI por su relevancia conceptual en la literatura financiera. Dichas variables son: el rendimiento del S&P 500, el índice de volatilidad VIX, los tipos de interés de la Reserva Federal, la curva de tipos 10Y-2Y, la inflación de Estados Unidos y el rendimiento del activo.

3.4.2. Proceso automatizado de selección

Para garantizar la reproducibilidad y objetividad del proceso, se ha implementado una función en Python denominada `seleccion_variables`. El algoritmo sigue los siguientes pasos:

Listing 3.2: Función para seleccionar variables

```
def seleccion_variables(df, target='target',
                       umbral_mi_percentil=50,
                       umbral_correlacion=0.80,
                       n_bins=10,
                       random_state=42):

    variables_forzadas = [
        'sp500_return', 'vix', 'tipos_fed',
        'curva10Y2Y', 'inflacion_usa', 'activo_return'
    ]

    X = df.select_dtypes(include=[np.number]).drop(columns=[target])
    y = df[target]

    # Discretizar X
    discretizer = KBinsDiscretizer(n_bins=n_bins,
                                    encode='ordinal', strategy='uniform')
    X_discrete = discretizer.fit_transform(X)
    X_discrete = pd.DataFrame(X_discrete,
                              columns=X.columns, index=X.index)

    # Discretizar y
    y_discrete = pd.cut(y, bins=n_bins, labels=False)

    # Calcular MI con variables discretas
    mi_scores = mutual_info_regression(X_discrete,
                                       y_discrete, random_state=random_state)

    mi_df = pd.DataFrame({
```

Capítulo 3. Datos y preparación del dataset

```
        'variable': X.columns,
        'mi_score': mi_scores
    })).sort_values('mi_score', ascending=False)

    for i, row in mi_df.head(15).iterrows():
        print(f"{row['variable']:25s} {row['mi_score']:.6f}")

mi_dict = dict(zip(mi_df['variable'], mi_df['mi_score']))
vars_ordenadas = mi_df['variable'].tolist()

variables_sin_corr = []
matriz_corr = X.corr().abs()

for var in vars_ordenadas:
    es_redundante = False

    for selected in variables_sin_corr:
        corr_val = matriz_corr.loc[var, selected]
        if corr_val > umbral_correlacion:
            es_redundante = True
            break

    if not es_redundante:
        variables_sin_corr.append(var)

n_vars = len(variables_sin_corr)
umbral_index = int(np.ceil(n_vars * umbral_mi_percentil / 100))

vars_seleccionadas = variables_sin_corr[:umbral_index]

for var in variables_forzadas:
    if var in X.columns and var not in vars_seleccionadas:
        vars_seleccionadas.append(var)

print(f"\nVariables seleccionadas:")
for i, var in enumerate(vars_seleccionadas, 1):
    mi_val = mi_dict.get(var, 0)
    es_forzada = " [FORZADA]" if var in variables_forzadas else ""
    print(f"    {i:2d}. {var:30s} (MI: {mi_val:.6f}){es_forzada}")

dataset_final = df[vars_seleccionadas + [target]].copy()

return dataset_final
```

3.4. Selección de variables y dataset final

#Llamada a la función:

```
dataset_optmizado = seleccion_variables(dataset, target='target')
```

1. **Cálculo de la información mutua:** Se discretizan todas las variables predictoras en 10 bins de anchura uniforme y se calcula la MI con respecto al target utilizando la función `mutual_info_regression` de scikit-learn [13].
2. **Eliminación de redundancia por correlación:** Las variables se ordenan de mayor a menor MI. A continuación, se recorre la lista y se selecciona una variable solo si su correlación con cualquiera de las ya seleccionadas es inferior a 0,80. En caso contrario, se descarta.
3. **Selección por percentil:** Una vez obtenido el conjunto de variables no redundantes, se calcula el percentil 50 de sus valores de MI y se conservan únicamente las que superan dicho umbral. Esto equivale a quedarse con el 50 % de las variables con mayor MI.
4. **Mantenimiento de variables forzadas:** Finalmente, se añaden las variables macroeconómicas forzadas, asegurando así su presencia en el dataset final.

3.4.3. Resultados de la selección

Tras aplicar el proceso de selección sobre el conjunto de datos completo, las variables seleccionadas se muestran en la Tabla 2.

Variable	Descripción
media_movil_6m	Media móvil a 6 meses del rendimiento de Apple
lag_3	Retraso de 3 meses del rendimiento de Apple
vix	Índice de volatilidad VIX (forzada)
oro_return	Retorno mensual del oro
eurusd	Tipo de cambio euro/dólar
lag_12	Retraso de 12 meses del rendimiento de Apple
lag_6	Retraso de 6 meses del rendimiento de Apple
volatilidad_3m	Volatilidad móvil a 3 meses del rendimiento de Apple
inflacion_usa	Inflación de Estados Unidos (forzada)
sp500_return	Retorno mensual del S&P 500 (forzada)
tipos_fed	Tipos de interés de la Reserva Federal (forzada)
curva10Y2Y	Diferencial bono 10 años - 2 años (forzada)
activo_return	Rendimiento pasado del activo (forzada)

Cuadro 3.1: Variables del dataset final. Fuente: elaboración propia.

3.4.4. Creación de datasets para Deep Learning y Machine Learning

Debido a que los modelos de Machine Learning carecen de memoria temporal, mientras que las redes LSTM están diseñadas específicamente para capturar dependencias secuenciales, se han construido dos versiones del dataset:

Capítulo 3. Datos y preparación del dataset

- **Dataset para Deep Learning (LSTM):** Contiene únicamente las variables seleccionadas en su valor contemporáneo, sin incluir retardos. La LSTM es capaz de aprender directamente la estructura temporal de la serie.
- **Dataset para Machine Learning:** Parte del mismo conjunto de variables seleccionadas, pero se han añadido retardos (*lags*) de variables económicas, dichas variables son los tipos de interés, la inflación, el VIX, el desempleo y la curva de tipos. De esta forma se proporciona a los modelos de ML información sobre el pasado, y solucionando así su falta de memoria temporal. Los retrdos que se han incorporado son de 1, 3 y 6 meses para los tipos y la inflación, y de 1, 2 y 3 meses para el VIX, el desempleo y la curva de tipos.

Ambos datasets se han alineado temporalmente eliminando las filas iniciales con valores faltantes debidos a los retardos, garantizando así la comparabilidad de los resultados.

Este dataset final, que consta de 13 variables predictoras y la variable target, será el utilizado para el entrenamiento y evaluación de los modelos Random Forest, Gradient Boosting y LSTM en los capítulos siguientes.

Capítulo 4

Entrenamiento y validación de los modelos predictivos

En este capítulo se describe la implementación, el entrenamiento y validación de los modelos predictivos seleccionados para este trabajo, dichos modelos son Random Forest, Gradient Boosting, LGBM y LSTM. Para tal entrenamiento, se partirá de los datasets optimizados obtenidos en el Capítulo 3 tras todo el procesamiento de datos (Se recuerda que había 2 datasets, uno de ellos para los modelos ML, con retardos en variables macroeconómicas y el otro para los modelos DL, sin retardos), se detalla la partición temporal de los datos, la configuración de hiperparámetros, el entrenamiento de los modelos y la evaluación de los mismos. En lo que respecta a los fundamentos teóricos de cada modelo, estos ya se presentaron en el Capítulo 2, por lo que aquí se abordará tan solo su aplicación práctica.

4.1. División de los datos en entrenamiento, validación y prueba

Una vez contruidos los dos datasets, el siguiente paso es dividir los datos en tres subconjuntos, entrenamiento, validación y prueba. Dado que se trata de una serie temporal, la división debe de respetar el orden cronológico.

4.1.1. Criterios de división

Para dicha división, se ha optado por un reparto del 80 % de los datos para entrenamiento, 10 % para validación y 10 % para prueba. Esta distribución permite disponer de un número un amplio número de observaciones para el entrenamiento (212 meses), al igual que se tienen conjuntos de validación y prueba con tamaños significativos (26 meses cada uno). De este modo, se garantiza que los modelos tengan suficiente información para aprender patrones en los datos, al mismo tiempo que se dispone de conjuntos adecuados para ajustar hiperparámetros y evaluar el rendimiento final.

Capítulo 4. Entrenamiento y validación de los modelos predictivos

La división de los datos se ha implementado mediante una función en Python que respeta el orden secuencial de los datos, dicha función es *division_conjuntos* y se ha aplicado sobre todos los modelos.

Listing 4.1: Función para la partición temporal de los datos

```
def division_conjuntos(dataframe, tr_size=0.8, vl_size=0.1, ts_size=0.1):
    N = dataframe.shape[0]
    Ntrain = int(tr_size * N)
    Nval = int(vl_size * N)

    train = dataframe.iloc[:Ntrain]
    val = dataframe.iloc[Ntrain:Ntrain+Nval]
    test = dataframe.iloc[Ntrain+Nval:]

    return train, val, test

#Llamada a la función
tr, vl, ts = division_conjuntos(df)

X_train = tr.drop(columns=['target'])
y_train = tr['target']

X_val = vl.drop(columns=['target']) +
y_val = vl['target']

X_test = ts.drop(columns=['target'])
y_test = ts['target']
```

4.1.2. Aplicación a los datasets de ML y DL

La función detallada anteriormente, se ha aplicado sobre ambos datasets, ya que tienen exactamente el mismo número de filas y las mismas fechas. De este modo, las divisiones temporales son idénticos para ambos conjuntos, lo que garantiza que la posterior comparación entre modelos sea justa y coherente.

4.1.3. Funcionalidad de cada conjunto

Como ya se ha comentado, la división se divide en tres conjuntos con funciones específicas durante el proceso de entrenamiento y evaluación de los modelos:

- **Conjunto de entrenamiento:** Se utiliza para ajustar los parámetros internos de cada modelo. En el caso de Random Forest y Gradient Boosting, este conjunto se emplea para construir los árboles de decisión, en el caso de la LSTM, se usa para actualizar los pesos de la red mediante el algoritmo de retropropagación.
- **Conjunto de validación:** Se emplea durante el entrenamiento para ajustar los hiperparámetros, para decidir cuándo detener el entrenamiento y para evitar el sobreajuste.

- **Conjunto de prueba:** Este conjunto, se usa únicamente para la evaluación final del modelo. Una vez que el modelo ha sido entrenado y ajustado, se calculan las métricas de error sobre este conjunto para obtener una estimación de su capacidad de generalización.

4.2. Métricas de evaluación

Antes de nada, mencionar que las métricas de evaluación utilizadas para comparar los modelos han sido las siguientes:

- **MAE** (Error Absoluto Medio): Mide el error promedio absoluto entre las predicciones y los valores reales. Es una métrica fácil de interpretar, ya que se expresa en las mismas unidades que la variable objetivo.
- **RMSE** (Raíz del Error Cuadrático Medio): Mide la raíz cuadrada del promedio de los errores al cuadrado. Penaliza más los errores grandes que el MAE, lo que puede ser útil para detectar modelos que cometen errores significativos.
- **R²** (Coeficiente de Determinación): Mide la proporción de la varianza en la variable objetivo que es explicada por el modelo.
- **DA** (Directional Accuracy): Mide el porcentaje de aciertos en la predicción de la dirección (subida o bajada) del rendimiento.

4.3. Entrenamiento de modelos de Machine Learning

Una vez divididos los datos en los conjuntos de entrenamiento, validación y prueba, se procede al entrenamiento de los dos modelos de Machine Learning. todos los modelos se entrenan sobre el `dataset_ml` (Dataset con retardos para los modelos de Machine Learning). Sin embargo, también se probará a entrenarlos con el dataset sin selección de variables, para así ver todas las posibilidades.

Para cada modelo se han seguido dos etapas. En primer lugar, se ha realizado una búsqueda de hiperparámetros con el objetivo de encontrar la configuración que minimice el error en el conjunto de validación. En segundo lugar, una vez seleccionados los mejores hiperparámetros, se ha entrenado el modelo final sobre el conjunto de entrenamiento completo.

4.3.1. Random Forest

A continuación, se describe el proceso de ajuste de hiperparámetros y entrenamiento del modelo Random Forest. Pero antes de continuar, es importante comentar que se han obtenido mejores resultados al trabajar con el conjunto reducido de variables que con el conjunto completo. Es por ello, que los resultados mostrados a continuación son los obtenidos tras el entrenamiento con el dataset reducido, dando así valor a la selección de variables.

1. **Configuración de hiperparámetros** Para el modelo Random Forest se ha definido un espacio de búsqueda que incluye los siguientes hiperparámetros:

- **n_estimators**: número de árboles del bosque (100, 200, 300).
- **max_depth**: profundidad máxima de cada árbol (5, 10, 15, 20, None).
- **min_samples_split**: número mínimo de muestras requerido para dividir un nodo (2, 5, 10, 12).
- **min_samples_leaf**: número mínimo de muestras requerido en una hoja (1, 2, 4).
- **max_features**: 'max_features': ['sqrt', 'log2', None]

El ajuste de hiperparámetros se ha realizado mediante búsqueda en rejilla (GridSearchCV) [43] combinada con validación cruzada temporal (TimeSeriesSplit) [44] con 3 divisiones, garantizando así el orden cronológico de los datos. En cuanto a la métrica de optimización, esta ha sido el error cuadrático medio (MSE) [45]. Mencionar que el GridSearch es igual en todos los modelos de Machine Learning, solo que cambiando hiperparametros.

Listing 4.2: Implementación del GridSearch para Random Forest

```
param_grid_rf = {
    'n_estimators': [100, 200, 300],
    'max_depth': [5, 10, 15, 20, None],
    'min_samples_split': [2, 5, 10, 12],
    'min_samples_leaf': [1, 2, 4],
    'max_features': ['sqrt', 'log2', None]
}

ts_cv = TimeSeriesSplit(n_splits=3)

# Inicializar el modelo
rf = RandomForestRegressor(random_state=42, n_jobs=-1)

grid_search_rf = GridSearchCV(
    estimator=rf,
    param_grid=param_grid_rf,
    cv=ts_cv,
    scoring=da_scorer,
    verbose=1,
    n_jobs=-1
)

# Ajustar la búsqueda
grid_search_rf.fit(X_train, y_train)
```

Tras la búsqueda de hiperparámetros, los mejores obtenidos han sido:

4.3. Entrenamiento de modelos de Machine Learning

- `n_estimators = 200`
- `max_depth = 10`
- `min_samples_split = 5`
- `min_samples_leaf = 2`
- `max_features = 'None'`

El mejor MAE alcanzado durante el entrenamiento ha sido de -0.6352. Realizando la misma búsqueda pero con el dataset completo, el mejor MAE obtenido ha sido de -0.8321, lo que confirma que el modelo obtiene mejores resultados al trabajar con el conjunto reducido de variables.

2. **Entrenamiento** Una vez seleccionados los mejores hiperparámetros, se ha entrenado el modelo Random Forest final sobre el conjunto de entrenamiento completo (212 meses). Para ello, se ha utilizado la implementación *RandomForestRegressor* de la librería *scikit-learn* [12]. Tras el entrenamiento, el modelo ha sido guardado para su posterior uso en la fase de evaluación. Esta implementación también es igual en todos los modelos de Machine Learning, solo que cambiando el modelo a entrenar (*RandomForestRegressor*, *GradientBoostingRegressor* ...).

Listing 4.3: Implementación de Random Forest Regressor

```
best_rf = RandomForestRegressor(**grid_search_rf.best_params_,
                                random_state=42, n_jobs=-1)

best_rf.fit(X_train, y_train)

y_pred_val_raw = best_rf.predict(X_val)

calibrator_rf = IsotonicRegression(out_of_bounds='clip')
calibrator_rf.fit(y_pred_val_raw, y_val)

# Calibrar predicciones de test
y_pred_test_raw = best_rf.predict(X_test)
y_pred_test_calibrated = calibrator_rf.predict(y_pred_test_raw)

r2_original = r2_score(y_test, y_pred_test_raw)
r2_calibrado = r2_score(y_test, y_pred_test_calibrated)

print(f"\nR2 original: {r2_original:.4f}")
print(f"\nR2 calibrado: {r2_calibrado:.4f}")

# Decidir cuál usar
if r2_calibrado > r2_original:
    print("\nUsando predicciones calibradas")
    y_pred_test = y_pred_test_calibrated
else:
    print("\nUsando predicciones originales")
    y_pred_test = y_pred_test_raw
```

```
y_pred_val = calibrator_rf.predict(y_pred_val_raw)
            if r2_calibrado > r2_original else y_pred_val_raw

# Métricas de validación
mae_val = mean_absolute_error(y_val, y_pred_val)
rmse_val = np.sqrt(mean_squared_error(y_val, y_pred_val))
r2_val = r2_score(y_val, y_pred_val)
da_val = directional_accuracy(y_val, y_pred_val)
```

En cuanto a las métricas de error obtenidas en la fase de validación, se ha obtenido lo siguiente:

- **MAE** (Error Absoluto Medio): 0,0888
- **RMSE** (Raíz del Error Cuadrático Medio): 0,1122
- **R2** (Coeficiente de Determinación): -0,8597
- **Directional Accuracy**: 0,5

Estos valores indican que, de media, la predicción del modelo se desvía aproximadamente un 8,88% del rendimiento real de Apple, un resultado razonable teniendo en cuenta la alta volatilidad de los mercados financieros. Puntualizar que estos valores, también son menores que los obtenidos con el dataset reducido.

4.3.2. Gradient Boosting

En lo que respecta al modelo Gradient Boosting, se ha seguido la misma metodología que en el caso anterior, búsqueda de hiperparámetros con validación cruzada temporal y entrenamiento final con el conjunto reducido de variables.

1. **Configuración de hiperparámetros** Para el modelo Gradient Boosting se ha definido el siguiente espacio de búsqueda:
 - **n_estimators**: número de árboles (300, 400, 500).
 - **learning_rate**: tasa de aprendizaje (0.03, 0.05, 0.08).
 - **max_depth**: profundidad máxima de cada árbol (4, 5, 6).
 - **subsample**: fracción de muestras utilizada en cada iteración (0.7, 0.8, 0.9).
 - **min_samples_split**: mínimo de muestras para dividir un nodo (10, 20, 50).
 - **min_samples_leaf**: mínimo de hojas para dividir un nodo (5, 10, 15).
 - **loss**: (huber)

Al igual que en el caso de Random Forest, el ajuste se ha realizado con GridSearchCV y validación cruzada temporal TimeSeriesSplit con 3 divisiones y los mejores hiperparámetros obtenidos han sido:

4.3. Entrenamiento de modelos de Machine Learning

- **n_estimators** = 500
- **learning_rate** = 0,08
- **max_depth** = 6
- **subsample** = 0,7
- **min_samples_split** = 20
- **min_samples_leaf** = 5
- **loss** = huber

El mejor MAE alcanzado durante el entrenamiento ha sido de 0.6226.

2. **Entrenamiento** Con los mejores hiperparámetros seleccionados, se ha entrenado el modelo Gradient Boosting final sobre el conjunto de entrenamiento. Para ello, se ha utilizado la implementación *GradientBoostingRegressor* de scikit-learn [14].

Tras el entrenamiento, las métricas de error obtenidas sobre el conjunto de validación han sido:

- **MAE** (Error Absoluto Medio): 0,0843
- **RMSE** (Raíz del Error Cuadrático Medio): 0,0991
- **R2** (Coeficiente de Determinación): -0,4511
- **Directional Accuracy**: 0,45

Estos resultados son ligeramente mejores que los obtenidos con Random Forest, lo que indica que, para este problema, el enfoque de boosting ha resultado más efectivo que el de bagging.

4.3.3. LGBM

Además de los modelos Random Forest y Gradient Boosting convencionales, se ha incorporado LightGBM (Light Gradient Boosting Machine) [15] como una variante optimizada del boosting. LightGBM presenta mejoras significativas respecto al Gradient Boosting, especialmente en términos de velocidad de entrenamiento y capacidad de manejo de grandes volúmenes de datos.

Este modelo LGBM no estaba pensado incorporarlo de un inicio, sin embargo, sus resultados han sido tan significativos, que se ha considerado necesario añadirlo.

1. **Ventajas de LightGBM frente a Gradient Boosting estándar** A diferencia del algoritmo *GradientBoostingRegressor* de scikitlearn, que utiliza un crecimiento de árboles por niveles, LightGBM emplea un crecimiento por hojas, lo que permite una mayor profundidad en las ramas más significativas y una mejor adaptación a patrones complejos. Adicionalmente, LightGBM incorpora técnicas de regularización avanzadas y soporte para early stopping.

Otra ventaja importante de LightGBM es su capacidad para manejar eficientemente grandes volúmenes de datos y su inclusión de mecanismos para evitar el sobreajuste, como la regularización L1 y L2 sobre los pesos de las hojas, el subsampling de filas y columnas en cada iteración, y la posibilidad de detener el entrenamiento de forma anticipada cuando la métrica de validación deja de mejorar.

2. **Configuración de hiperparámetros** Para el modelo LightGBM se ha definido el siguiente espacio de búsqueda, adaptado a las características del dataset:

- **n_estimators**: número de árboles (50, 100, 150)
- **max_depth**: profundidad máxima (3, 5, 7)
- **min_samples_split**: mínimo de muestras para dividir un nodo (10, 20, 50)
- **min_samples_leaf**: número mínimo de hojas por árbol (5, 10, 15)
- **subsample**: fracción de muestras por iteración (0.7, 0.8, 0.9)

La búsqueda de hiperparámetros se ha realizado mediante `GridSearchCV` con validación cruzada temporal `TimeSeriesSplit` de 3 divisiones, optimizando la precisión direccional. Los mejores hiperparámetros obtenidos han sido:

- **n_estimators** = 50
- **max_depth** = 7
- **min_samples_split** = 10
- **min_samples_leaf** = 10
- **subsample** = 0.7

3. **Entrenamiento y resultados** Una vez seleccionados los hiperparámetros óptimos, se ha entrenado el modelo LightGBM sobre el conjunto de entrenamiento. Para ello, se ha utilizado `LGBMRegressor` de la librería `lightgbm` [15]

Tras el entrenamiento, las métricas de error obtenidas sobre el conjunto de validación han sido:

- **MAE** (Error Absoluto Medio): 0,0852
- **RMSE** (Raíz del Error Cuadrático Medio): 0,154
- **R2** (Coeficiente de Determinación): -0,5171
- **Directional Accuracy**: 0,3462

4.4. Modelo de Deep Learning: LSTM

Pasando ahora a describir la implementación de la red LSTM, se trata de un tipo de red neuronal recurrente diseñada para capturar dependencias temporales en datos secuenciales. Este modelo LSTM a diferencia de los modelos de Machine Learning, requiere un preprocesamiento adicional y una arquitectura específica para poder aprovechar su capacidad de memoria a largo plazo. Añadir también que en el caso de Deep Learning y tal y como se hizo con Machine Learning, se ha entrenado el modelo tanto con el dataset completo de variables como con el dataset reducido, obteniendo mejores resultados con el dataset reducido, por lo que se mostrarán los resultados obtenidos con dicho dataset.

4.4.1. Preprocesamiento específico para LSTM

Los procesos de preprocesamiento para la red LSTM son primero de todo, un escalado de los datos [46] y posteriormente la creación de secuencias temporales. A continuación, se detallan ambos procesos:

1. **Escalado de los datos** A diferencia de los modelos de Machine Learning, que no varían ante transformaciones lineales de las variables, las redes neuronales son sensibles a la escala de los datos de entrada. Es por ello que es necesario escalar todas las variables para que se encuentren en un rango similar, ayudando así al algoritmo durante el entrenamiento. El proceso de escalado en este trabajo se ha llevado a cabo a través de la técnica `MinMaxScaler` de `scikit-learn` [47], que transforma los datos al rango $[-1, 1]$.

Listing 4.4: Implementación del escalado de datos para la X en LSTM

```
scaler_X = MinMaxScaler(feature_range=(-1, 1))
X_tr_resaped = X_tr.reshape(-1, X_tr.shape[-1])
X_vl_resaped = X_vl.reshape(-1, X_vl.shape[-1])
X_ts_resaped = X_ts.reshape(-1, X_ts.shape[-1])

scaler_X.fit(X_tr_resaped)

X_tr_scaled = scaler_X.transform(X_tr_resaped).reshape(X_tr.shape)
X_vl_scaled = scaler_X.transform(X_vl_resaped).reshape(X_vl.shape)
X_ts_scaled = scaler_X.transform(X_ts_resaped).reshape(X_ts.shape)
```

2. **Creación de secuencias temporales** El modelo LSTM no procesa las observaciones de forma independiente, sino que necesita una serie de pasos para predecir el siguiente valor. Por esto mismo, se ha definido una ventana de entrada de `INPUT_LENGTH = 12` meses, es decir, el modelo utiliza los doce meses anteriores para realizar la predicción. Por otro lado, el número de meses a predecir es de `OUTPUT_LENGTH = 6` meses (Es la ventana de salida que mejores resultados ha dado, mejor que 1, 3 y 12 meses), lo que permite evaluar la capacidad del modelo para predecir a medio plazo. Por último, se ha definido en Python una función llamada `crear_secuencias`, que trans-

Capítulo 4. Entrenamiento y validación de los modelos predictivos

forma el dataset original en un conjunto de secuencias supervisadas, donde cada muestra de entrada es un array de dimensiones (INPUT_LENGTH, num_features) y la salida es un array de dimensiones (OUTPUT_LENGTH, 1).

Listing 4.5: Función para la creación de secuencias

```
def crear_secuencias(dataframe, input_length, output_length):

    X, Y = [], []
    values = dataframe.values

    for i in range(len(values) - input_length - output_length):
        X.append(values[i:i+input_length, :])
        Y.append(values[i+input_length:
                        i+input_length+output_length, -1])

    X = np.array(X)
    Y = np.array(Y).reshape(-1, output_length, 1)

    return X, Y

#Llamada a la función
X_tr, Y_tr = crear_secuencias(tr, INPUT_LENGTH, OUTPUT_LENGTH)
X_vl, Y_vl = crear_secuencias(vl, INPUT_LENGTH, OUTPUT_LENGTH)
X_ts, Y_ts = crear_secuencias(ts, INPUT_LENGTH, OUTPUT_LENGTH)
```

4.4.2. Técnicas de regularización para datos limitados

Continuando con el procesamiento de los datos para LSTM, dado el reducido tamaño del conjunto de datos disponibles, se han implementado dos técnicas complementarias para mitigar el riesgo de sobreajuste y mejorar la capacidad de generalización del modelo.

1. **Data Augmentation** La primera técnica consiste en la aumentación de datos (*data augmentation*) [48] mediante la adición controlada de ruido gaussiano a las muestras de entrenamiento. Esta técnica, ampliamente utilizada en el ámbito del Deep Learning cuando se dispone de conjuntos de datos limitados, permite generar nuevas muestras sintéticas a partir de las existentes, incrementando artificialmente el tamaño del conjunto de entrenamiento. En concreto, se ha implementado una función `augment_data` que duplica el conjunto de entrenamiento añadiendo ruido gaussiano con una desviación típica de 0,0005 a cada muestra. De este modo, el modelo dispone del doble de ejemplos para aprender, lo que contribuye a reducir el sobreajuste y mejora la robustez de las predicciones. Esto se ha hecho debido a que al entrenar el modelo con una muestra de datos tan reducida, los valores que se obtenían eran bastante malos (Directional Accuracy por debajo del 50% o R2 muy negativo). Tras la aplicación de la función `data_augmentation`, se ha conseguido pasar de un dataset de entrenamiento

de 194 muestras a 388.

2. **Inyección de ruido controlado** Además de la aumentación de datos, se ha incorporado una capa de ruido gaussiano (`GaussianNoise`) [49] al inicio de la arquitectura de la red. Esta capa añade pequeñas perturbaciones aleatorias a las entradas durante el entrenamiento, pero permanece inactiva durante la fase de inferencia. El objetivo de esta técnica es doble, por un lado, fuerza al modelo a aprender representaciones más robustas y menos sensibles a pequeñas variaciones en los datos de entrada; por otro lado, actúa como un regularizador adicional que dificulta la memorización de los patrones específicos de entrenamiento. En este trabajo, se ha configurado con una desviación típica de 0,0005, un valor lo suficientemente pequeño como para no distorsionar la señal original pero lo bastante significativo para aportar el efecto regularizador deseado.

Listing 4.6: Función para la data augmentation

```
def augment_data(X, Y, noise_factor=0.0005):
    X_aug = X + np.random.normal(0, noise_factor, X.shape)
    Y_aug = Y + np.random.normal(0, noise_factor, Y.shape)

    X_combined = np.vstack([X, X_aug])
    Y_combined = np.vstack([Y, Y_aug])

    return X_combined, Y_combined

# Aplicar data augmentation solo al conjunto de entrenamiento
X_tr_aug, Y_tr_aug = augment_data(X_tr_scaled, Y_tr_scaled)
```

4.4.3. Arquitectura de la red

Pasando ahora a la arquitectura de la red, esta se ha diseñado de forma sencilla para poder adaptarse al tamaño reducido del dataset. Para ello, se ha utilizado una única capa LSTM con 32 neuronas. A continuación, se ha añadido una capa de salida densa con activación lineal y con 6 neuronas, correspondientes a los meses a predecir. A su vez, se ha incluido una tasa de `dropout` [50] del 20% tanto en la entrada como en las conexiones recurrentes para evitar el sobreajuste. Adicionalmente, como se ha mencionado anteriormente, se ha incorporado una capa de `GaussianNoise` al inicio de la red y se ha aplicado `data augmentation` sobre el conjunto de entrenamiento.

4.4.4. Compilación y entrenamiento

El modelo se ha compilado utilizando Adam [51] con una tasa de aprendizaje de 0,001. En cuanto a la función de pérdida empleada, esta ha sido el error cuadrático medio (MSE), monitorizándose también el error absoluto medio (MAE). Durante el entrenamiento, se han utilizado dos *callbacks* [52]. El primero, `EarlyStopping` [53], con una paciencia de 50 épocas, detiene el entrenamiento cuando la pérdida en validación deja de mejorar y restaura los pesos del mejor modelo. El

Capítulo 4. Entrenamiento y validación de los modelos predictivos

segundo, `ReduceLROnPlateau` [54], reduce la tasa de aprendizaje a la mitad si la pérdida en validación no mejora durante 10 épocas consecutivas.

Listing 4.7: Compilación y entrenamiento del modelo LSTM

```
modelo.compile(  
    optimizer=Adam(learning_rate=LEARNING_RATE),  
    loss='mse',  
    metrics=['mae']  
)  
  
early_stop = EarlyStopping(  
    monitor='val_loss',  
    patience=50,  
    restore_best_weights=True,  
    verbose=1  
)  
  
reduce_lr = ReduceLROnPlateau(  
    monitor='val_loss',  
    factor=0.5,  
    patience=10,  
    min_lr=1e-6,  
    verbose=1  
)  
  
historia = modelo.fit(  
    X_tr_aug, Y_tr_aug,  
    validation_data=(X_vl_scaled, Y_vl_scaled),  
    epochs=EPOCHS,  
    batch_size=BATCH_SIZE,  
    callbacks=[early_stop, reduce_lr],  
    verbose=1  
)
```

En cuanto al entrenamiento, este se ha realizado durante un máximo de 500 épocas con un *batch size* de 32 muestras. El proceso se detuvo automáticamente en la época 326, restaurándose los pesos de la época 276, momento en el que se obtuvo el menor error de validación.

En la Figura 38 se muestran las curvas de evolución de la pérdida (MSE) y del error absoluto medio (MAE) durante el entrenamiento. Se observa que tanto la pérdida como el MAE disminuyen progresivamente, y que la diferencia entre las curvas de entrenamiento y validación es reducida, lo que indica que las técnicas de regularización aplicadas (data augmentation, Gaussian noise y dropout) han sido efectivas para controlar el sobreajuste.




Figura 4.1: Evolución de la pérdida MSE y del MAE durante el entrenamiento de la LSTM. Fuente: elaboración propia.

Los mejores resultados obtenidos en el conjunto de validación fueron un MSE de 0,0722 y un MAE de 0,2130. Estos valores, aunque superiores a los obtenidos por los modelos de Machine Learning, demuestran que la LSTM es capaz de aprender patrones temporales pese a su rendimiento limitado por el reducido tamaño del conjunto de datos y la alta volatilidad inherente a las series financieras.

4.5. Evaluación de los modelos

En esta sección se presentan los resultados obtenidos por cada modelo en el conjunto de prueba, utilizando las métricas de error, al igual que en el backtesting. Además, se realiza una comparativa global entre los tres modelos para determinar cuál ha sido el más efectivo en la predicción del rendimiento de Apple.

4.5.1. Estrategia de backtesting

Para evaluar la robustez temporal de los modelos y evitar conclusiones optimistas derivadas de una única partición, se ha llevado a cabo un **backtesting** con ventana deslizante. La estrategia consiste en entrenar el modelo con una ventana histórica de datos y evaluarlo sobre el período siguiente, desplazando la ventana secuencialmente. Este enfoque simula el comportamiento real del modelo en diferentes períodos históricos, incluyendo la crisis financiera de 2008, la pandemia de COVID-19 y el posterior episodio inflacionario.

4.5.2. Resultados de Random Forest

A continuación, se presentan los resultados obtenidos por el modelo Random Forest en el conjunto de prueba y en el backtesting.

1. **Evaluación en el conjunto de prueba** Sobre el conjunto de prueba, el modelo Random Forest obtuvo las siguientes métricas:

Capítulo 4. Entrenamiento y validación de los modelos predictivos

- **MAE:** 0,0477 (4,77 % de error medio) Este valor indica que, en promedio, las predicciones del modelo se desvían un 4,53 % del rendimiento real de Apple, lo que representa una mejora significativa respecto a los resultados obtenidos en la fase de validación.
- **RMSE:** 0,579 (5,79 % de error cuadrático medio) Este valor, aunque algo más alto que el MAE, sigue indicando un buen rendimiento del modelo, ya que penaliza más los errores grandes. La diferencia entre el MAE y el RMSE sugiere que el modelo comete algunos errores más significativos, pero en general mantiene una buena precisión.
- **R²:** -0,0001 (prácticamente 0% de la varianza explicada). Este valor indica que el modelo no logra explicar la variabilidad del rendimiento de Apple, comportándose de manera similar a un predictor ingenuo basado en la media histórica.
- **DA:** 0,5926 (59,26 % de aciertos direccionales). El modelo acierta la dirección del movimiento (subida o bajada) en aproximadamente 6 de cada 10 meses.

Atendiendo a los valores obtenidos, el modelo Random Forest muestra un rendimiento modesto en la predicción del rendimiento de Apple. Pese a que la direccional accuracy (59,26 %) supera ligeramente el 50 %, el R² prácticamente nulo indica que el modelo no captura adecuadamente la magnitud de los movimientos. Esto sugiere que, si bien el modelo puede anticipar la dirección en más de la mitad de las ocasiones, su capacidad para cuantificar el rendimiento esperado es limitada.

En la Figura 39 se muestra un gráfico comparativo entre las predicciones del modelo y los valores reales del rendimiento de Apple en el conjunto de prueba. Se observa que las predicciones siguen la tendencia general en algunos periodos, aunque presentan desviaciones significativas en meses con movimientos más bruscos.




Figura 4.2: Comparativa entre las predicciones del modelo Random Forest y los valores reales del rendimiento de Apple en el conjunto de prueba. Fuente: elaboración propia.

2. **Backtesting** En cuanto al backtesting, en el modelo de Random Forest, se utilizó una ventana de 220 meses de entrenamiento 12 meses de prueba y una ventana deslizante de 22 meses. Los resultados obtenidos con estos datos, fueron:

- **MAE medio:** 0,0663 (± 0.0355) Este valor indica que, en promedio, las predicciones del modelo se desvían un 6,63 % del rendimiento real de Apple a lo largo de las diferentes ventanas de backtesting. La desviación estándar de $\pm 0,0355$ refleja una variabilidad considerable en el error según el período evaluado, oscilando entre errores bajos (cerca-nos al 4 %) y errores altos (superiores al 9 %).
- **RMSE medio:** 0.0786 ($\pm 0,0377$) Este valor, ligeramente superior al MAE, indica la existencia de errores puntuales de mayor magnitud. La desviación estándar de $\pm 0,0377$ refuerza la idea de una alta heterogeneidad en el rendimiento del modelo a lo largo del tiempo.
- **R² medio:** -0.039 (± 0.1664) Este valor medio negativo indica que, en promedio, el modelo no supera a un predictor ingenuo basado en la media histórica. La elevada desviación estándar de $\pm 0,1664$ revela una alta heterogeneidad en el rendimiento del modelo según el período estudiado.
- **DA medio:** 0,5833 (± 0.3536). La direccional accuracy media del 58,33 % indica que, a lo largo de las diferentes ventanas, el modelo acierta la dirección en aproximadamente 6 de cada 10 meses. Sin embargo, la desviación estándar de $\pm 0,3536$ es extremadamente alta, lo que sugiere que el rendimiento direccional del modelo varía drásticamente según el período evaluado.

Con los valores anteriores, se puede concluir que el modelo Random Forest muestra un rendimiento muy inconsistente en el backtesting. Aunque en el conjunto de prueba aislado alcanza una direccional accuracy del 59,26 %, la evaluación mediante ventanas deslizantes revela que dicho rendimiento no es estable a lo largo del tiempo. La alta variabilidad de todas las métricas indica que el modelo es extremadamente sensible al régimen de mercado.

En la Figura 40 se puede ver la evolución de tanto la MAE como del R² a lo largo de las iteraciones. En ambos casos, se puede ver como en ambos casos, a medida que avanzan las iteraciones, los resultados mejoran (MAE más pequeña y R², más grande, llegando a valores positivos incluso). Esta mejora, indica ue el modelo capta mejor los patrones de mercado actuales.




Figura 4.3: Graficas de la evolución de MAE y R^2 a lo largo de las iteracciones del backtesting. Fuente: elaboración propia.

4.5.3. Resultados de Gradient Boosting

A continuación, se presentan los resultados obtenidos por el modelo Gradient Boosting en el conjunto de prueba y en el backtesting.

1. **Evaluación en el conjunto de prueba** El modelo Gradient Boosting obtuvo los siguientes resultados sobre el conjunto de prueba:
 - **MAE:** 0,0437 (4,37 % de error medio) Este valor indica que en promedio, las predicciones del modelo se desvían un 4,37 % del rendimiento real de Apple, lo que representa una mejora respecto a los resultados obtenidos durante la fase de validación, aunque es algo inferior al rendimiento alcanzado por el modelo Random Forest.
 - **RMSE:** 0,0531 (5,31 % de error cuadrático medio) Este valor, aunque algo más alto que el MAE, sigue indicando un rendimiento razonable del modelo, aunque es ligeramente inferior al obtenido por Random Forest, lo que sugiere que el modelo comete algunos errores más significativos.
 - **R²:** 0,1574 (15,74 % de la varianza explicada) Este valor indica que el modelo es capaz de explicar aproximadamente el 16 % de la variabilidad del rendimiento mensual de Apple, lo que se considera un resultado modesto para un problema de predicción financiera, aunque sigue siendo una mejora respecto a los resultados obtenidos durante la fase de validación.
 - **DA:** 0.6296 (62,96 % de aciertos direccionales). El modelo acierta la dirección del movimiento (subida o bajada) en un poco más de 6 de cada 10 meses.

Según los valores obtenidos, se puede concluir que el modelo Gradient Boosting ha logrado un rendimiento superior al de Random Forest en la predicción en este caso, del rendimiento de Apple. Este modelo consigue

explicar una parte significativa de la variabilidad del rendimiento (R^2 positivo del 15,74 %), mientras que Random Forest no lograba explicar prácticamente nada. Además, la direccional accuracy del 62,96 % supera en más de 3 puntos porcentuales a la obtenida por Random Forest. Estos resultados sugieren que, para este problema específico, el enfoque de boosting ha resultado más efectivo que el de bagging.

Por otro lado, en la Figura 41 se muestra un gráfico comparativo entre las predicciones del modelo Gradient Boosting y los valores reales del rendimiento de Apple en el conjunto de prueba. Se observa que las predicciones siguen la tendencia general del rendimiento real, capturando adecuadamente tanto los movimientos alcistas como los bajistas, con desviaciones moderadas incluso en meses de mayor volatilidad.




Figura 4.4: Comparativa entre las predicciones del modelo Gradient Boosting y los valores reales del rendimiento de Apple en el conjunto de prueba. Fuente: elaboración propia.

2. **Backtesting** En el caso de Gradient Boosting, se ha realizado el backtesting con una ventana de entrenamiento de 220 meses, una ventana de prueba de 20 y una ventana deslizante de 12. En cuanto a los valores obtenidos en el backtesting, estos han sido los siguientes:

- **MAE medio:** 0,0602 ($\pm 0,0210$). Este valor indica que, en promedio, las predicciones del modelo se desvían un 6,02 % del rendimiento real de Apple a lo largo de las diferentes ventanas de backtesting. La desviación estándar de $\pm 0,0210$ refleja una variabilidad moderada en el error según el período evaluado.
- **RMSE medio:** 0,0734 ($\pm 0,0248$). Este valor, ligeramente superior al MAE, indica la existencia de errores puntuales de mayor magnitud. La desviación estándar de $\pm 0,0248$ sugiere que la variabilidad del error es coherente con la observada en el MAE.
- **R^2 medio:** -0,1684 ($\pm 0,2465$). Este valor medio negativo indica que, en promedio a lo largo de las diferentes ventanas, el modelo no consigue

superar a un predictor ingenuo basado en la media histórica. La desviación estándar de $\pm 0,2465$, aunque elevada, es ligeramente superior a la de Random Forest ($\pm 0,1664$), lo que indica que el rendimiento del modelo es algo más variable entre períodos.

- **DA medio:** $0,5500 (\pm 0,1323)$. La direccional accuracy media del 55 % indica que, a lo largo de las diferentes ventanas, el modelo acierta la dirección en aproximadamente 5,5 de cada 10 meses. La desviación estándar de $\pm 0,1323$ sugiere que el rendimiento direccional varía entre el 42 % y el 68 % dependiendo del período evaluado.

Analizando los valores anteriores, se puede concluir que el modelo Gradient Boosting muestra un rendimiento razonable en la predicción del rendimiento de Apple, aunque su capacidad para generalizar a diferentes períodos históricos es limitada, lo que refleja la complejidad y volatilidad de los mercados financieros. Sin embargo, su rendimiento es algo más consistente a lo largo del tiempo que el de Random Forest (R^2 medio de $-0,1684$ frente a $-0,5738$, y desviación estándar de $\pm 0,2465$ frente a $\pm 0,7044$), lo que indica una mayor estabilidad en sus predicciones.

En la Figura 42 se puede ver la evolución tanto del MAE como del R^2 a lo largo de las iteraciones. Al igual que sucede en Random Forest, en el caso de Gradient Boosting, a medida que avanzan las iteraciones, los resultados mejoran (MAE más pequeño y R^2 más grande, llegando en algunas iteraciones a valores cercanos a cero o ligeramente positivos). Esta mejora indica que el modelo capta mejor los patrones de mercado más recientes.




Figura 4.5: Graficas de la evolución de MAE y R^2 a lo largo de las iteraciones del backtesting. Fuente: elaboración propia.

4.5.4. Resultados de LGBM

Para concluir con los modelos Machine Learning, se presentan los resultados obtenidos por el modelo LightGBM en el conjunto de prueba y en el backtesting.

1. **Evaluación en el conjunto de prueba** El modelo LightGBM obtuvo los siguientes resultados sobre el conjunto de prueba:

- **MAE:** 0,0385 (3,85 % de error medio). Este valor indica que, en promedio, las predicciones del modelo se desvían un 3,85 % del rendimiento real de Apple, lo que representa una mejora significativa respecto a los modelos Random Forest (4,77 %) y Gradient Boosting (4,37 %).
- **RMSE:** 0,0495 (4,95 % de error cuadrático medio). La proximidad entre el MAE y el RMSE sugiere que el modelo no comete errores excesivamente grandes, manteniendo una consistencia en sus desviaciones y superando también a los modelos anteriores (RF: 5,79 %, GB: 5,31 %).
- **R²:** 0,2688 (26,88 % de la varianza explicada). Este valor positivo indica que el modelo es capaz de explicar aproximadamente el 27 % de la variabilidad del rendimiento mensual de Apple, lo que supone una mejora sustancial respecto a Gradient Boosting (15,74 %) y Random Forest (prácticamente nulo).
- **DA:** 0,7778 (77,78 % de aciertos direccionales). El modelo acierta la dirección del movimiento (subida o bajada) en aproximadamente 8 de cada 10 meses, superando ampliamente a Random Forest (59,26 %) y Gradient Boosting (62,96 %).

Según los valores obtenidos, se puede concluir que el modelo LightGBM ha logrado un rendimiento claramente superior al de Random Forest y Gradient Boosting en la predicción del rendimiento de Apple. Este modelo consigue explicar más de una cuarta parte de la variabilidad del rendimiento (R^2 del 26,88 %), mientras que Random Forest no lograba explicar prácticamente nada y Gradient Boosting se quedaba en el 16 %. Además, la direccional accuracy del 77,78 % supera en más de 15 puntos porcentuales a la obtenida por Gradient Boosting y en casi 19 puntos a la de Random Forest. Estos resultados demuestran que LightGBM, gracias a sus optimizaciones como el crecimiento leaf-wise y las técnicas de regularización avanzadas, es el modelo más efectivo de los tres evaluados.

En la Figura 43 se muestra un gráfico comparativo entre las predicciones del modelo LightGBM y los valores reales del rendimiento de Apple en el conjunto de prueba. Se observa que las predicciones siguen con gran fidelidad la tendencia general del rendimiento real, capturando adecuadamente tanto los movimientos alcistas como los bajistas. Las desviaciones son reducidas incluso en meses de mayor volatilidad, lo que refleja la capacidad del modelo para anticipar tanto la dirección como la magnitud de los movimientos del activo.




Figura 4.6: Comparativa entre las predicciones del modelo LightGBM y los valores reales del rendimiento de Apple en el conjunto de prueba. Fuente: elaboración propia.

2. **Backtesting** Finalmente, en el backtesting de LightGBM, se utilizó una ventana de entrenamiento de 220 meses, una ventana de test de 12 meses y un desplazamiento de 18 meses. En lo que respecta a los resultados, se han obtenido los siguientes:
 - **MAE medio:** 0,0710 ($\pm 0,0502$). Este valor indica que, en promedio, las predicciones del modelo se desvían un 7,10 % del rendimiento real de Apple a lo largo de las diferentes ventanas de backtesting. La elevada desviación estándar de $\pm 0,0502$ refleja una alta variabilidad en el error según el período evaluado, con valores que oscilan entre el 2 % en las mejores iteraciones y más del 10 % en las peores.
 - **RMSE medio:** 0,0798 ($\pm 0,0475$). Este valor, ligeramente superior al MAE, indica la existencia de errores puntuales de mayor magnitud. La desviación estándar de $\pm 0,0475$ confirma la alta variabilidad observada en el MAE.
 - **R² medio:** 0,0147 ($\pm 0,5069$). Este valor medio, ligeramente positivo, indica que, en promedio a lo largo de las diferentes ventanas, el modelo logra superar ligeramente a un predictor ingenuo basado en la media histórica. Sin embargo, la elevadísima desviación estándar de $\pm 0,5069$ revela una heterogeneidad extrema en el rendimiento del modelo según el período estudiado. Como se aprecia en la Figura 44, en las primeras iteraciones el R² alcanza valores muy negativos (cerca de -0,33), mientras que en las últimas iteraciones alcanza valores positivos notables.
 - **DA medio:** 0,5417 ($\pm 0,4125$). La direccional accuracy media del 54,17 % indica que, a lo largo de las diferentes ventanas, el modelo acierta la dirección en aproximadamente 5,4 de cada 10 meses. La desviación estándar de $\pm 0,4125$ es extremadamente alta, lo que sugiere que el rendimiento direccional varía drásticamente según el período evalua-

do, alcanzando valores cercanos al 100 % en las mejores iteraciones y valores muy bajos en las peores.

Analizando los valores anteriores, se puede concluir que el modelo LightGBM muestra un rendimiento muy heterogéneo en el backtesting. Aunque en el conjunto de prueba aislado logra resultados excepcionales (R^2 de 0,2688 y DA del 77,78 %), la evaluación mediante ventanas deslizantes revela que dicho rendimiento no es estable a lo largo de toda la serie histórica. Sin embargo, es importante señalar que el modelo mejora significativamente en las iteraciones más recientes, lo que sugiere que es capaz de capturar los patrones de mercado actuales con mayor efectividad que los modelos Random Forest y Gradient Boosting.

En la Figura 44 se puede ver la evolución tanto del MAE como del R^2 a lo largo de las iteraciones del backtesting. Se observa una clara tendencia ascendente del R^2 y descendente del MAE a medida que avanzan las iteraciones. En las primeras iteraciones (correspondientes a períodos más antiguos, como la crisis financiera de 2008), el modelo presenta un rendimiento muy pobre, con R^2 negativos cercanos a -0,33 y MAE superiores al 10 %. Sin embargo, a partir de la iteración 4, el R^2 comienza a estabilizarse en valores cercanos a cero, y en las últimas iteraciones (períodos más recientes, correspondientes a 2019-2024) el modelo alcanza su mejor rendimiento, con un R^2 positivo que llega hasta 0,4 y un MAE que desciende hasta aproximadamente el 2 %. Esta evolución indica que LightGBM es capaz de capturar eficazmente los patrones de mercado más recientes, aunque muestra limitaciones en períodos históricos de alta volatilidad o cambios de régimen estructural.




Figura 4.7: Evolución del MAE y del R^2 a lo largo de las iteraciones del backtesting para LightGBM. Fuente: elaboración propia.

4.5.5. Resultados de LSTM

En esta sección se presentan los resultados obtenidos por el modelo LSTM en el conjunto de prueba y en el backtesting.

1. Evaluación en el conjunto de prueba

Una vez finalizado el entrenamiento, se ha evaluado el modelo sobre el conjunto de prueba, obteniendo los siguientes resultados:

- **MAE:** 0,0509 (5,09 % de error medio). Este valor indica que, en promedio, las predicciones del modelo se desvían aproximadamente un 5,09 % del rendimiento real, lo que representa un error moderado y aceptable para el contexto financiero.
- **RMSE:** 0,0603 (6,03 % de error cuadrático medio). La proximidad entre el MAE y el RMSE sugiere que el modelo no comete errores excesivamente grandes, manteniendo una consistencia en sus desviaciones.
- **R²:** 0,0396 (3,96 % de la varianza explicada). Este valor positivo, aunque modesto, indica que el modelo logra explicar una pequeña parte de la variabilidad del rendimiento mensual, superando a un predictor ingenuo basado en la media histórica. Este resultado es especialmente relevante dado el reducido tamaño del conjunto de datos y la conocida dificultad de predicción de los mercados financieros.
- **DA:** 0,6111 (61,11 % de aciertos direccionales). El modelo acierta la dirección del movimiento (subida o bajada) en aproximadamente 6 de cada 10 meses, lo que supone un rendimiento superior al azar y valida la capacidad del modelo para anticipar la tendencia del activo.

Estos resultados confirman que, pese a las limitaciones inherentes al tamaño del dataset, la implementación de técnicas de regularización como la aumentación de datos y la inyección de ruido controlado ha permitido obtener un modelo LSTM funcional con capacidad predictiva positiva. Aunque sus prestaciones son inferiores a las alcanzadas por los modelos de boosting, el hecho de haber conseguido un R² positivo y una directional accuracy superior al 60 % representa un logro significativo, especialmente considerando que las redes LSTM suelen requerir volúmenes de datos mucho mayores para ofrecer su máximo rendimiento.

En la Figura 45 se muestra la comparativa entre las predicciones del modelo y los valores reales en el conjunto de prueba. Se observa que los errores se distribuyen de forma relativamente homogénea en torno a cero, sin presentar patrones temporales claros, lo que indica que el modelo no presenta sesgos sistemáticos en sus predicciones.




Figura 4.8: Comparativa entre las predicciones de la LSTM y los valores reales del rendimiento en el conjunto de prueba. Fuente: elaboración propia.

2. **Backtesting** Para evaluar la robustez temporal del modelo LSTM y evitar conclusiones optimistas derivadas de una única partición, se ha llevado a cabo un **backtesting** con ventana deslizante. La estrategia consiste en entrenar el modelo con una ventana histórica de datos y evaluarlo sobre el período siguiente, desplazando la ventana secuencialmente. Este enfoque simula el comportamiento real del modelo en diferentes períodos históricos, incluyendo contextos económicos muy diversos como la crisis financiera de 2008, la pandemia de COVID-19 y el posterior episodio inflacionario.

La configuración del backtesting ha sido la siguiente, ventana de entrenamiento inicial de 10 años (120 meses), ventana de prueba de 12 meses y desplazamiento de 6 meses entre iteraciones, completándose un total de 23 iteraciones que abarcan prácticamente todo el período muestral disponible.

En cuanto a los resultados obtenidos, el modelo LSTM ha mostrado un rendimiento muy heterogéneo a lo largo de las diferentes ventanas de evaluación. Las métricas medias obtenidas han sido:

- **MAE medio:** 0,0677 ($\pm 0,0245$). Este valor indica que, en promedio, las predicciones del modelo se desvían un 6,77 % del rendimiento real. La desviación estándar de $\pm 0,0245$ refleja una variabilidad considerable en el error según el período evaluado, con valores que oscilan entre el 2,83 % en la mejor iteración y el 12,08 % en la peor.
- **RMSE medio:** 0,0794 ($\pm 0,0267$). La proximidad entre el MAE y el RMSE medios sugiere que, de forma agregada, el modelo no comete errores extremadamente grandes. Sin embargo, la desviación estándar de $\pm 0,0267$ confirma la heterogeneidad observada.
- **R² medio:** -0,6832 ($\pm 0,9667$). Este valor medio negativo indica que, en promedio a lo largo de las diferentes ventanas, el modelo no logra superar a un predictor ingenuo basado en la media histórica. La elevadísima desviación estándar de $\pm 0,9667$ revela una heterogeneidad

extrema en el rendimiento del modelo según el período estudiado. En las iteraciones 3, 5 y 1 se alcanzan R^2 positivos de 0,3094, 0,2063 y 0,1863 respectivamente, mientras que en otras iteraciones (como la 12, con un R^2 de -3,7560) el rendimiento es muy pobre.

- **DA medio:** 0,5435 ($\pm 0,2369$). La direccional accuracy media del 54,35 % indica que, a lo largo de las diferentes ventanas, el modelo acierta la dirección en aproximadamente 5,4 de cada 10 meses. La desviación estándar de $\pm 0,2369$ es muy alta, lo que sugiere que el rendimiento direccional varía drásticamente según el período evaluado, alcanzando valores del 83,33 % en las mejores iteraciones (iteraciones 1, 5, 14, 15 y 19) y valores tan bajos como el 0 % o el 16,67 % en las peores.

En términos globales, considerando todas las predicciones realizadas durante el backtesting como un único conjunto, se obtiene un MAE de 0,0677, un RMSE de 0,0835, un R^2 de -0,1671 y una DA del 54,35 %. Estos valores globales suavizan la alta variabilidad observada entre iteraciones, pero confirman la dificultad del modelo para mantener un rendimiento consistente a lo largo de todo el período histórico.

En la Figura 46 se muestra la evolución de las métricas a lo largo de las iteraciones del backtesting. Se observa una alta volatilidad en todas las métricas, sin una tendencia clara de mejora o empeoramiento a medida que se avanza en el tiempo. Las iteraciones con mejor rendimiento (R^2 positivos superiores a 0,18) se concentran en las primeras iteraciones y en algunas intermedias, mientras que las peores se distribuyen a lo largo de todo el período.




Figura 4.9: Evolución del MAE, R^2 , DA y RMSE a lo largo de las iteraciones del backtesting para la LSTM. Fuente: elaboración propia.

4.5.6. Comparativa global

Una vez presentados los resultados individuales de cada modelo, en esta sección, lo que se hará es analizar de forma conjunta las prestaciones ofrecidas por cada arquitectura. Es importante mencionar que en esta sección, no se trata de elegir un modelo sobre otro, sino de comprender qué aporta cada enfoque y en qué contextos puede resultar más adecuado.

4.5. Evaluación de los modelos

En la Figura 47 se resumen los resultados obtenidos por cada modelo en el conjunto de prueba, mientras que la Figura 48 presenta las métricas obtenidas en el backtesting.

Modelo	MAE	RMSE	R2	DA
Random Forest	0.0477	0.0579	-0.0001	59.26%
Gradient Boosting	0.0437	0.0531	0.1574	62.96%
LightGBM	0.0385	0.0495	0.2688	77.78%
LSTM	0.0509	0.0603	0.0396	61.11%

Figura 4.10: Resultados comparativos en el conjunto de prueba. Fuente: elaboración propia.

Modelo	MAE	RMSE	R2	DA
Random Forest	0.0663 $\pm$ 0.0355	0.0786 $\pm$ 0.0377	-0.0390 $\pm$ 0.1664	58.33% $\pm$ 35.36%
Gradient Boosting	0.0602 $\pm$ 0.0210	0.0734 $\pm$ 0.0248	-0.1684 $\pm$ 0.2455	55.00% $\pm$ 13.23%
LightGBM	0.0710 $\pm$ 0.0502	0.0798 $\pm$ 0.0475	0.0147 $\pm$ 0.5069	54.17% $\pm$ 41.25 %
LSTM	0.0677 $\pm$ 0.0245	0.0794 $\pm$ 0.0267	-0.6832 $\pm$ 0.9667	54.35% $\pm$ 23.69%

Figura 4.11: Resultados comparativos en backtesting. Fuente: elaboración propia.

A continuación, se analiza el aporte de cada modelo:

- **Random Forest:** Aporta una gran robustez frente a ruido y valores atípicos, esto es debido a su naturaleza de bagging. Su principal fortaleza es la estabilidad, siendo el modelo que presenta menor variabilidad en R^2 durante el backtesting (desviación de $\pm 0,1664$). Sin embargo, su capacidad predictiva es limitada, como refleja su R^2 prácticamente nulo en el conjunto de prueba. El modelo de backtesting, es adecuado cuando se prioriza la robustez frente a la precisión máxima.
- **Gradient Boosting:** Aporta una mejora significativa en precisión respecto a Random Forest, logrando un R^2 positivo del 15,74 % en prueba. Su principal fortaleza es el equilibrio entre precisión y estabilidad, ya que presenta una variabilidad moderada en backtesting (desviación de R^2 de $\pm 0,2465$). A su vez, es una opción equilibrada cuando se busca un buen rendimiento sin sacrificar demasiada consistencia temporal.
- **LightGBM:** Aporta el mejor rendimiento predictivo en el conjunto de prueba, con un R^2 del 26,88 % y una DA del 77,78 %, superando claramente al resto. Su principal fortaleza es la capacidad para capturar patrones complejos gracias a su crecimiento leaf-wise. Sin embargo, su rendimiento es muy heterogéneo en backtesting (desviación de R^2 de $\pm 0,5069$), mostrando una alta sensibilidad al contexto económico. Es el modelo más potente cuando se dan las condiciones de mercado adecuadas, pero el menos fiable en periodos de cambio de régimen.
- **LSTM:** Aporta la capacidad de modelar dependencias temporales secuen-

ciales, algo que los modelos basados en árboles no pueden hacer explícitamente. Su principal fortaleza es que, pese a las limitaciones de datos, logra un R^2 positivo (3,96 %) y una DA superior al 60 %. Sin embargo, es el modelo que peor se comporta en backtesting (R^2 medio de -0,6832), lo que indica que su capacidad de generalización temporal es limitada con el reducido tamaño del dataset. Este modelo de Deep Learning, sería recomendable cuando se dispone de series temporales largas y se busca capturar memoria a largo plazo.

4.6. Conclusiones del capítulo

Para concluir con este capítulo, se hará un pequeño resumen de todo lo que se ha hecho y las conclusiones a las que se han llegado. Primero de todo, en este cuarto capítulo, se han implementado, entrenado y evaluado cuatro modelos predictivos diferentes sobre el problema de predicción del rendimiento financiero.

Las principales conclusiones que se extraen son las siguientes:

1. **La selección de variables ha sido clave.** En todos los modelos evaluados, el dataset reducido (tras aplicar las técnicas de selección de variables descritas en el Capítulo 3) ha producido mejores resultados que el dataset completo, validando así la importancia de eliminar variables redundantes y ruidosas.
2. **Los modelos de boosting superan a bagging en este problema.** Tanto Gradient Boosting como LightGBM han obtenido resultados superiores a Random Forest, lo que indica que la corrección secuencial de errores es más efectiva que el promediado independiente para capturar los patrones de los mercados financieros.
3. **LightGBM es el modelo con mayor capacidad predictiva,** alcanzando un R^2 del 26,88 % y una directional accuracy del 77,78 % en el conjunto de prueba. Sin embargo, su rendimiento es muy sensible al periodo evaluado, como refleja la alta variabilidad en backtesting (R^2 medio de $0,0147 \pm 0,5069$). Esto sugiere que LightGBM es excelente cuando el mercado se comporta de manera similar a los patrones aprendidos, pero puede fallar estrepitosamente en contextos de cambio de régimen.
4. **Gradient Boosting ofrece el mejor equilibrio** entre precisión y estabilidad. Con un R^2 del 15,74 % en prueba y una variabilidad moderada en backtesting (desviación de $\pm 0,2465$), se presenta como la opción más robusta para su implementación práctica, especialmente si no se dispone de un mecanismo para detectar cambios de contexto.
5. **La LSTM, pese a sus limitaciones, ha demostrado ser viable,** y el **data augmentation ha sido clave** para lograr esta mejora. Con un R^2 positivo del 3,96 % y una directional accuracy del 61,11 %, el modelo ha superado a un predictor ingenuo. Antes de aplicar la aumentación de datos, los

resultados eran muy pobres (R^2 negativos y directional accuracy por debajo del 50%). Tras duplicar el conjunto de entrenamiento y añadiendo ruido gaussiano controlado, se logró estabilizar el entrenamiento y obtener predicciones significativamente mejores. Por ende, se podría decir que las técnicas de regularización han sido efectivas para mitigar el sobreajuste, permitiendo que la red aprenda patrones temporales a pesar del reducido tamaño del dataset. Sin embargo, pese a la aplicación de estas técnicas, su rendimiento en backtesting (R^2 medio de -0,6832) indica que se requieren más datos para explotar todo su potencial.

6. Ningún modelo es consistentemente superior en todos los períodos.

La alta variabilidad observada en las métricas de backtesting de todos los modelos refleja una realidad fundamental de los mercados financieros: la predictibilidad no es uniforme en el tiempo, sino que depende críticamente del régimen de mercado vigente.

En definitiva, para el problema concreto de predicción del rendimiento de Apple con los datos disponibles, se puede concluir que:

- Si el objetivo es **maximizar la precisión** y se dispone de mecanismos para identificar el contexto de mercado, **LightGBM** es la mejor opción.
- Si se prioriza la **estabilidad y robustez** frente a cambios de régimen, **Gradient Boosting** es la alternativa más equilibrada.
- **Random Forest** es una opción conservadora que, si bien no destaca en precisión, ofrece la mayor estabilidad en backtesting.
- **LSTM** es una alternativa muy llamativa y que probablemente mejoraría significativamente con un mayor volumen de datos históricos.

Estas conclusiones serán retomadas en el siguiente capítulo, donde se presentarán los experimentos adicionales y se profundizará en el análisis de la inter-pretabilidad de los modelos mediante técnicas SHAP y LIME.

Capítulo 5

Discusión e interpretabilidad de los modelos

Una vez se han implementado, entrenado y evaluado los modelos predictivos en el Capítulo 4, ahora en este quinto capítulo se abordará un análisis más profundo de los resultados obtenidos, centrándose en la interpretabilidad de los modelos y en la discusión de su comportamiento bajo diferentes condiciones.

En primer lugar, se aplicarán técnicas de interpretabilidad como SHAP y LIME sobre los modelos desarrollados, permitiendo descomponer sus predicciones y comprender qué variables han influido más en cada decisión. En este capítulo, a diferencia del Capítulo 2, donde se explicó el fundamento teórico de estas técnicas, aquí se presentarán los resultados prácticos obtenidos tras su aplicación, analizando las similitudes y diferencias en la importancia de variables entre los distintos modelos.

En segundo lugar, se discutirá el modelo y las decisiones de diseño tomadas a lo largo del trabajo, en función de los resultados obtenidos en el análisis de interpretabilidad.

Finalmente, se presentará una discusión global de los resultados obtenidos en este capítulo, relacionándolos con los hallazgos del Capítulo 4, y se extraerán las conclusiones generales del trabajo.

5.1. Aplicación de técnicas de interpretabilidad

Una vez entrenados y evaluados los modelos predictivos en el Capítulo 4, se han aplicado las técnicas SHAP y LIME para comprender cómo realizan sus predicciones y qué variables resultan más influyentes en cada modelo. En esta sección se presentan los resultados obtenidos para cada uno de los cuatro modelos desarrollados, Random Forest, Gradient Boosting, LightGBM y LSTM.

5.1.1. Análisis con SHAP

SHAP (Shapley Additive Explanations) [22] permite descomponer cada predicción en la contribución individual de cada variable, ofreciendo tanto un análisis global como local. A continuación, se presentan los resultados para cada modelo.

1. **Random Forest** El análisis SHAP aplicado al modelo Random Forest ha permitido identificar las variables más influyentes en sus predicciones, así como comprender la relación entre dichas variables y el rendimiento previsto.

Para la realización de este análisis, se ha utilizado el explainer `TreeExplainer` [55] de la librería SHAP. A su vez, debido a que el cálculo de los valores SHAP sobre el dataset completo puede ser computacionalmente costoso, se ha tomado una muestra representativa del conjunto de entrenamiento de 100 observaciones para construir el explainer. Sobre dicha muestra, se ha ajustado el explainer y posteriormente se han calculado los valores SHAP para todo el conjunto de prueba. Mencionar que los otros modelos de Machine Learning, siguen la misma metodología que Random Forest.

Listing 5.1: Implementación de `TreeExplainer` en Random Forest

```
X_train_sample = X_train.sample(n=
    min(100, len(X_train)), random_state=42)

explainer_rf = shap.TreeExplainer(best_rf)

shap_values_rf = explainer_rf.shap_values(X_test)
```

- **Importancia global de las variables** En la Figura 49 se muestra la importancia global de las variables para el modelo Random Forest, esta importancia ha sido calculada como la media de los valores SHAP absolutos.

Capítulo 5. Discusión e interpretabilidad de los modelos




Figura 5.1: Importancia global de variables para Random Forest según SHAP. Fuente: elaboración propia.

En la imagen anterior se observa que la variable más influyente es el precio del activo, seguida de los tipos de interés del BCE y el `vix_lag1`.

El hecho de que los tipos BCE tengan más valor que los tipos FED, sugiere que para el caso de Apple, las condiciones monetarias europeas tienen un peso relevante, esto es muy posiblemente debido a la importante presencia de la compañía en el mercado europeo.

Por otro lado, llama la atención el rendimiento del S&P 500, que se sitúa en octava posición. Esto indica que el mercado aporta informa-

5.1. Aplicación de técnicas de interpretabilidad

ción, pero sin embargo, no es el factor más importante para predecir el rendimiento de Apple.

- **Gráfica de dependencia** Ahora se analizará concretamente la variable precio. En la Figura 50 se muestra la gráfica de dependencia SHAP para esta variable. En esta gráfica, cada punto representa una muestra del conjunto de prueba.




Figura 5.2: Gráfica de dependencia SHAP para la variable precio en Random Forest. Fuente: elaboración propia

En la imagen se observa que todos los puntos presentan valores SHAP negativos, comprendidos aproximadamente entre -0,019 y -0,014, independientemente del valor del precio. Esto significa que, para cualquier nivel de precio, la contribución de esta variable a la predicción es siempre negativa, el modelo Random Forest asocia el precio del activo con una reducción sistemática del rendimiento previsto.

A su vez, se aprecia una relación no lineal entre el precio y su impacto. Esta no linealidad indica que el efecto del precio sobre la predicción no es constante, sino que varía en función de su valor y de las interacciones con otras variables.

- **Análisis de una predicción individual** El análisis SHAP permite des-

componer una predicción concreta en la contribución individual de cada variable, respondiendo a la pregunta de ¿por qué el modelo predijo este valor? Para ello se utiliza el gráfico waterfall, representado en la Figura 51.




Figura 5.3: Descomposición SHAP de una predicción individual para Random Forest. Fuente: elaboración propia.

En este caso concreto, el modelo partía de un **valor base de 0,034** (3,4%), que representa el rendimiento promedio que el modelo predeciría en ausencia de información específica. Sin embargo, para esta muestra, la predicción final fue de **-0,01**. La diferencia entre ambos valores se explica por la contribución acumulada de las distintas variables.

Las variables que más contribuyeron a reducir la predicción fueron:

- **tipos_ecb = 4,0**: los tipos de interés del BCE en ese momento eran del 4 %, lo que restó 2 puntos porcentuales a la predicción.
- **inflacion_usa_lag6 = 0,05**: la inflación estadounidense de hace seis meses era del 5 %, lo que también restó 2 puntos porcentuales.
- **precio = 168,79**: el precio del activo en ese momento se encontraba en un rango que el modelo asocia con rendimientos negativos, restando otros 2 puntos porcentuales.

5.1. Aplicación de técnicas de interpretabilidad

Por el contrario, la variable **tipos_fed_lag1 = 5,33** actuó en sentido contrario, contribuyendo positivamente con aproximadamente 1 punto porcentual.

El resultado neto de estas contribuciones, sumado al valor base, arrojó la predicción final del -1 %. Este ejemplo ilustra cómo el modelo Random Forest integra información de múltiples variables (tipos de interés, inflación y precio) para llegar a una predicción concreta, y cómo SHAP permite desglosar este razonamiento de forma comprensible.

■ **Conclusiones del análisis SHAP para Random Forest** Del análisis SHAP aplicado al modelo Random Forest se concluye que:

- El **precio del activo** es el predictor más relevante, mostrando una relación no lineal con el rendimiento previsto.
- Los **tipos de interés del BCE** tienen una influencia significativa, superior incluso a los tipos de la Fed.
- La **volatilidad** (VIX) y la **inflación** con retardos de 3 y 6 meses, también se encuentran entre las variables más importantes.
- El rendimiento del S&P 500 tiene un papel secundario, lo que indica que las variables específicas del activo y las macroeconómicas son más determinantes que el comportamiento general del mercado.
- Las variables macroeconómicas, tienen una fuerte importancia a la hora de explicar el modelo.
- El modelo muestra **relaciones no lineales** que justifican el uso de Machine Learning.
- El análisis individual de predicciones es interpretable mediante waterfall y force plots, lo que facilita la explicación de predicciones concretas.

2. **Gradient Boosting** El análisis SHAP aplicado al modelo Gradient Boosting sigue la misma metodología que en el caso de Random Forest. Se ha utilizado el explainer `TreeExplainer` de la librería SHAP, tomando una muestra representativa de 100 observaciones del conjunto de entrenamiento para construir el explainer, y posteriormente se han calculado los valores SHAP para todo el conjunto de prueba.

- **Importancia global de las variables** En la Figura 52 se muestra la importancia global de las variables para el modelo Gradient Boosting, calculada como la media de los valores SHAP absolutos.




Figura 5.4: Importancia global de variables para Gradient Boosting según SHAP. Fuente: elaboración propia.

Se observa que, al igual que en Random Forest, la variable más influyente es el **precio** del activo, con una importancia SHAP de 0,0315. Le siguen la **inflación estadounidense con tres meses de retardo** (0,0097) y la **volatilidad del mercado con un mes de retardo** (0,0092).

Por otro lado, a diferencia de Random Forest, donde los tipos del BCE ocupaban la segunda posición, en Gradient Boosting cobra mayor protagonismo la **inflación estadounidense**, que aparece de 3 formas diferentes. Esto indica que Gradient Boosting le da un peso especial a

5.1. Aplicación de técnicas de interpretabilidad

las variables relacionadas con los precios y la política monetaria de Estados Unidos.

A su vez, también destaca la presencia del **rendimiento del oro** en la octava posición, que no aparecía entre las más importantes en Random Forest. Esto indica que Gradient Boosting captura mejor la relación entre el oro y el rendimiento de Apple, esto muy posiblemente se deba a la capacidad de Gradient Boosting para modelar interacciones más complejas entre variables.

- **Gráfica de dependencia** En la Figura 53 se muestra la gráfica de dependencia SHAP para la variable más relevante, el precio.




Figura 5.5: Gráfica de dependencia SHAP para la variable precio en Gradient Boosting. Fuente: elaboración propia.

En la imagen se observa que todos los puntos presentan valores SHAP negativos, comprendidos aproximadamente entre -0,038 y -0,024, independientemente del valor del precio. Esto significa que, al igual que en Random Forest, la contribución del precio a la predicción es siempre negativa, por lo tanto, el modelo Gradient Boosting asocia el precio del activo con una reducción del rendimiento previsto.

A su vez, se aprecia una relación no lineal entre el precio y su impacto.

Aunque todos los valores son negativos, los puntos no se alinean sobre una línea recta horizontal constante. Esta no linealidad indica que el efecto del precio sobre la predicción no es perfectamente constante, sino que varía ligeramente en función de su valor y de las interacciones con otras variables, tal y como sucede en Random Forest.

Por otro lado, en el análisis de interpretabilidad, se ha visto como por ejemplo variables como la inflación de usa con retardo de 3 meses o la volatilidad, con retardo de 1, ambas variables presentaban valores positivos de SHAP, lo que indica que estas variables mejoran el rendimiento previsto.

- **Análisis de una predicción individual** Pasando ahora al análisis de una predicción individual, en la Figura 54 se muestra el gráfico waterfall para dicha predicción individual del modelo Gradient Boosting.




Figura 5.6: Descomposición SHAP de una predicción individual para Gradient Boosting. Fuente: elaboración propia.

En este caso concreto, el modelo partía de un **valor base de 0,037**, que representa el rendimiento que el modelo predeciría en ausencia de información específica. Finalmente, la predicción fue de **0,056**, un rendimiento positivo que supera al valor base.

Las variables que más contribuyeron a esta predicción positiva fueron:

5.1. Aplicación de técnicas de interpretabilidad

- **precio = 168,79**: el precio del activo en ese momento restó 3 puntos porcentuales a la predicción.
- **inflacion_usa_lag6 = 0,05**: la inflación estadounidense de hace seis meses (5 %) también restó 2 puntos porcentuales.
- **inflacion_usa = 0,033**: la inflación normal (3,3 %) contribuyó positivamente con 2 puntos porcentuales.
- **volatilidad_6m = 0,065**: la volatilidad a seis meses aportó 2 puntos porcentuales positivos.
- **curva10Y2Y = -0,19**: el diferencial de la curva de tipos (negativo, lo que indica inversión de la curva) contribuyó positivamente con 1 punto porcentual.
- **oro_return = 0,043**: el rendimiento del oro (4,3 %) aportó 1 punto porcentual positivo.

A diferencia de lo analizado en Random Forest, donde la predicción fue negativa (-1 %), en este caso Gradient Boosting predijo un rendimiento positivo del 5,6 %.

■ Conclusiones del análisis SHAP para Gradient Boosting

Del análisis SHAP aplicado al modelo Gradient Boosting se concluye que:

- El **precio del activo** vuelve a ser el predictor más relevante, mostrando una relación no lineal similar a la observada en Random Forest.
- La **inflación estadounidense** cobra un protagonismo especial en este modelo, apareciendo en tres de las primeras siete posiciones (inflación normal, con retardo de 1 mes y con retardo de 3 meses).
- El **rendimiento del oro** aparece entre las variables más importantes, a diferencia de Random Forest, lo que sugiere que Gradient Boosting captura mejor las relaciones entre activos.
- Los **tipos de interés de la Fed** aparecen en sexta posición, mientras que los tipos del BCE no se encuentran entre las primeras variables, a diferencia de Random Forest. Esto refleja diferencias en la estrategia de aprendizaje entre ambos modelos.
- El análisis individual de predicciones permite identificar qué variables han impulsado una predicción positiva o negativa, lo que resulta especialmente útil para explicar rendimientos extremos.

3. **LightGBM** Para finalizar con los modelos de Machine Learning, ahora se verá el análisis SHAP aplicado al modelo LightGBM, el cual sigue la misma metodología que en los casos anteriores. Es decir, se ha utilizado el explainer `TreeExplainer` de la librería SHAP, tomando una muestra representativa de 100 observaciones del conjunto de entrenamiento, y posteriormente se han calculado los valores SHAP para todo el conjunto de prueba.

Capítulo 5. Discusión e interpretabilidad de los modelos

- **Importancia global de las variables** En la Figura 55 se muestra la importancia global de las variables para el modelo LightGBM, calculada como la media de los valores SHAP absolutos.




Figura 5.7: Importancia global de variables para LightGBM según SHAP. Fuente: elaboración propia.

Se observa que, al igual que en Random Forest y Gradient Boosting, la variable más influyente es el **precio** del activo, con una importancia SHAP de 0,0233. Le siguen los **tipos de interés del BCE** (0,0127) y la **inflación estadounidense con seis meses de retardo** (0,0119).

LightGBM presenta un patrón interesante ya que combina característi-

5.1. Aplicación de técnicas de interpretabilidad

cas observadas en los dos modelos anteriores. Por ejemplo, LightGBM, al igual que Random Forest, le da una gran importancia a los **tipos de interés del BCE**, mientras que también le da peso a la **inflación estadounidense**, similar a Gradient Boosting.

Cabe destacar también **rendimiento del oro** (0,0083) y del **rendimiento del activo con tres meses de retardo** (0,0081). Esto indica que LightGBM es capaz de capturar tanto relaciones entre activos como componentes autorregresivos de la serie temporal.

Por último, cabe destacar también la importancia de la política monetaria estadounidense, ya que aparecen entre las 10 variables más importantes, tanto los tipos de interes contemporaneo como con retardo de 3 meses.

- **Gráfica de dependencia** Al igual que en los anteriores modelos, se muestra en la Figura 56 la gráfica de dependencia SHAP para la variable más relevante, el precio.




Figura 5.8: Gráfica de dependencia SHAP para la variable precio en LightGBM. Fuente: elaboración propia.

En la imagen se observa que todos los puntos presentan valores SHAP negativos, comprendidos aproximadamente entre -0,03 y -0,01, inde-

pendientemente del valor del precio. Esto significa que, al igual que en Random Forest y Gradient Boosting, la contribución del precio a la predicción es siempre negativa, lo que significa que el modelo LightGBM asocia el precio del activo con una reducción sistemática del rendimiento previsto.

A su vez, se aprecia una relación no lineal entre el precio y su impacto, al igual que en los modelos anteriores.

Sin embargo, al igual que en Gradient Boosting, en LGBM existen algunas variables con valores SHAP positivos que por tanto mejoran el rendimiento previsto. Algunas de estas variables son la inflación estadounidense con retardo de 1 y 3 meses y el retorno del oro también.

- **Análisis de una predicción individual** Por último, en la Figura 57 se muestra el gráfico waterfall para una predicción individual del modelo LightGBM.




Figura 5.9: Descomposición SHAP de una predicción individual para LightGBM. Fuente: elaboración propia.

En este caso concreto, el modelo partía de un **valor base de 0,034**, que representa el rendimiento promedio que el modelo predeciría en ausencia de información específica. Finalmente, la predicción final fue de **0,049**, un rendimiento positivo superior al valor base.

5.1. Aplicación de técnicas de interpretabilidad

Las variables que más contribuyeron a esta predicción fueron:

- **precio = 168,79**: el precio del activo restó 2 puntos porcentuales a la predicción (impacto negativo).
- **inflacion_usa_lag6 = 0,05**: la inflación estadounidense de hace seis meses (5 %) también restó 2 puntos porcentuales.
- **tipos_ecb = 4,0**: los tipos de interés del BCE (4 %) restaron otros 2 puntos porcentuales.
- **inflacion_usa_lag3 = 0,033**: la inflación con tres meses de retardo (3,3 %) contribuyó positivamente con 1 punto porcentual.
- **inflacion_usa_lag1 = 0,037**: la inflación con un mes de retardo (3,7 %) contribuyó positivamente con 1 punto porcentual.
- **oro_return = 0,043**: el rendimiento del oro (4,3 %) aportó 1 punto porcentual positivo.
- **tipos_fed_lag3 = 5,12**: los tipos de la Fed con tres meses de retardo (5,12 %) contribuyeron positivamente con 1 punto porcentual.
- **eurusd = 1,062**: el tipo de cambio euro-dólar (1,062) aportó 1 punto porcentual positivo.
- **vix_lag3 = 13,63**: la volatilidad con tres meses de retardo (13,63) contribuyó positivamente con 1 punto porcentual.

A diferencia de los ejemplos anteriores, en LightGBM se observa una mayor cantidad de variables con contribuciones positivas, que en conjunto compensan ampliamente los impactos negativos del precio, la inflación pasada y los tipos del BCE, resultando en una predicción positiva del 4,9 %.

■ Conclusiones del análisis SHAP para LightGBM

Del análisis SHAP aplicado al modelo LightGBM se concluye que:

- El **precio del activo** vuelve a ser el predictor más relevante, mostrando esta vez una relación casi lineal con el rendimiento previsto, a diferencia de la relación no lineal observada en Random Forest y Gradient Boosting.
- LightGBM combina lo mejor de ambos mundos: otorga gran importancia a los **tipos de interés del BCE** (como Random Forest) y también a la **inflación estadounidense** (como Gradient Boosting).
- El **rendimiento del oro** aparece en sexta posición, confirmando su relevancia como variable predictora, algo que no ocurría en Random Forest.
- Los **tipos de interés de la Fed** aparecen en dos versiones, lo que indica que LightGBM captura tanto el nivel actual como la tendencia de la política monetaria.

- El **tipo de cambio euro-dólar** aparece por primera vez entre las variables que contribuyen a una predicción individual, lo que sugiere que LightGBM es capaz de aprovechar información de divisas que otros modelos no utilizan.
 - El análisis individual de predicciones revela que LightGBM tiende a utilizar un mayor número de variables para construir sus predicciones, lo que podría explicar su mayor rendimiento predictivo observado en el Capítulo 4.
4. **LSTM** El análisis SHAP no se ha aplicado al modelo LSTM debido a su naturaleza de caja negra y a la complejidad computacional que conlleva interpretar redes neuronales recurrentes. Como se discute en el Capítulo 2, la limitada interpretabilidad es una de las principales desventajas de los modelos de Deep Learning frente a los métodos tradicionales. Por tanto, el análisis de interpretabilidad se ha centrado en los modelos de Machine Learning (Random Forest, Gradient Boosting y LightGBM), que son los que ofrecen un mejor equilibrio entre precisión predictiva y capacidad explicativa.
5. **Conclusiones y comparativa de importancia entre modelos** Una vez presentados los resultados del análisis SHAP para los tres modelos de Machine Learning, se pueden extraer conclusiones globales y comparar el comportamiento de cada uno.
- a) **Comparativa entre modelos** La Tabla 58 resume las principales diferencias y similitudes entre los tres modelos analizados.

Aspecto	Random Forest	Gradient Boosting	LightGB,
Variable más importante	Precio	Precio	Precio
2ª variable más importante	tipos_ecb	inflacion_usa_lag3	tipos_ecb
3ª variable más importante	vix_lag1	vix_lag1	inflacion_usa_lag6
4ª variable más importante	inflacion_usa_lag3	inflacion_usa	tipos_fed

Figura 5.10: Comparativa de los modelos según el análisis SHAP. Fuente: elaboración propia.

En todos los modelos, el precio es la variable más importante. Dicho precio tiene un impacto negativo en todos los modelos

De la comparativa se observa que:

- **Random Forest** otorga un peso relevante a los tipos de interés del BCE, lo que sugiere que las condiciones monetarias europeas son especialmente relevantes para este modelo. La inflación estadounidense también aparece, pero en posiciones más secundarias. A su vez, es el modelo donde el precio tiene un impacto negativo de menor magnitud (hasta -0,019).

- **Gradient Boosting** destaca por dar un protagonismo especial a la inflación estadounidense, que aparece hasta en tres versiones diferentes. También es el modelo donde el precio tiene un impacto negativo más pronunciado (hasta -0,038), lo que indica que es más sensible a esta variable. El rendimiento del oro aparece entre las más importantes, a diferencia de Random Forest.
- **LightGBM** combina características de los dos anteriores: da importancia tanto a los tipos del BCE (como Random Forest) como a la inflación estadounidense (como Gradient Boosting). Además, es el único modelo donde el tipo de cambio euro-dólar aparece entre las variables que contribuyen a una predicción individual, lo que sugiere una mayor capacidad para aprovechar información de divisas.

b) **Importancia de las variables macroeconómicas y los retardos** Antes de pasar a las conclusiones, es necesario hacer un pequeño inciso y ver la gran importancia que ha tenido la introducción de las variables macroeconómicas a los datasets. En el análisis SHAP ha confirmado la importancia de haber incluido variables macroeconómicas y sus versiones retardadas en los datasets de entrenamiento. Variables como la inflación estadounidense, los tipos de interés del BCE y de la Fed, y el rendimiento del oro aparecen consistentemente entre las más relevantes en los tres modelos. Esto valida la decisión de no limitarse únicamente a variables de mercado, ya que el contexto macroeconómico aporta información predictiva relevante.

c) **Conclusiones** Los resultados del análisis SHAP tienen implicaciones prácticas relevantes:

- 1) **La selección de variables realizada en el Capítulo 3 ha sido acertada.** La presencia de variables macroeconómicas y sus retardos entre las más importantes confirma que estas magnitudes contienen información predictiva útil más allá de las propias variables de mercado.
- 2) **La inclusión de retardos es fundamental.** La aparición de variables con lag_1, lag_3 y lag_6 en los top de importancia valida la decisión de construir un dataset específico para Machine Learning con versiones retardadas de las variables macroeconómicas.
- 3) **No existe un modelo claramente superior en todos los aspectos.** Cada modelo tiene sus fortalezas: Random Forest es el más estable, Gradient Boosting el que mejor captura la inflación, y LightGBM el que combina lo mejor de ambos.
- 4) **El precio del activo es universalmente relevante.** En los tres modelos, el precio es la variable más importante, y siempre con impacto negativo. Esto indica que, independientemente del algoritmo utilizado, el nivel de precio del activo es un predictor fundamental de su rendimiento futuro.

Más tarde en este capítulo, se someterá a los modelos a diferentes escenarios, de acuerdo a las conclusiones obtenidas en este análisis de SHAP.

5.1.2. Análisis con LIME

Aunque SHAP ha sido el método principal de interpretabilidad en este trabajo, se ha explorado también la técnica LIME para validar los resultados obtenidos. LIME, lo que hace es generar explicaciones locales aproximando el comportamiento del modelo en la vecindad de una instancia específica mediante un modelo más simple e interpretable.

Explicaciones locales para cada modelo

Las explicaciones LIME obtenidas para los tres modelos de Machine Learning fueron consistentes con los resultados de SHAP. En todos los casos, las variables identificadas como más influyentes en las predicciones individuales fueron las mismas.

- **Random Forest:** LIME identificó el precio y la inflación como los principales factores negativos, coincidiendo con lo observado en SHAP. La predicción del modelo fue de -0,0098, igual que la obtenida en SHAP (-0.01).
- **Gradient Boosting:** En este caso, el modelo predijo un valor positivo de 0,0561, igual que en SHAP (0.056). A su vez, LIME señala que las variables que más contribuyeron positivamente fueron el bajo desempleo, la volatilidad con seis y tres meses de retardo. Por otro lado, el precio, la inflación con seis y tres meses de retardo, y los tipos de interés de la Fed actuaron como factores negativos. Estos resultados son consistentes con el análisis SHAP, donde se observó que Gradient Boosting otorga un peso especial a la inflación.
- **LightGBM:** El modelo predijo un valor de 0,0489, igual que en SHAP (0.049). Del mismo modo, LIME muestra una mayor cantidad de variables con contribuciones positivas, lo que confirma la observación de SHAP de que LightGBM utiliza un mayor número de variables para construir sus predicciones. En este análisis de LIME, algunas de las variables que actuaron como factores negativos, fueron el precio, la inflación con seis meses de retardo y los tipos del BCE.

Comparativa SHAP vs LIME

Ambos métodos mostraron resultados consistentes, identificando las mismas variables como las más relevantes en cada predicción individual. En particular:

- En los tres modelos, el **precio** fue el principal factor negativo, coincidiendo con SHAP.
- La **inflación estadounidense** (en sus distintas versiones) apareció como factor negativo en todos los modelos.

- El **desempleo bajo** (inferior a 4,70) actuó como factor positivo en Gradient Boosting y LightGBM.
- LightGBM fue el modelo que presentó un mayor número de variables con contribuciones positivas, lo que explica su mejor rendimiento predictivo observado en el Capítulo 4.

La principal diferencia práctica entre ambos métodos es que SHAP proporciona propiedades matemáticas más sólidas (consistencia, aditividad) y permite análisis global y local, mientras que LIME se limita a explicaciones locales. Por estas razones, SHAP ha sido el método principal en este trabajo, utilizando LIME únicamente como validación de los hallazgos.

5.2. Discusión del modelo

Atendiendo a los valores obtenidos en el análisis de interpretabilidad del apartado anterior, se someterá al modelo a diferentes simulaciones con el objetivo de justificar las decisiones de diseño tomadas a lo largo del trabajo, especialmente la inclusión de variables macroeconómicas y la selección de variables realizada en el Capítulo 3.

Antes de comenzar, mencionar que en los experimentos se han usado los mismos códigos, con la misma estructura y parámetros que se usaron en el capítulo 4. Lo único que cambiará, serán los datasets utilizados, los cuales estarán adaptados a las diferentes situaciones.

1. **Impacto de las variables macroeconómicas** En el Capítulo 2, se mencionó que las variables macroeconómicas aportan una gran información a la hora de predecir el retorno futuro de un activo. A su vez, en el análisis de interpretabilidad se ha visto cómo estas variables macro tenían una gran importancia en las predicciones de los modelos, apareciendo consistentemente entre las más relevantes en los tres modelos analizados (inflación, tipos de interés, desempleo, etc.).

Teniendo en cuenta todo lo mencionado, se ha sometido a los modelos a un entrenamiento y backtesting sobre un dataset que contiene únicamente las variables del propio activo (precio, medias móviles, volatilidad, momentum y retardos del target), eliminando por completo todas las variables macroeconómicas. De este modo, se puede ver el impacto real que estas variables tienen sobre la capacidad predictiva de los modelos.

- **Resultados para Random Forest** En la Tabla 3 se muestra la comparativa de resultados para Random Forest entre la configuración original (con variables macro) y la configuración del experimento (sin variables macro).

Capítulo 5. Discusión e interpretabilidad de los modelos

Métrica	Original	Sin macro
<i>Conjunto de entrenamiento</i>		
MAE	0,0741	0,0737
RMSE	0,0888	0,0855
R ²	-0,1660	-0,0804
DA	46,15 %	50,00 %
<i>Conjunto de validación</i>		
MAE	0,0477	0,0496
RMSE	0,0579	0,0589
R ²	-0,0001	-0,0352
DA	59,26 %	59,26 %
<i>Backtesting (media ± desviación)</i>		
MAE	0,0663 ± 0,0355	0,0727 ± 0,0266
RMSE	0,0786 ± 0,0377	0,0834 ± 0,0268
R ²	-0,0399 ± 0,1664	-0,2582 ± 0,2322
DA	58,33 % ± 35,36 %	41,67 % ± 11,79 %

Cuadro 5.1: Comparativa de resultados para Random Forest: original vs sin macro. Fuente: elaboración propia.

Se observa que, en el conjunto de validación, las diferencias son relativamente pequeñas, el R² pasa de -0,0001 a -0,0352, y la directional accuracy se mantiene en 59,26 %. Sin embargo, en el backtesting las diferencias son más notables. El R² medio empeora significativamente, pasando de -0,0399 a -0,2582, y la directional accuracy media cae del 58,33 % al 41,67 %. Esto indica que, aunque el modelo sin macro puede tener un rendimiento aceptable, su capacidad de generalización a diferentes períodos históricos se ve seriamente comprometida al eliminar las variables macroeconómicas.

En cuanto a las gráficas de predicción versus valor real, ambas configuraciones presentan un aspecto similar, con la diferencia de que las predicciones del modelo sin macro tienden a estar más cerca de la media histórica, lo que refleja una menor capacidad para capturar los movimientos extremos del mercado.

- **Resultados para Gradient Boosting** La Tabla 4 muestra la comparativa de resultados para Gradient Boosting.

5.2. Discusión del modelo

Métrica	Original	Sin macro
<i>Conjunto de entrenamiento</i>		
MAE	0,0843	0,0636
RMSE	0,0991	0,0773
R ²	-0,4511	0,1161
DA	42,31 %	57,69 %
<i>Conjunto de validación</i>		
MAE	0,0437	0,0567
RMSE	0,0531	0,0698
R ²	0,1574	-0,4525
DA	62,96 %	55,56 %
<i>Backtesting (media ± desviación)</i>		
MAE	0,0729 ± 0,0378	0,0717 ± 0,0086
RMSE	0,0865 ± 0,0409	0,0872 ± 0,0133
R ²	-0,1832 ± 0,2970	-0,7459 ± 0,3830
DA	41,67 % ± 23,57 %	36,67 % ± 12,58 %

Cuadro 5.2: Comparativa de resultados para Gradient Boosting: original vs sin macro. Fuente: elaboración propia.

En el caso de Gradient Boosting, el deterioro al eliminar las variables macro es mucho más pronunciado que en Random Forest. En el conjunto de validación, el R² cae de 0,1574 a -0,4525 y la direccional accuracy desciende del 62,96 % al 55,56 %. Mientras tanto, en el backtesting, el R² medio pasa de -0,1832 a -0,7459, y la direccional accuracy media cae del 41,67 % al 36,67 %, indicando así una bajada de rendimiento brutal.

La diferencia más notable se aprecia en las gráficas de predicción versus valor real. Mientras que el modelo original de Gradient Boosting mostraba un seguimiento razonable de la tendencia real, el modelo sin macro produce predicciones prácticamente horizontales, centradas en la media histórica, lo que indica una pérdida total de capacidad predictiva.

- **Resultados para LightGBM** La Tabla 5 muestra la comparativa de resultados para LightGBM entre la configuración original (con variables macro) y la configuración del experimento (sin variables macro).

Métrica	Original	Sin macro
<i>Conjunto de entrenamiento</i>		
MAE	0,0852	0,0744
RMSE	0,1013	0,0951
R ²	-0,5171	-0,3361
DA	34,62 %	57,69 %
<i>Conjunto de validación</i>		
MAE	0,0385	0,0579
RMSE	0,0495	0,0758
R ²	0,2688	-0,7161
DA	77,78 %	55,56 %
<i>Backtesting (media ± desviación)</i>		
MAE	0,0595 ± 0,0172	0,0851 ± 0,0355
RMSE	0,0725 ± 0,0200	0,0989 ± 0,0356
R ²	-0,0544 ± 0,0861	-0,6033 ± 0,0102
DA	57,69 % ± 10,88 %	37,50 % ± 5,89 %

Cuadro 5.3: Comparativa de resultados para LightGBM de original vs sin macro. Fuente: elaboración propia.

LightGBM es, de todos los modelos de Machine Learning, el que sufre una degradación más severa al eliminar las variables macroeconómicas. En el conjunto de validación, el R² pasa de un sólido 0,2688 (el mejor de todos los modelos) a un -0,7161, y la directional accuracy cae del excepcional 77,78 % al 55,56 %, perdiendo más de 22 puntos porcentuales.

En el backtesting, el deterioro es aún más evidente. El R² medio pasa de -0,0544 a -0,6033, y la directional accuracy media cae del 57,69 % al 37,50 %, situándose muy por debajo del azar. Esto confirma lo observado en el análisis SHAP, LightGBM era el modelo que más variables utilizaba en sus predicciones y el que mejor rendimiento alcanzaba en la configuración original, precisamente porque era capaz de aprovechar la información macroeconómica de manera más eficaz que los demás modelos.

- **Resultados para LSTM** En la Tabla 6 se muestra la comparativa de resultados para la red LSTM.

Métrica	Original	Sin macro
<i>Conjunto de entrenamiento</i>		
Loss	0,0984	0,0966
MAE	0,2467	0,2438
<i>Conjunto de validación</i>		
MAE	0,0509	0,0723
RMSE	0,0603	0,0898
R ²	0,0396	-1,1262
DA	61,11 %	53,70 %
<i>Backtesting (media ± desviación)</i>		
MAE	0,0723 ± 0,0294	0,0886 ± 0,0364
RMSE	0,0849 ± 0,0337	0,1028 ± 0,0395
R ²	-0,8073 ± 0,9785	-2,4345 ± 3,7019
DA	47,83 % ± 19,01 %	54,35 % ± 28,96 %
<i>Backtesting (métricas globales)</i>		
MAE	0,0723	0,0886
RMSE	0,0910	0,1099
R ²	-0,3863	-1,0191
DA	47,83 %	54,35 %

Cuadro 5.4: Comparativa de resultados para LSTM de original vs sin macro. Fuente: elaboración propia.

La LSTM, que ya de por sí presentaba un rendimiento limitado en la configuración original debido al reducido tamaño del dataset, empeora notablemente al eliminar las variables macro. En el conjunto de validación, el R² cae de 0,0396 a -1,1262 y el MAE aumenta de 0,0509 a 0,0723.

En el backtesting, el R² medio pasa de -0,8073 a -2,4345, lo que indica una pérdida total de capacidad predictiva.

- **Conclusiones del experimento** Los resultados obtenidos confirman que la inclusión de variables macroeconómicas mejora el rendimiento de todos los modelos evaluados. LightGBM es el modelo que más se beneficia de su inclusión, mejorando su R² en validación de -0,7161 a 0,2688 y su directional accuracy del 55,56 % al 77,78 %. Gradient Boosting también experimenta una mejora significativa, mientras que Random Forest se muestra como el modelo más robusto ante la ausencia de estas variables. Por último, la LSTM, aunque limitada por el reducido tamaño del dataset, también empeora su rendimiento al eliminar las variables macro. En definitiva, los resultados validan la decisión de incluir variables macroeconómicas en los modelos predictivos, ya que aportan información relevante y mejoran tanto la precisión como la robustez temporal de las predicciones.

2. **Impacto de la selección de variables** En el Capítulo 3 se realizó un proceso de selección de variables (A partir de la función **seleccion_variables**)

Capítulo 5. Discusión e interpretabilidad de los modelos

con el objetivo de eliminar aquellas redundantes o con poca capacidad predictiva, reduciendo así el ruido y mejorando el rendimiento de los modelos. Para validar esta decisión, se han entrenado los modelos con el dataset completo (sin selección de variables) y se han comparado los resultados con los obtenidos en el Capítulo 4, donde se utilizó el dataset optimizado para cada modelo.

La Tabla 59 muestra la comparativa de resultados para los cuatro modelos evaluados.

Modelo	R ² validación con selección	R ² validación sin selección	DA backtesting con selección	DA backtesting sin selección
Random Forest	-0.0001	-0.1081	58.33%	50.00%
Gradient Boosting	0.1574	-0.2916	41.67%	46.67%
LightGBM	0.2688	-0.5151	57.69%	41.67%
LSTM	0.0396	-3.0678	47.83%	47.10%

Figura 5.11: Comparativa de resultados: con selección de variables vs sin selección. Fuente: elaboración propia.

- **Conclusiones del experimento** Los resultados confirman que la selección de variables realizada en el Capítulo 3 fue beneficiosa para todos los modelos. LightGBM es el que más mejora con la selección de variables, pasando de un R² de -0,5151 a 0,2688 en validación, y mejorando su directional accuracy en backtesting del 41,67 % al 57,69 %. Gradient Boosting también experimenta una mejora significativa, elevando su R² en validación de -0,2916 a 0,1574. Random Forest, aunque más robusto, también mejora sus métricas. Por último, la LSTM, ve su R² en validación mejorar drásticamente de -3,0768 a 0,0396. En definitiva, eliminar variables redundantes y ruidosas mediante un proceso de selección adecuado mejora la capacidad predictiva de los modelos y reduce el sobreajuste.
3. **Importancia del precio** Como se vió en el análisis de interpretabilidad, la variable que más importancia aporta a los modelos, es el precio. Por ello mismo, en esta sección, se someterá a los modelos a un entrenamiento y backtesting sobre los datasets optimizados para cada modelo, pero sin la variable precio.

En la siguiente Tabla 60, se ve la comparativa de las métricas sin modificaciones y las métricas obtenidas para este experimento

Modelo	R ² validación con precio	R ² validación sin precio	DA backtesting con precio	DA backtesting sin precio
Random Forest	-0.0001	-0.1691	58.33%	50.00%
Gradient Boosting	0.1574	-0.0019	41.67%	56.67%
LightGBM	0.2688	-0.7227	57.69%	41.67%

Figura 5.12: Impacto de eliminar la variable precio en los modelos de Machine Learning. Fuente: elaboración propia.

Los resultados confirman que el precio es una variable fundamental para los modelos. LightGBM es el más afectado, con una caída del R² en validación de 0,2688 a -0,7227. Random Forest y Gradient Boosting también empeoran, aunque de forma menos pronunciada. En el caso de los backtesting, los resultados también empeoran en los 3 modelos. Estos resultados anteriores, validan lo observado en el análisis SHAP, donde el precio aparecía consistentemente como el predictor más importante en los tres modelos.

Por otro lado, este experimento no se ha realizado sobre LSTM, ya que el análisis SHAP no se aplicó a este modelo al tratarse de una caja negra.

4. **Simulación de escenarios** Por ver si lo hago o nno, seguramente no, pero por si acaso, lo dejo aqui de momento
5. **Predicciones sobre otro activo** Para evaluar si los modelos desarrollados son capaces de generalizar su capacidad predictiva a otros activos, se ha aplicado el mismo pipeline de datos descrito en la Figura 5 a otros activos tecnológicos, concretamente Microsoft y NVIDIA. A continuación, se han entrenado los mismos modelos del Capítulo 4 (Random Forest, Gradient Boosting, LightGBM y LSTM) utilizando los mismos códigos y parámetros, pero con los datasets correspondientes a cada nuevo activo. Es importante destacar que, debido a que la selección de variables está automatizada, el conjunto de variables resultante es diferente para cada activo.

Con respecto a los resultados obtenidos, estos fueron notablemente peores que los alcanzados con Apple en todos los modelos evaluados. Las métricas de validación mostraron R² negativos y directional accuracies cercanas o inferiores al 50 %, lo que indica una pérdida total de capacidad predictiva.

Estos resultados, aunque negativos en términos de rendimiento, aportan una conclusión relevante y es que, el pipeline diseñado no generaliza de forma automática a cualquier activo tecnológico. Una posible explicación es que Apple presenta una estructura temporal y una sensibilidad a las variables macroeconómicas más regular y predecible que otros activos del mismo sector. Otra hipótesis es que el proceso de selección de variables, al ser diferente para cada activo, puede estar eligiendo conjuntos de características que no capturan adecuadamente la dinámica de MSFT o NVDA.

La solución más clara, sería reentrenar y reoptimizar los modelos específicamente para cada activo, permitiendo que la búsqueda de hiperparáme-

tros y la selección de variables se adapten a las particularidades de cada uno. Esto sugiere que, aunque el pipeline es transferible, los modelos resultantes no lo son sin un proceso de recalibración específico.

5.3. Conclusiones del trabajo

Para finalizar este capítulo, se presentan las principales conclusiones extraídas del trabajo, desde el proceso de construcción y entrenamiento hasta la evaluación de los modelos. Las principales conclusiones extraídas son las siguientes:

- **Selección automática de variables.** Este proceso ha sido clave para reducir el ruido y eliminar redundancias. Los modelos entrenados con el dataset optimizado superaron con creces a los entrenados con el dataset completo, especialmente LightGBM, cuyo R^2 mejoró de -0,5151 a 0,2688.
- **Retardos (lags).** La inclusión de versiones retardadas de las variables macroeconómicas, basada en el análisis de autocorrelación del Capítulo 3, ha resultado fundamental en los modelos de Machine Learning. Su importancia se refleja en el análisis SHAP, donde aparecen recurrentemente variables como `inflacion_usa_lag3`, `inflacion_usa_lag6` o `vix_lag1`.
- **Datasets diferenciados.** La creación de dos datasets (uno para Machine Learning con retardos en variables macroeconómicas y otro para Deep Learning sin retardos) ha sido acertada. Los modelos de Machine Learning se benefician de los lags, mientras que la LSTM no los necesita, debido a su gran memoria temporal.
- **Partición temporal.** A la hora de crear secuencias temporales para los modelos, el reparto 80/10/10, realizado respetando el orden cronológico ha sido clave para evaluar la capacidad predictiva real de los modelos, evitando fugas de información futura.
- **Comparativa de modelos.** LightGBM ha alcanzado el mejor rendimiento predictivo (R^2 0,2688, DA 77,78%). Por otro lado, Gradient Boosting ha ofrecido el mejor equilibrio entre precisión (R^2 0,1574) y estabilidad temporal. Random Forest se ha mostrado como el modelo más robusto ante la ausencia de variables macro. En cuanto a Deep Learning, la LSTM, pese a estar limitada por el reducido tamaño del dataset (265 muestras mensuales), logró un R^2 positivo (0,0396) gracias a las técnicas de regularización aplicadas (data augmentation y Gaussian noise). A su vez, tal y como se mencionó en las conclusiones del Capítulo 4, cada uno de los modelos es útil en función de la situación. En caso de buscar precisión, el más acertado es LGBM, en caso de buscar estabilidad, la mejor opción es Gradient Boosting o Random Forest, y en caso de buscar un modelo que pueda captar patrones temporales complejos, la LSTM es la mejor opción siempre y cuando se disponga de un conjunto de muestras lo suficientemente grande.
- **Interpretabilidad.** El análisis mediante SHAP y LIME identificó el precio del activo como el predictor más relevante en todos los modelos, con un impacto sistemáticamente negativo. Le siguen en importancia los tipos de

interés del BCE, la inflación estadounidense (con retardos de 3 y 6 meses) y la volatilidad del mercado (VIX).

- **Validación experimental.** Los experimentos confirmaron que eliminar el precio, las variables macro o la selección de variables degrada drásticamente el rendimiento. Además, los modelos no son generalizables a cualquier activo, lo que sugiere la necesidad de recalibración específica por activo.

5.3.1. Limitaciones del estudio

Sin embargo, a pesar de los buenos resultados obtenidos, el presente trabajo presenta una serie de limitaciones que deben tenerse en cuenta:

- **Reducido tamaño del dataset.** Con solo 265 muestras mensuales, la LSTM no ha podido explotar todo su potencial, ya que los modelos de Deep Learning requieren grandes volúmenes de datos (Miles o decenas de miles de muestras) para poder compararse e incluso superar a más tradicionales como los de Machine Learning. El reducido tamaño del dataset, explica por qué la LSTM obtuvo un rendimiento limitado frente a LightGBM o Gradient Boosting, a pesar de las técnicas de regularización aplicadas.
- **Alta variabilidad en backtesting.** El rendimiento de los modelos no es estable a lo largo del tiempo, como reflejan las altas desviaciones estándar en las métricas de backtesting. Esta variabilidad se debe a que la predictibilidad de los mercados financieros no es uniforme, es decir, existen períodos más estables, donde los modelos aciertan más, y otros como crisis o cambios de régimen donde fallan estrepitosamente.
- **Dificultad para predecir eventos extremos y outliers.** Los modelos han mostrado un rendimiento muy variable en períodos de alta volatilidad, donde las predicciones fueron bastante peores de lo normal. Esto se debe a que los eventos extremos son poco frecuentes en los datos de entrenamiento, por lo que los modelos no tienen suficientes ejemplos para aprender patrones robustos en esos contextos.
- **Sobreajuste a Apple.** Los modelos entrenados específicamente para Apple no funcionaron correctamente al aplicarlos a otros activos tecnológicos como por ejemplo Microsoft o NVIDIA. Esto indica que los patrones aprendidos son específicos de Apple y por lo tanto, para poder aplicarlos a otros activos o fondos, será necesaria una recalibración y una reoptimización de los hiperparámetros para cada modelo. Esto se debe a que cada activo tiene su propia "personalidad", lo que limita la generalización de los modelos.
- **Baja interpretabilidad de la LSTM.** A diferencia de los modelos de Machine Learning basados en árboles, la red LSTM es una caja negra. Esto se debe a su arquitectura recurrente y al elevado número de parámetros internos (pesos y sesgos), que hacen prácticamente imposible descomponer una predicción en contribuciones individuales de cada variable.

Capítulo 6

Conclusiones y análisis de impacto

En este capítulo se evalúa el grado de cumplimiento de los objetivos iniciales del trabajo y se analiza el impacto del proyecto en diferentes ámbitos, incluyendo su alineación con los Objetivos de Desarrollo Sostenible. Asimismo, se proponen líneas de trabajo futuro orientadas a superar las limitaciones identificadas y a ampliar el alcance del sistema desarrollado.

6.1. Cumplimiento de los objetivos del trabajo

A continuación, se evalúa el cumplimiento de los objetivos iniciales del trabajo propuestos en la propuesta inicial del TFG.

6.1.1. Objetivos cumplidos

- **Analizar datos históricos de productos de inversión.** Se han analizado los datos históricos de Apple desde enero de 2003 hasta diciembre de 2025, a partir de unos modelos predictivos con frecuencia mensual.
- **Definir el datastream multidimensional y documentar variables.** En el Capítulo 3 se documentaron todas las variables (precio, inflación, tipos de interés, VIX ...) y se diseñó en python un pipeline de procesamiento completo y cuyo flujo se puede ver en la Figura 3.1.
- **Definición del problema: obtención y gestión de datos.** Se recopilieron datos de Yahoo Finance y de la FED, a su vez se definió una estructura de almacenamiento en CSV. Por otro lado, pese a encontrarse en los objetivos inicales el uso de una base de datos relacional, finalmente nose implementó debido al reducido tamaño de la muestra (265 meses), optándose por un almacenamiento más sencillo y ágil en formato CSV.
- **Procesamiento y análisis de datos (EDA).** En el Capítulo 3 se realizó un análisis exploratorio completo con R, en dicho análisis, se incluyeron distribuciones, correlaciones, autocorrelaciones, PCA y clustering.

6.1. Cumplimiento de los objetivos del trabajo

- **Ingeniería de características.** Se generaron variables derivadas como lags, medias móviles o volatilidades entre otras. Del mismo modo, se crearon dos datasets diferenciados, uno para Machine Learning con retardos y otro para Deep Learning sin retardos.
- **Desarrollo de modelos predictivos.** En el Capítulo 4, se implementaron en Python los modelos de Machine Learning Random Forest y Gradient Boosting, a su vez, se implementó un modelo adicional, LightGBM, el cual daba mejores resultados que los anteriores. En lo que respecta a Deep Learning, se implementó el modelo LSTM, tal como se describe en el Capítulo 4.
- **Predicción a diferentes intervalos de tiempo.** En el modelo LSTM, la arquitectura permite predecir secuencias de 6 meses (OUTPUT_LENGTH=6), de las cuales se extrajeron las predicciones para horizontes de 1, 3 y 6 meses. Mientras tanto, en los modelos de Machine Learning, la predicción se realizó a un horizonte de 1 mes.
- **Evaluación experimental (backtesting).** En el Capítulo 4, se realizó en Python, backtesting con ventana deslizante para todos los modelos, comparando su rendimiento y analizando su robustez temporal, permitiendo ver así, que modelo es más eficiente en cada situación.
- **Visualización de resultados.** En los Capítulos 3, 4 y 5, se generaron gráficas para visualizar los resultados obtenidos (Gráficas de evolución de variables, gráficas de predicción vs real, gráficas de SHAP, tablas comparativas...). Estas gráficas fueron generadas con la librería matplotlib, de Python. Por lo tanto, no se utilizó Power BI debido a que hacer un dashboard, era mucho más costoso y más difícil de visualizar que las gráficas y tablas mostradas en la memoria.
- **Análisis de requisitos (herramientas).** Se utilizaron Python, Pandas, NumPy, yfinance, matplotlib, Jupyter Notebook, Scikit-learn, TensorFlow, SHAP, LIME, y la memoria se redactó en Overleaf, con control de versiones en GitHub.
- **Modelos predictivos generalizados y discriminativos.** Se implementaron Random Forest y Gradient Boosting (modelos generalizados) y LSTM (modelo discriminativo). Adicionalmente, se incorporó LightGBM por sus mejores resultados.

Se podría concluir que se han cumplido la mayoría de los objetivos planteados inicialmente, aunque algunos de ellos, como la implementación de una base de datos relacional o el uso de Power BI para visualización, fueron modificados durante el desarrollo del proyecto debido a consideraciones prácticas y al tamaño del dataset.

6.1.2. Líneas de trabajo futuro

A partir de las limitaciones identificadas y los resultados obtenidos, se proponen las siguientes líneas de trabajo futuro, ordenadas por prioridad:

1. **Aumento de la frecuencia de los datos.** La principal limitación de la LSTM fue el reducido tamaño del dataset (265 muestras). Como línea prioritaria, se propone utilizar datos diarios en lugar de mensuales, lo que proporcionaría miles de muestras y permitiría a la red recurrente explotar todo su potencial, mejorando previsiblemente su rendimiento.
2. **Modelo híbrido LightGBM + LSTM.** Dado que LightGBM ha sido el modelo con mejor rendimiento predictivo (R^2 0,2688, DA 77,78 %) y la LSTM aporta capacidad para capturar dependencias temporales, se propone desarrollar un modelo híbrido, ta que combine ambos modelos. Este híbrido podría aprovechar la precisión de LightGBM y la memoria temporal de la LSTM, superando seguramente a cada modelo por separado.
3. **Incorporación del filtro de Kalman.** El filtro de Kalman [56] es una técnica de estimación recursiva que permite filtrar el ruido de las series temporales y estimar componentes latentes. Entonces, se propone integrarlo como paso de preprocesamiento para reducir el ruido de las variables macroeconómicas y del precio, o combinarlo con los modelos existentes (por ejemplo, mediante un enfoque híbrido Kalman-LSTM) para mejorar la robustez frente a cambios de régimen y eventos extremos.
4. **Simulación de escenarios.** Como línea de trabajo futuro, se propone desarrollar un simulador de escenarios económicos que permita evaluar la respuesta de los modelos ante diferentes contextos macroeconómicos (recesión, crisis financiera ...). Este simulador modificaría todas las variables macroeconómicas a la vez y de forma coherente, generando así escenarios realistas que podrían utilizarse para analizar la robustez de los modelos y su capacidad de generalización ante condiciones adversas del mercado.
5. **SHAP para LSTM.** Aunque SHAP no se aplicó a la LSTM en este trabajo por su complejidad, se plantea como línea futura su implementación mediante DeepExplainer [57] o GradientExplainer [58], lo que permitiría descomponer las predicciones de la red recurrente y hacerla más transparente, mejorando su aplicabilidad en entornos financieros.
6. **Generalización a múltiples activos.** Como se observó que los modelos no generalizan bien a otros activos, se propone desarrollar técnicas de transfer learning o incluir características invariantes al activo que permitan aplicar el mismo pipeline a cualquier activo sin necesidad de recalibración exhaustiva.
7. **Optimización avanzada de hiperparámetros.** La búsqueda de hiperparámetros se realizó mediante GridSearch sobre un espacio limitado. Como línea futura, se propone utilizar búsqueda bayesiana [59], que permite explorar espacios de búsqueda más amplios con el mismo coste computacional, encontrando potencialmente configuraciones mejores.

6.2. Evaluación del proceso de elaboración del TFG

La realización de este Trabajo de Fin de Grado ha supuesto una experiencia positiva y útil tanto a nivel académico como personal. Esto es debido a que a lo largo del desarrollo del proyecto, he tenido la oportunidad de aplicar de forma práctica los conocimientos adquiridos durante el grado, enfrentándome a retos reales de análisis de datos, modelado predictivo y evaluación de algoritmos de Machine Learning y Deep Learning.

Del mismo modo, este trabajo me ha permitido familiarizarme y trabajar con herramientas y tecnologías que, pese a conocerlas, no había tenido la oportunidad de profundidad en ellas, una de estas herramientas es Python y sus correspondientes librerías (Pandas, NumPy, Scikit-learn, TensorFlow ...). Con Python, he sido capaz de trabajar y tratar series temporales e implementar los modelos predictivos. Otra de las herramientas que me ha permitido aprender este trabajo, es R, el cual me fue de gran utilidad para el EDA. Este proceso de aprendizaje ha sido clave para ampliar mis competencias técnicas y comprender las dificultades reales que conlleva la predicción de series financieras.

En lo que respecta a la planificación temporal, todo ha transcurrido de acuerdo a lo planeado inicialmente y es que, pese a haber encontrado algunos baches y dificultades, he conseguido solventarlos y poder continuar con lo planificado, ciniéndome siempre a los objetivos establecidos para cada semana.

Antes de finalizar, comentar que si bien no me ha sido posible completar el reto personal de conseguir un modelo generalizable a cualquier activo, el trabajo realizado constituye una base sólida y escalable sobre la que construir futuras mejoras. La estructura del pipeline de datos, la selección automática de variables y la implementación de los modelos, permiten visualizar con claridad el potencial del sistema para ser aplicado a otros activos o ampliado con nuevas funcionalidades.

Para concluir, personalmente este proyecto me ha permitido profundizar en metodologías de desarrollo orientadas a la calidad y la eficiencia, reforzando mi compromiso con el diseño de soluciones útiles y sostenibles que respondan a necesidades reales. Además, me ha ayudado a confirmar mi interés por el análisis de datos y la inteligencia artificial, áreas en las que me gustaría seguir formándome y desarrollándome profesionalmente.

6.3. Análisis de impacto

En esta última sección, se analizará el impacto que tiene este TFG sobre diferentes ámbitos, incluyendo el económico, tecnológico, social, personal y medioambiental. Además, se evaluará la alineación del trabajo con los Objetivos de Desarrollo Sostenible (ODS) [60] de la Agenda 2030.

6.3.1. Impacto económico

Desde un punto de vista económico, el hecho de poder predecir el rendimiento de activos financieros con una *directional accuracy* del 77,78% en algunos modelos, supone una ventaja importante para inversores y gestores de carteras. Aunque los modelos desarrollados no garantizan el acierto total, ofrecen una ventaja estadística sobre un predictor ingenuo, lo que podría traducirse en mejores decisiones de inversión y una asignación más eficiente de los recursos. Además, al tratarse de herramientas de código abierto y gratuitas (Python, R), entonces la solución propuesta es de un coste bastante bajo, siendo así accesible para pequeños inversores o instituciones con recursos limitados.

6.3.2. Impacto tecnológico

El trabajo demuestra que la combinación de variables macroeconómicas, técnicas de selección automática de variables y modelos de Machine Learning, permite obtener predicciones útiles en el ámbito financiero. A su vez, el pipeline desarrollado es escalable y transferible a otros activos, sentando las bases para futuras mejoras en el campo del análisis predictivo financiero. Del mismo modo, el uso de técnicas de interpretabilidad como SHAP y LIME, hace que sus predicciones sean comprensibles y transparentes, lo que resulta muy importante en el ámbito financieros.

6.3.3. Impacto social

El proyecto contribuye a la democratización del acceso a herramientas avanzadas de análisis financiero. Al estar basado en tecnologías de código abierto y documentarse de forma detallada el proceso, entonces cualquier persona con conocimientos básicos de programación podría repetir o adaptar el pipeline desarrollado. Además, el trabajo puede servir como material didáctico para estudiantes de finanzas, ingeniería financiera o inteligencia artificial, fomentando la formación en áreas de creciente demanda.

6.3.4. Alineación con los Objetivos de Desarrollo Sostenible (ODS)

Para concluir, teniendo en cuenta el impacto de este trabajo en las diferentes áreas, por último se evaluará su alineación con los Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030. En este caso, el trabajo se alinea principalmente con los siguientes ODS:

- **ODS 4: Educación de calidad.** El trabajo puede ser utilizado como material didáctico en cursos de finanzas, inteligencia artificial y análisis de datos, fomentando la formación en áreas tecnológicas de alta demanda.
- **ODS 8: Trabajo decente y crecimiento económico.** La mejora en la capacidad de predicción de rendimientos financieros contribuye a una toma de decisiones más informada, lo que puede suponer un crecimiento económico más eficiente y estable.

- **ODS 9: Industria, innovación e infraestructura.** El proyecto aplica tecnologías avanzadas de Machine Learning y Deep Learning al sector financiero, fomentando la innovación y la modernización de una industria clave para la economía global.

Bibliografía

- [1] L. Vancsura et al., «Navigating AI-Driven Financial Forecasting: A Systematic Review of Current Status and Critical Research Gaps», *MDPI*, vol. 7, n.º 3, pág. 36, 2025. dirección: <https://www.mdpi.com/2571-9394/7/3/36>
- [2] S. El Alami, A. Mouiha, A. Hafid y A. E. H. Alaoui, «Machine Learning and Deep Learning in Computational Finance: A Systematic Review», *arXiv preprint arXiv:2511.21588*, 2025. dirección: <https://arxiv.org/pdf/2511.21588>
- [3] MDPI, «From Black Box to Glass Box: A Practical Review of Explainable Artificial Intelligence (XAI)», *MDPI*, 2025. dirección: https://www.researchgate.net/publication/397220182_From_Black_Box_to_Glass_Box_A_Practical_Review_of_Explainable_Artificial_Intelligence_XAI
- [4] R. Ye y J. Chen, «Unlocking the Black Box: A Five-Dimensional Framework for Evaluating Explainable AI in Credit Risk», *arXiv preprint arXiv:2511.04980*, 2025. dirección: <https://arxiv.org/pdf/2511.04980>
- [5] Raisin. «Mercados financieros: definición, características y volatilidad», visitado 15 de abr. de 2025. dirección: <https://www.raisin.com/es-es/educacion-financiera/mercados-financieros-definicion-caracteristicas-y-volatilidad/>
- [6] E. F. Fama, «Efficient Capital Markets: A Review of Theory and Empirical Work», *The Journal of Finance*, vol. 25, n.º 2, págs. 383-417, 1970. dirección: <http://efinance.org.cn/cn/fm/Efficient%20Capital%20Markets%20A%20Review%20of%20Theory%20and%20Empirical%20Work.pdf>
- [7] Banco Santander. «¿Qué es un fondo de inversión?», visitado 15 de abr. de 2025. dirección: <https://www.bancosantander.es/faqs/particulares/ahorro-inversion/que-es-fondo-inversion>
- [8] UNIR. «¿Qué son las variables macroeconómicas (VME)?», visitado 15 de abr. de 2025. dirección: <https://www.unir.net/revista/empresa/variables-macroeconomicas/>

-
- [9] G. E. P. Box y G. M. Jenkins, *Time Series Analysis: Forecasting and Control*. Holden-Day, 1970. dirección: https://repo.darmajaya.ac.id/4781/1/Time%20Series%20Analysis_%20Forecasting%20and%20Control%20%28%20PDFDrive%20%29.pdf
- [10] IBM. «¿Qué es la autocorrelación?», visitado 15 de abr. de 2025. dirección: <https://www.ibm.com/mx-es/think/topics/autocorrelation>
- [11] IBM. «¿Qué es el machine learning?», visitado 15 de abr. de 2025. dirección: <https://www.ibm.com/es-es/think/topics/machine-learning>
- [12] scikit-learn developers, *RandomForestRegressor*, scikit-learn, 2025. visitado 17 de abr. de 2025. dirección: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html>
- [13] F. Pedregosa et al., *scikit-learn: Machine Learning in Python*, 2011. visitado 15 de abr. de 2025. dirección: <https://scikit-learn.org/>
- [14] scikit-learn developers, *GradientBoostingRegressor*, scikit-learn, 2025. visitado 17 de abr. de 2025. dirección: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.GradientBoostingRegressor.html>
- [15] LightGBM developers, *LGBM*, LightGBM, 2025. visitado 22 de abr. de 2025. dirección: <https://lightgbm.readthedocs.io/en/latest/pythonapi/lightgbm.LGBMRegressor.html>
- [16] IBM. «¿Qué es la retropropagación?», visitado 17 de abr. de 2025. dirección: <https://www.ibm.com/es-es/think/topics/backpropagation>
- [17] IBM. «¿Qué es el descenso de gradiente?», visitado 17 de abr. de 2025. dirección: <https://www.ibm.com/es-es/think/topics/gradient-descent>
- [18] S. Hochreiter y J. Schmidhuber, «Long Short-Term Memory», *Neural Computation*, vol. 9, n.º 8, págs. 1735-1780, 1997. dirección: <https://ieeexplore.ieee.org/abstract/document/6795963>
- [19] Google Brain Team, *TensorFlow: An end-to-end platform for machine learning*, 2025. visitado 15 de abr. de 2025. dirección: <https://www.tensorflow.org/>
- [20] IBM. «¿Qué es explainable AI?», visitado 17 de abr. de 2025. dirección: <https://www.ibm.com/think/topics/explainable-ai>
- [21] Geeks Forgeeks developers. «XAI Using Lime», Geeks Forgeeks, visitado 17 de abr. de 2025. dirección: <https://www.geeksforgeeks.org/artificial-intelligence/introduction-to-explainable-ai-xai-using-lime/>
- [22] Geeks Forgeeks developers. «XAI Using SHAP», Geeks Forgeeks, visitado 17 de abr. de 2025. dirección: <https://www.geeksforgeeks.org/machine-learning/shap-a-comprehensive-guide-to-shapley-additive-explanations/>
- [23] Economipedia developers. «Teoría de juegos cooperativos», Economipedia, visitado 17 de abr. de 2025. dirección: <https://economipedia.com/definiciones/juegos-cooperativos.html>

- [24] M. Nabipour et al., «Predicting Stock Market Trends Using Machine Learning and Deep Learning Algorithms», *The Journal of Supercomputing*, 2020. dirección: <https://scispace.com/pdf/predicting-stock-market-trends-using-machine-learning-and-50ru6rl37h.pdf>
- [25] H. Abdou, «The Impact of Oil and Global Markets on Saudi Stock Market Predictability: A Machine Learning Approach», *Energy Economics*, 2024. dirección: <https://www.sciencedirect.com/science/article/pii/S0140988324001245>
- [26] M. T. Mohsin y N. B. Nasim, «Explaining the Unexplainable: A Systematic Review of Explainable AI in Finance», *arXiv preprint arXiv:2503.05966*, 2025. dirección: <https://arxiv.org/pdf/2503.05966>
- [27] W. Morten, *fredapi: Python API for Federal Reserve Economic Data (FRED)*, 2025. visitado 15 de abr. de 2025. dirección: <https://github.com/mortada/fredapi>
- [28] R. Aroussi, *yfinance: Yahoo Finance market data downloader*, 2025. visitado 15 de abr. de 2025. dirección: <https://github.com/ranaroussi/yfinance>
- [29] Python Software Foundation, *The Python Tutorial*, 2025. visitado 15 de abr. de 2025. dirección: <https://docs.python.org/3/tutorial/>
- [30] ING developers. «Explicación del SP500», ING, visitado 18 de abr. de 2025. dirección: <https://www.ing.es/ennaranja/invertir-dinero/como-invertir/sp-500-y-su-importancia>
- [31] Forex.com developers. «¿Qué es el índice VIX?», Forex.com, visitado 18 de abr. de 2025. dirección: <https://www.forex.com/es/news-and-analysis/what-is-the-vix/>
- [32] Banc Santander developers. «Índice de Precios al Consumo (IPC)», Banco Santander, visitado 18 de abr. de 2025. dirección: <https://www.bancosantander.es/glosario/ipc-indice-precios-consumo>
- [33] R Core Team, *R: A Language and Environment for Statistical Computing*, 2025. visitado 15 de abr. de 2025. dirección: <https://cran.r-project.org/doc/manuals/r-release/R-intro.html>
- [34] Docentes de la Universidad Nacional de Cajamarca, *Manual de Google Sheets*, 2025. visitado 15 de abr. de 2025. dirección: <https://siteplus.unc.edu.pe/wp-content/uploads/2021/04/MANUAL-GOOGLE-SHEETS.pdf>
- [35] Wikipedia developers. «Apple Inc.», Wikipedia, visitado 18 de abr. de 2025. dirección: <https://www.apple.com/financial-info/>
- [36] Economipedia developers. «Que es la curtosis», Economipedia, visitado 18 de abr. de 2025. dirección: <https://economipedia.com/definiciones/curtosis.html>
- [37] Economipedia developers. «Skewness», Economipedia, visitado 18 de abr. de 2025. dirección: <https://economipedia.com/definiciones/skewness.html>

-
- [38] World Health Organization. «COVID-19 Pandemic», WHO, visitado 18 de abr. de 2025. dirección: <https://www.who.int/emergencies/diseases/novel-coronavirus-2019>
- [39] Reserva Federal de los Estados Unidos. «Historical Data on Interest Rates», Federal Reserve, visitado 18 de abr. de 2025. dirección: <https://www.federalreserve.gov/>
- [40] Banco Central Europeo. «Historical Data on Interest Rates», European Central Bank, visitado 18 de abr. de 2025. dirección: <https://www.ecb.europa.eu/>
- [41] Mario Beraha, Alberto Maria Metelli, and others. «Feature Selection with Mutual Information», arXiv, visitado 19 de abr. de 2025. dirección: <https://arxiv.org/pdf/1907.07384>
- [42] QuestionPro developers. «Que es la correlación de Pearson», QuestionPro, visitado 19 de abr. de 2025. dirección: <https://www.questionpro.com/blog/es/coeficiente-de-correlacion-de-pearson/>
- [43] scikit-learn developers, *GridSearchCV*, scikit-learn, 2025. visitado 21 de abr. de 2025. dirección: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html
- [44] scikit-learn developers, *TimeSeriesSplit*, scikit-learn, 2025. visitado 21 de abr. de 2025. dirección: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.TimeSeriesSplit.html
- [45] Interactive Chaos developers. «Mean Squared Error (MSE)», Interactive Chaos, visitado 19 de abr. de 2025. dirección: <https://interactivechaos.com/es/manual/tutorial-de-machine-learning/mean-squared-error>
- [46] Interactive Chaos developers. «Que es el escalado de datos», Interactive Chaos, visitado 22 de abr. de 2025. dirección: <https://interactivechaos.com/es/manual/tutorial-de-machine-learning/escalado-de-datos>
- [47] scikit-learn developers, *MinMaxScaler*, scikit-learn, 2025. visitado 22 de abr. de 2025. dirección: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.MinMaxScaler.html>
- [48] IBM developers. «Que es data augmentation», IBM, visitado 3 de mayo de 2025. dirección: <https://www.ibm.com/es-es/think/topics/data-augmentation>
- [49] Geeks For Geeks developers. «Que es el ruido gaussiano», Geeks For Geeks, visitado 3 de mayo de 2025. dirección: <https://www.geeksforgeeks.org/electronics-engineering/gaussian-noise/>
- [50] García-Ferreira developers. «Conoce todo sobre el Dropout: la técnica de regularización para redes neuronales», García-Ferreira, visitado 22 de abr. de 2025. dirección: <https://www.garcia-ferreira.es/conoce-todo-sobre-el-dropout/>
- [51] DataCamp developers. «Tutorial del optimizador Adam», DataCamp, visitado 22 de abr. de 2025. dirección: <https://www.datacamp.com/es/tutorial/adam-optimizer-tutorial>

- [52] TensorFlow developers. «Callbacks en TensorFlow», TensorFlow, visitado 22 de abr. de 2025. dirección: https://www.tensorflow.org/api_docs/python/tf/keras/callbacks/Callback
- [53] TensorFlow developers. «EarlyStopping en TensorFlow», TensorFlow, visitado 22 de abr. de 2025. dirección: https://www.tensorflow.org/api_docs/python/tf/keras/callbacks/EarlyStopping
- [54] TensorFlow developers. «ReduceLROnPlateau en TensorFlow», TensorFlow, visitado 22 de abr. de 2025. dirección: https://www.tensorflow.org/api_docs/python/tf/keras/callbacks/ReduceLROnPlateau
- [55] SHAP Documentation developers. «TreeExplainer de SHAP», SHAP Documentation, visitado 9 de mayo de 2025. dirección: <https://shap.readthedocs.io/en/latest/generated/shap.TreeExplainer.html>
- [56] Kalman Filter developers. «Filtro de Kalman», Kalman Filter, visitado 22 de mayo de 2025. dirección: https://kalmanfilter.net/ES/default_es.aspx
- [57] SHAP Documentation developers. «DeepExplainer de SHAP», SHAP Documentation, visitado 22 de mayo de 2025. dirección: <https://shap.readthedocs.io/en/latest/generated/shap.DeepExplainer.html>
- [58] SHAP Documentation developers. «GradientExplainer de SHAP», SHAP Documentation, visitado 22 de mayo de 2025. dirección: <https://shap.readthedocs.io/en/stable/generated/shap.GradientExplainer.html>
- [59] Peter I Fraizer. «A Tutorial on Bayesian Optimization», Peter I Fraizer, visitado 22 de mayo de 2025. dirección: <https://arxiv.org/pdf/1807.02811>
- [60] ONU. «Objetivos de Desarrollo Sostenible (ODS)», ONU, visitado 22 de mayo de 2025. dirección: <https://www.un.org/sustainabledevelopment/es/sustainable-development-goals/>
- [61] IBM. «¿Qué es random forest?», visitado 17 de abr. de 2025. dirección: <https://www.ibm.com/mx-es/think/topics/random-forest>
- [62] The pandas development team, *pandas: Python Data Analysis Library*, 2025. visitado 15 de abr. de 2025. dirección: <https://pandas.pydata.org/>
- [63] NumPy developers, *NumPy: The fundamental package for scientific computing with Python*, 2025. visitado 15 de abr. de 2025. dirección: <https://numpy.org/>
- [64] Matplotlib development team, *Matplotlib: Visualization with Python*, 2025. visitado 15 de abr. de 2025. dirección: <https://matplotlib.org/>
- [65] Banco de España. «Estadísticas y Publicaciones», visitado 15 de abr. de 2025. dirección: <https://www.bde.es/>
- [66] Google. «Google Finance», visitado 15 de abr. de 2025. dirección: <https://www.google.com/finance/>

- [67] Q2BStudio. «Entropía de Shannon: qué es, cómo se calcula y para qué sirve», visitado 15 de abr. de 2025. dirección: <https://www.q2bstudio.com/nuestro-blog/447316/descubre-que-es-la-entropia-de-shannon-como-se-calcula-y-sus-multiples-aplicaciones-en-diferentes-areas-una-herramienta-fundamental-en-el-analisis-de-informacion-y-comunicacion>
- [68] M. T. Ribeiro, S. Singh y C. Guestrin, «"Why Should I Trust You?": Explaining the Predictions of Any Classifier», en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, págs. 1135-1144. dirección: <https://dl.acm.org/doi/10.1145/2939672.2939778>
- [69] S. M. Lundberg y S.-I. Lee, «A Unified Approach to Interpreting Model Predictions», *arXiv preprint arXiv:1705.07874*, 2017. dirección: <https://arxiv.org/pdf/1705.07874>
- [70] Banco Santander. «¿Qué son las acciones y cómo se clasifican?», visitado 15 de abr. de 2025. dirección: <https://www.bancosantander.es/glosario/acciones>
- [71] ETSIINF. «Recomendaciones sobre el contenido de la Memoria Final», visitado 1 de jun. de 2023. dirección: <http://www.fi.upm.es/?pagina=1475>
- [72] A. Feder. «BibTeX.org», visitado 1 de jun. de 2023. dirección: <http://www.bibtex.org>
- [73] W. Stallings, *Computer Organization and Architecture*. Prentice Hall, 2006.

Anexos

Apéndice A

Primer anexo

Este capítulo (anexo) es opcional, y se escribirá de acuerdo con las indicaciones del Tutor.